Analisi dei Dati

Corso di Laurea in Innovazione Sociale, Comunicazione e Nuove Tecnologie

Università degli Studi di Torino

Francesco Screti

Basato sulle lezioni di Renzo Carriero

Indice

I Teoria **5**

1 Variabili e scopi dell'analisi **6**
1.1 Analisi secondaria 6
1.2 Tipi di variabili 6
1.3 Analisi delle variabili: per quali scopi? 7
1.4 Variabile indipendente e dipendente 7

2 Centro e variabilità dei dati **8**
2.1 Descrivere centro e variabilità 8
2.2 La tendenza centrale 9
2.3 Mediana 9
2.4 Moda 9
2.5 Come si calcola la mediana? 10
2.6 Operatori di posizione 11
2.7 La deviazione standard o dispersione 11
2.8 Cos'è un box plot? 12

3 Costruzione di indici e sintesi dei dati **14**
3.1 Cosa sono gli indici sintetici? 14
3.2 Perché si usano? 14
3.3 Tipi di indici 14
3.4 Esempio di indice tipologico: post-materialismo 14
3.5 Indice derivato da conteggio 15
3.6 La scala Likert e i suoi presupposti 16
3.7 Analisi degli item 17
3.8 Selezione e calcolo degli item per un indice 17
3.9 Indici sommativi con scale auto-ancoranti 19

4 Tabelle di contingenza **21**
4.1 Cosa sono le tabelle di contingenza? 21
4.2 Come si fa il confronto tra variabili? 21
4.3 Come si analizzano le tabelle e calcolano le percentuali corrette? 21

5 Elementi di inferenza statistica **25**
5.1 Campione e popolazione 25

5.2 Perché casuale significa rappresentativo? 25
5.3 Dalle statistiche campionarie ai parametri della popolazione . 26
5.4 Variabili casuali e distribuzioni di probabilità 26
5.5 Variabili casuali discrete 26
5.6 Variabili casuali continue 27
5.7 Distribuzioni teoriche di probabilità: la normale 27
5.8 Uso dei valori standardizzati (z score) 28
5.9 Distribuzioni delle statistiche campionarie 29
5.10 Da ricordare 32
5.11 Stima intervallare 32
5.12 Intervalli di confidenza al 95% e 99% 33
5.13 Deviazione standard ed errore standard 33

6 Test di ipotesi statistiche 35
6.1 Domande di ricerca e ipotesi statistiche 35
6.2 Elementi di un test statistico: assunti 35
6.3 Elementi di un test statistico: ipotesi 36
6.4 Elementi di un test statistico: la statistica test 36
6.5 Elementi di un test statistico: il valore di probabilità (P-value) 37
6.6 Elementi di un test statistico: conclusioni 37
6.7 Limiti dei test di significatività 37
6.8 Confronto tra gruppi 38
6.9 Approfondimento sul test di significatività 38

7 Analisi delle tabelle di contingenza 40
7.1 Associazione tra variabili categoriali 40
7.2 Come si analizzano le tabelle: calcolo delle percentuali corrette 40
7.3 Lettura della tabella di contingenza 41
7.4 Indipendenza tra variabili categoriali 42
7.5 Test del Chi-quadro per l'indipendenza 42
7.6 Quali sono i limiti del Chi-quadro? 43
7.7 Strettezza della relazione 44
7.8 Associazione tra variabili ordinali: co-graduazione 45
7.9 Indice Gamma di Goodman e Kruskal 45
7.10 Calcolo di Gamma e interpretazione 47

8 La logica dell'analisi multivariata 49
8.1 Due variabili non bastano 49
8.2 Controllo della relazione per stratificazione 50
8.3 Condizioni per il controllo empirico di una relazione causale . 51
8.4 Il linguaggio degli effetti 52

8.5 Variabili di controllo e ordine causale 53

9 La regressione lineare **55**
9.1 Che cos'è la regressione lineare 55
9.2 Il significato della retta di regressione 56
9.3 Scopi della regressione 57
9.4 Variabili indipendenti categoriali nella regressione 57
9.5 Inferenza statistica sui coefficienti di regressione 58
9.6 Come si legge l'output di una regressione 59

II Laboratorio con Stata **61**

10 Sportello 1 **62**
10.1 Come collegare il file dati da do-file su Stata? 62
10.2 Come analizzare i dati che soddisfano una sola condizione? . . 62
10.3 Come ricodificare una variabile in 5 quintili? 62
10.4 Come visualizzare una tabella di contingenza? 63
10.5 Come si ricodifica creando una variabile dicotomica? 64
10.6 Come commentare la tabella di contingenza? 64
10.7 Quali sono le statistiche e i grafici più opportuni a seconda del tipo di variabile? 65
10.8 Come si commenta una distribuzione di variabile? 65
10.9 Come si costruisce un indice informativo? 67
10.10 Quando invertiamo la polarità? 67
10.11 Quale formula permette di creare un indice informativo? . . . 67
10.12 Come si calcola l'alpha di Cronbach? 68
10.13 Come si riscala un indice da 0 a 10? 69
10.14 Tabella di contingenza per indice e variabile 69
10.15 Un esercizio completo 70

11 Sportello 2 **74**
11.1 Che differenza c'è tra variabili dipendenti e indipendenti? . . . 74
11.2 Come si ricodifica e si crea una nuova variabile? 75
11.3 Come e quando invertire la polarità di un item? 75
11.4 Come e perché calcolare l'alpha di Cronbach? 76
11.5 Come creare un indice sommativo o informativo? 77
11.6 Come riscalare l'indice da 0 a 10? 77
11.7 Come descrivere la distribuzione dell'indice riscalato? 78
11.8 Come fare un'analisi bivariata? 78
11.9 Come si valuta l'associazione tra indice e variabili indipendenti? 80

11.10Come commentare i risultati di un'analisi bivariata? 81

12 La regressione in Stata **84**
12.1 A cosa serve la regressione lineare? 84
12.2 Quali sono i comandi per la regressione lineare su Stata? . . . 84
12.3 Cosa interpretiamo dell'output? 84
12.4 Esercizio sulla regressione lineare 86
12.5 La regressione multipla 87
12.6 Come si commenta una regressione multipla? 88
12.7 Guida per commentare una regressione multipla 88

13 Schemi di commento **90**
13.1 Commentare le variabili indipendenti 90
13.2 Commentare le variabili dipendenti 92
13.3 Commentare l'alpha e la coerenza interna 94
13.4 Commentare l'istogramma di un indice riscalato 95
13.5 Commentare le analisi bivariate 97
13.6 Commentare un'analisi bivariata con i test statistici 98

III Commenti ed esercizi svolti 100

14 Elaborato: la fiducia nelle istituzioni **101**
14.1 Fiducia nel parlamento 101
14.2 Fiducia nei politici 102
14.3 Fiducia nella politica 103
14.4 Soddisfazione 104
14.5 L'indice di fiducia nelle istituzioni 105
14.6 Analisi bivariata con lo status migratorio 106
14.7 Regressione lineare semplice 107
14.8 Regressione multipla con variabili di controllo 108

Parte I

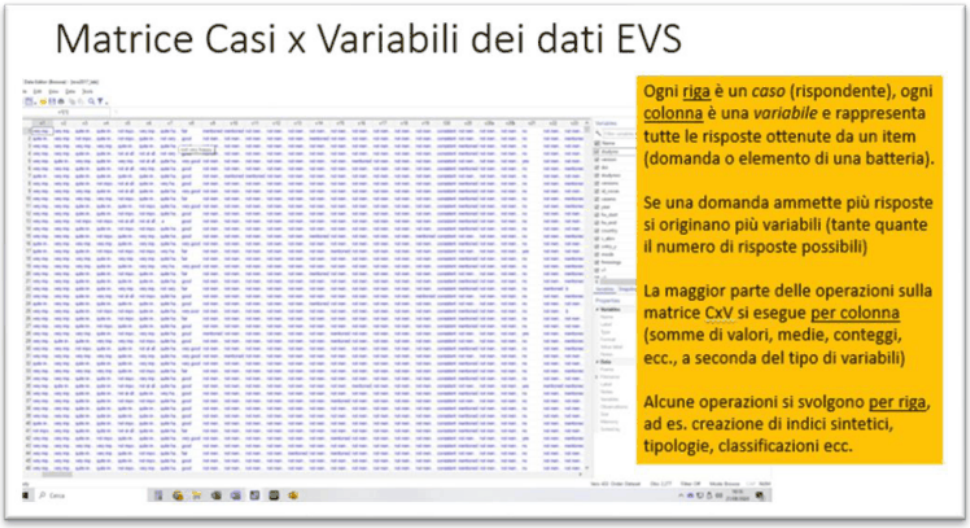
Teoria

1

Variabili e scopi dell'analisi

1.1 Analisi secondaria

Per dare senso ai dati colleghiamo concetti e indicatori. Il rapporto tra concetti e indicatori non è un rapporto biunivoco, e questo consente di collegare un concetto con una serie di indicatori, e allo stesso tempo una serie di indicatori possono essere collegati a concetti diversi.



1.2 Tipi di variabili

Nell'analisi dei dati è necessario distinguere i tipi di variabili su cui operiamo.

- **Categoriali o nominali**: i valori non hanno significato numerico, sono etichette per distinguere una categoria dall'altra (`graph bar`). Esempio: materie preferite? 1 italiano, 2 francese, 3 tedesco.

- **Ordinali**: i valori rispecchiano un ordine tra le categorie (`graph bar`), senza definire una distanza precisa. Esempio: livello di inglese? 1 basso, 2 medio, 3 alto.
- **Cardinali o numeriche**: sono quelle che hanno un numero che possiamo contare e misurare (`box plot`, `histogram`). Esempio: altezza, età, anni di studio.

1.3 Analisi delle variabili: per quali scopi?

L'analisi statistica aiuta a capire se due cose sono collegate, come ad esempio se studi di più e prendi voti più alti. Si confrontano i risultati per vedere se c'è un legame tra quello che fai e quello che accade.

Inoltre, serve a fare previsioni su quello che potrebbe succedere in futuro. Ad esempio, puoi cercare di indovinare che tempo farà domani o quanti voti prenderai in futuro, anche se le previsioni non sono sempre precise al 100%, ma possiamo capire quanto possiamo fidarci di esse.

1.4 Variabile indipendente e dipendente

Immagina che tu voglia capire come il tempo di studio (variabile indipendente) influenzi il voto all'esame (variabile dipendente).

- **Variabile indipendente**: tempo di studio (quante ore studi).
- **Variabile dipendente**: voto all'esame (risultato misurato).

In questo caso, il voto dipende da quanto tempo studi, quindi il tempo di studio è la variabile che manipoli o modifichi, mentre il voto all'esame è l'effetto che misuri.

2

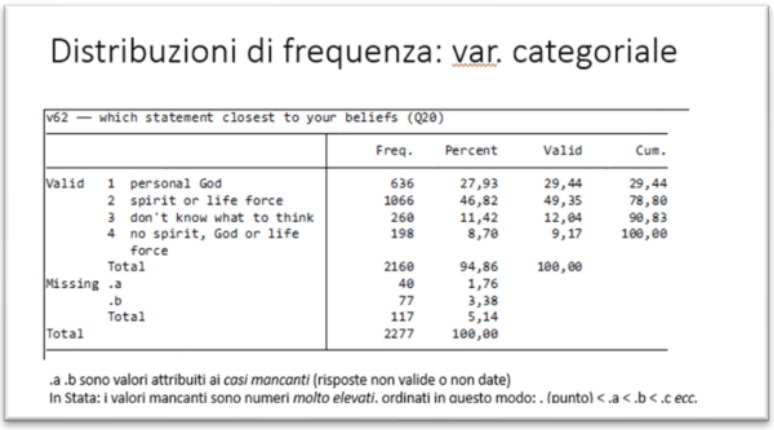
Centro e variabilità dei dati

2.1 Descrivere centro e variabilità

Per esplorare variabili con pochi valori distinti (categoriali o ordinali), si utilizza la distribuzione di frequenza, che comprende:

- una tabella con i valori della variabile, la loro frequenza assoluta (numero di casi) e la frequenza relativa (quanti sono sul totale o in %);
- se la variabile è ordinale, si può aggiungere la frequenza percentuale cumulata, utile per capire quanta parte del totale abbiamo già visto.

Quando una variabile ha molti valori differenti, la distribuzione di frequenza diventa meno utile come strumento di sintesi.

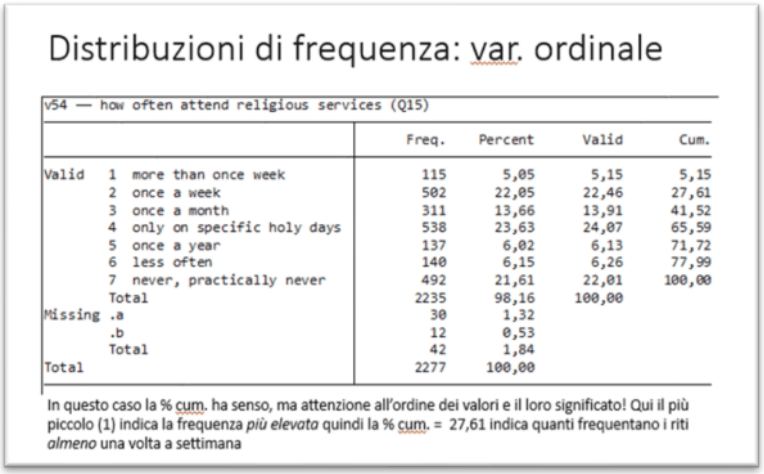


Distribuzioni di frequenza: var. categoriale

v62 — which statement closest to your beliefs (Q20)

			Freq.	Percent	Valid	Cum.
Valid	1	personal God	636	27,93	29,44	29,44
	2	spirit or life force	1066	46,82	49,35	78,80
	3	don't know what to think	260	11,42	12,04	90,83
	4	no spirit, God or life force	198	8,70	9,17	100,00
	Total		2160	94,86	100,00	
Missing	.a		40	1,76		
	.b		77	3,38		
	Total		117	5,14		
Total			2277	100,00		

.a .b sono valori attribuiti ai *casi mancanti* (risposte non valide o non date)
In Stata: i valori mancanti sono numeri *molto elevati*, ordinati in questo modo: . (punto) < .a < .b < .c *ecc.*



Distribuzioni di frequenza: var. ordinale

v54 — how often attend religious services (Q15)

			Freq.	Percent	Valid	Cum.
Valid	1	more than once week	115	5,05	5,15	5,15
	2	once a week	502	22,05	22,46	27,61
	3	once a month	311	13,66	13,91	41,52
	4	only on specific holy days	538	23,63	24,07	65,59
	5	once a year	137	6,02	6,13	71,72
	6	less often	140	6,15	6,26	77,99
	7	never, practically never	492	21,61	22,01	100,00
	Total		2235	98,16	100,00	
Missing	.a		30	1,32		
	.b		12	0,53		
	Total		42	1,84		
Total			2277	100,00		

In questo caso la % cum. ha senso, ma attenzione all'ordine dei valori e il loro significato! Qui il più piccolo (1) indica la frequenza *più elevata* quindi la % cum. = 27,61 indica quanti frequentano i riti *almeno* una volta a settimana

2.2 La tendenza centrale

La distribuzione di frequenza è una rappresentazione sintetica. Esiste un valore della variabile che la può rappresentare sinteticamente tutta? Sì, se la variabile è cardinale (numerica), perché solo su di esse ha senso l'operazione di somma dei valori e divisione per il numero di casi (N). La media è il "centro" dei dati.

2.3 Mediana

La mediana rappresenta il valore che si trova a metà della distribuzione ordinata.

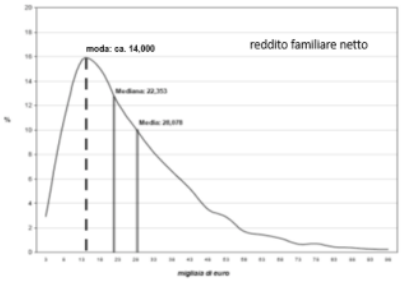
- È più robusta della media, poiché è meno influenzata dai valori estremi.
- Anche se la mediana può essere calcolata per variabili ordinali, è poco utile in pratica, dato che queste variabili tendono ad avere pochi valori distinti.

2.4 Moda

- Se la variabile è categoriale, l'unico modo di esprimere la tendenza centrale è individuare la moda.
- Quando ci sono due valori che appaiono con la stessa massima frequenza, la distribuzione è bi-modale.
- Si può individuare anche la moda di variabili ordinali e cardinali, ma è meno informativa: la moda è 4, ma potrebbero esserci tanti 3 o 5.

In sintesi:

- **Capacità informativa**: capacità di considerare tutte le proprietà dei numeri cardinali (ordine e distanza).
- **Robustezza**: essere poco influenzati da valori anomali.
- Per capacità informativa: media > mediana > moda.
- Per robustezza: moda > mediana > media.



2.5 Come si calcola la mediana?

Se N è dispari c'è solo un caso mediano, se è pari ce ne sono due.

Immagina di avere i seguenti valori di una variabile, i punteggi di 7 studenti in un test: 5, 7, 9, 10, 12, 13, 15.

1. Ordina i valori, in questo caso sono già in ordine crescente.
2. Il numero totale di casi è 7 (dispari), quindi il caso mediano è il $(7 + 1)/2 = 4$.
3. Il 4ř valore è 10, quindi la mediana è 10.

Se invece i valori fossero 5, 7, 9, 10, 12, 13, 15, 17 (8 studenti, pari):

1. Il numero totale di casi è 8 (pari), quindi i casi mediani sono $8/2 = 4$ e $(8/2) + 1 = 5$.
2. I valori del 4ř e 5ř posto sono 10 e 12.
3. La mediana è la media di 10 e 12, cioè $(10 + 12)/2 = 11$. Quindi la mediana è 11.

Con pochi numeri:

- se hai un numero dispari di numeri, prendi il numero al centro;
- se hai un numero pari, prendi i due numeri centrali e fai la media.

2.6 Operatori di posizione

La mediana è un operatore di posizione, individua cioè un valore in riferimento alla posizione dei casi lungo la distribuzione. Altri operatori sono i quartili, i decili e i percentili.

La mediana è il secondo quartile.

- **Primo quartile**: il valore nella distribuzione che ha sotto di sé il 25% dei casi e sopra di sé il 75%.
- **Terzo quartile**: il valore nella distribuzione che ha sotto di sé il 75% dei casi e sopra di sé il 25%.

In pratica ordino i casi per valori crescenti e li divido in 4 gruppi equinumerosi per individuare i valori corrispondenti ai quartili.

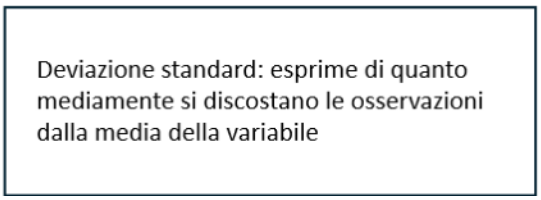
Per esempio, se hai i punteggi 2, 4, 5, 7, 9, 10, 12, 15, dopo averli ordinati e divisi in quattro gruppi, puoi identificare i quartili.

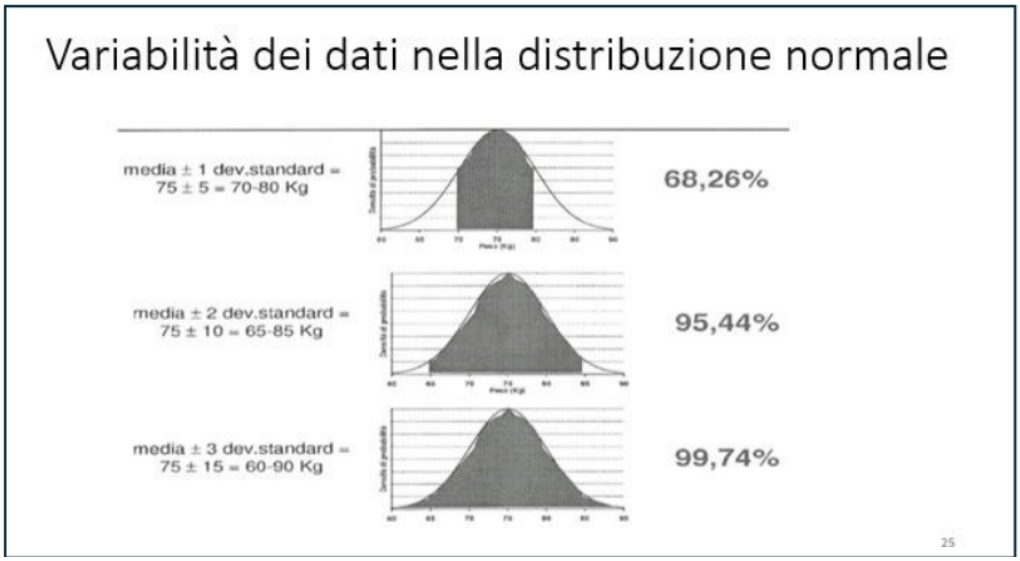
- Q1 potrebbe essere il punteggio che rappresenta il limite del primo 25% (ad esempio 5).
- Q2 (mediana) è il punteggio centrale (ad esempio 9).
- Q3 rappresenta il limite del 75% (ad esempio 12).

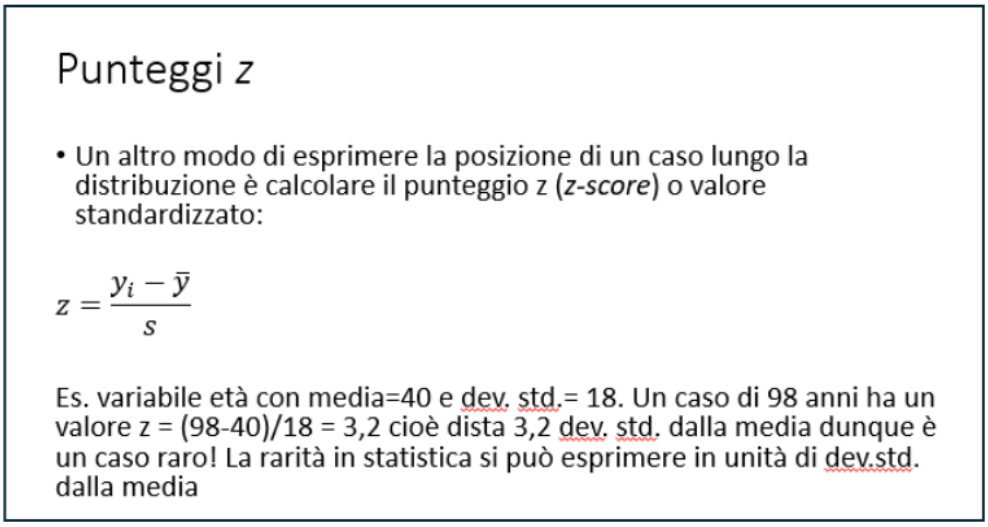
2.7 La deviazione standard o dispersione

Per valutare quanto l'indice di tendenza centrale rappresenta al meglio la distribuzione bisogna affiancarlo a una misura di dispersione, o di "distanza" dal centro.

1. Campo di variazione o range (differenza tra valore massimo e minimo).
2. Scarto interquartile (differenza tra valore del 3ř e del 1ř quartile).
3. Deviazione standard e varianza.







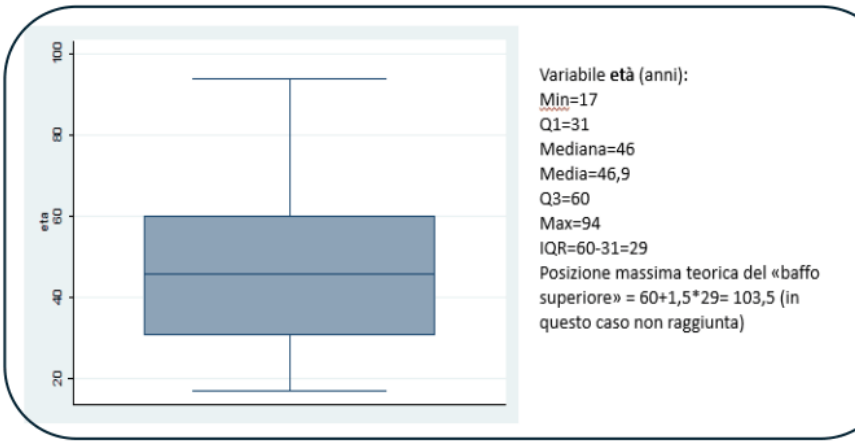
2.8 Cos'è un box plot?

Un box plot è un tipo di grafico che mostra come sono distribuiti i numeri in un gruppo. Aiuta a capire la media e la variabilità di una variabile, che è un modo per dire quanto i numeri possono essere diversi tra loro.

Come funziona:

1. **Scatola**: il grafico ha una "scatola" che mostra i due quartili, cioè il primo (Q1) e il terzo quartile (Q3). Questo significa che dentro la scatola ci sono i valori che si trovano nel 50% centrale dei dati.

2. **Linea della mediana**: dentro la scatola c'è una linea che rappresenta la mediana. Questo è il valore che si trova al centro quando ordini i numeri.
3. **Baffi**: dalla scatola escono dei "baffi" (whiskers) che si estendono fino ai valori massimi e minimi. Questi mostrano il resto dei dati che non sono inclusi nella scatola.
4. **Valori estremi**: se ci sono numeri molto diversi dagli altri (valori estremi), vengono mostrati con simboli speciali nel grafico.



3

Costruzione di indici e sintesi dei dati

3.1 Cosa sono gli indici sintetici?

Sono il risultato della combinazione di più variabili. Essi sintetizzano informazioni provenienti da diverse fonti e servono a rappresentare concetti complessi in modo più completo rispetto all'uso di una singola variabile.

3.2 Perché si usano?

Sono utili perché riescono a descrivere meglio fenomeni complessi, se sono coerenti tra loro, e aiutano a semplificare l'analisi di molti dati.

3.3 Tipi di indici

1. **Tipologici**: si basano su variabili categoriali e creano una nuova variabile categoriale, combinando i valori di input.
2. **Derivati da conteggio**: contano quante volte un elemento o una risposta appare (es. quanti "sì"). I valori vanno da 0 al numero massimo di elementi.
3. **Sommativi**: sommano o fanno la media di variabili che indicano punteggi. Il risultato dipende dalla scala dei punteggi originali e dal tipo di operazione (somma o media), ma il concetto espresso è lo stesso.

3.4 Esempio di indice tipologico: post-materialismo

Vediamo un indice creato per capire meglio se una persona è più preoccupata da temi "materialistici" o "post-materialistici".

- Mantenere l'ordine nella nazione → preoccupazione materialistica.
- Dare alla gente più voce → preoccupazione post-materialistica.
- Combattere l'aumento dei prezzi → preoccupazione materialistica.

- Salvaguardare la libertà di parola → preoccupazione post-materialistica.

In modo semplice, si fanno domande sulle cose a cui le persone tengono di più e, combinando le loro risposte, si capisce se sono più preoccupate per i bisogni pratici o per i valori più alti come la libertà.

Prima risp. \ Seconda risp.	Mantenere l'ordine	Più voce alla gente	Combattere aumento prezzi	Libertà di parola
Mantenere l'ordine	-	I	M	I
Più voce alla gente	I	-	I	P
Combattere aumento prezzi	M	I	-	I
Libertà di parola	I	P	I	-

.

Il testo spiega come si crea un indice per classificare le persone in base alle loro risposte. Le persone possono essere:

- **M (materialiste)**: se danno due risposte legate a bisogni materiali.
- **I (intermedie)**: se danno una risposta materiale e una legata a valori più alti.
- **P (postmaterialiste)**: se danno due risposte legate ai valori post-materialisti.
- Il trattino indica le celle teoricamente vuote.

3.5 Indice derivato da conteggio

- **Batteria Q6**: consiste in 8 categorie di persone (es. tossicodipendenti, musulmani, omosessuali) che possono essere considerate sgradite.
- **Indice di intolleranza**: si calcola contando quante categorie un intervistato indica come sgradite, con punteggio da 0 (nessuna) a 8 (tutte).
- **Calcolo**: si usa il comando `egen` con `anycount`, che conta le categorie sgradite per ogni intervistato.
- **Uniformità**: tutte le categorie sono trattate allo stesso modo, un punteggio più alto indica maggiore intolleranza.

3.6 La scala Likert e i suoi presupposti

Le risposte sono organizzate su una scala graduata a intervalli apparentemente uguali, solitamente con 5 modalità di risposta, da "molto d'accordo" a "molto in disaccordo".

Perché si utilizzano domande bilanciate in una scala di misurazione e come si gestiscono i punteggi?

Alcune domande possono essere bilanciate, cioè una parte orientata in un senso (es. progressista) e l'altra in senso opposto (es. conservatore). Questo serve per evitare che le persone rispondano automaticamente senza pensare.

Quando si sommano i punteggi di queste domande bilanciate, bisogna ricordarsi di invertire i punteggi delle affermazioni opposte, in modo che un "1" diventi "5" e viceversa. Questo aiuta a mantenere la coerenza nei risultati finali.

In sintesi

1. **Differenze uguali**: la distanza tra le risposte "molto d'accordo" e "abbastanza d'accordo" deve essere uguale a quella tra "un po' in disaccordo" e "molto in disaccordo". Non è automatico.
2. **Correlazione**: tutte le domande devono essere collegate allo stesso concetto che si sta misurando.
3. **Difficoltà simile**: le affermazioni devono avere un impatto simile, così possono essere scambiate senza problemi. Ogni affermazione misura il concetto con un po' di errore, ma in media questi errori si bilanciano.
4. **Additività**: i punteggi delle risposte si sommano semplicemente, quindi puoi arrivare allo stesso punteggio in modi diversi (ad esempio, $3 + 3 + 3$ è uguale a $4 + 4 + 1$).
5. **Punteggi**: anche se i punteggi sono ordinali, indicando solo un ordine, vengono trattati come se fossero numeri reali (cardinali), quindi le differenze tra i punteggi sono significative.

La scala Likert ti permette di arrivare allo stesso punteggio totale anche attraverso risposte contrastanti perché si basa sulla semplice somma delle valutazioni, senza tener conto del significato delle differenze tra le opinioni.

Q47 In che misura è d'accordo o contrario con le seguenti affermazioni?

		Decisamente d'accordo	D'accordo	Né d'accordo né contrario	Contrario	Decisamente contrario
(v152)	Per essere realizzato un uomo deve avere dei figli	1	2	3	4	5
(v153)	Per essere felici è necessario il matrimonio o una relazione stabile e duratura	1	2	3	4	5
(v154)	Le coppie omosessuali dovrebbero poter adottare dei bambini	1	2	3	4	5
(v155)	E' giusto che due persone convivano senza essere sposate	1	2	3	4	5
(v156)	Avere figli è un dovere verso la società	1	2	3	4	5
(v157)	Le persone dovrebbero decidere da sé se avere o non avere figli	1	2	3	4	5
(v158)	E' principalmente dovere dei figli adulti prendersi cura dei genitori quando essi sono gravemente ammalati o gravemente debilitati	1	2	3	4	5

NB: questionario EVS 2008

→ item a *polarità semantica invertita*

3.7 Analisi degli item

- **Correlazione tra item**: tutti gli item devono essere collegati tra loro e le distribuzioni delle risposte devono essere simili.
- **Punteggi e correlazione**: i punteggi di un singolo item dovrebbero riflettere il punteggio totale della scala, senza includere l'item stesso. Si verifica usando il coefficiente di correlazione (r), che va da -1 a $+1$. Un r vicino a 0 significa che non c'è correlazione, mentre valori $\geq 0{,}5$ indicano una buona correlazione.
- **Coerenza interna**: per valutare quanto gli item siano coerenti tra loro si usa l'alfa di Cronbach, che misura quanto le domande condividono variabilità. Un alfa più alto indica maggiore coerenza. Un alfa di Cronbach alto, di solito $\geq 0{,}7$, indica che le domande del questionario stanno misurando davvero lo stesso concetto.

3.8 Selezione e calcolo degli item per un indice

Analisi delle correlazioni

- Se due item fossero molto simili, potresti voler mantenere solo uno di essi.
- Se un item non ha una buona correlazione, può essere rimosso.

- **Alpha di Cronbach**: questo valore indica quanto sono coerenti gli item della scala. Un alpha maggiore di 0,70 è considerato buono. Se un item riducesse l'alpha, potrebbe essere meglio eliminarlo.

```stata
alpha var1 var2 var3 var4
```

Calcolo dell'indice: somma o media

Comandi per il calcolo:

```stata
gen somma = var1 + var2 + var3
```

```stata
egen media = rowmean(var1 var2 var3)
```

Ricodifica della polarità invertita

Se gli item sono messi al contrario, ad esempio un punteggio alto significa meno accordo, puoi usare queste regole per cambiarne il significato:

- 5 diventa 1 e viceversa;
- 4 diventa 2;
- 3 rimane 3;
- 2 diventa 4.

```
recode item2 (1=5) (2=4) (3=3) (4=2) (5=1), gen(item2_invertito)
recode item3 (1=5) (2=4) (3=3) (4=2) (5=1), gen(item3_invertito)
```

```
* Ricodifica la polarità invertita di v4
gen v4_inv = 6 - v4
```

Output di *alpha* in Stata

Item	Obs	Sign	item-test corr.	item-rest corr.	interitem cov.	alpha	Label
v152	1473	+	0,6211	0,4162	,173586	0,5742	men need children in order to be fulfil[illegible]A)
v153	1483	+	0,5867	0,3770	,1857239	0,5916	long-term relationship necessary t[illegible]7B)
v154	1457	-	0,5797	0,3597	,1908669	0,6023	homosex couples - adopt child[illegible]
v155	1477	-	0,6439	0,4342	,1649193	0,5655	It is alright to live to[illegible]g married (Q47D)
v156	1441	+	0,5587	0,3221	,1913801	0,6084	duty towards societ[illegible]47E)
v157	1474	-	0,3600	0,1710	,2408408	0,6469	people should [illegible] have children (Q47F)
v158	1491	+	0,3402	0,1619	,2503405	0,6570	It is chil[illegible] of ill parent (Q47G)
Test scale					,1996341	0,6456	mean(unstand[illegible] items)

Questa batteria non forma una buona scala coerente!

Da notare:

- il valore di alpha della scala non è del tutto soddisfacente
- v158 si potrebbe eliminare e l'alpha salirebbe a 0,657
- v157 e v158 hanno bassa correlazione con il resto della scala: possibile eliminarli
- il numero di casi è differente per ogni item (per via dei missing)
- la scala (media) che calcola in automatico il comando *alpha* con l'opzione *gen* inverte il segno degli item (-), non li ricodifica

3.9 Indici sommativi con scale auto-ancoranti

- **Definizione**: nelle scale auto-ancoranti, solo i valori estremi (1 e 10 oppure 0 e 10) sono etichettati. Il soggetto deve scegliere un numero che rappresenti il proprio punto di vista, tenendo conto del significato degli estremi.
- **Esempio**: per misurare l'atteggiamento verso gli immigrati, si possono usare affermazioni con scale da 1 a 10.
- "Gli immigrati portano via il lavoro agli italiani (1)" contro "Gli immigrati non portano via il lavoro agli italiani (10)".
- "Gli immigrati aggravano i problemi di criminalità (1)" contro "Gli immigrati non aggravano i problemi di criminalità (10)".
- "Gli immigrati costituiscono un peso per il sistema di welfare (1)" contro "Gli immigrati non costituiscono un peso per il sistema di welfare (10)".
- "È meglio se gli immigrati mantengono i loro specifici costumi e tradizioni (1)" contro "È meglio se gli immigrati non mantengono i loro specifici costumi e tradizioni (10)".

In sintesi, le scale auto-ancoranti permettono agli intervistati di esprimere le loro opinioni su un continuum numerico, con riferimenti agli estremi per guidare la loro scelta.

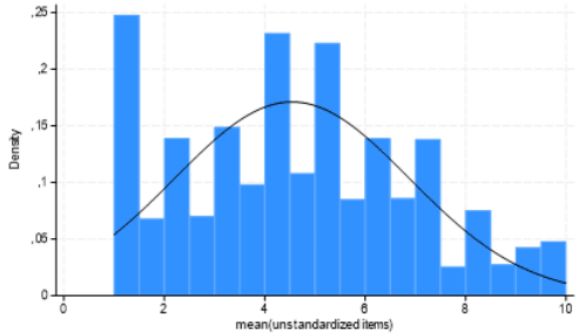
Indici sommativi con scale auto-ancoranti

Item	Obs	Sign	Item-test corr.	Item-rest corr.	Interitem cov.	alpha	Label
v185	2237	+	0,7717	0,5439	2,599369	0,6353	immigrants take away jobs from [nationality] (Q52A)
v186	2232	+	0,7856	0,5947	2,623231	0,6072	immigrants increase crime problems (Q52B)
v187	2132	+	0,8018	0,6246	2,519002	0,5988	immigrants are a strain on welfare system (Q52C)
v188	2184	-	0,5550	0,2625	4,419481	0,8143	better if immigrants maintain/not maintain own customs (Q52D)
Test scale					3,041182	0,7338	mean(unstandardized items)

La scala con 4 item avrebbe un discreto alpha, ma l'item v188 (a polarità semantica invertita) potrebbe essere eliminato e l'alpha salirebbe decisamente (da 0,73 a 0,81). Inoltre l'item v188 ha correlazione item-rest bassa (0,26). Quindi si preferisce costruire l'indice come somma o come media dei primi tre item: v185, v186, v187

Distribuzione e statistiche descrittive dell'indice

Variable	Obs	Mean	Std. dev.	Min	Max
att_imm	2.261	4,542754	2,331988	1	10



Il minimo è 1 (atteggiamento più negativo), il massimo 10 (più positivo).
La media è 4,5 quindi segnala atteggiamento tendenzialmente negativo. La variabilità è ampia (SD=2,3 CV=2,3/4,5=0,5).
La distribuzione non è simmetrica, c'è una concentrazione di casi sul valore 1

4

Tabelle di contingenza

4.1 Cosa sono le tabelle di contingenza?

Sono uno strumento semplice e chiaro per analizzare l'associazione tra due variabili categoriali o ordinali. Possono essere usate anche con variabili cardinali, ricodificando in classi per semplificare l'analisi. Inoltre consentono un'analisi multivariata di base tramite tabelle stratificate se ci sono abbastanza dati.

4.2 Come si fa il confronto tra variabili?

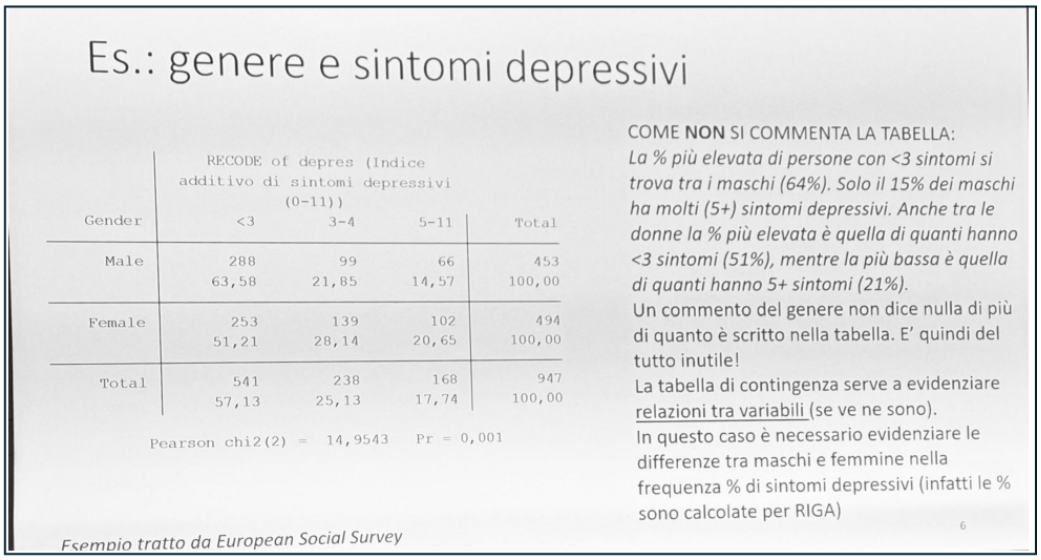
- **Quando Y è cardinale e X è categoriale**: si confrontano le medie di Y tra i gruppi definiti dalle categorie di X.
- **Quando Y e X sono entrambe categoriali o ordinali**: si utilizza una tabella a doppia entrata per rappresentare tutte le possibili combinazioni delle modalità delle due variabili. L'analisi consiste nel valutare la distribuzione di Y all'interno di ciascuna modalità di X per determinare se la distribuzione di Y varia a seconda delle modalità di X.

4.3 Come si analizzano le tabelle e calcolano le percentuali corrette?

1. **Identificazione della variabile indipendente**: determina se si trova nelle righe o nelle colonne.
2. **Orientamento di lettura**: stabilisci una direzione di lettura per facilitare l'interpretazione dei dati.
3. **Calcolo delle percentuali**: se l'indipendente è in righe, calcola le percentuali per riga, se è in colonne calcola per colonna. Usa le percen-

tuali anziché le frequenze assolute, poiché sono indipendenti dal numero totale di casi.

4. **Collocazione dell'indipendente**: la sua posizione nella tabella non è importante, ma deve essere chiaramente identificata.



Es.: genere e sintomi depressivi

Gender	RECODE of depres (Indice additivo di sintomi depressivi (0-11)) <3	3-4	5-11	Total
Male	288 63,58	99 21,85	66 14,57	453 100,00
Female	253 51,21	139 28,14	102 20,65	494 100,00
Total	541 57,13	238 25,13	168 17,74	947 100,00

Pearson chi2(2) = 14,9543 Pr = 0,001

COME **NON** SI COMMENTA LA TABELLA:

La % più elevata di persone con <3 sintomi si trova tra i maschi (64%). Solo il 15% dei maschi ha molti (5+) sintomi depressivi. Anche tra le donne la % più elevata è quella di quanti hanno <3 sintomi (51%), mentre la più bassa è quella di quanti hanno 5+ sintomi (21%).

Un commento del genere non dice nulla di più di quanto è scritto nella tabella. E' quindi del tutto inutile!

La tabella di contingenza serve a evidenziare relazioni tra variabili (se ve ne sono).

In questo caso è necessario evidenziare le differenze tra maschi e femmine nella frequenza % di sintomi depressivi (infatti le % sono calcolate per RIGA)

6

Esempio tratto da European Social Survey

COMMENTO CORRETTO DELLA TABELLA:
C'è un'associazione tra genere e intensità dei sintomi depressivi. Passando dal genere maschile al genere femminile la % di quanti hanno pochi sintomi (<3) diminuisce di 12 punti (63,58-51,21) e aumenta di 6 punti la percentuale di quanti hanno molti sintomi (5-11). In altre parole la depressione è più frequente e intensa tra le donne che tra gli uomini. L'associazione tra genere e sintomi depressivi è statisticamente significativa come indicato dal P-value (Pr) del test del Chi quadro (0,001 è inferiore a 0,05).

Distribuzioni condizionate

	Classe di età						
Fiducia interpersonale	18-29	30-39	40-49	50-59	60-69	70+	Total
most people can be trusted	26,9%	28,0%	30,5%	40,5%	29,0%	29,5%	30,8%
cannot be too careful	73,1%	72,1%	69,5%	59,5%	71,0%	70,5%	69,2%
Total	100%	100%	100%	100%	100%	100%	100%

Per interpretare la tabella e individuare una possibile associazione tra variabili, si calcolano le percentuali di riga o di colonna, a seconda di qual è la variabile indipendente (in questo caso per colonna). La distribuzione condizionata è la distribuzione di «fiducia interpersonale» entro ciascuna classe di età

Interpretazione della tabella

	Classe di età						
Fiducia interpersonale	18-29	30-39	40-49	50-59	60-69	70+	Total
most people can be trusted	26,9%	28,0%	30,5%	40,5%	29,0%	29,5%	30,8%
cannot be too careful	73,1%	72,1%	69,5%	59,5%	71,0%	70,5%	69,2%
Total	100%	100%	100%	100%	100%	100%	100%

Si individua una modalità della v.d. (es.: «most people can be trusted») e si osserva come varia la % che dà quella risposta al variare della classe di età. E' anche possibile confrontare la % che dà quella risposta in una classe di età specifica (es: 40,5% nella classe 50-59 anni) con la % sul totale del campione (30,8%). Si considerano rilevanti le variazioni di almeno 5 *punti percentuali*, ma non è una regola assoluta perché dipende dal livello di partenza (una variazione da 5% a 10% è di fatto un raddoppio, mentre una variazione da 80% a 85% è un aumento di poco conto)

5

Elementi di inferenza statistica

5.1 Campione e popolazione

Nelle scienze sociali si utilizzano i campioni per studiare le popolazioni, poiché non sempre è possibile analizzare l'intera popolazione, tranne nei casi dei censimenti o di popolazioni molto piccole.

- Questa tecnica si chiama inchiesta campionaria (o survey) ed è molto usata nelle scienze sociali.
- Per fare in modo che i risultati siano affidabili e rappresentino bene la popolazione, è importante scegliere il campione in modo casuale.

5.2 Perché casuale significa rappresentativo?

- **Legge empirica del caso**: quando si ripete molte volte un esperimento casuale, ad esempio lanciare una moneta, la frequenza di un risultato specifico, come ottenere "testa", si avvicina alla probabilità che quell'evento si verifichi, per la moneta 0,5.
- **Legge dei grandi numeri**: quando si ripete un esperimento molte volte, la media dei risultati tende a convergere verso la media teorica. Ad esempio, lanciando un dado non truccato molte volte, la media dei numeri ottenuti tende a 3,5, il valore medio dei sei numeri equiprobabili.

Se si estraggono un numero grande di persone in modo casuale, la media o la percentuale di una qualsiasi variabile tende a coincidere con quella della popolazione da cui si sta campionando. Quindi:

- ripetendo molte volte un esperimento casuale, il risultato osservato tende a coincidere con quello atteso, la probabilità teorica o la media;
- lo stesso principio vale per il campionamento, se scegli casualmente un numero sufficiente di persone i risultati rappresentano bene l'intera popolazione.

5.3 Dalle statistiche campionarie ai parametri della popolazione

Le statistiche campionarie, come medie, percentuali e correlazioni, sono variabili che cambiano da campione a campione e vengono usate per stimare i parametri della popolazione, che invece sono costanti.

I metodi di inferenza statistica, basati sul calcolo delle probabilità, permettono di valutare l'incertezza di queste stime rispetto ai parametri reali della popolazione.

5.4 Variabili casuali e distribuzioni di probabilità

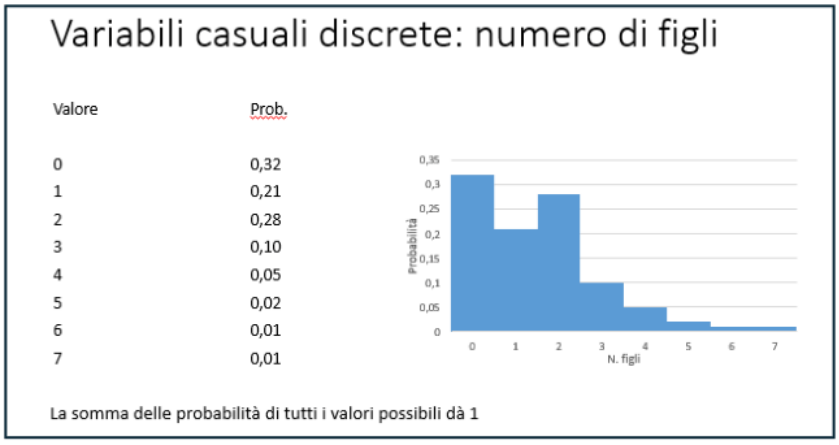
La variabile casuale (v.c.) è una funzione che associa un valore a un evento casuale. Ad esempio il lancio di un dado o l'estrazione di palline da un'urna. La distribuzione di probabilità descrive la probabilità con cui ogni valore della v.c. si verifica.

Le v.c. possono essere:

- **discrete**, con valori enumerabili, contabili, elencabili;
- **continue**, con un insieme infinito di valori;

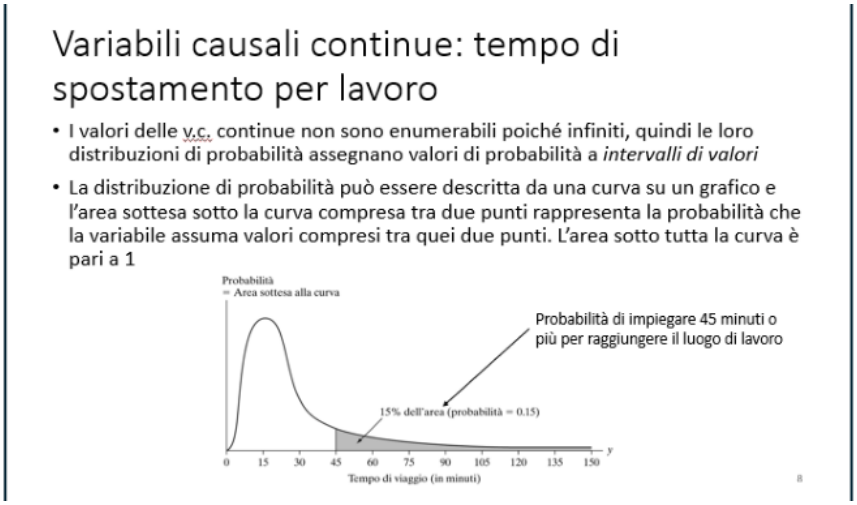
e possono seguire distribuzioni teoriche, ad esempio gaussiana o binomiale.

5.5 Variabili casuali discrete



La probabilità di avere almeno un figlio è la somma delle probabilità al caso 0 e al caso 1, quindi 0,53.

5.6 Variabili casuali continue



Le variabili casuali continue possono assumere infiniti valori, quindi non possiamo attribuire una probabilità a un singolo valore, ma solo a intervalli.

La distribuzione di probabilità può essere vista come una curva su un grafico: l'altezza della curva in un punto non indica la probabilità di quel valore, ma la probabilità che i valori siano attorno a quel punto.

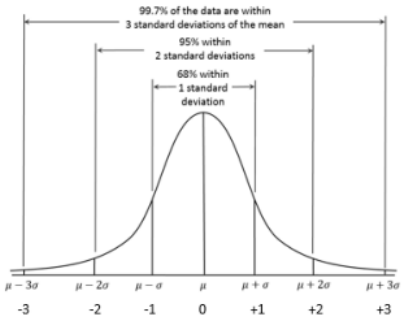
La probabilità tra due valori è data dall'area sotto la curva in quell'intervallo, e l'area totale sotto la curva è 1, rappresentando la certezza che la variabile assumerà un valore possibile.

5.7 Distribuzioni teoriche di probabilità: la normale

La distribuzione normale (o gaussiana) è fondamentale in statistica inferenziale, poiché rappresenta bene le variabili continue e le statistiche campionarie, come la media, anche quando le variabili stesse non seguono un andamento normale.

Graficamente la curva normale ha una forma a campana simmetrica, rendendola uno strumento chiave per analisi statistiche.

La v.c. normale standard



La normale standard ha media (μ) = 0 e dev.std. (σ) = 1

La v.c. normale standard (Z) ha una distribuzione di probabilità nota e calcolabile descritta da una specifica funzione matematica

12

Esempio di standardizzazione

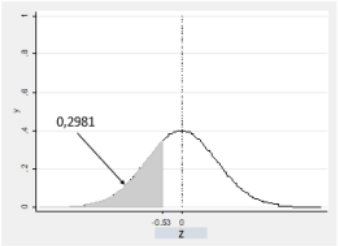
La popolazione italiana ha un'età media di 42 anni e dev.std. 22,8. Se l'età è approssimativamente distribuita normalmente, qual è la probabilità di estrarre dalla popolazione un caso di età pari o inferiore a 30 anni?

Per saperlo occorre trasformare i valori in punteggi Z, cioè come se fossero valori di una normale standard (anziché di una normale generica)

$$\Pr(Y \leq 30) = \Pr\left(Z \leq \frac{30-42}{22.8}\right)$$

$$\Pr(Z \leq -0.53)$$

Area sotto la normale standard



La probabilità che ci interessa è data dall'area grigia.

Notare che la curva è simmetrica:
P(Z<-0,53) = P(Z>0,53) = 0,2981 (≈30%)

L'area sotto tutta la curva normale è **pari a 1**, l'area sotto tutta la parte sinistra (o destra) è pari a 0,5

15

5.8 Uso dei valori standardizzati (z score)

La standardizzazione dei valori consente di confrontare risultati provenienti da variabili diverse, rendendoli più facilmente interpretabili. La standardizzazione viene effettuata tramite la trasformazione dei punteggi originali in

punteggi z, che ci indicano quante deviazioni standard un dato punteggio si discosta dalla media.

Esempio: uno studente ottiene 550 punti nel test A, dove la media degli studenti è 500 e la deviazione standard è 100, e 30 punti nel test B, dove la media degli studenti è 18 e la deviazione standard è 6. In quale test ha fatto meglio?

5.9 Distribuzioni delle statistiche campionarie

Variabili casuali teoriche ed empiriche

Le variabili casuali sono funzioni che assegnano un valore numerico a ogni risultato di un esperimento casuale. Queste possono essere utilizzate per:

- rappresentare distribuzioni di variabili empiriche, come l'età degli intervistati in un'indagine;
- descrivere la variabilità delle statistiche campionarie, come la media delle età, quando si prelevano campioni da una popolazione.

Variabilità delle statistiche campionarie

Ogni campione prelevato da una popolazione può fornire un valore diverso per una certa statistica, come la media. Questa variabilità è naturale e può essere analizzata utilizzando le distribuzioni di probabilità: la distribuzione delle statistiche campionarie fornisce informazioni su quali valori di una statistica sono probabili e quali sono meno probabili.

Stimare parametri della popolazione

Nella pratica statistica di solito abbiamo accesso a un solo campione e utilizziamo il valore della statistica campionaria, ad esempio la media, per stimare il valore del parametro corrispondente nella popolazione.

Esempio: se la media dell'età in un campione è 30 anni, possiamo stimare che la media della popolazione sia anch'essa intorno ai 30 anni, ma dobbiamo anche considerare l'incertezza legata a questa stima.

Distribuzione normale e teorema del limite centrale

Il teorema del limite centrale è uno dei risultati più importanti della statistica e afferma che, sotto certe condizioni, la distribuzione delle medie cam-

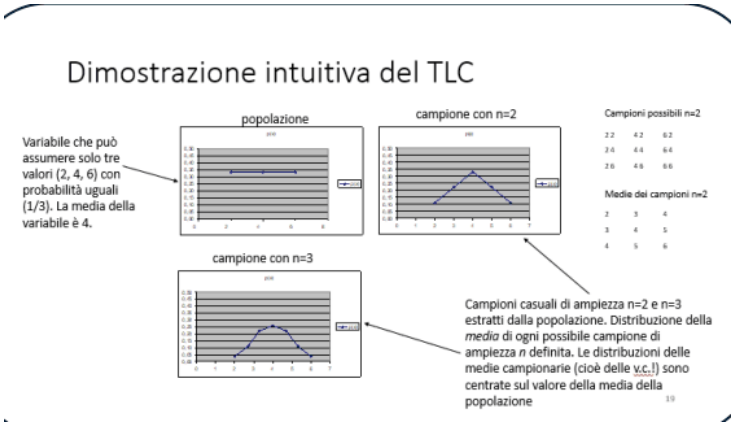
pionarie tende a essere normale, indipendentemente dalla distribuzione della popolazione da cui i campioni sono estratti. Le condizioni chiave sono:

- campioni sufficientemente grandi, di solito $n \geq 30$ è considerato una buona regola;
- la popolazione da cui vengono estratti i campioni non deve necessariamente avere una distribuzione normale.

Applicazioni pratiche

Grazie al teorema del limite centrale possiamo utilizzare la distribuzione normale per fare inferenze sulle statistiche campionarie.

- **Intervalli di confidenza**: possiamo costruire intervalli di confidenza attorno alla media campionaria per stimare il range in cui ci aspettiamo che si trovi il parametro della popolazione.
- **Test di ipotesi**: possiamo usare la distribuzione normale per testare le ipotesi riguardo alla media o proporzione di una popolazione.



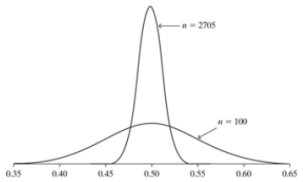
TLC e variabilità della media campionaria

- Se si estraggono *ripetutamente* campioni di ampiezza ***n*** da una popolazione e per ciascuno di essi di calcola la media di una variabile *y* (sia essa cardinale o dicotomica) si ottiene una distribuzione di valori di medie possibili:
  - La media di queste medie coincide con la **media della popolazione**
  - La variabilità di tali medie (calcolata come la deviazione standard) è detta ***errore standard***. Essa ci dice quanto la media campionaria si discosta dalla media della popolazione
- E' una statistica molto importante perché definisce il margine di variazione tipico (errore) delle stime di una media
- **Errore standard della media campionaria**: $\sigma_{\bar{y}} = \frac{\sigma}{\sqrt{n}}$
- Per stimare l'errore standard con i dati campionari si usa la deviazione standard campionaria *s* come stima di σ

Dimensione campionaria e precisione delle stime

Poiché l'ampiezza campionaria *n* sta al denominatore della formula dell'errore standard, al crescere di *n* diminuisce l'errore standard

Per un campione di ampiezza *n* = 2705 il margine di errore di una statistica campionaria (es.: una media oppure una proporzione) sarà molto inferiore a quello di un campione di ampiezza *n* = 100.



22

Esempio: età media

Nella slide 14 la prob. di estrarre un individuo di età pari o inferiore a 30 dalla popolazione italiana (media 42; dev. std. 22,8) era quasi 0,3.

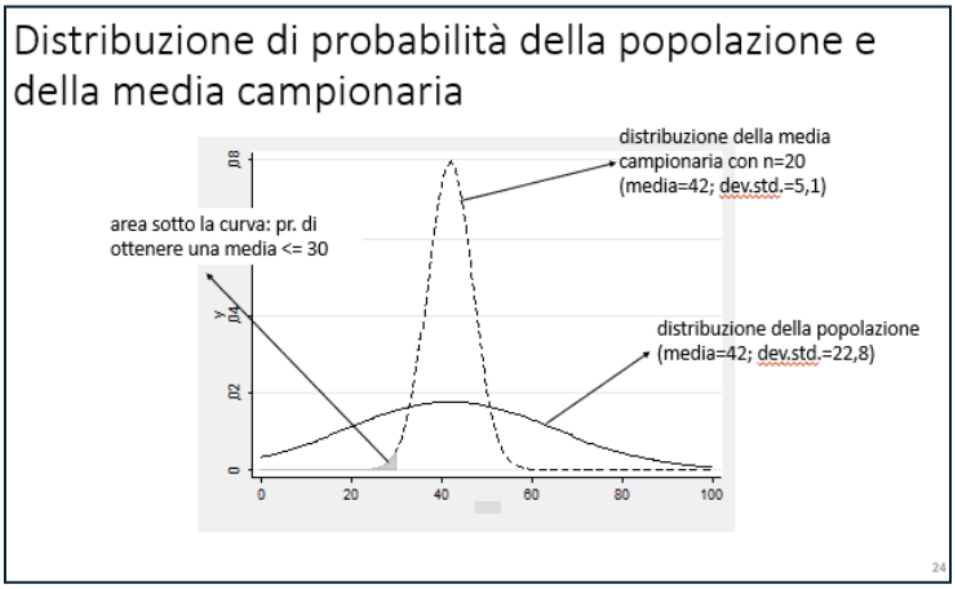
Ora possiamo domandarci: estraendo un campione casuale di n=20 soggetti, qual è la prob. che l'età **media** di tali soggetti sia pari o inferiore 30 anni?

Standardizzo...

$$\Pr(\bar{Y} \leq 30) = Pr\left(Z \leq \frac{30-42}{22{,}8/\sqrt{20}}\right) = \Pr(Z \leq -2{,}35) < 0{,}001$$

Anche se la prob. di estrarre ***un*** individuo di età pari o inferiore a 30 dalla popolazione non è piccolissima (0,3), la prob. di estrarre un campione di 20 soggetti con ***età media*** pari o inferiore a 30 anni diventa pressoché trascurabile (<0,001). La media campionaria ha una dispersione molto inferiore ai dati della popolazione, tanto inferiore quanto più ampio è il campione

23



5.10 Da ricordare

- **Distribuzione della popolazione**: è la distribuzione dalla quale si estrae il campione. Le caratteristiche non sono generalmente note, ad eccezione di quelle rilevate nei censimenti. L'ampiezza è N.
- **Distribuzione dei dati campionari**: è la distribuzione dei casi di fatto osservati. Si può descrivere con statistiche quali la media e la deviazione standard. Quanto maggiore è l'ampiezza n del campione, tanto più la distribuzione dei dati campionari assomiglierà a quella della popolazione.
- **Distribuzione campionaria**: è la distribuzione di probabilità per tutti i possibili valori di una statistica campionaria, ad esempio media, mediana, proporzione o percentuale. Questa distribuzione determina la probabilità che la statistica assuma valori entro una determinata distanza dal valore del parametro di popolazione che viene stimato. Non è direttamente osservabile.

5.11 Stima intervallare

- La stima puntuale è un valore unico che rappresenta la miglior previsione di un parametro sconosciuto di una popolazione, mentre la stima intervallare è un intervallo di valori che circonda la stima puntuale, indicando una possibile gamma entro cui si trova il parametro.

- Uno stimatore è una statistica, come la media, utilizzata per stimare un parametro. Quando si applica lo stimatore ai dati, il valore ottenuto si chiama stima.

Per una stima più accurata non basta solo la stima puntuale, serve anche una misura della sua precisione, indicata dall'intervallo di confidenza. Questo intervallo contiene il parametro con una probabilità specifica, detta livello di confidenza, spesso 95% o 99%.

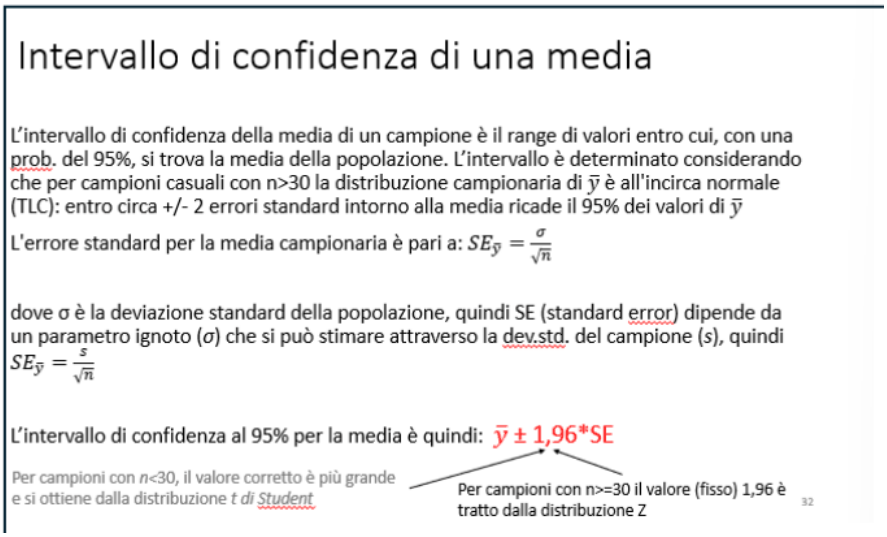
5.12 Intervalli di confidenza al 95% e 99%

Se la distribuzione campionaria dello stimatore puntuale è normale, si può stabilire la probabilità che lo stimatore si collochi vicino al parametro reale.

Ad esempio, la media campionaria normalmente distribuita avrà un 95% di probabilità di produrre stime entro 1,96 errori standard dalla media, mentre al 99% si utilizza un valore z di 2,58. All'aumentare della dimensione campionaria l'intervallo diventa più stretto, migliorando la precisione della stima.

5.13 Deviazione standard ed errore standard

La deviazione standard si riferisce alla variabilità delle singole osservazioni attorno alla media del campione. L'errore standard invece riguarda la variabilità della media campionaria rispetto alla media della popolazione ed è sempre inferiore alla deviazione standard del campione, essendo una misura della precisione della media campionaria come stima del parametro.



Proporzione campionaria e suo intervallo di confidenza

Le variabili casuali dicotomiche sono casi particolari di variabili (cardinali) la cui distribuzione di probabilità è:

Valore	Probabilità
1	π
0	$(1-\pi)$

N.B: π (pi dell'alfabeto greco) è in questo caso un simbolo per indicare un valore di probabilità, ***non** è il pi greco = 3,14!*

Di una *variabile dicotomica* si può calcolare media e deviazione standard esattamente come per una variabile qualsiasi (v. formule slide 9):

Media = $1*\pi + 0*(1-\pi) = \pi$ (di fatto è la proporzione di casi con valore 1)

Dev. Std. = $\sqrt{(1-\pi)^2\pi + (0-\pi)^2(1-\pi)} = \sqrt{\pi\,(1-\pi)}$

Proporzione campionaria e suo intervallo di confidenza

Poiché la media di una variabile dicotomica è equivalente alla proporzione di casi con valore 1, possiamo usare la *proporzione campionaria* (p) come stima della media della popolazione (π) di una variabile dicotomica.
La proporzione campionaria di fatto si comporta come la v.c. media campionaria.
Vale quindi il TLC e la sua distribuzione teorica di probabilità, la normale standard.
L'intervallo di confidenza al 95% per una proporzione *p* diventa quindi:

$$p \pm 1{,}96 * \sqrt{\frac{p*(1-p)}{n}}$$

6

Test di ipotesi statistiche

6.1 Domande di ricerca e ipotesi statistiche

Spesso nella ricerca interessano domande del tipo:

- "I cittadini italiani sono favorevoli all'aborto?"
- "Esiste un divario di genere nelle retribuzioni?"
- "La religione rende più felici?"

Le domande prefigurano ipotesi statistiche:

- il 50% o più dei cittadini è favorevole all'aborto;
- il reddito medio degli uomini è superiore a quello delle donne;
- la proporzione di quanti si dichiarano felici è maggiore tra le persone religiose che tra quelle non religiose.

Un'ipotesi statistica è un'affermazione sulla popolazione, solitamente una previsione che un certo parametro di popolazione abbia un certo valore numerico o ricada in un certo intervallo di valori.

Poiché le ipotesi più interessanti riguardano quasi sempre due o più variabili, spesso il parametro oggetto dell'affermazione è una statistica che esprime la relazione tra le due variabili. Le ipotesi statistiche si controllano tramite appropriati test.

6.2 Elementi di un test statistico: assunti

- **Tipo di dati**: ciascun test si applica a determinati tipi di dati, variabili cardinali, ordinali o categoriali.
- **Casualità**: un test assume che i dati siano ottenuti casualmente, cioè da un campione casuale.

- **Distribuzione della popolazione**: per alcuni test si assume che la variabile abbia una particolare distribuzione, come ad esempio la distribuzione normale.
- **Dimensione campionaria**: la validità di molti test cresce all'aumentare della dimensione campionaria.

6.3 Elementi di un test statistico: ipotesi

Quando si fa un test statistico si parte da due ipotesi.

1. **Ipotesi nulla (H0)**: è come dire "non c'è nulla di strano". È l'affermazione che non c'è differenza o effetto. Per esempio, se vogliamo vedere se c'è una differenza tra gli stipendi di uomini e donne, l'ipotesi nulla dirà che non c'è differenza tra gli stipendi, sono uguali.
2. **Ipotesi alternativa (Ha)**: è l'ipotesi che vogliamo provare, cioè che c'è un effetto o una differenza. Nello stesso esempio l'ipotesi alternativa sarebbe che gli uomini guadagnano di più delle donne, o che c'è comunque una differenza tra gli stipendi.

Il test statistico ci aiuta a capire quanto sia improbabile che H0 sia vera, dato ciò che osserviamo.

6.4 Elementi di un test statistico: la statistica test

La statistica test è un numero che ci dice quanto il risultato ottenuto dal nostro campione si discosta da quello che ci aspetteremmo se l'ipotesi nulla fosse vera.

- Se facessimo lo stesso test molte volte, otterremmo una serie di valori, ognuno con una probabilità di verificarsi.
- Ogni tipo di test ha una distribuzione teorica di probabilità a cui si fa riferimento. Le distribuzioni più comuni sono la Z, la t di Student e il Chi quadrato.

Ad esempio, nel test per confrontare le medie di due gruppi, la statistica test è la differenza tra le medie, espressa in termini standardizzati, e la distribuzione di riferimento per questo test è la t di Student.

6.5 Elementi di un test statistico: il valore di probabilità (P-value)

Il P-value è la probabilità di ottenere un risultato pari a quello osservato, se l'ipotesi nulla fosse vera. In pratica, se il P-value è molto piccolo significa che è poco probabile che H0 sia vera. In sostanza il P-value ci dà delle prove empiriche per decidere se accettare o rifiutare H0.

6.6 Elementi di un test statistico: conclusioni

- Se il P-value è molto basso, di solito meno di 0,05, si rifiuta H0. Questo significa che i risultati sono considerati "significativi" e che c'è una buona probabilità che Ha sia vera.
- Se il P-value è maggiore di 0,05 non si rifiuta H0, ma non possiamo dire con certezza che H0 sia vera.

Attenzione però:

1. anche se rifiutiamo H0 ($< 0{,}05$) c'è sempre una piccola probabilità di commettere un errore, chiamato errore di primo tipo o "falso positivo", cioè rifiutare H0 quando invece è vera;
2. allo stesso modo, se non rifiutiamo H0 c'è il rischio di commettere un errore di secondo tipo o "falso negativo", cioè accettare H0 quando in realtà è falsa.

Per ridurre questi errori è meglio aumentare la dimensione del campione o raccogliere più dati, piuttosto che puntare solo ad avere un P-value molto basso.

6.7 Limiti dei test di significatività

1. Il P-value non ci dice nulla sulla differenza esatta tra il valore reale del parametro e quello ipotizzato in H0.
2. Un P-value molto piccolo indica semplicemente che c'è una forte evidenza contro H0.

Ad esempio, se in un campione di 100 persone il 70% è favorevole all'aborto e il P-value è 0,0001 sotto l'ipotesi nulla che i favorevoli siano solo il 50%, questo non significa che nella popolazione generale il 70% sia favorevole. Il vero valore potrebbe essere compreso, ad esempio, tra il 61% e il 79%, come indicato dall'intervallo di confidenza.

È importante capire che la significatività statistica, cioè un P-value basso, non coincide necessariamente con la significatività pratica o rilevanza sostanziale. Ad esempio, se in un campione di 2500 persone il 52% è favorevole all'aborto e il P-value è 0,046 sotto l'ipotesi nulla che i favorevoli siano il 50%:

- la differenza è statisticamente significativa;
- la differenza reale, 52% contro 50%, è molto piccola dal punto di vista pratico.

La significatività pratica diventa fondamentale con l'aumento della dimensione del campione, perché con campioni grandi è facile rifiutare l'ipotesi nulla anche per differenze minime tra i dati osservati e quelli ipotizzati.

Con campioni sufficientemente grandi praticamente qualsiasi ipotesi può essere rifiutata, quindi diventa essenziale valutare quanto la differenza sia rilevante nel contesto reale, oltre al risultato statistico.

Parliamo di intervalli di confidenza, perché sono utili?

Sono utili perché indicano la distanza dei valori dall'ipotesi nulla, permettendo di considerare anche la rilevanza pratica e non solo quella statistica.

6.8 Confronto tra gruppi

Nelle scienze sociali è comune confrontare dati tra due o più gruppi, come maschi e femmine. Si parte dall'assunto che i gruppi siano campioni casuali delle rispettive popolazioni.

- La variabile che definisce i gruppi (X) può essere dicotomica, con due gruppi, oppure categoriale, con tre o più gruppi.
- La variabile su cui si basano i confronti (Y) è solitamente cardinale, e allora si confrontano le medie, oppure dicotomica, e allora si confrontano le proporzioni.

Il nostro focus: la differenza osservata tra i gruppi è significativamente diversa da zero? In altre parole, le medie di Y nei due gruppi sono uguali o diverse?

6.9 Approfondimento sul test di significatività

L'utilizzo degli intervalli di confidenza serve allo stesso scopo dei test di significatività, e in certi casi è persino più utile. Bisogna seguire questi passaggi.

1. Definire la statistica test e la sua distribuzione teorica di probabilità, ad esempio Z, t di Student, Chi quadrato.
2. Definire le ipotesi: l'ipotesi nulla H0 e l'ipotesi alternativa Ha, insieme al livello di significatività alpha, spesso 0,05 o 0,01.
3. Individuare la regione di rifiuto, cioè identificare i valori della statistica test che porterebbero a rifiutare H0 e quindi ad accettare Ha.
4. Standardizzare la stima campionaria, traducendo il valore della stima ottenuta dal campione nella metrica della statistica test, e verificare se ricade nella regione di rifiuto oppure no.

7

Analisi delle tabelle di contingenza

7.1 Associazione tra variabili categoriali

- Quando la variabile dipendente (Y) è cardinale e quella indipendente (X) è categoriale, si confrontano le medie di Y tra i diversi gruppi definiti dalle categorie di X.
- Quando entrambe le variabili sono categoriali o ordinali, il confronto tra i gruppi si rappresenta con una tabella di contingenza, che mostra tutti gli incroci tra le modalità delle due variabili.

L'analisi consiste nel vedere se la distribuzione di Y varia tra le diverse modalità di X o se rimane costante.

Da notare: si possono usare anche con variabili cardinali, se ricodificate in classi, per semplificare l'analisi della loro relazione.

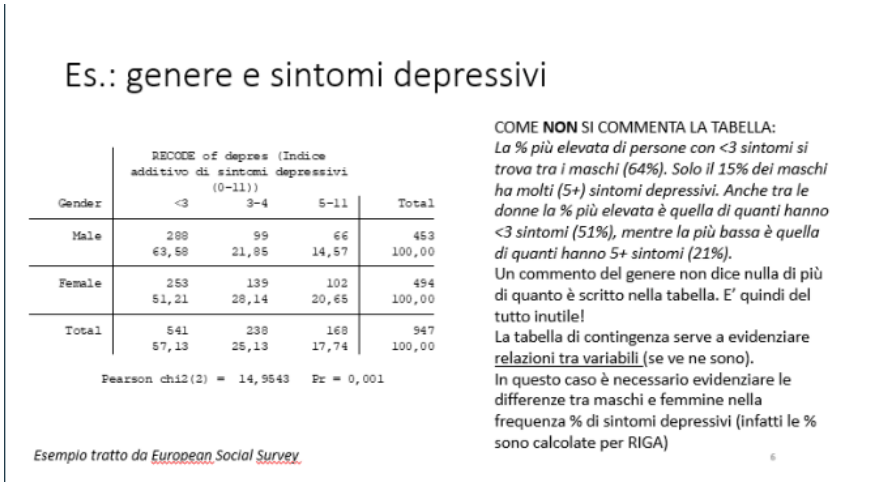
7.2 Come si analizzano le tabelle: calcolo delle percentuali corrette

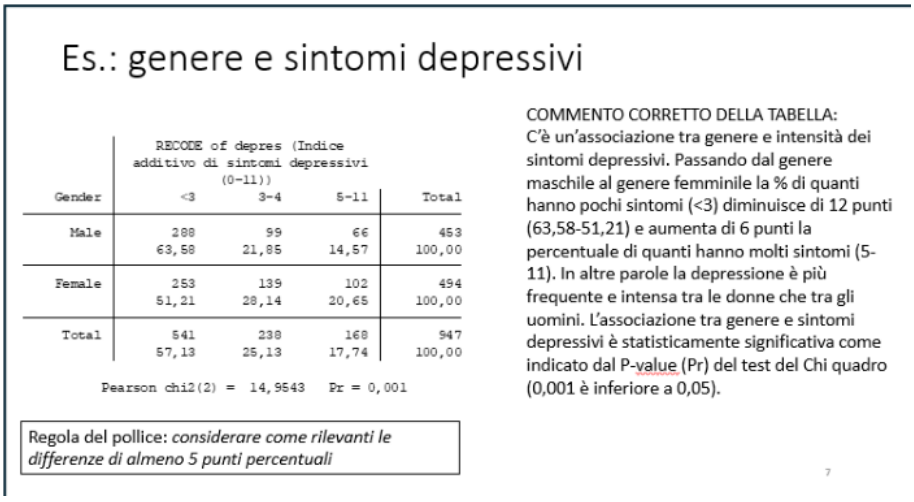
1. **Individuare la variabile indipendente**: questa si trova nelle righe o nelle colonne della tabella. Se non c'è una variabile indipendente ovvia, ad esempio orientamento politico e religioso, bisogna decidere una direzione di lettura.
2. **Calcolo delle percentuali**: se l'indipendente è nelle righe si calcolano le percentuali per riga, se è nelle colonne si calcolano per colonna. Si usano percentuali anziché frequenze assolute, perché sono indipendenti dal numero totale di casi.
3. **Collocazione grafica**: non è importante dove si mette la variabile indipendente, righe o colonne, ma è fondamentale stabilire quale sia.

7.3 Lettura della tabella di contingenza

Non ha senso ripetere le percentuali dalla tabella, bisogna commentarle in modo utile.

1. Scegliere una modalità significativa della variabile dipendente.
2. Osservare la percentuale di quella modalità nel gruppo definito dalla prima categoria dell'indipendente.
3. Verificare come varia la percentuale passando ad altre modalità dell'indipendente.





7.4 Indipendenza tra variabili categoriali

Obiettivo principale delle tabelle di contingenza è verificare se esiste una dipendenza tra due variabili categoriali. Si adotta un approccio falsificazionista, cioè si testa l'ipotesi che le variabili siano indipendenti. Se non sono indipendenti, allora significa che sono associate.

- **Indipendenza statistica**: due variabili categoriali sono indipendenti se, in tutta la popolazione, la distribuzione condizionata di una variabile è la stessa in ogni categoria dell'altra variabile.
- **Dipendenza statistica**: le variabili sono dipendenti se le distribuzioni condizionate variano tra le diverse categorie della seconda variabile.

Situazione di indipendenza

Se le variabili sono perfettamente indipendenti l'una dall'altra, le distribuzioni condizionate sono tutte identiche

	Classe di età						
Fiducia interpersonale	18-29	30-39	40-49	50-59	60-69	70+	Total
most people can be trusted	30,8%	30,8%	30,8%	30,8%	30,8%	30,8%	30,8%
cannot be too careful	69,2%	69,2%	69,2%	69,2%	69,2%	69,2%	69,2%
Total	100%	100%	100%	100%	100%	100%	100%

7.5 Test del Chi-quadro per l'indipendenza

Il test del chi-quadro serve a verificare se due variabili categoriali sono indipendenti o associate nella popolazione.

Ipotesi del test:

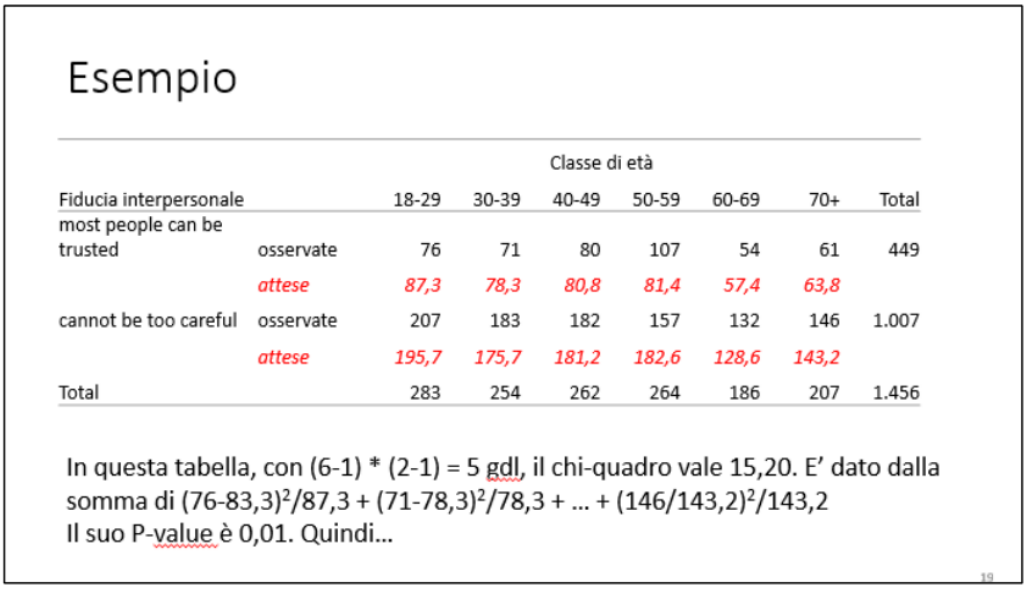
- **H0**: le variabili sono indipendenti.
- **Ha**: le variabili sono dipendenti.

Il test si basa sul confronto tra le frequenze osservate (fo) nei dati e le frequenze attese (fe), che rappresentano ciò che ci aspetteremmo se le variabili fossero indipendenti.

Requisiti:

- campionamento casuale;
- campione grande per garantire affidabilità.

Il chi-quadro confronta le frequenze attese e osservate. Se le differenze sono significative si rifiuta l'ipotesi di indipendenza, suggerendo che le variabili sono associate.



Esempio

		Classe di età						
Fiducia interpersonale		18-29	30-39	40-49	50-59	60-69	70+	Total
most people can be trusted	osservate	76	71	80	107	54	61	449
	attese	*87,3*	*78,3*	*80,8*	*81,4*	*57,4*	*63,8*	
cannot be too careful	osservate	207	183	182	157	132	146	1.007
	attese	*195,7*	*175,7*	*181,2*	*182,6*	*128,6*	*143,2*	
Total		283	254	262	264	186	207	1.456

In questa tabella, con (6-1) * (2-1) = 5 gdl, il chi-quadro vale 15,20. E' dato dalla somma di $(76-83{,}3)^2/87{,}3 + (71-78{,}3)^2/78{,}3 + \ldots + (146/143{,}2)^2/143{,}2$
Il suo P-value è 0,01. Quindi...

19

7.6 Quali sono i limiti del Chi-quadro?

- Il test si applica a variabili nominali. Non usa l'informazione di variabili ordinali o quantitative.
- Se il P-value è molto piccolo vi è certamente un'evidenza sulla presenza di una dipendenza importante, ma non siamo in grado di quantificarla.
- Come tutti i test, ma questo in particolare, all'aumentare di n aumenta il valore di Chi-quadro. Se n raddoppia anche il Chi-quadro raddoppia, pur rimanendo identica l'associazione.

Chiarimenti sulle numerosità di cella

Per una corretta analisi delle tabelle di contingenza ci dovrebbero essere almeno 50 casi per ciascun marginale, per ridurre gli errori nelle percentuali.

Il test del chi-quadro si basa sui casi attesi, non su quelli osservati. Questi casi attesi sono quelli che ci aspetteremmo se le variabili fossero indipendenti. In Stata si possono calcolare con l'opzione `exp` del comando `tab`.

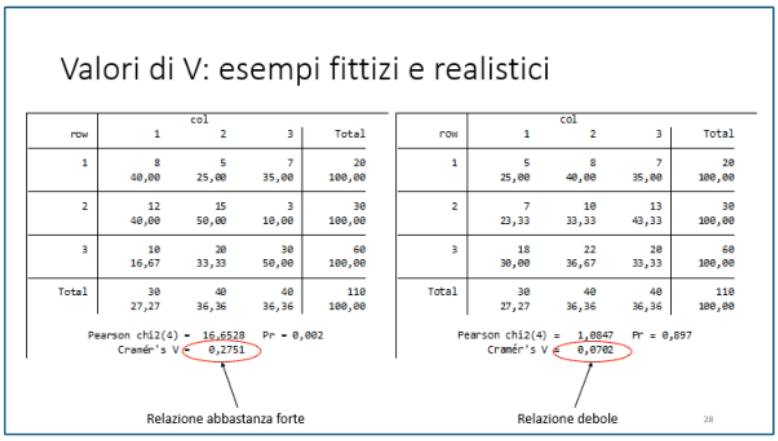
> Tabelle di contingenza e Chi quadro: chiarimenti sulle numerosità di cella
>
> Le condizioni precise da rispettare sono:
>
> 1. in nessuna cella la frequenza attesa deve essere inferiore a 1
> 2. in almeno 80% delle celle la frequenza attesa deve essere superiore a 5.
>
> La seconda condizione significa che, ad es., in una tabella 3x4 contenente 12 celle, in almeno 10 celle (=12*0.8 arrotondato) la frequenza attesa deve essere >5. In due celle posso ammettere una frequenza attesa <5 (ma sempre >1).
>
> Le condizioni sono sicuramente rispettate se *tutte* le celle hanno una frequenza attesa >5.

7.7 Strettezza della relazione

Il Chi quadro ci indica se esiste una relazione tra due variabili, ma non la sua forza. Per una misura più accurata si usa il V di Cramér, che varia da 0, nessuna relazione, a 1, associazione perfetta. Nella pratica non si raggiunge mai 1.

V di Cramér

Il V si basa sul Chi quadro, il cui valore viene "normalizzato" per renderlo indipendente dal numero di casi della tabella e dal numero di modalità delle variabili.



7.8 Associazione tra variabili ordinali: co-graduazione

Quando entrambe le variabili di una tabella di contingenza sono ordinali, oltre a capire la forza dell'associazione possiamo determinare anche la sua direzione, positiva o negativa. Questo significa capire se, al crescere del valore di una variabile, l'altra tende ad aumentare o diminuire.

Esempio: considerando il livello di istruzione e la percezione di controllo sulla vita, possiamo osservare che all'aumentare dell'istruzione aumenta anche la percezione di controllo, su una scala da 1 a 10.

7.9 Indice Gamma di Goodman e Kruskal

L'indice Gamma di Goodman e Kruskal misura la direzione e la forza della relazione tra variabili ordinali, con valori che vanno da:

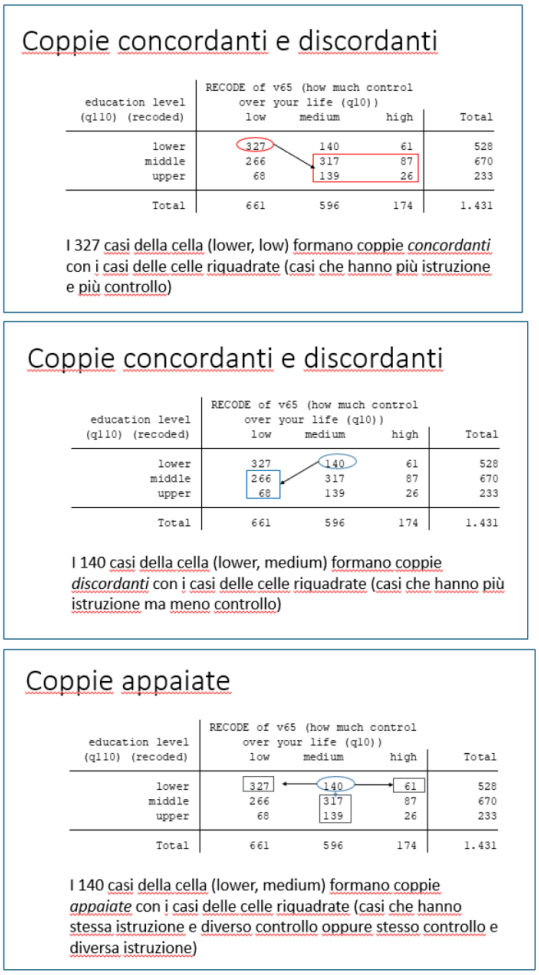
- -1: co-graduazione perfettamente negativa, all'aumentare di una variabile l'altra diminuisce;
- 0: assenza di relazione;
- $+1$: co-graduazione perfettamente positiva, entrambe aumentano insieme.

Questo indice funziona in modo simile al coefficiente di correlazione di Pearson, ma l'interpretazione è diversa, poiché si applica a variabili ordinali.

Coppie di casi: concordanza, discordanza e appaiamento

La co-graduazione si basa sul confronto tra le variabili in tutte le possibili coppie di casi.

- **Coppie concordanti**: quando una coppia di casi mostra che entrambi i valori delle due variabili (X e Y) sono maggiori o minori rispetto all'altro caso. Esempio: il caso 1 ha più istruzione e maggiore percezione di controllo rispetto al caso 2.
- **Coppie discordanti**: quando una variabile ha un valore maggiore in un caso, ma l'altra variabile ha un valore minore. Esempio: il caso 1 è più istruito, ma percepisce meno controllo rispetto al caso 2.
- **Coppie appaiate (tied)**: quando i due casi hanno lo stesso valore per una o entrambe le variabili. Esempio: il caso 1 ha lo stesso livello di istruzione ma percepisce meno controllo rispetto al caso 2, oppure entrambi hanno gli stessi livelli di istruzione e percezione di controllo.

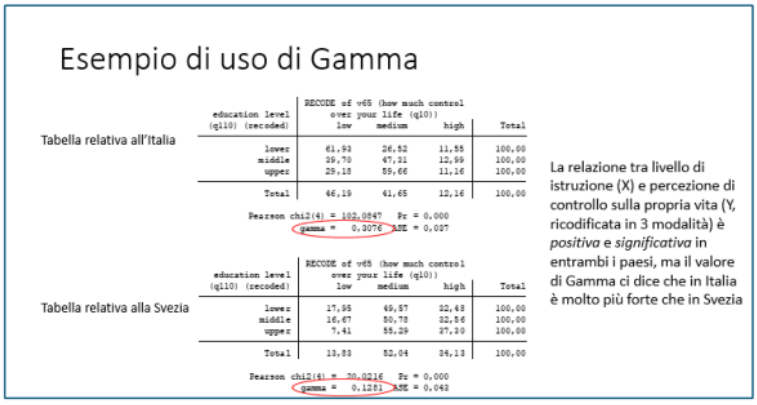


7.10 Calcolo di Gamma e interpretazione

L'indice Gamma di Goodman e Kruskal permette di capire la direzione della relazione tra due variabili ordinali, basandosi sul confronto tra coppie di casi. Dove:

- c è il numero di coppie concordanti, cioè quando entrambe le variabili crescono o decrescono insieme;
- d è il numero di coppie discordanti, quando una variabile cresce mentre l'altra decresce.

Gamma non considera le coppie appaiate, cioè quelle in cui i valori delle variabili sono uguali.



Come interpretare Gamma?

- **Relazione positiva**: se la maggioranza delle coppie è concordante, il valore di Gamma sarà positivo, indicando che al crescere di una variabile tende a crescere anche l'altra.
- **Relazione negativa**: se prevalgono le coppie discordanti, il valore di Gamma sarà negativo, suggerendo che al crescere di una variabile l'altra tende a diminuire.
- **Assenza di relazione**: se le coppie concordanti e discordanti sono in equilibrio, Gamma sarà vicino a 0, indicando che non c'è relazione tra le variabili.

Esempio pratico

Se in una relazione tra livello di istruzione e percezione di controllo sulla vita il valore di Gamma è 0,27, significa che la probabilità che una persona

con maggiore istruzione percepisca anche un maggior controllo sulla propria vita è superiore del 27% rispetto alla probabilità opposta, cioè che chi ha più istruzione percepisca meno controllo.

8

La logica dell'analisi multivariata

8.1 Due variabili non bastano

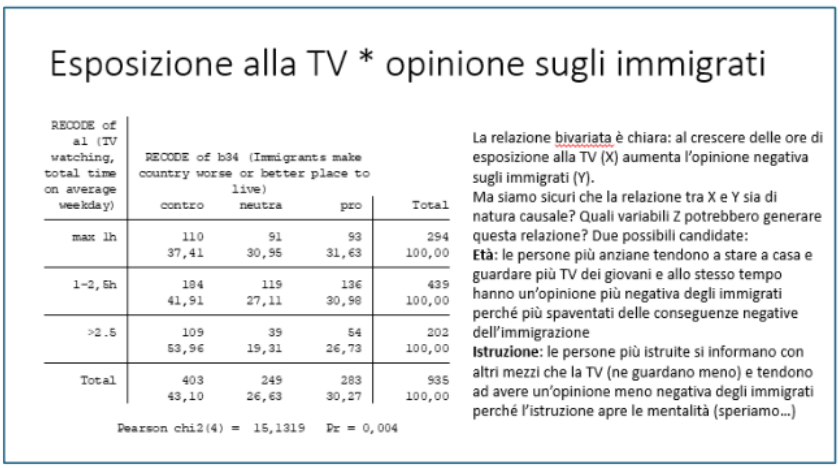
- **Correlazione non significa causalità**: la correlazione tra due variabili (X e Y) è solo il primo passo per studiare una relazione causa-effetto, ma non dimostra che una variabile causa l'altra.
- **Necessità di una terza variabile (Z)**: negli studi osservativi è necessario introdurre una terza variabile, detta "variabile di controllo", per verificare che l'associazione tra X e Y non sia spuria. La variabile Z può influenzare sia X sia Y.

Nei fenomeni sociali il comportamento umano è influenzato da molti fattori. Non basta considerare solo tre variabili, in genere servono molte altre variabili Z per avvicinarsi a un'inferenza causale.

Esempio: TV e opinioni sugli immigrati

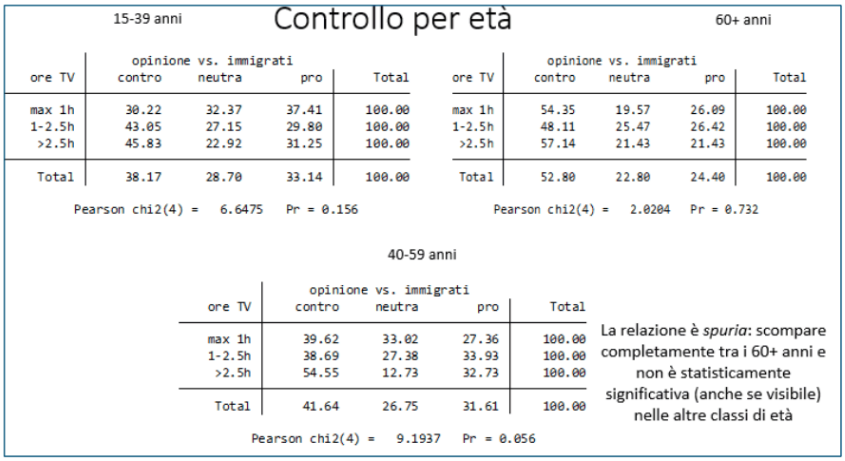
Si ipotizza che l'esposizione alla TV (X) influenzi l'opinione sugli immigrati (Y). Tuttavia, non essendo un esperimento, non si può controllare quanta TV le persone guardano e come formano le loro opinioni.

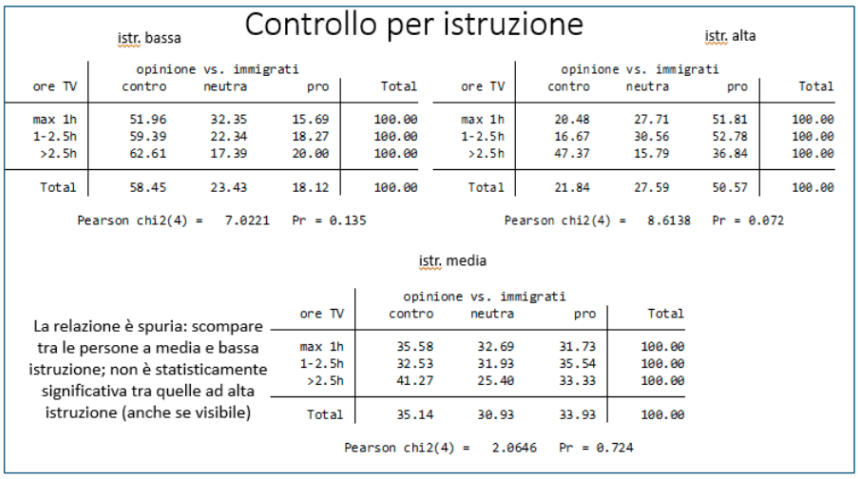
Inoltre l'opinione stessa potrebbe influenzare la scelta di guardare la TV, e questo rende la relazione tra l'esposizione alla TV e l'opinione sugli immigrati ancora più complessa da interpretare, evidenziando la necessità di includere molte variabili per comprendere meglio il fenomeno.



8.2 Controllo della relazione per stratificazione

Qual è lo strumento ideale per l'analisi multivariata? Le tecniche di analisi multivariata, come la regressione, ci permettono di tenere sotto controllo più variabili contemporaneamente.





8.3 Condizioni per il controllo empirico di una relazione causale

Le tre condizioni, la cosiddetta "holy trinity", sono le seguenti.

1. **Correlazione tra X e Y**: X e Y devono essere correlate. Non è necessaria una correlazione perfetta, poiché nelle scienze sociali è improbabile.

2. **Priorità temporale o logica di X su Y**: X, la causa, deve avvenire prima di Y, l'effetto, nel tempo. Possiamo verificarlo osservando il cambiamento nel tempo, con indagini longitudinali o panel, oppure deducendo la sequenza, con indagini trasversali o cross-section.

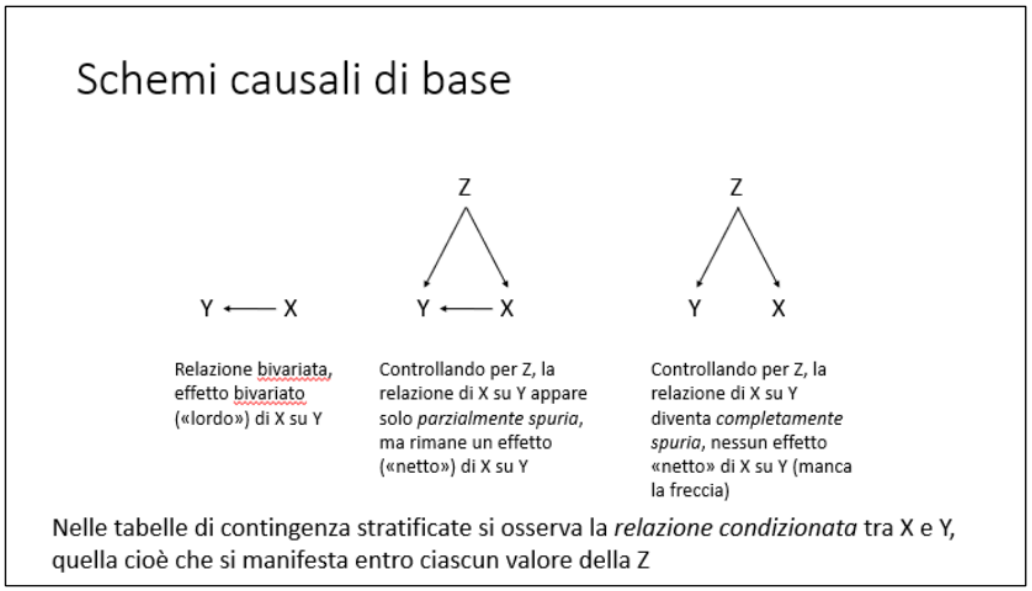
3. **Controllo delle variabili Z**: tutte le variabili Z che influenzano sia X sia Y devono essere sotto controllo. Negli esperimenti questo è ga-

rantito dalla randomizzazione. Negli studi osservativi non è possibile un controllo perfetto, ma si cerca di avvicinarsi misurando il maggior numero possibile di variabili Z rilevanti e usando l'analisi multivariata per il controllo.

8.4 Il linguaggio degli effetti

Relazione spuria e variabili confondenti

Quando la relazione tra X e Y scompare dopo il controllo di una variabile Z, si dice che la relazione era spuria, poiché dipendeva dall'influenza di Z su entrambe. Le variabili Z, dette confondenti, precedono X e Y nel tempo o nella logica.



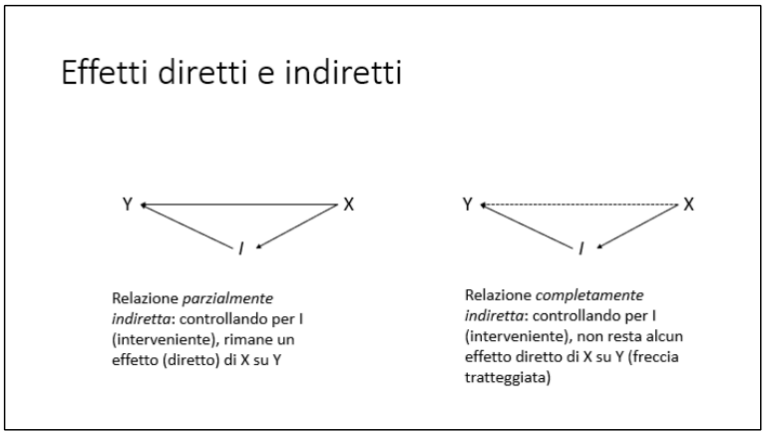
Effetti diretti e indiretti attraverso l'analisi multivariata

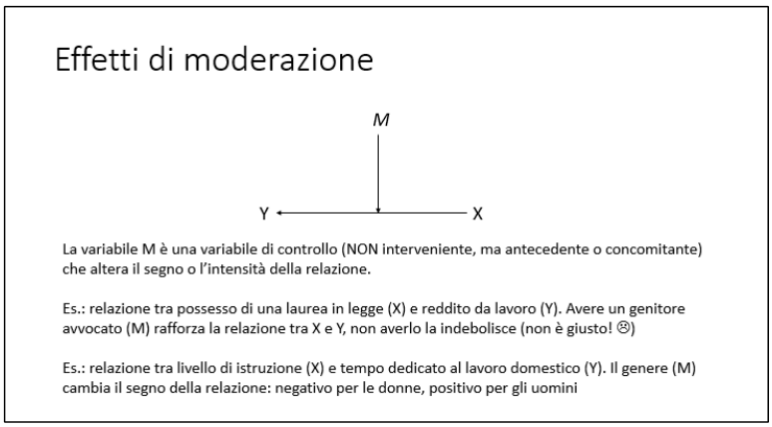
L'analisi multivariata aiuta a individuare quali catene di causazione influenzano la relazione tra X e Y, evidenziando quanto dell'effetto di X su Y sia dovuto all'intervento di variabili intervenienti (I).

- **Effetto indiretto**: se, controllando per la variabile I, la relazione tra X e Y scompare, allora l'effetto di X su Y è completamente mediato da I.

- **Effetto diretto**: se, anche dopo aver controllato per I, rimane un effetto di X su Y, allora si tratta di un effetto diretto, non mediato da I.

Esempio classico: nelle analisi di mobilità sociale l'origine sociale (O) influisce sull'istruzione (E), che a sua volta incide sulla destinazione sociale (D). L'istruzione agisce come variabile interveniente tra origine e destinazione, ma persiste anche un effetto diretto di O su D, legato all'ereditarietà sociale o genetica.





8.5 Variabili di controllo e ordine causale

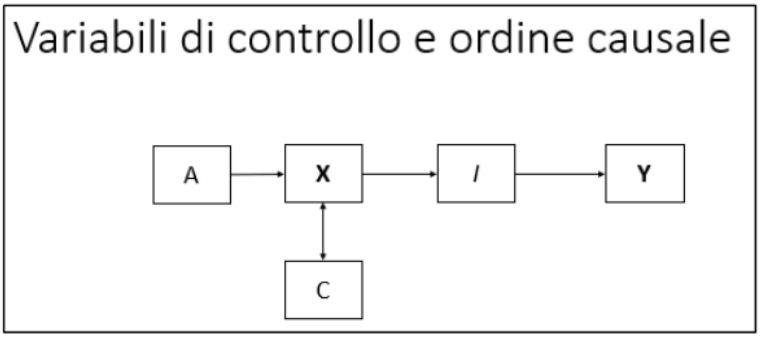
In un'analisi multivariata è importante capire dove si collocano le variabili di controllo rispetto alla relazione tra la variabile principale X e l'effetto Y. Ci sono tre tipi di variabili di controllo.

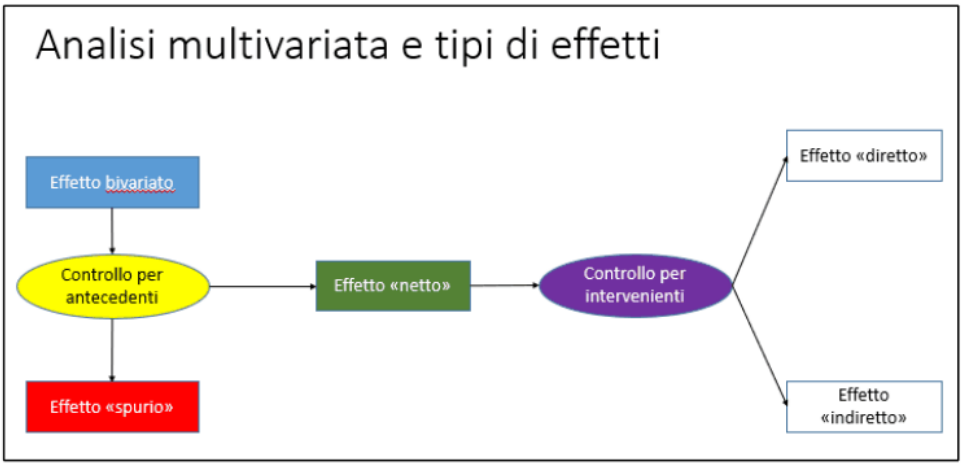
1. **Antecedenti (A)**: queste variabili si presentano prima di X e Y e sono essenziali per stimare l'effetto reale tra X e Y. Vanno sempre incluse

nell'analisi.

2. **Concomitanti (C)**: sono correlate con X, ma non sono né una causa né un effetto di X. Anche queste variabili vanno considerate come le antecedenti. Un esempio: la regione di nascita è una variabile concomitante rispetto all'origine sociale (X) quando si osserva il livello di istruzione (Y).

3. **Intervenienti (I)**: queste variabili si trovano tra X e Y, mediando la loro relazione. Non vanno incluse nell'analisi principale, poiché riducono l'effetto che vogliamo misurare. Si utilizzano solo se si vuole verificare l'esistenza di relazioni dirette o indirette.





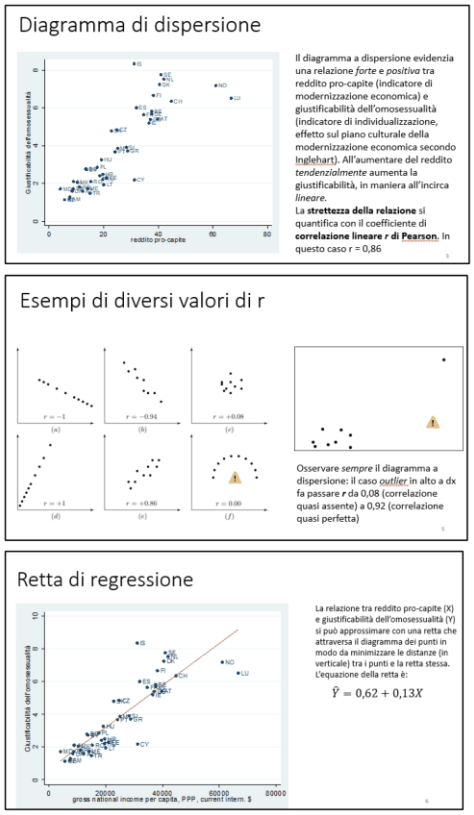
9

La regressione lineare

9.1 Che cos'è la regressione lineare

La regressione lineare è un metodo che ci aiuta a capire la relazione tra due o più variabili.

- **Quando usarla?** La regressione lineare è usata quando la variabile Y può essere misurata, ad esempio l'altezza, il peso, il prezzo di qualcosa.
- **Cosa fa?** La regressione lineare ci permette di stimare il valore medio o previsto di Y basandoci sui valori di una o più variabili X. Queste X possono essere numeri, categorie o posizioni in una scala.
- **Forma della relazione?** Nella forma più semplice la regressione lineare disegna una linea retta che cerca di adattarsi il meglio possibile alla distribuzione dei punti di dati tra Y e X.



9.2 Il significato della retta di regressione

La retta di regressione permette di stimare il rapporto tra due variabili. È definita da due parametri.

1. **Intercetta (alfa)**: rappresenta il valore medio di Y quando X è zero. È un valore teorico, poiché in certi casi, come nel reddito, non esistono realmente paesi con reddito zero.
2. **Coefficiente (beta)**: indica di quanto varia in media Y quando X aumenta di 1 unità. Se è positivo, ogni aumento di X porta a un aumento di Y.

Esempio:

- **Intercetta di 0,62**: significa che, se il reddito pro-capite fosse zero, anche se non è realistico, il valore di "giustificabilità dell'omosessualità" sarebbe 0,62. Questo è un valore teorico, solo per stabilire un punto di partenza sulla linea.

- **Coefficiente di 0,13**: ogni volta che il reddito pro-capite aumenta di 1000 dollari, il livello medio di "giustificabilità" aumenta di 0,13.
- **Aumento costante**: la relazione è lineare, quindi non importa il livello iniziale del reddito, ogni 1000 dollari di aumento nel reddito comporta sempre lo stesso incremento, 0,13, nella giustificabilità.

9.3 Scopi della regressione

La regressione può avere due obiettivi.

- **Predittivo**: serve per prevedere il valore della variabile dipendente (Y) nel modo più accurato possibile.
- **Causale**: serve per stimare l'effetto di una variabile indipendente su Y. La regressione non garantisce una relazione causale, ma solo una stima dell'associazione tra X e Y, considerando le variabili di controllo.

Quando parliamo di regressione lineare multipla?

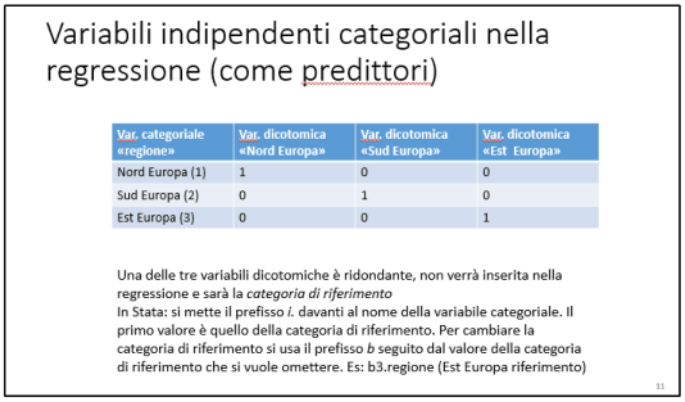
Quando la regressione include più di una variabile indipendente, chiamate anche regressori o predittori, si parla di regressione multipla. In questo caso il modello non rappresenta più una retta, ma un piano o un iperpiano.

9.4 Variabili indipendenti categoriali nella regressione

Nella regressione lineare si possono usare variabili indipendenti di qualsiasi tipo, cardinali, ordinali, categoriali, dicotomiche, mentre Y deve essere cardinale. Per variabili ordinali o categoriali bisogna trasformarle in variabili dicotomiche.

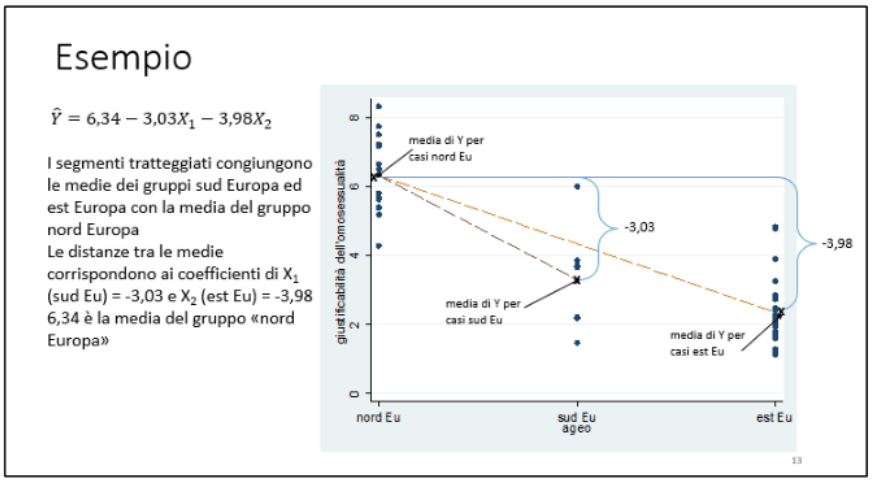
Ad esempio, una variabile categoriale come "regione geografica" con tre categorie, Nord, Sud, Est Europa, può essere trasformata in tre variabili dicotomiche:

- la prima vale 1 per Nord Europa, 0 altrimenti;
- la seconda vale 1 per Sud Europa, 0 altrimenti;
- la terza vale 1 per Est Europa, 0 altrimenti.



Nella regressione si usano solo due delle tre variabili dicotomiche come predittori, la terza è omessa come categoria di riferimento. Ad esempio, se un paese ha valore zero sia per "nord" che per "sud", sarà automaticamente un paese dell'Est Europa.

- Se l'intercetta è 5, significa che il punteggio medio di soddisfazione per chi lavora part-time, la categoria di riferimento, è 5.
- Se il coefficiente per "tempo pieno" è 2, significa che chi lavora a tempo pieno ha, in media, un punteggio di soddisfazione di 2 punti superiore a chi lavora part-time.



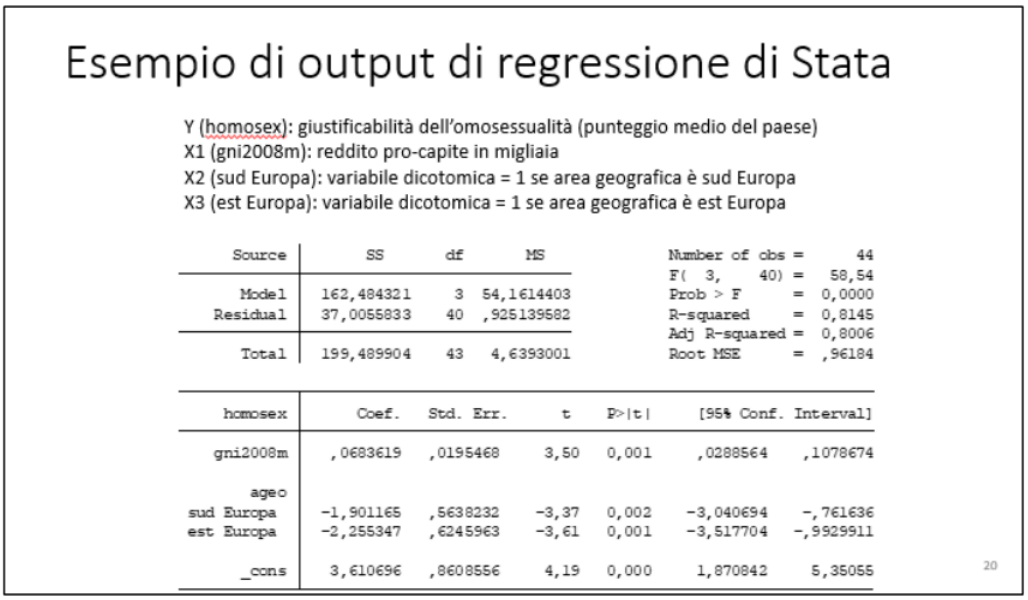
9.5 Inferenza statistica sui coefficienti di regressione

I coefficienti di regressione sono numeri che calcoliamo dai dati di un campione per capire la relazione tra variabili. Tuttavia, se prendiamo un campione

diverso, questi coefficienti possono cambiare, perché ogni gruppo di dati può dare risultati leggermente diversi.

Per verificare se gli effetti non sono casuali analizziamo la distribuzione campionaria dei coefficienti, che è circa normale.

- Possiamo stimare l'errore standard dei coefficienti.
- Con un livello di affidabilità del 95% o 99% possiamo verificare se i coefficienti sono statisticamente significativi, indicando effetti diversi da zero.



Esempio di output di regressione di Stata

Y (homosex): giustificabilità dell'omosessualità (punteggio medio del paese)
X1 (gni2008m): reddito pro-capite in migliaia
X2 (sud Europa): variabile dicotomica = 1 se area geografica è sud Europa
X3 (est Europa): variabile dicotomica = 1 se area geografica è est Europa

Source	SS	df	MS
Model	162,484321	3	54,1614403
Residual	37,0055833	40	,925139582
Total	199,489904	43	4,6393001

Number of obs = 44
F(3, 40) = 58,54
Prob > F = 0,0000
R-squared = 0,8145
Adj R-squared = 0,8006
Root MSE = ,96184

homosex	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
gni2008m	,0683619	,0195468	3,50	0,001	,0288564	,1078674
ageo						
sud Europa	-1,901165	,5638232	-3,37	0,002	-3,040694	-,761636
est Europa	-2,255347	,6245963	-3,61	0,001	-3,517704	-,9929911
_cons	3,610696	,8608556	4,19	0,000	1,870842	5,35055

20

9.6 Come si legge l'output di una regressione

1. **Coefficiente di X1 (reddito)**: ogni aumento di 1000 dollari nel reddito pro-capite aumenta la giustificabilità dell'omosessualità di 0,068 punti, considerando l'area geografica costante.
2. **Coefficiente di X2 (sud Europa)**: nei paesi del sud Europa la giustificabilità media è inferiore di 1,90 punti rispetto al nord Europa, mantenendo il reddito invariato.
3. **Coefficiente di X3 (est Europa)**: nei paesi dell'est Europa la giustificabilità media è inferiore di 2,26 punti rispetto al nord Europa, a parità di reddito.

4. **Intercetta (_cons)**: rappresenta la giustificabilità media dell'omosessualità, 3,61, nei paesi del nord Europa con reddito pari a zero. È un valore teorico, utile come riferimento.
5. **P>|t| (p-value)**: mostra la significatività statistica. Un valore inferiore a 0,05 indica che il coefficiente è significativo, cioè molto probabilmente diverso da zero. Tutti i coefficienti qui sono significativi.
6. **Intervallo di confidenza (95% Conf. Interval)**: indica l'intervallo entro cui il coefficiente si trova con il 95% di certezza. Nessuno degli intervalli comprende lo zero, quindi i coefficienti sono significativi.
7. **R-squared**: indica che l'81% della variabilità nella giustificabilità dell'omosessualità è spiegata dai fattori considerati, reddito e area geografica.
8. **Adjusted R-squared**: un R^2 corretto per il numero di variabili usate, considerando solo quelle effettivamente utili.
9. **Root MSE**: misura l'accuratezza del modello. Più è basso, meglio il modello prevede i dati rispetto alla semplice media.
10. **Confronto tra sud ed est Europa**: per confrontare sud ed est Europa bisogna cambiare la categoria di riferimento, ad esempio usare il sud come riferimento, e rieseguire l'analisi.

Parte II

Laboratorio con Stata

10

Sportello 1

10.1 Come collegare il file dati da do-file su Stata?

Abbiamo due modi per impostare la directory del file dati che useremo.

```
// 1 modo per startare
use "C:\Users\fscre\Desktop\Stata18\DO FILE LABORATORIO\sportello\ESS9_venerdi.dta", clear

//2 modo, corretto
cd "C:\Users\fscre\Desktop\Stata18\DO FILE LABORATORIO\sportello\"
use"ESS9_venerdi", clear
```

10.2 Come analizzare i dati che soddisfano una sola condizione?

```
keep if paese == "AT" //campione relativo all'austria
```

10.3 Come ricodificare una variabile in 5 quintili?

```
/*1.    Ricodificare la variabile reddito e crearne una nuova in 5 categorie con etichette
e l'etichetta di descrizione della variabile (cat 1, 2= I quintile; 3,4=II quintile;
5,6=III quintile; 7,8=IV quintile; 9,10=V quintile) */

describe reddito
tab reddito // diamo una prima occhiata alla variabile reddito

recode reddito (1 / 2 = 1 "I quintile") (3 / 4 = 2 "II quintile") ///
               (5 / 6 = 3 "III quintile") (7 / 8 = 4 "IV quintile" ) ///
               (9 / 10 = 5 "V quintile"), gen (reddito_r)

label variable reddito_r "reddito dei rispondenti" /// assegno etichetta alla variabile

fre reddito_r // osserviamo la distribuzione di frequenza
graph bar, over (reddito_r)
```

10.4 Come visualizzare una tabella di contingenza?

Da sapere: le tabelle di contingenza aiutano a capire come due variabili categoriali sono collegate tra loro, mostrando quante persone appartengono a ciascuna combinazione di categorie.

```
*stiamo ricodificando la variabile reddito in austria, accorpando 1/2 decile nel I
quintile che corrisponde al 20% del reddito... e così via

tab variabile_originale altra_variabile
tab reddito reddito_r // tabella di contingenza
```

Household's total net income, all sources	RECODE of reddito (Household's total net income, all sources)					
	I quintil	II quinti	III quint	IV quinti	V quintil	Total
J - 1st decile	158	0	0	0	0	158
R - 2nd decile	290	0	0	0	0	290
C - 3rd decile	0	250	0	0	0	250
M - 4th decile	0	270	0	0	0	270
F - 5th decile	0	0	255	0	0	255
S - 6th decile	0	0	203	0	0	203
K - 7th decile	0	0	0	233	0	233
P - 8th decile	0	0	0	163	0	163
D - 9th decile	0	0	0	0	145	145
H - 10th decile	0	0	0	0	89	89
Total	448	520	458	396	234	2056

Esempio:

- 158 persone del primo decile e 290 del secondo decile sono state riclassificate come primo quintile;
- 145 del nono decile e 89 del decimo decile sono state classificate come quinto quintile.

10.5 Come si ricodifica creando una variabile dicotomica?

```
/* 2.   Ricodificare la variabile statusocc relativa allo status occupazionale
individuale e crearne una nuova in due categorie con le etichette e l'etichetta di
descrizione della variabile (cat 1=Occupati; dalla cat 2 alla 9=Non occupati) */


describe statusocc
tab statusocc //vediamo come è distribuita la variabile iniziale

recode statusocc (1 = 1 "occupati") (2/9 = 2 "non occupati"), gen (statusocc_r)
label variable statusocc_r "quanti occupati tra i rispondenti"

fre statusocc_r //frequenza della variabile ricodificata
tab statusocc statusocc_r //tabella di contingenza per capire i non occupati che
categorie sono
```

10.6 Come commentare la tabella di contingenza?

```
. tab statusocc statusocc_r

Main activity, last 7 |
          days. All   | quanti occupati tra i
   respondents. Post  |      rispondenti
               coded  |  occupati  non occup |     Total
----------------------+----------------------+----------
           Paid work  |      1312         0  |      1312
           Education  |         0        87  |        87
Unemployed, looking f |         0        53  |        53
Unemployed, not looki |         0        40  |        40
Permanently sick or d |         0        24  |        24
             Retired  |         0       814  |       814
Housework, looking af |         0       150  |       150
               Other  |         0        17  |        17
----------------------+----------------------+----------
               Total  |      1312      1185  |      2497
```

Osservando la tabella che mette in relazione le due variabili sullo status occupazionale dei rispondenti, emerge che una buona percentuale della popolazione è occupata. Tuttavia colpisce l'elevata percentuale di non occupati, composta in gran parte da pensionati. Sociologicamente questo potrebbe indicare una società caratterizzata da un'età media elevata e una bassa natalità.

10.7 Quali sono le statistiche e i grafici più opportuni a seconda del tipo di variabile?

Variabili qualitative, categoriche non misurabili:

- `fre variabile`
- `tab variabile`
- `graph bar, over(variabile)`

Variabili quantitative, numeriche e misurabili:

- `sum variabile, det`
- `hist variabile`
- `graph box variabile`

10.8 Come si commenta una distribuzione di variabile?

politica2 — RECODE of psppipla (Political system allows people to have influence on politics

		Freq.	Percent	Valid	Cum.
Valid	1 Not at all	469	18,77	18,90	18,90
	2 Very little	958	38,34	38,60	57,49
	3 Some	858	34,33	34,57	92,06
	4 A lot	167	6,68	6,73	98,79
	5 A great deal	30	1,20	1,21	100,00
	Total	2482	99,32	100,00	
Missing	.	17	0,68		
Total		2499	100,00		

La variabile analizzata rappresenta una scala a 5 posizioni che misura quanto i sistemi politici permettano ai cittadini di influenzarli. Dalla distribuzione di frequenza emerge che la maggior parte dei rispondenti si colloca nella categoria "Very little", indicando che, secondo loro, la politica è scarsamente influenzata dai cittadini. Tuttavia una quota significativa si posiziona su "Some", suggerendo che una parte dei rispondenti ritiene che i cittadini abbiano un'influenza, seppur moderata.

La vicinanza nelle frequenze tra queste due categorie riflette una percezione condivisa di distanza tra politica e cittadinanza, ma con un certo margine di variazione. Le ragioni di tali differenze potrebbero essere legate a fattori esterni come le aspettative di vita, la situazione economica o le condizioni sociali. Questi dati, tuttavia, restituiscono un quadro generale di una società

in cui la politica e i cittadini appaiono come entità separate, con i cittadini che spesso percepiscono di non essere ascoltati.

```
. fre statusocc_r

statusocc_r — RECODE of statusocc (Main activity, last 7 days. All respondents. Post coded)
```

		Freq.	Percent	Valid	Cum.
Valid	1 occupati	1312	52,50	52,54	52,54
	2 non occupati	1185	47,42	47,46	100,00
	Total	2497	99,92	100,00	
Missing	.b	1	0,04		
	.c	1	0,04		
	Total	2	0,08		
Total		2499	100,00		

La variabile analizzata rappresenta, attraverso due modalità di risposta, il numero di rispondenti occupati e non occupati dal punto di vista lavorativo. La maggioranza si colloca nella categoria "occupati", con poco più del 50% (52,5%). Tuttavia una quota considerevole, pari al 47%, appartiene ai "non occupati". Questa categoria include probabilmente persone pensionate, suggerendo una possibile alta età media della popolazione e, potenzialmente, una bassa natalità, caratteristiche che potrebbero riflettere una società demograficamente matura.

```
. fre reddito_r

reddito_r — reddito dei rispondenti
```

		Freq.	Percent	Valid	Cum.
Valid	1 I quintile	448	17,93	21,79	21,79
	2 II quintile	520	20,81	25,29	47,08
	3 III quintile	458	18,33	22,28	69,36
	4 IV quintile	396	15,85	19,26	88,62
	5 V quintile	234	9,36	11,38	100,00
	Total	2056	82,27	100,00	
Missing	.a	324	12,97		
	.b	119	4,76		
	Total	443	17,73		
Total		2499	100,00		

Sociologicamente la distribuzione evidenzia una moderata disuguaglianza economica, con la maggioranza concentrata nelle fasce medio-basse e pochi nel quintile più alto. Le risposte mancanti potrebbero riflettere riservatezza o disagio nel dichiarare il reddito, indicando possibili tensioni legate alla percezione delle disuguaglianze.

10.9 Come si costruisce un indice informativo?

```
*4. Costruire un indice che ci dia informazioni su quanto i rispondenti credono nella
democrazia (ATTENZIONE: valutare se invertire la polarità semantica di alcuni se non di
tutti gli items). Riportare anche il commento dell'alpha di Crobanch. */


//inveritre polarità se c'è bisogno, esempio:
gen politca1_inv = 6 - politica1

//crea indice
egen indice_democrazia = rowmean (politica1 politica2 politica3)

//alpha di cronbach
alpha politica1 politica2 politica3
```

10.10 Quando invertiamo la polarità?

```
//inveritre polarità se c'è bisogno, esempio:
gen politca1_inv = 6 - politica1
```

Bisogna cambiare la variabile solo se i suoi numeri vanno in una direzione diversa dalle altre.

- Se i numeri alti significano fiducia, lasciala com'è.
- Se i numeri alti significano sfiducia, cambia i numeri per farli significare fiducia.

10.11 Quale formula permette di creare un indice informativo?

```
//crea indice
egen indice_democrazia = rowmean (politica1 politica2 politica3)
```

Creiamo un indice di questo tipo quando vogliamo combinare più variabili, ad esempio politica1, politica2, politica3, in un unico valore che rappresenti la media delle risposte, per analizzare un concetto generale come la fiducia nella democrazia.

10.12 Come si calcola l'alpha di Cronbach?

```
//alpha di cronbach
alpha politica1 politica2 politica3
```

```
//alpha con piu dettagli
alpha politica1 politica2 politica3, it lab
```

Cosa indica?

L'alpha di Cronbach dice se le variabili lavorano bene insieme per indicare la stessa cosa.

- È buono, le variabili sono coerenti, se $\geq 0{,}7$.
- Non è buono, le variabili non sono coerenti, se $< 0{,}7$.

Come si commenta?

```
. alpha politica1 politica2 politica3

Test scale = mean(unstandardized items)

Average interitem covariance:      ,413306
Number of items in the scale:            3
Scale reliability coefficient:      0,7514
```

L'Alpha di 0,7514 indica che le variabili misurano bene la fiducia nella democrazia, mostrando una visione coerente dei rispondenti su fiducia, partecipazione e influenza politica.

Togliendo politica1 l'Alpha salirebbe a 0,7941, quindi politica1 è la variabile meno coerente con le altre.

```
. alpha politica1 politica2 politica3, it lab

Test scale = mean(unstandardized items)

                                Item-test  Item-rest  Interitem
Item          |  Obs  Sign        corr.      corr.       cov.      alpha  Label
--------------+--------------------------------------------------------------------------
politica1     |  2414     +     0,7622     0,4667    ,5288374    0,7941  RECODE of frprtpl (Political
              |                                                          system in country ensures
              |                                                          everyone fair chance to p
politica2     |  2482     +     0,8501     0,6405    ,3463845    0,5876  RECODE of psppipla (Political
              |                                                          system allows people to have
              |                                                          influence on politics
politica3     |  2472     +     0,8454     0,6331    ,3617152    0,6045  RECODE of psppsgva (Political
              |                                                          system allows people to have a
              |                                                          say in what governm
--------------+--------------------------------------------------------------------------
Test scale    |                                     ,413306    0,7514  mean(unstandardized items)
```

Quale schema seguire per commentare in modo ottimale?

Interpretazione sociologica:

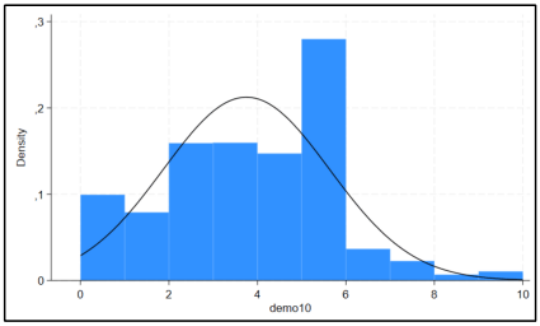
- **Alpha buono**: "Questo riflette che i rispondenti percepiscono [specifica il tema] come un fenomeno unitario, evidenziando una visione condivisa e coerente."
- **Alpha basso**: "Ciò può indicare una frammentazione nelle opinioni dei rispondenti o che le variabili catturano aspetti diversi del fenomeno."

10.13 Come si riscala un indice da 0 a 10?

```
*5. Riscalare l'indice su una scala da 0 a 10, indice che prima era da 1 a 5
gen new= ((variabile - min_val) / (max_val - min_val)) * 10 //formula per riscalare
gen demo10 = ((indice_democrazia - 1) / (5 - 1)) * 10
```

Serve a trasformare l'indice da una scala da 1 a 5 a una scala da 0 a 10, per rendere i risultati più intuitivi o comparabili con altre scale.

Come si commenta?



Notiamo un picco intorno tra 5 e 6, suggerendo che molti rispondenti si collocano in questa fascia e che pochi si collocano verso i valori alti. Sociologicamente notiamo un contesto in cui le persone hanno un'idea intermedia nella misura di fiducia nella democrazia, con pochi che esprimono opinioni estremamente positive o negative.

10.14 Tabella di contingenza per indice e variabile

Le tabelle di contingenza sono un'analisi bivariata perché analizzano la relazione tra due variabili.

```
//tabella di contingenza
tabstat demo10, by (statusocc_r) s (mean med)
```

Come si commenta?

```
. tabstat demo10, by (statusocc_r) s (mean med)

Summary for variables: demo10
Group variable: statusocc_r (RECODE of statusocc (Main activity, last 7 days. All respondents. Post co
> ded))

 statusocc_r |      Mean       p50
-------------+--------------------
    occupati |  3,897358  4,166667
non occupati |    3,58665  3,333333
-------------+--------------------
       Total |  3,750167  4,166667
-------------------------------------
```

Gli occupati hanno una media di 3,897 e una mediana di 4,167, leggermente più alta rispetto ai non occupati, con media 3,587 e mediana 3,333. Gli occupati tendono ad avere una percezione leggermente più alta, positiva, di demo10 rispetto ai non occupati. Questo potrebbe indicare che l'occupazione influisce sulla fiducia o sull'atteggiamento verso il concetto misurato da demo10.

10.15 Un esercizio completo

```
/* PROVA B
1.  Ricodificare la variabile istruzione e crearne una nuova in tre categorie con
etichette e l'etichetta di descrizione della variabile (cat 1 e cat 2=Basso; cat 3 e
cat 4=Medio; dalla cat 5 in poi=Alto) */


fre istruzione //vediamo la distribuzione della variabile di partenza

recode istruzione (1 / 2 = 1 "basso") (3 / 4 = 2 "medio") (5 / 10 = 3 "alto"), gen (
istruzione_r)

label variable istruzione_r "livello istruzione"

fre istruzione_r
```

Ricorda: generare una nuova variabile dopo il recode.

```
/*2.    Ricodificare la variabile eta e crearne una nuova in tre categorie con le
etichette e l'etichetta di descrizione della variabile (dai 15 ai 34 anni=Giovani; da
35 a 59 anni=Mezza età; dai 60 anni in poi=Anziani) */

recode eta (15 / 34 = 1 "giovani") (35 / 59 = 2 "mezza eta") (60 / max = 3 "anziani"),
 gen (eta_r)

label variable eta_r "eta dei rispondenti"

fre eta_r
```

```
/* 3.   Descrivere le distribuzioni delle variabili (societa1 societa2 societa3
societa4, la ricodifica di istruzione, eta) con le statistiche e/o grafici che
ritenete più opportuni (a seconda del tipo di variabile). */

fre societa*
graph bar, over (societa1)
graph bar, over (societa2)
graph bar, over (societa3)
graph bar, over (societa4)

fre istruzione_r
graph bar, over (istruzione_r)

fre eta_r
graph bar, over (eta_r)
```

```
. fre societa1

societa1 — RECODE of sofrdst (Society fair when income and wealth is equally distributed)
```

		Freq.	Percent	Valid	Cum.
Valid	1 Agree strongly	991	13,18	13,39	13,39
	2 Agree	3005	39,95	40,61	54,00
	3 Neither agree not disagree	1473	19,59	19,91	73,91
	4 Disagree	1475	19,61	19,93	93,84
	5 Disagree strongly	456	6,06	6,16	100,00
	Total	7400	98,39	100,00	
Missing	.	121	1,61		
Total		7521	100,00		

```
*/4.    Costruire un indice che ci dia informazioni su quanto i rispondenti sono
orientati verso una società equa in termini di opportunità e risorse (ATTENZIONE:
valutare se invertire la polarità semantica di alcuni se non di tutti gli items).
Riportare anche il commento dell'alpha di Crobanch. */

//polarità invertita
gen societa4_inv = 6 - societa4

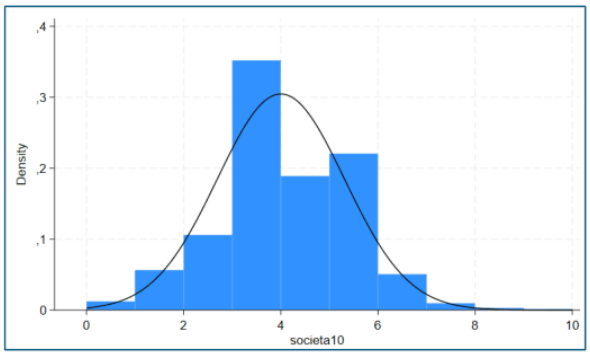
//indice
egen ind_societa_equa = rowmean (societa1 societa2 societa3 societa4)

//alpha
alpha societa*
alpha societa*, it lab
```

Commento. La variabile analizzata ci mostra come la maggior parte delle persone ritenga che una società sia equa quando ricchezza e reddito sono equamente distribuite. Più del 54% dei rispondenti concorda con "agree" e "agree strongly", indicando che l'uguaglianza economica sia fondamentale per una società equa. Tuttavia una minoranza (19,93%) non è d'accordo con questa opinione, probabilmente influenzata da altri fattori quali ideologie o contesti economici.

```
*/5.    Riscalare l'indice su una scala da 0 a 10*/
gen societa10 = ((ind_societa_equa - 1) / (5 - 1)) * 10

*/6.    Descrivere la distribuzione dell'indice con le statistiche e/o grafici che
ritenete più opportuni */
hist societa10, normal w(1)
```



Commento. Il grafico mostra che la maggior parte dei rispondenti si trova sui valori centrali, indicando posizioni moderate sulla società equa, la normale sovrapposta mostra deviazioni limitate rispetto a quella che è la distribuzione reale della variabile. Tuttavia esistono alcune osservazioni che riguardano valori più estremi, che potrebbero essere influenzati da altri fattori, quali contesto, reddito o genere.

```
*/7.    Mostrare come varia la media dell'indice al variare del livello di istruzione
(ricodificata), l'età (ricodificata) e genere. Commentare e considerare anche la
deviazione standard. Interpretare: esiste una relazione tra le due variabili? */

tabstat societa10, by (istruzione_r) s (mean sd)
tabstat societa10, by (eta_r) s (mean sd)
tabstat societa10, by (genere) s (mean sd)
```

Ricorda: `sd` indica la deviazione standard.

eta_r	Mean	SD
giovani	4,008641	1,278409
mezza eta	4,006673	1,318764
anziani	3,991727	1,318912
Total	4,001893	1,309412

Commento. La tabella mostra che le medie sulla percezione di una società equa sono molto simili tra gruppi di età: i giovani e le persone di mezza età hanno medie leggermente più alte rispetto agli anziani. La deviazione standard è uniforme tra i gruppi, indicando una variabilità simile tra le risposte. Questi dati suggeriscono che l'età non influenza in modo significativo le percezioni di una società equa.

Summary for variables: societa10
Group variable: genere (Gender)

genere	Mean	SD
Male	4,009271	1,297887
Female	3,995305	1,319569
Total	4,001754	1,309534

Commento. La tabella mostra che le medie sulla percezione di una società equa sono molto simili tra generi: i maschi hanno una media leggermente più alta rispetto alle femmine. La deviazione standard è uniforme tra gruppi, indicando una variabilità molto simile tra le risposte. Questi dati suggeriscono che la differenza di genere non è significativa nella percezione di una società equa.

11

Sportello 2

11.1 Che differenza c'è tra variabili dipendenti e indipendenti?

Le indipendenti sono le cause, mentre le dipendenti sono gli effetti.

- **Variabili indipendenti**: sono i fattori che spiegano un fenomeno, ad esempio istruzione, genere, reddito.
- **Variabili dipendenti**: sono quelle che subiscono l'influenza delle indipendenti, ad esempio l'atteggiamento verso la disuguaglianza.

11.2 Come si ricodifica e si crea una nuova variabile?

```
* ESERCIZIO 1 - esercizio di ricodifica e creazione di una nuova variabile

*ricodificare la variabile istruzione in tre categorie 1 Basso (modalità 1-2) 2 Medio
(modalità 3-4) 3 Alto (modalità 5 in poi)

recode istruzione (1 / 2 = 1 "basso") (3 / 4 = 2 "medio") ///
                  (5 / max = 3 "alto"), gen (istruzione_cat)

tab istruzione_cat

*ricodificare la variabile reddito da 10 decili a 5 quintili I quintile (modalità 1-2)
II quintile (modalità 3-4) III quintile (modalità 5-6) IV quintile (modalità 7-8) V
quintile (9-10)
recode reddito (1 / 2 = 1 "I quintile") (3 / 4 = 2 "II quintile") ///
               (5 / 6 = 3 "III quintile") (7 / 8 = 4 "IV quintile") ///
               (9 10 = 5 "V quintile"), gen (reddito_cat)

tab reddito_cat

*ricodificare la variabile età in tre modalità Giovani (18-34) Mezza età (35-59)
Anziani (>=60)
recode eta (15 / 34 = 1 "giovani") (35 / 59 = 2 "mezza età") ///
           (60 / max = 3 "anziani"), gen (eta_catt)
tab eta_catt


*ricodificare la variabile statusocc in due modalità (cat 1=Occupati; dalla cat 2 alla
9=Non occupati)
recode statusocc (1 = 1 "occupati") (2 / 9 = 2 "non occupati"), gen (statusocc_catt)
tab (statusocc_catt)
```

11.3 Come e quando invertire la polarità di un item?

Invertiamo la polarità quando una variabile segue un verso opposto rispetto a ciò che stiamo misurando. Quale item invertire dipende dal nostro obiettivo di ricerca, un esempio può essere pro uguaglianza o pro disuguaglianza.

```
. fre diff_reddito diff_condizioni

diff_reddito — Large differences in income acceptable to reward talents and efforts
```

		Freq.	Percent	Valid	Cum.
Valid	1 Agree	657	25,02	25,77	25,77
	2 Agree strongly	76	2,89	2,98	28,76
	3 Disagree	787	29,97	30,87	59,63
	4 Disagree strongly	373	14,20	14,63	74,26
	5 Neither agree nor disagree	656	24,98	25,74	100,00
	Total	2549	97,07	100,00	
Missing	.	77	2,93		
Total		2626	100,00		

```
diff_condizioni — For fair society, differences in standard of living should be small
```

		Freq.	Percent	Valid	Cum.
Valid	1 Agree	1297	49,39	50,60	50,60
	2 Agree strongly	445	16,95	17,36	67,97
	3 Disagree	223	8,49	8,70	76,67
	4 Disagree strongly	40	1,52	1,56	78,23
	5 Neither agree nor disagree	558	21,25	21,77	100,00
	Total	2563	97,60	100,00	
Missing	.	63	2,40		
Total		2626	100,00		

```
fre diff_reddito diff_condizioni
// cosa scelgo? pro uguaglianza o pro disuguaglianza?
//pro uguaglianza
// inverto polarità di diff_reddito
gen diff_reddito_inv = 6 - diff_reddito
```

11.4 Come e perché calcolare l'alpha di Cronbach?

L'alpha lo calcoliamo per verificare se le nostre variabili lavorano bene insieme per indicare un concetto, ci misura la coerenza interna.

- $\geq 0{,}7$ coerenza;
- $< 0{,}7$ bassa coerenza.

```
*calcolare e commentare alpha di Cronbach
alpha diff_reddito_inv diff_condizioni
```

```
Average interitem covariance:      ,169701
Number of items in the scale:           2
Scale reliability coefficient:     0,1328
```

Commento. L'alpha di Cronbach (0,132) è molto basso, indicando che le due variabili hanno una correlazione debole nel misurare lo stesso concetto in modo coerente. I due item sembrano quindi riflettere due condizioni di disuguaglianza differenti.

11.5 Come creare un indice sommativo o informativo?

```
egen new = rowmean(v1 v2 vn)
```

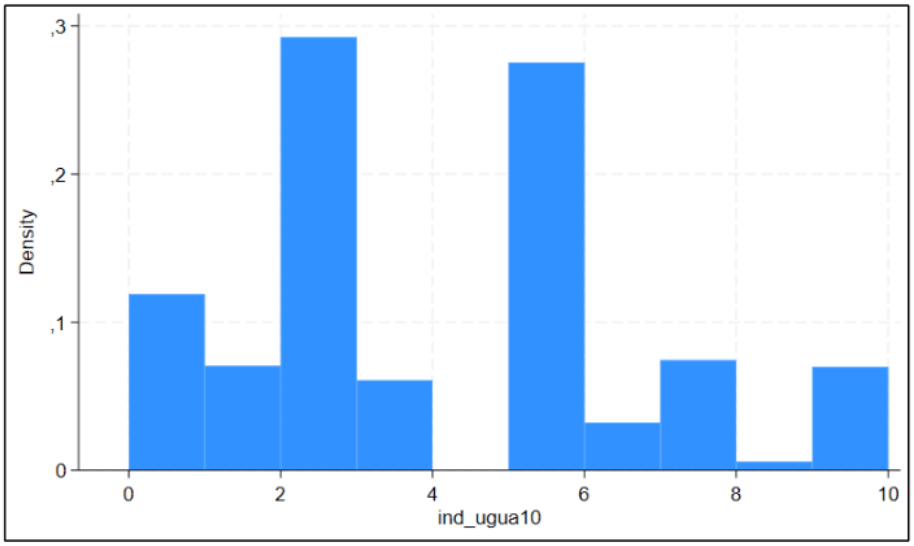
```
*creare indice sommativo / informativo
egen ind_ugua = rowmean (diff_reddito_inv diff_condizioni)
```

11.6 Come riscalare l'indice da 0 a 10?

```
gen new = ((variabile - min) / (max - min)) * 10
```

```
*riscalare l'indice su una scala da 0 a 10
gen ind_ugua10 = ((ind_ugua - 1) / (5 - 1)) * 10
```

11.7 Come descrivere la distribuzione dell'indice riscalato?



Commento. Le risposte sono distribuite principalmente su pochi valori, soprattutto intorno a 2 e 6, questo suggerisce che le opinioni sulle disuguaglianze tendono a polarizzarsi con gruppi di persone che hanno visioni simili. Questa divisione potrebbe essere influenzata da altri fattori come reddito, istruzione, genere, ideologie.

Importante: l'analisi di questa distribuzione aiuta a comprendere come si articolano le risposte e se emergono polarizzazioni o consenso su un determinato tema.

11.8 Come fare un'analisi bivariata?

```
*mostrare come varia la media dell'indice al variare del livello di istruzione
ricodificato, l'età ricodificato, genere e nascita all'estero

tabstat ind_ugua10, by (istruzione_cat) s (mean sd)
tabstat ind_ugua10, by (genere) s (mean sd)
```

```
. tabstat ind_ugua10, by (istruzione_cat) s (mean sd)

Summary for variables: ind_ugua10
Group variable: istruzione_cat (RECODE of istruzione)

istruzione_cat |      Mean        SD
---------------+--------------------
         basso |  3,805291  2,555998
         medio |  3,860294  2,685058
          alto |  4,617834   2,88616
---------------+--------------------
         Total |  3,928571  2,665212
```

Commento. I dati mostrano che l'istruzione influisce sull'indice, la media aumenta all'aumentare del livello di istruzione. La variabilità nelle risposte è simile con deviazione standard intorno ai 2,6. Sociologicamente questi dati mostrano come l'istruzione influenza la percezione della disuguaglianza, mostrando che chi ha più alta istruzione potrebbe essere più attento alle dinamiche sociali.

```
. tabstat ind_ugua10, by (genere) s (mean sd)

Summary for variables: ind_ugua10
Group variable: genere (Gender)

   genere |      Mean        SD
----------+--------------------
     Male |  3,939635  2,646264
   Female |  3,921958   2,67737
----------+--------------------
    Total |  3,930577  2,661747
```

Commento. I dati mostrano che il genere non influisce significativamente sull'indice ind_ugua10, poiché uomini e donne hanno opinioni molto simili. Anche la variabilità è quasi identica, indicando che il genere non è un fattore rilevante per spiegare la percezione della disuguaglianza. Questo potrebbe indicare che la sensibilità verso il tema della disuguaglianza dipende più da altri fattori, come istruzione o status socio-economico, piuttosto che dal genere.

11.9 Come si valuta l'associazione tra indice e variabili indipendenti?

L'analisi bivariata studia la relazione tra due variabili.

```
* ESERCIZIO 5- analisi bivariata - tabelle di contingenza

*ricodificare l'indice in tre o quattro modalità a partire dalla distribuzione
dell'indice

fre ind_ugua10

gen ind_ugua10_r = .
replace ind_ugua10_r = 1 if ind_ugua10 >= 0 & ind_ugua10 < 3
replace ind_ugua10_r = 2 if ind_ugua10 >= 3 & ind_ugua10 < 6
replace ind_ugua10_r = 3 if ind_ugua10 >= 6 & ind_ugua10 <= 10

label define ind_lbl 1 "basso" 2 "medio" 3 "alto"
label values ind_ugua10_r ind_lbl
tab ind_ugua10_r

tab ind_ugua10 ind_ugua10_r

*incrociare l'indice ricodificato in una tabella di contingenza con tutte le
variabili indipendenti elencate sopra e ricodificate
tab ind_ugua10_r istruzione_cat
tab ind_ugua10_r genere
tab ind_ugua10_r eta_catt
tab ind_ugua10_r statusocc_catt
```

- **Test del chi-quadro**

- Un χ^2 **alto senza significatività (p > 0.05)** può indicare **problemi nei dati** (campione piccolo, celle con frequenze basse).
- Un χ^2 **basso con significatività (p < 0.05)** può avvenire con **campioni molto grandi**, dove anche differenze minime diventano significative.

- **Pr (p-value)**. Come si interpreta? Se $< 0{,}05$ allora la relazione è significativa.
- **Gamma**. Quando usarlo? Se entrambe sono ordinali, come istruzione ed età. Come si interpreta? Positivo indica relazione diretta, negativo inversa, 0 nessuna relazione.
- **V di Cramér**. Quando usarlo? Se almeno una variabile è nominale, come genere o lavoro. Come si interpreta? 0 nessuna associazione, 1 forte associazione.

11.10 Come commentare i risultati di un'analisi bivariata?

```
. tab ind_ugua10_r istruzione_cat, chi gamma  //gamma: entrambe ordinali

ind_ugua10 |       RECODE of istruzione
        _r |     basso      medio       alto |     Total
-----------+---------------------------------+----------
     basso |       581        532        120 |      1233
     medio |       394        354        108 |       856
      alto |       178        202         86 |       466
-----------+---------------------------------+----------
     Total |      1153       1088        314 |      2555

          Pearson chi2(4) =  27,7066   Pr = 0,000
                    gamma =   0,1135  ASE = 0,029
```

Commento. L'analisi mostra che l'istruzione influisce sulla percezione della disuguaglianza, esiste una relazione significativa non casuale, lo vediamo dal chi2 = 27 e il pr = 0. Tuttavia l'associazione diretta è debole (gamma 0,11), suggerendo che l'istruzione ha influenza ma non è il fattore principale. Altri aspetti, come il reddito o il contesto sociale, potrebbero essere più determinanti.

```
. tab ind_ugua10_r genere, chi V //v: genere è nominale

ind_ugua10 |       Gender
        _r |      Male     Female |     Total
-----------+----------------------+----------
     basso |       606        638 |      1244
     medio |       413        455 |       868
      alto |       240        230 |       470
-----------+----------------------+----------
     Total |      1259       1323 |      2582

          Pearson chi2(2) =   1,4827   Pr = 0,476
               Cramér's V =   0,0240
```

Commento. L'analisi mostra che il genere non influisce in modo significativo sulla percezione delle disuguaglianze (chi2 = 1,4; pr = 0,47). Inoltre il valore del V di Cramér indica che la relazione fra le due variabili è molto debole, suggerendo che il genere non è un fattore determinante per studiare

la percezione delle disuguaglianze. Altri aspetti, come il reddito o il contesto sociale, potrebbero essere più determinanti.

```
. tab ind_ugua10_r eta_catt, chi gamma // gamma: entrambe ordinali
```

ind_ugua10_r	RECODE of eta (Age of respondent, calculated)			Total
	giovani	mezza età	anziani	
basso	310	533	395	1238
medio	218	380	266	864
alto	142	212	114	468
Total	670	1125	775	2570

Pearson chi2(4) = 11,0037 Pr = 0,027
gamma = -0,0733 ASE = 0,028

Commento. L'analisi bivariata mostra l'influenza non casuale che l'età ha sulla percezione dell'uguaglianza. La relazione non è estremamente significativa considerando il valore del chi2 e del pr. Inoltre il gamma negativo suggerisce la presenza di una relazione inversa fra le due variabili e non molto forte. Altri aspetti, come il reddito o il contesto sociale, potrebbero essere più determinanti.

```
. tab ind_ugua10_r statusocc_catt, chi V //v: status è nominale
```

ind_ugua10_r	RECODE of statusocc (Main activity, last 7 days. All respondents. Post coded)		Total
	occupati	non occup	
basso	572	664	1236
medio	410	451	861
alto	239	228	467
Total	1221	1343	2564

Pearson chi2(2) = 3,2618 Pr = 0,196
Cramér's V = 0,0357

Commento. L'analisi bivariata mostra che lo status occupazionale non ha

un'influenza significativa sulla percezione delle disuguaglianze. Il p-value alto (Pr = 0,196) indica che la relazione non è statisticamente significativa, e il V di Cramér molto basso (0,0357) conferma che l'associazione è quasi inesistente. Questo suggerisce che lo status lavorativo non è un fattore rilevante per spiegare la percezione della disuguaglianza, e che sarebbe più utile analizzare altri elementi, come reddito o istruzione.

12

La regressione in Stata

12.1 A cosa serve la regressione lineare?

Si usa la regressione lineare quando vuoi capire se due cose sono collegate e prevedere un valore. Il modello di regressione stima la relazione tra una variabile dipendente e una o più variabili indipendenti, identificando come i cambiamenti nelle variabili indipendenti influenzano la variabile dipendente.

12.2 Quali sono i comandi per la regressione lineare su Stata?

```
//istruzione per eseguire una regressione lineare
reg variabileY i.categorialeX
reg variabileY c.numericaX
```

- **y (dipendente)**: la variabile che vuoi prevedere o spiegare.
- **x (indipendente)**: la variabile che pensi influenzi y.

Cosa chiedersi per capire di che tipo è la variabile?

"Questa variabile rappresenta categorie distinte o numeri continui?"

È obbligatoria la `i.` davanti alla variabile categorica, altrimenti Stata la tratta come variabile numerica.

12.3 Cosa interpretiamo dell'output?

Coefficiente

Indica l'effetto della variabile indipendente su quella dipendente.

- Il segno +: x fa aumentare y.

- Il segno $-$: x fa diminuire y.

P-value

Indica se il coefficiente è statisticamente significativo, se è $< 0{,}05$ è significativo.

R-squared

Indica quanto il modello spiega bene Y, la variabile dipendente. Un valore molto basso come 0,1 significa che solo lo 0,1 di variazione della dipendente è causata dalla indipendente.

- Vicino a 1: il modello spiega quasi tutta la variabile y.
- Vicino a 0: il modello spiega nulla o poco di y.

Intervallo di confidenza

È un range, se include lo 0 suggerisce la non significatività.

- Non include lo 0: effetto significativo.
- È stretto: la stima è precisa.
- Troppo ampio: stima poco affidabile anche se non include lo 0.

12.4 Esercizio sulla regressione lineare

```
*considerare come Y la v39 (soddisfazione per la propria vita)
**individuare almeno 4 buoni predittori
**considerare come X principale: reddito familiare (v261). Individuare almeno 4 variabili di
controllo (antecedenti/concomitanti)
**da inserire per provare a stimare effetto causale del reddito familiare sulla soddisfazione
di vita
**come varia l'effetto del reddito con/senza le variabili di controllo?


la Y, la variabile dipendente è la soddisafazione della vita --> v39
la X, la variabile indie, è il reddito, v261

reg v39 v261
```

```
. reg v39 v261
```

Source	SS	df	MS		
Model	462,083626	1	462,083626	Number of obs	= 1.630
				F(1, 1628)	= 149,14
Residual	5044,17956	1.628	3,0983904	Prob > F	= 0,0000
				R-squared	= 0,0839
				Adj R-squared	= 0,0834
Total	5506,26319	1.629	3,38014929	Root MSE	= 1,7602

v39	Coefficient	Std. err.	t	P>|t|	[95% conf.	interval]
v261	,2190861	,01794	12,21	0,000	,1838982	,254274
_cons	6,250352	,0933428	66,96	0,000	6,067267	6,433436

Commento. Il modello mostra che il reddito ha un effetto positivo sulla soddisfazione per la vita: più reddito è associato a più soddisfazione. Tuttavia spiega solo una piccola parte della variabilità, quindi altri fattori come salute e relazioni sociali sono probabilmente più importanti. La relazione è significativa, ma non possiamo dire che il reddito "causa" la soddisfazione, perché la regressione mostra solo una correlazione.

Il modello analizza la relazione tra **soddisfazione per la vita** (`v39`) e **reddito familiare** (`v261`).

- $R^2 = 0.0839$ → Il reddito spiega solo **l'8,39%** della variabilità della soddisfazione, quindi ha un impatto limitato.
- **P-value = 0.000** → La relazione è **statisticamente significativa**, quindi il legame tra reddito e soddisfazione non è dovuto al caso.
- **Coefficiente = 0.219** → Indica che **un aumento del reddito è associato a un aumento della soddisfazione**.
- **Intervallo di confidenza [0.1839 ; 0.2543]** → Non include **0**, confermando che l'effetto è significativo.

📌 **Conclusione**: il reddito è legato alla soddisfazione, ma spiega solo una piccola parte della sua variabilità. **Altri fattori, come salute e relazioni sociali, possono avere un ruolo più importante**. Inoltre, la regressione mostra **correlazione, non causalità**.

12.5 La regressione multipla

Quali sono le istruzioni per eseguirla su Stata?

```
//istruzione per la regressione multipla
reg Y X1 X2 X3
reg Y i.X1 i.X2 i.X3 //categoriale
```

Dove:

- Y = Variabile dipendente (**ciò che vuoi spiegare**).
- $X1, X2, X3, X4$ = Variabili indipendenti (**predittori, incluse le variabili di controllo**).

Cosa commentare?

1. **R-squared**: controlla la qualità generale del modello, per capire quanta parte di variabilità riesce a spiegare il modello.
2. **Coefficienti**: negativi o positivi, influenzano la Y in quella direzione.
3. **P-value**: se $< 0{,}05$ è significativo.
4. **Intervallo**: se include lo 0, effetto non significativo.

Quale variabile di controllo è più significativa?

La variabile migliore è quella con coefficiente più alto in valore assoluto e p-value $< 0{,}05$, quindi significativa.

12.6 Come si commenta una regressione multipla?

```
reg gov_ind i.genere i.reddito5 occupazione
```

Source	SS	df	MS		
Model	81.3590062	6	13.5598344	Number of obs	= 1,506
Residual	5314.64754	1,499	3.545462	F(6, 1499)	= 3.82
				Prob > F	= 0.0009
Total	5396.00655	1,505	3.58538641	R-squared	= 0.0151
				Adj R-squared	= 0.0111
				Root MSE	= 1.8829

gov_ind	Coefficient	Std. err.	t	P>|t|	[95% conf.	interval]
genere						
Female	.1584069	.0983784	1.61	0.108	-.034567	.3513809
reddito5						
II quintile	-.344741	.1447995	-2.38	0.017	-.6287721	-.06071
II quintile	-.2854039	.1424664	-2.00	0.045	-.5648586	-.0059492
IV quintile	-.3651397	.1580346	-2.31	0.021	-.6751321	-.0551473
V quintile	-.4613991	.2138901	-2.16	0.031	-.8809547	-.0418435
occupazione	-.2429444	.1021236	-2.38	0.017	-.4432648	-.042624
_cons	8.056575	.1274842	63.20	0.000	7.806509	8.306641

Commento. Il modello mostra che la fiducia nel governo è influenzata principalmente dal reddito, con effetto negativo: chi ha più reddito tende ad avere meno fiducia. Questo è molto evidente nel quintile più alto, che ha il coefficiente più forte ($-0{,}4613$), è statisticamente significativo ($p < 0{,}05$) e l'intervallo di confidenza non include lo 0. Anche l'occupazione ha un impatto negativo e significativo, mentre il genere non ha effetto rilevante. Tuttavia il modello spiega solo l'1,51% della variabilità della fiducia nel governo ($r^2 = 0{,}0151$), suggerendo che ci sono molti altri fattori importanti che non sono considerati.

12.7 Guida per commentare una regressione multipla

1. **Il modello in generale spiega bene Y?** Si guarda l'R-squared. "Il modello è significativo o non significativo e spiega X% della variabilità di Y."
2. **Variabile più importante?** Chi ha coefficiente più alto? Positivo o negativo? Qual è il p-value? "La variabile X ha il maggiore impatto su Y, con un effetto positivo o negativo e significativo."
3. **Ci sono altre variabili significative?**
4. **Ci sono variabili mancanti?** "Il modello potrebbe essere migliorato includendo variabili come A e B."

5. **Come concludere?** “Il modello mostra che X è la variabile più influente, seguita da Y. Tuttavia spiega solo X% della variabilità di Y, quindi servono altre variabili per migliorarlo.”

13

Schemi di commento

13.1 Commentare le variabili indipendenti

Come commentare una variabile indipendente?

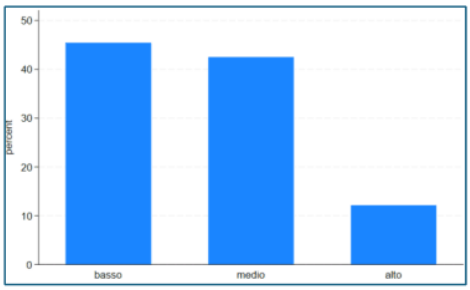
Guida sintetica per commentare grafici e tabelle

1. **Descrizione generale**: Spiega cosa rappresenta il grafico/tabella e quali categorie sono analizzate.
2. **Dati rilevanti**: Evidenzia le differenze principali tra le categorie, sottolineando i valori più alti e più bassi.
3. **Interpretazione sociologica**: Collega i dati a possibili cause sociali, economiche o culturali e alle loro conseguenze.
4. **Conclusione**: Riassumi il punto chiave e le implicazioni generali.

Commento della ricodifica di istruzione in 3 categorie

```
. tab istruzione1
```

livello di istruzione	Freq.	Percent	Cum.
basso	1180	45,40	45,40
medio	1104	42,48	87,88
alto	315	12,12	100,00
Total	2599	100,00	



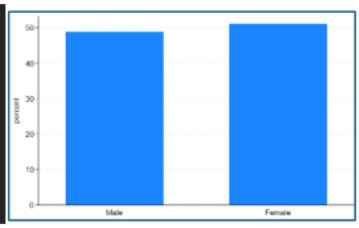
Il grafico e la tabella mostrano una distribuzione del livello di istruzione fortemente sbilanciata verso i livelli più bassi. Solo il 12% ha raggiunto un livello di studi superiore. Sociologicamente questo potrebbe dipendere da difficoltà economiche, opportunità mancate o dal fatto che molte persone smetto-

no di studiare per iniziare a lavorare. Questo ovviamente può influenzare opportunità di lavoro e benessere sociale.

Commento della variabile genere

genere — Gender

		Freq.	Percent	Valid	Cum.
Valid	1 Male	1283	48,86	48,86	48,86
	2 Female	1343	51,14	51,14	100,00
	Total	2626	100,00	100,00	

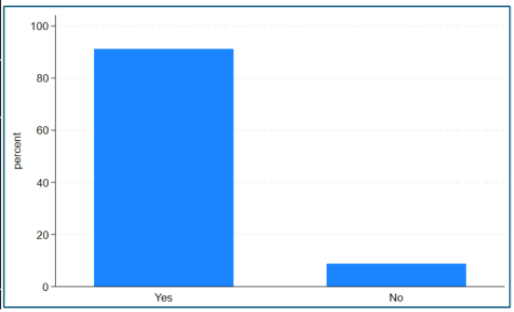


Il grafico e la tabella mostrano la distribuzione del genere nel campione analizzato. La suddivisione è quasi equa, con una leggera prevalenza della categoria "Female" (51,14%) rispetto alla categoria "Male" (48,86%). La differenza è minima e non sembra indicare uno squilibrio significativo. Sociologicamente questo suggerisce che il campione potrebbe essere stato selezionato con l'intento di garantire una rappresentanza bilanciata tra generi, evitando distorsioni nei risultati dell'analisi.

Commento della variabile nascita

nascita — Born in country

		Freq.	Percent
Valid	1 Yes	2392	91,09
	2 No	231	8,80
	Total	2623	99,89
Missing	.a	3	0,11
Total		2626	100,00



Il grafico e la tabella mostrano la distribuzione delle risposte sulla nascita nel paese di riferimento. La maggior parte dei rispondenti (91%) è nata nel paese, mentre solo l'8% dichiara di essere nata altrove. Questo dato suggerisce una presenza limitata di persone immigrate nel campione analizzato. Sociologicamente potrebbe indicare un contesto con bassa immigrazione e un'analisi che non intendeva creare un campione rappresentativo della parte migrante. Tuttavia, per comprendere meglio il fenomeno, sarebbe utile incrociare questi dati con variabili come l'età, il livello di istruzione o il reddito.

13.2 Commentare le variabili dipendenti

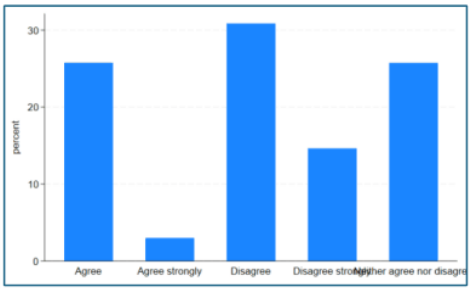
Come si commenta una variabile dipendente?

1. **Dì di cosa parla la variabile**
   - Spiega brevemente il tema della domanda e cosa si vuole indagare.
   - Esempio: "*Questa variabile misura l'opinione delle persone sulle differenze di reddito come ricompensa per talento e impegno.*"
2. **Descrivi i dati principali**
   - Indica quali categorie hanno le frequenze più alte e più basse.
   - Nota se c'è equilibrio o una tendenza prevalente.
   - Esempio: "*La maggior parte delle persone è in disaccordo (30%), ma una quota simile è d'accordo (25%), mentre il 25% si mantiene neutrale.*"
3. **Dai un'interpretazione sociologica**
   - Spiega perché potrebbe esserci questa distribuzione.
   - Collega i risultati a fattori sociali, economici o culturali.
   - Esempio: "*Questo suggerisce che l'opinione pubblica è divisa, probabilmente influenzata da esperienze personali, posizione sociale o livello di reddito.*"
4. **Concludi con una riflessione sintetica**
   - Riassumi il punto chiave e suggerisci possibili approfondimenti.
   - Esempio: "*Il dato mostra che non c'è un'opinione dominante e che altri fattori potrebbero spiegare meglio queste differenze di pe zione.*"

Commento della variabile dipendente diff_reddito in 5 categorie

diff_reddito — Large differences in income acceptable to reward

		Freq.	Percent
Valid	1 Agree	657	25,02
	2 Agree strongly	76	2,89
	3 Disagree	787	29,97
	4 Disagree strongly	373	14,20
	5 Neither agree nor disagree	656	24,98
	Total	2549	97,07
Missing	.	77	2,93
Total		2626	100,00



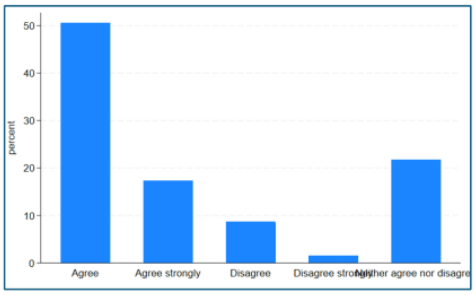
Il grafico e la tabella mostrano la distribuzione delle risposte sulla percezione delle differenze di reddito come ricompensa per talento e impegno. La maggior parte dei rispondenti rientra nella categoria "Disagree" (29,97%),

ma una quota significativa (25,02%) concorda con questa idea, con una differenza di soli cinque punti percentuali. Inoltre una parte considerevole del campione (24,98%) si astiene, scegliendo la posizione neutrale. Sociologicamente si evidenziano due correnti di pensiero opposte, il che suggerisce che questa percezione potrebbe essere influenzata da fattori socio-economici o culturali.

Commento della variabile dipendente diff_condizioni

diff_condizioni — For fair society, differences in standard of

		Freq.	Percent
Valid	1 Agree	1297	49,39
	2 Agree strongly	445	16,95
	3 Disagree	223	8,49
	4 Disagree strongly	40	1,52
	5 Neither agree nor disagree	558	21,25
	Total	2563	97,60
Missing	.	63	2,40
Total		2626	100,00



La variabile dipendente diff_condizioni rappresenta le opinioni sull'idea che una società più giusta sia una società senza disuguaglianze. La maggior parte dei rispondenti concorda con questa visione, con la modalità "Agree" che raccoglie il 49,39% delle risposte e "Agree strongly" il 16,95%. Le risposte in disaccordo sono molto meno frequenti, suggerendo che la tendenza generale sia a favore dell'uguaglianza come principio di giustizia sociale. Sociologicamente questa percezione potrebbe essere influenzata da fattori come reddito, età o livello di istruzione, che andrebbero approfonditi per comprendere meglio le dinamiche alla base di questa opinione.

13.3 Commentare l'alpha e la coerenza interna

Come commentare l'alpha di Cronbach?

Come commentare l'Alpha di Cronbach

1. **Cosa misura** → Indica che l'Alpha di Cronbach serve a valutare l'affidabilità della scala, cioè quanto gli item misurano lo stesso concetto.
2. **Valore e significato** → Se è **alto (>0,7)**, la scala è affidabile; se è **basso (<0,6)**, gli item potrebbero non essere coerenti tra loro.
3. **Possibili problemi** → Un Alpha basso può indicare che:
   - Gli item non misurano bene lo stesso concetto.
   - La scala ha pochi item.
   - Alcune domande sono poco chiare.
4. **Conclusione** → Se il valore è basso, è utile rivedere o modificare gli item per migliorare la scala.

Commento dell'alpha tra diff_reddito e diff_condizioni_inv

```
Test scale = mean(unstandardized items)
Reversed item:  diff_reddito_inv

Average interitem covariance:      ,169701
Number of items in the scale:            2
Scale reliability coefficient:      0,1328
```

L'alpha di Cronbach misura l'affidabilità della scala, la coerenza interna, indicando quanto gli item sono in grado di misurare lo stesso concetto. Il valore misurato è di 0,132, molto basso, e suggerisce bassa coerenza interna. Il problema riguarda quindi la capacità di misurare lo stesso concetto, oppure potrebbe derivare dal fatto che la scala ha pochi item. Solitamente quando il valore è basso è utile rivedere o modificare gli item per migliorare la scala.

Commento dell'alpha di politica*

```
. alpha politica1 politica2 politica3

Test scale = mean(unstandardized items)

Average interitem covariance:      ,413306
Number of items in the scale:            3
Scale reliability coefficient:      0,7514
```

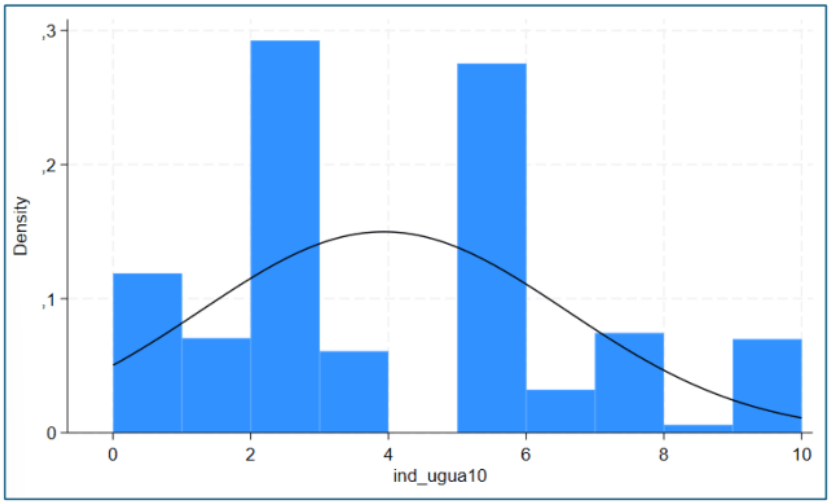
L'Alpha di Cronbach aiuta a capire se gli item di una scala misurano lo stesso concetto in modo coerente. In questo caso il valore è 0,751, indicando una buona affidabilità della scala. La coerenza interna tra gli item è soddisfacente, quindi la scala può essere considerata affidabile. Potremmo ottenere un Alpha più alto eliminando politica1, ma non è consigliabile perché la scala ha solo tre item e ridurla ulteriormente potrebbe comprometterne la validità.

13.4 Commentare l'istogramma di un indice riscalato

Guida sintetica per commentare un istogramma di un indice riscalato

1. **Descrizione del grafico** → Indica cosa rappresenta l'indice e il suo intervallo di valori (es. da 0 a 10).
   Esempio: "Il grafico mostra la distribuzione dell'indice ind_ugua10, che misura le opinioni sull'uguaglianza economica su una scala da 0 a 10."
2. **Osservazione della distribuzione** → Nota se i valori si concentrano in certi punti (picchi), se sono distribuiti in modo uniforme o se ci sono sbilanciamenti.
   Esempio: "La distribuzione è bimodale, con picchi intorno ai valori 2 e 6, indicando una divisione nelle opinioni."
3. **Interpretazione sociologica** → Spiega cosa significa questa distribuzione e quali fattori (es. reddito, età, istruzione) potrebbero influenzarla.
   Esempio: "La polarizzazione suggerisce che il tema sia divisivo e possa dipendere da fattori socio-economici o politici."
4. **Conclusione** → Riassumi il punto principale in modo chiaro.
   Esempio: "Il grafico mostra opinioni contrastanti sull'uguaglianza economica, con due gruppi distinti di pensiero."

Commento dell'indice riscalato



L'indice misura le opinioni riguardanti una visione pro uguaglianza come sinonimo di società giusta, su una scala da 0 a 10. Notiamo principalmente due picchi intorno ai valori 2 e 6, suggerendo che le risposte si concentrano su questi due gruppi distinti. Questo indica una polarizzazione delle opinioni: alcune persone sono contrarie alle disuguaglianze mentre altre le sostengono. Sociologicamente questa divisione potrebbe essere influenzata da fattori come il livello di reddito o l'ideologia, fattori che andrebbero approfonditi per comprendere meglio la tendenza osservata.

13.5 Commentare le analisi bivariate

Come si commenta un'analisi bivariata?

1. **Spiega cosa mostra la tabella**
   → Indica quale variabile è analizzata e come sono divisi i gruppi (es. "La tabella mostra la media dell'indice *ind_ugua10*, suddiviso tra chi è nato nel paese e chi no").
2. **Confronta le medie**
   → Guarda quale gruppo ha la media più alta e se la differenza è grande o piccola (es. "Chi è nato nel paese ha una media di 3,95, leggermente più alta rispetto a 3,74 di chi è nato altrove, ma la differenza è minima").
3. **Guarda la deviazione standard**
   → Se le deviazioni standard sono simili, significa che le risposte nei due gruppi sono variabili nello stesso modo (es. "Le deviazioni standard sono simili, quindi la variabilità delle risposte nei due gruppi è comparabile").
4. **Interpreta il dato**
   → Spiega cosa significa: se la differenza è piccola, il luogo di nascita probabilmente non influisce molto (es. "La piccola differenza suggerisce che il luogo di nascita non ha un forte impatto sulla percezione dell'uguaglianza economica, ma un test statistico potrebbe confermarlo").

```
tabstat ind_ugua10, by (nascita) s (mean sd)

ummary for variables: ind_ugua10
roup variable: nascita (Born in country)

ascita |      Mean        SD
-------+--------------------
   Yes |  3,949745  2,669618
    No |  3,738938  2,590021
-------+--------------------
 Total |  3,931272  2,662914
```

La tabella mostra la media dell'indice ind_ugua10 in base al luogo di nascita. Chi è nato nel paese ha una media leggermente più alta (3,95) rispetto a chi è nato altrove (3,74), ma la differenza è minima e le deviazioni standard simili. Questo suggerisce che il luogo di nascita non influenzi in modo significativo la percezione dell'uguaglianza economica, anche se un test statistico potrebbe confermarlo.

Commento della media dell'indice in base al livello di istruzione

```
. tabstat ind_ugua10, by (istruzione1) s (mean sd)

Summary for variables: ind_ugua10
Group variable: istruzione1 (livello di istruzione)

istruzione1 |      Mean        SD
------------+--------------------
      basso |  3,805291  2,555998
      medio |  3,860294  2,685058
       alto |  4,617834   2,88616
------------+--------------------
      Total |  3,928571  2,665212
```

La tabella mostra come varia la media dell'indice sulle opinioni pro-uguaglianza in base al livello di istruzione. Chi ha un'istruzione più alta tende ad avere una media più elevata, suggerendo una maggiore associazione tra uguaglianza economica e giustizia sociale. Nei livelli di istruzione più bassi le medie sono molto simili, indicando risposte tendenzialmente omogenee. Le deviazioni standard sono anch'esse simili tra i gruppi, segnalando una variabilità comparabile nelle risposte. Sebbene non in modo drastico, l'istruzione sembra influenzare la percezione dell'uguaglianza economica.

13.6 Commentare un'analisi bivariata con i test statistici

```
. tab ind_ugua10_r istruzione1, chi gamma

 RECODE of |      livello di istruzione
ind_ugua10 |     basso      medio       alto |     Total
-----------+---------------------------------+----------
     basso |       649        599        142 |      1390
     medio |       429        411        131 |       971
      alto |        75         78         41 |       194
-----------+---------------------------------+----------
     Total |      1153       1088        314 |      2555

          Pearson chi2(4) =  21,4540   Pr = 0,000
                    gamma =   0,0971  ASE = 0,032
```

I dati mostrano che il livello di istruzione e la variabile ind_ugua10_r sono collegati in modo significativo ($p = 0{,}000$). Le persone con istruzione più bassa sono più presenti nelle categorie inferiori della variabile, suggerendo possibili disuguaglianze sociali. Tuttavia il valore di gamma (0,0971) indica

che questa relazione è debole. In sintesi, chi ha meno istruzione potrebbe avere meno opportunità, ma il legame tra istruzione e questa variabile non è molto forte.

```
. tab ind_ugua10_r genere, chi V

 RECODE of |       Gender
ind_ugua10 |      Male     Female |     Total
-----------+----------------------+----------
     basso |       672        729 |      1401
     medio |       500        486 |       986
      alto |        87        108 |       195
-----------+----------------------+----------
     Total |      1259       1323 |      2582

          Pearson chi2(2) =   3,1950   Pr = 0,202
               Cramér's V =   0,0352
```

I dati mostrano che il genere e la variabile ind_ugua10_r non sono significativamente collegati ($p = 0{,}202$). Le differenze osservate nei dati potrebbero essere dovute al caso e non a un vero legame tra le due variabili. Inoltre il valore di Cramér's V (0,0352) indica una relazione molto debole. In sintesi, il genere non sembra influenzare in modo rilevante la distribuzione di ind_ugua10_r.

Parte III

Commenti ed esercizi svolti

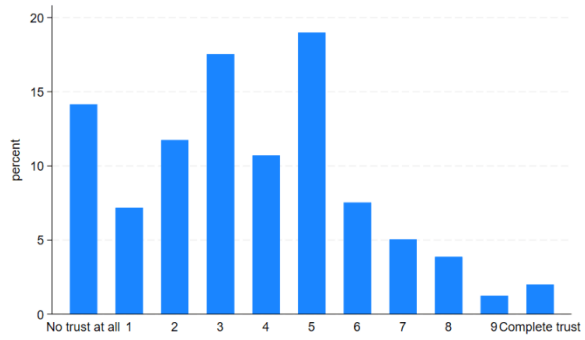
14

Elaborato: la fiducia nelle istituzioni

14.1 Fiducia nel parlamento

fidu1 — Trust in country's parliament

			Freq.	Percent	Valid	Cum.
Valid	0	No trust at all	205	13.68	14.16	14.16
	1	1	104	6.94	7.18	21.34
	2	2	170	11.35	11.74	33.08
	3	3	254	16.96	17.54	50.62
	4	4	155	10.35	10.70	61.33
	5	5	275	18.36	18.99	80.32
	6	6	109	7.28	7.53	87.85
	7	7	73	4.87	5.04	92.89
	8	8	56	3.74	3.87	96.75
	9	9	18	1.20	1.24	98.00
	10	Complete trust	29	1.94	2.00	100.00
	Total		1448	96.66	100.00	
Missing	.a	Refusal	3	0.20		
	.b	Don't know	46	3.07		
	.c	No answer	1	0.07		
	Total		50	3.34		
Total			1498	100.00		



In questa distribuzione vediamo l'analisi della variabile fidu1, che indica la fiducia nel parlamento in un campione che prende in considerazione i dati correlati all'Ungheria, e a giudicare dalle frequenze di risposta vediamo come la maggior parte dei rispondenti tenda ad avere una percezione della fiducia medio bassa. Pochissimi valori negli estremi destri a indicare che quasi nessuno prova piena fiducia nei politici.

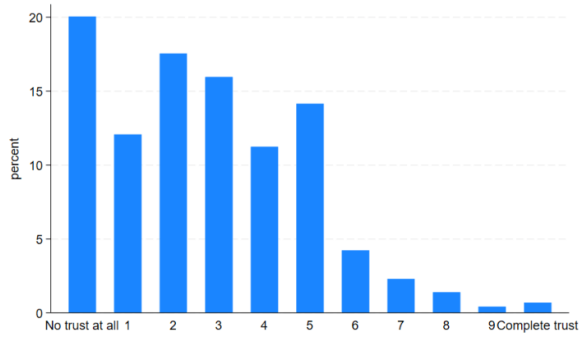
Il picco più alto è al 5 con una frequenza di 275 risposte, indicando e confermando che la fiducia nel proprio paese non riesce a raggiungere gradi alti. Analizzando i dati mancanti notiamo anche un 3% di persone che non hanno

opinione sul tema. In conclusione possiamo dire che generalmente la fiducia che si prova nelle istituzioni è molto bassa e che per capire in modo efficace l'analisi andrebbero considerati altri fattori, quali il reddito ad esempio o lo status occupazionale o le ideologie.

14.2 Fiducia nei politici

fidu2 — Trust in politicians

			Freq.	Percent	Valid	Cum.
Valid	0	No trust at all	289	19.29	20.04	20.04
	1	1	174	11.62	12.07	32.11
	2	2	253	16.89	17.55	49.65
	3	3	230	15.35	15.95	65.60
	4	4	162	10.81	11.23	76.84
	5	5	204	13.62	14.15	90.98
	6	6	61	4.07	4.23	95.21
	7	7	33	2.20	2.29	97.50
	8	8	20	1.34	1.39	98.89
	9	9	6	0.40	0.42	99.31
	10	Complete trust	10	0.67	0.69	100.00
		Total	1442	96.26	100.00	
Missing	.a	Refusal	5	0.33		
	.b	Don't know	47	3.14		
	.c	No answer	4	0.27		
		Total	56	3.74		
Total			1498	100.00		



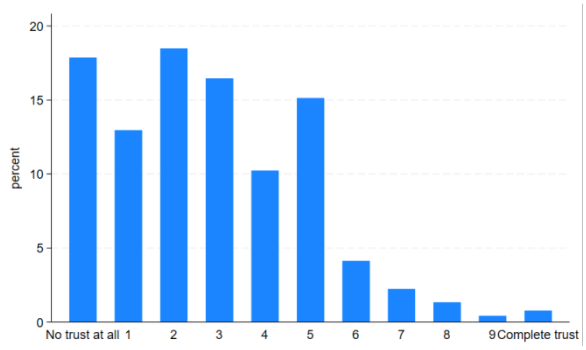
In questa distribuzione vediamo l'analisi della variabile fidu2, che indica la fiducia nei politici, e a giudicare dalle frequenze di risposta vediamo come la maggior parte dei rispondenti tenda ad avere una percezione della fiducia nei partiti medio bassa, col picco più alto nella non fiducia rappresentato dalla categoria 0. Pochissimi valori negli estremi destri a indicare che quasi nessuno prova piena fiducia nei politici.

Analizzando i dati mancanti notiamo anche un 3% di persone che non hanno opinione sul tema. In conclusione possiamo dire che generalmente la fiducia che si prova nelle istituzioni è molto bassa e che per capire in modo efficace l'analisi andrebbero considerati altri fattori, quali il reddito ad esempio o lo status occupazionale o le ideologie.

14.3 Fiducia nella politica

fidu3 — Trust in political parties

			Freq.	Percent	Valid	Cum.
Valid	0	No trust at all	255	17.02	17.86	17.86
	1	1	185	12.35	12.96	30.81
	2	2	264	17.62	18.49	49.30
	3	3	235	15.69	16.46	65.76
	4	4	146	9.75	10.22	75.98
	5	5	216	14.42	15.13	91.11
	6	6	59	3.94	4.13	95.24
	7	7	32	2.14	2.24	97.48
	8	8	19	1.27	1.33	98.81
	9	9	6	0.40	0.42	99.23
	10	Complete trust	11	0.73	0.77	100.00
		Total	1428	95.33	100.00	
Missing	.a	Refusal	5	0.33		
	.b	Don't know	57	3.81		
	.c	No answer	8	0.53		
		Total	70	4.67		
Total			1498	100.00		



In questa distribuzione vediamo l'analisi della variabile fidu3, che indica la fiducia nella politica, e a giudicare dalle frequenze di risposta vediamo come la maggior parte dei rispondenti tenda ad avere una percezione della fiducia nei partiti medio bassa, con i picchi più alti nella non fiducia rappresentati dalle categorie 0-3. Pochissimi valori negli estremi destri a indicare che quasi nessuno prova piena fiducia.

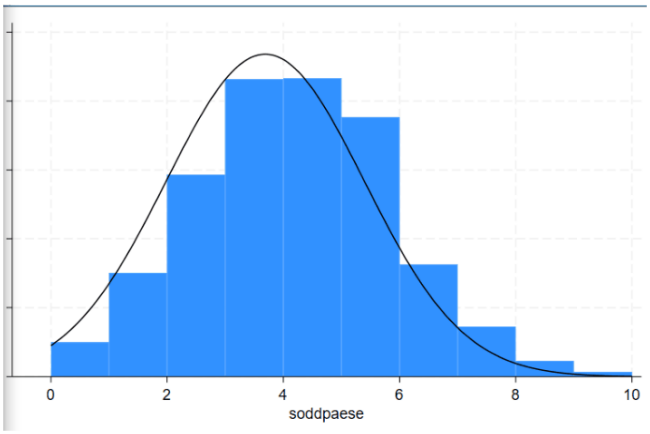
Analizzando i dati mancanti notiamo anche un 3% di persone che non hanno opinione sul tema. In conclusione possiamo dire che generalmente la fiducia che si prova nelle istituzioni è molto bassa e che per capire in modo efficace l'analisi andrebbero considerati altri fattori, quali il reddito ad esempio o lo status occupazionale o le ideologie.

14.4 Soddisfazione

. fre soddpaese

soddpaese

		Freq.	Percent	Valid	Cum.
Valid	0	37	2.47	2.49	2.49
	1	112	7.48	7.53	10.02
	2	218	14.55	14.66	24.68
	3	321	21.43	21.59	46.27
	4	322	21.50	21.65	67.92
	5	280	18.69	18.83	86.75
	6	121	8.08	8.14	94.89
	7	54	3.60	3.63	98.52
	8	17	1.13	1.14	99.66
	9	3	0.20	0.20	99.87
	10	2	0.13	0.13	100.00
	Total	1487	99.27	100.00	
Missing	.	11	0.73		
Total		1498	100.00		



Da questa distribuzione vediamo una normalità deviata non in modo ampio, e una preferenza per i valori medio bassi: la maggior parte dei rispondenti ha opinioni centrali sulla scala 0-10, con pochi valori agli estremi. Indicando quindi una soddisfazione che resta comunque nella norma senza eccedere. Negli eccessi andrebbero valutati sicuramente altri fattori per supportare l'analisi.

14.5 L'indice di fiducia nelle istituzioni

Test scale = mean(unstandardized items)

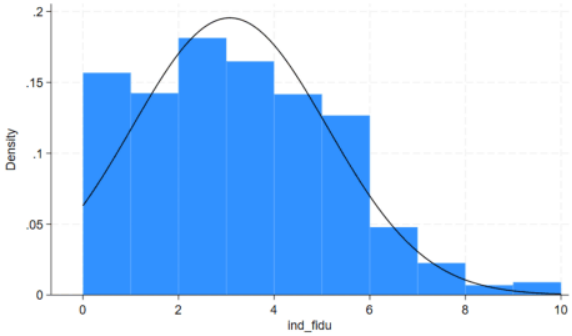
Items	S	it-cor	ir-cor	ii-cov	alpha	Label
fidu1	+	0.872	0.684	3.8488	0.910	Trust in country's parliament
fidu2	+	0.925	0.827	3.3287	0.772	Trust in politicians
fidu3	+	0.905	0.793	3.6004	0.805	Trust in political parties
Test scale				3.5931	0.878	mean(unstandardized items)

```
. sum ind_fidu, det

                        ind_fidu
-------------------------------------------------------------
      Percentiles      Smallest
 1%            0              0
 5%            0              0
10%            0              0       Obs               1,461
25%     1.666667              0       Sum of wgt.       1,461

50%            3                      Mean           3.07107
                      Largest          Std. dev.      2.040371
75%     4.666667             10
90%     5.666667             10       Variance       4.163115
95%     6.666667             10       Skewness       .456411
99%     8.666667             10       Kurtosis       3.00202

.
```



L'indice mostra la percezione della fiducia nei confronti delle istituzioni e rappresenta una media delle tre variabili sulla fiducia. A giudicare dalla distribuzione notiamo una distribuzione che non devia in modo significativo dalla normale e che le tendenze sono verso i valori bassi, a indicare che i rispondenti non provano molta fiducia nelle istituzioni del proprio paese. Il picco più alto è infatti tra 2 e 3, e con pochissimi valori alti. Possiamo quindi dire che, a giudicare esclusivamente dalla fiducia, siamo in un contesto in cui c'è poca fiducia, andrebbero quindi analizzate le cause di questa poca fiducia, quali potrebbero essere ad esempio il reddito o il genere, lo status occupazionale o l'età.

14.6 Analisi bivariata con lo status migratorio

RECODE of ind_fidu	Born in country: Yes	No	Total
basso	98.41	1.59	100.00
	64.90	48.39	64.54
medio	97.37	2.63	100.00
	33.71	41.94	33.88
alto	86.96	13.04	100.00
	1.40	9.68	1.57
Total	97.88	2.12	100.00
	100.00	100.00	100.00

Pearson chi2(2) = 15.0977 Pr = 0.001
Cramér's V = 0.1017

L'analisi mostra come lo status migratorio influenzi la percezione di fiducia, a giudicare dalle percentuali notiamo come chi è nato nel paese in cui viene svolta l'analisi si trovi nella posizione di percepire minor fiducia. Analizzando il p-value minore di 0,05 possiamo affermare che ciò che osserviamo è statisticamente significativo, ma il V di Cramér ci indica che siamo in presenza di una relazione molto debole, prossima allo 0. Possiamo quindi dire che lo status migratorio ha effetto sulla percezione di fiducia, ma che andrebbero considerati anche altri fattori per essere in grado di avere una visione più chiara del contesto sociologico che vogliamo analizzare, come ad esempio considerare se il reddito o il genere ha influenza.

14.7 Regressione lineare semplice

```
. reg ind_fidu soddpaese
```

Source	SS	df	MS	Number of obs	=	1,456
				F(1, 1454)	=	632.13
Model	1823.91128	1	1823.91128	Prob > F	=	0.0000
Residual	4195.3088	1,454	2.88535681	R-squared	=	0.3030
				Adj R-squared	=	0.3025
Total	6019.22008	1,455	4.13692102	Root MSE	=	1.6986

ind_fidu	Coefficient	Std. err.	t	P>|t|	[95% conf.	interval]
soddpaese	.6584505	.0261891	25.14	0.000	.607078	.709823
_cons	.642758	.1061591	6.05	0.000	.4345167	.8509994

Il modello di regressione spiega il 30% della variabilità della dipendente, con un coefficiente di 0,6, a indicare un incremento di 0,6 nella percezione di fiducia nelle istituzioni causato dalla variabile indipendente. Ciò che osserviamo sembra essere robusto e rappresentare un pattern significativo dal punto di vista statistico, considerando che il p-value è inferiore a 0,05 e l'intervallo di confidenza non include lo 0. Inoltre dall'intervallo di confidenza vediamo un range molto stretto, a sottolineare che si tratta di una stima precisa. Possiamo quindi affermare che la variabile indipendente ha un effetto statisticamente significativo sulla dipendente, ovvero sulla percezione della fiducia nelle istituzioni.

14.8 Regressione multipla con variabili di controllo

```
. do "C:\Users\FRANCE~1.SCR\AppData\Local\Temp\STD87c_00001g.tmp"

. reg ind_fidu soddpaese i.istruzione i.genere  i.condizione_poverta

      Source |       SS           df       MS      Number of obs   =     1,446
-------------+----------------------------------   F(5, 1440)      =    132.51
       Model |  1889.79625         5  377.959251   Prob > F        =    0.0000
    Residual |  4107.38466     1,440  2.85235046   R-squared       =    0.3151
-------------+----------------------------------   Adj R-squared   =    0.3127
       Total |  5997.18092     1,445  4.15029821   Root MSE        =    1.6889

------------------------------------------------------------------------------
     ind_fidu | Coefficient  Std. err.      t    P>|t|     [95% conf. interval]
--------------+---------------------------------------------------------------
   soddpaese |   .6571881   .0261961    25.09   0.000     .6058015    .7085747

   istruzione |
       Medio |  -.1202986   .1034631    -1.16   0.245    -.3232531     .082656
        Alto |   .2503315   .1350566     1.85   0.064    -.0145972    .5152603

      genere |
      Female |   .2349649   .0907217     2.59   0.010     .0570041    .4129258

condizione_p~a |
          Si |  -.2834131   .1448096    -1.96   0.051    -.5674735    .0006473
       _cons |   .5692107   .1445154     3.94   0.000     .2857273     .852694
------------------------------------------------------------------------------
```

Il modello di regressione spiega il 30,15% della variazione osservabile nella variabile dipendente, rappresentata dall'indice che misura la percezione di fiducia nelle istituzioni. Analizzando i coefficienti notiamo come la soddisfazione abbia un coefficiente positivo, a significare che la variabile indipendente fa aumentare di 0,657 la percezione di fiducia nelle istituzioni, e possiamo affermare la significatività statistica di ciò che osserviamo a giudicare dal p-value minore di 0,05 e dall'intervallo di confidenza che non include il caso nullo in un range molto stretto.

I coefficienti dei livelli di istruzione mostrano un aumento di percezione solo nel caso di "alta" istruzione, ma a giudicare dal p-value e dall'intervallo di confidenza che include lo 0 ciò non rappresenta un pattern robusto, ma probabilmente una variazione nei dati dovuta al caso.

Il coefficiente di "female" mostra un incremento dello 0,2 nella percezione di fiducia rispetto alla categoria di riferimento, osservazione statisticamente significativa ($p < 0{,}05$) e con intervallo che non include lo 0. Infine per chi è in condizioni di povertà la percezione tende a diminuire rispetto a chi

non lo è, ma ciò non sembra essere significativo dal punto di vista statistico ($p = 0{,}05$) e l'intervallo di confidenza include lo 0.

In conclusione possiamo affermare che le variabili di controllo, escluse "condizioni povertà" e "istruzione", sembrano causare delle variazioni sulla variabile dipendente, ma a giudicare dall'R-squared il modello spiega il 30%, il che è buono, ma potrebbe significare che andrebbero valutati altri fattori non presenti nel modello per avere una visione più chiara.

Le variabili di controllo sono state scelte in base al maggior apporto di R-squared.