Elementi di basi di dati e data mining

Corso di Laurea in Innovazione Sociale, Comunicazione e Nuove Tecnologie

Università degli Studi di Torino

Francesco Screti

Basato sulle lezioni di Federica Cena

Indice

1 Database **3**
- 1.1 Modello Entità-Relazione (concettuale) . . . 5
- 1.2 Il modello relazionale o logico . . . 9
- 1.3 Dal modello concettuale al modello logico . . . 13
- 1.4 Ristrutturazione del modello ER . . . 15
- 1.5 Algebra relazionale . . . 17
- 1.6 MY SQL . . . 25

2 Business Intelligence e Data warehouse **33**
- 2.1 Modello concettuale dei dati . . . 35
- 2.2 Datawarehouse: Progettazione logica . . . 40
- 2.3 Data warehouse, regole essenziali . . . 42
- 2.4 Operatori OLAP . . . 42
- 2.5 Operazioni OLAP . . . 43

3 Data mining **45**
- 3.1 Task supervisionati . . . 48
- 3.2 Task NON supervisionati . . . 49
- 3.3 Contesto applicativo e contesto aziendale . . . 50

4 Cluster Analysis **52**
- 4.1 K-means . . . 54
- 4.2 Il problema del k-means . . . 58
- 4.3 Introduzione ai Cluster Gerarchici . . . 60
- 4.4 Logica del k-modes . . . 62
- 4.5 Considerazioni Finali . . . 63

5 Alberi Decisionali **64**
- 5.1 L'Entropia . . . 65
- 5.2 L'Algoritmo ID3 . . . 66
- 5.3 Il modello predittivo . . . 66
- 5.4 Valutazione delle prestazioni . . . 71
- 5.5 Le matrici di confusione . . . 72

6 Naive Bayes **77**
- 6.1 Esempio pratico . . . 77
- 6.2 Vantaggi e svantaggi . . . 78

7 Text mining **81**
7.1 Raccolta di dati 83
7.2 Annotazione 84
7.3 Preprocessing 87
7.4 Vettorizzazione 96
7.5 TF-IDF 98

1

Database

Qual è la differenza tra dati e informazione?

- Dati = Elementi grezzi, privi di interpretazione.
- Informazione = Dati interpretati, utili per comprendere fatti, eventi o situazioni.

Sistemi informativi => organizzano e gestiscono le informazioni necessarie alle attività di un'organizzazione. Inizialmente non erano automatizzati, prima dell'informatica.

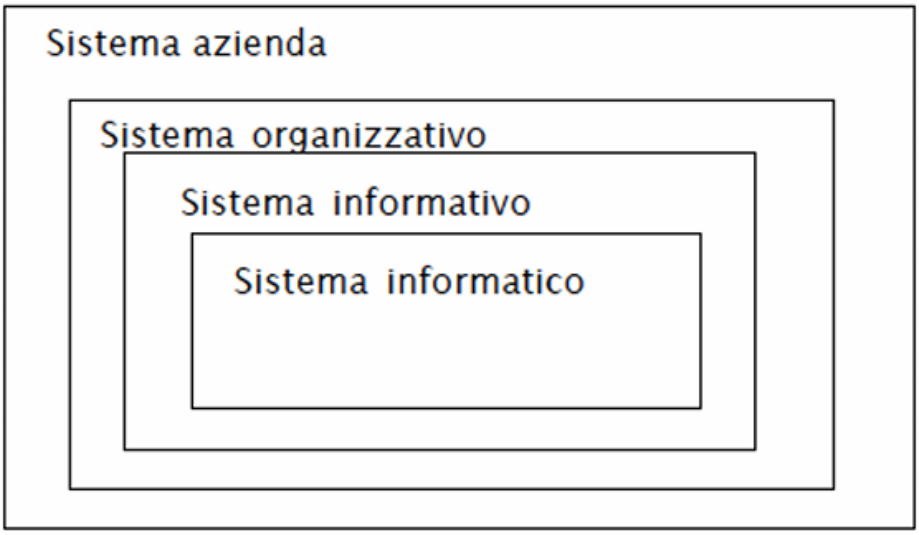

Una prima distinzione: Dati strutturati e non strutturati.

Dati non strutturati: non rispettano formati o regole. Es.: documenti di testo, e-mail, video, suono, immagini, ...

Dati strutturati: sono organizzati e descritti in modo uniforme. Es.: basi di dati, documenti XML e XHTML

- possibilità di interrogarli in base alla struttura
- necessario definire la struttura & manutenzione costosa

Basi di dati (db), quale è il problema? Memorizzare grandi quantità di informazioni.

Prima soluzione? Il file system. Ma abbiamo degli svantaggi:

- Organizzazione dei file affidata all'utente.
- Difficoltà nella gestione di un grande volume di dati.

Seconda soluzione? Foglio elettronico. Ma abbiamo degli svantaggi anche qui:

- Difficile condivisione tra più utenti
- Difficile reperire informazioni

Soluzione corretta? Database. Un DB è un grande magazzino di dati, organizzati e memorizzati in forma strutturata e omogenea.

- Strutturata: es. anagrafe: nome, cognome, data di nascita,
- Omogenea: es. anagrafe: per ogni persona mantengo le stesse informazioni

Ricorda → Una base di dati è un insieme di dati atomici organizzati con la minima ridondanza, per essere utilizzati da applicazioni diverse in modo sicuro e controllato.

Il DBMS: Data Base Management System, che cos'è? È un insieme di programmi che permettono di definire e gestire i dati e consente la condivisione simultanea tra più utenti.

Vediamo le Caratteristiche.

- Dimensioni: Può raggiungere i terabyte, gestendo dati su memoria secondaria.
- Persistenza: Dati conservati oltre le esecuzioni delle applicazioni.
- Condivisione: Accessibile da più utenti con applicazioni diverse.
- Privacy: Accessi regolati da autorizzazioni (es. lettura o modifica).
- Efficienza: Operazioni rapide per l'utente.
- Efficacia: Funzionalità avanzate e flessibili per attività produttive.

Quali modelli di dati abbiamo?

- Gerarchico
- Reticolare
- Relazionale (quello che useremo)

Quali sono le caratteristiche di un buon modello?

- Espressività: Rappresenta i dati e le loro proprietà in modo semplice.
- Semplicità: Usa pochi meccanismi, facili da comprendere e utilizzare.
- Realizzabilità: Deve essere implementabile in modo efficiente su un computer.

Quali sono i livelli dell'architettura di un sistema di database? L'architettura a tre livelli di un sistema di database facilita la gestione e garantisce che i cambiamenti a un livello non influenzino gli altri.

1. Livello esterno: Vista dell'utente, differente dalla memorizzazione reale.
2. Livello logico: Struttura del database, con dati e relazioni, senza dettagli fisici.
3. Livello interno: È la gestione tecnica, che descrive come i dati sono effettivamente salvati nel computer.

Quali sono i tipi di indipendenza nei database?

- Indipendenza logica: L'utente può lavorare con i dati senza preoccuparsi della loro organizzazione. (livello esterno).
- Indipendenza fisica: Le applicazioni funzionano anche se i dati vengono modificati fisicamente. (livello logico).

Due tipi principali di modelli, quali sono?

1. Concettuale → concetti. Rappresenta concetti generali e astratti, come nel modello Entità-Relazioni (ER).
2. Logico → dati. Organizza i dati per il DBMS, con esempi come il modello relazionale e quello a oggetti, descrivendo i dati in modo intermedio tra utente e sistema.

1.1 Modello Entità-Relazione (concettuale)

Che cos'è? È un modello grafico e astratto che:

- Descrive i concetti e le loro relazioni.
- È comprensibile anche per i non specialisti.
- Si basa su entità, attributi e relazioni (associazioni).

Cosa sono le ENTITÀ nel modello concettuale? Rappresentano concetti del mondo reale, come una città, un dipartimento, un impiegato o un acquisto.

Graficamente? Le entità sono disegnate come rettangoli.

Cosa sono le ASSOCIAZIONI / RELAZIONI nel modello concettuale? Rappresentano i legami logici tra due o più entità. Si possono considerare le entità come sostantivi e le associazioni come verbi che collegano questi sostantivi.

Graficamente? Le associazioni sono rappresentate da un rombo, con linee che collegano il rombo alle entità coinvolte.

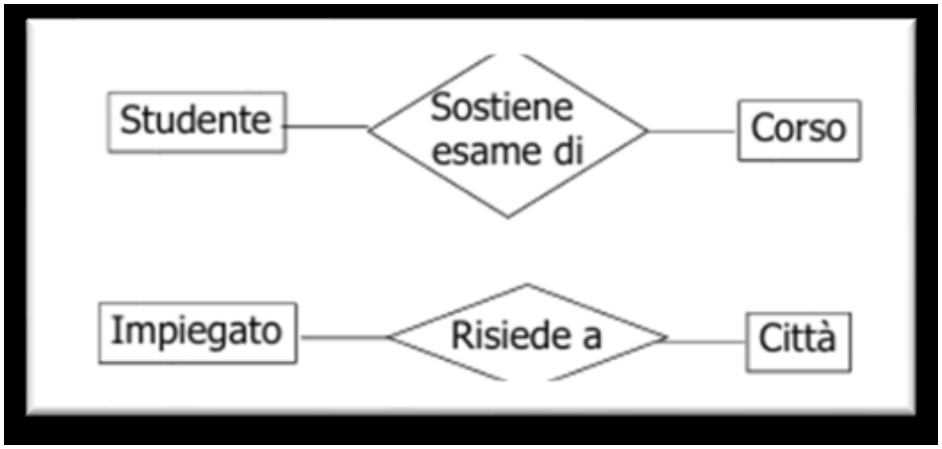

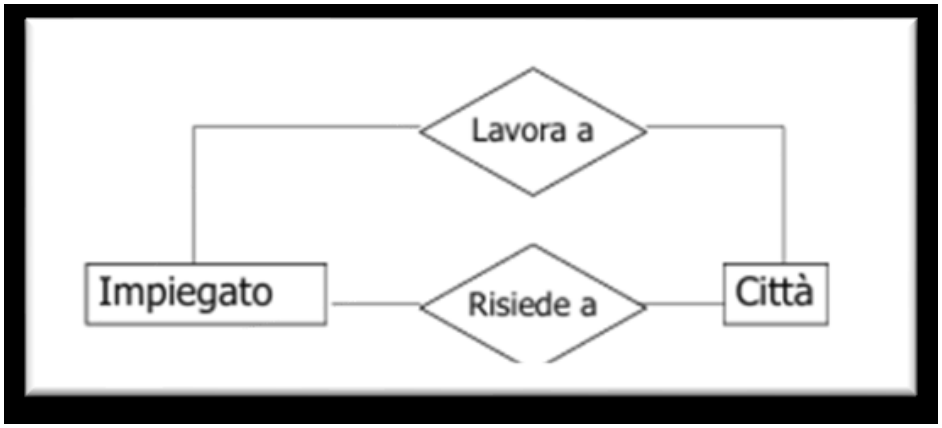

Gli Attributi delle entità, cosa sono? Sono caratteristiche comuni di tutti gli individui di un'entità. Il valore degli attributi è il Dominio.

Le Cardinalità delle associazioni / relazioni, cosa sono? La cardinalità mostra quante volte un'entità può essere collegata a un'altra in una relazione.

La Cardinalità massima

- Uno a uno (1:1): un'entità A può essere associata a una sola entità B, e viceversa. Esempio → un cittadino ha un solo passaporto.
- Uno a molti (1:N): un'entità A può essere associata a molte entità B, ma una entità B è associata a una sola entità A. Esempio → un cliente può fare più ordini.
- Molti a molti (N:N): molte entità A possono essere associate a molte entità B. Esempio → studenti possono seguire più corsi, e ogni corso può avere più studenti.

La Cardinalità minima indica il numero minimo di partecipazioni di un'entità a una relazione. Può essere 0 o 1:

- 0: la partecipazione è facoltativa.
- 1: la partecipazione è obbligatoria.

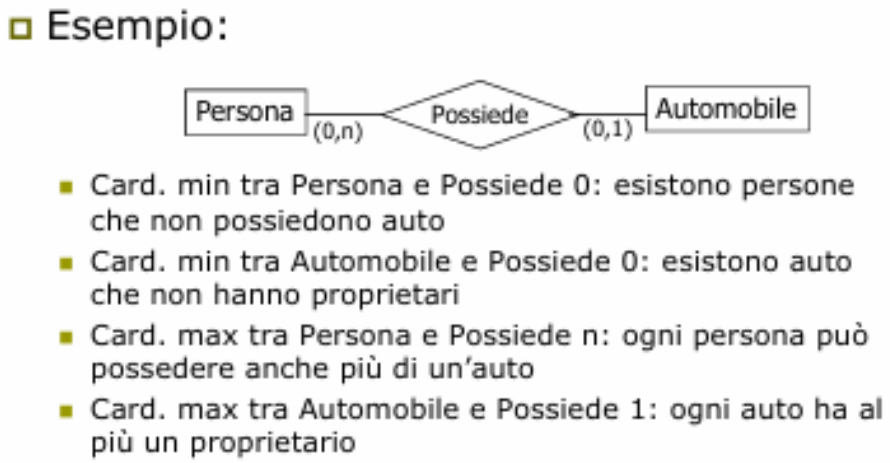

Esempi:

[1, N] Un esempio di relazione 1 a molti può essere il rapporto tra un insegnante e i suoi studenti.

- Insegnante (uno): Un insegnante può avere più studenti.
- Studenti (molti): Ogni studente può avere un solo insegnante per una determinata materia o corso.

[1,1] Un esempio semplice di relazione 1 a 1 potrebbe essere il rapporto tra una persona e il suo numero di codice fiscale (in Italia).

- Persona (uno): Ogni persona ha un solo codice fiscale.
- Codice fiscale (uno): Ogni codice fiscale è associato a una sola persona.

[N,N] Un esempio di relazione molti a molti può essere il rapporto tra studenti e corsi universitari.

- Studenti (molti): Ogni studente può iscriversi a più corsi.
- Corsi (molti): Ogni corso può essere frequentato da più studenti. Per rappresentare questa relazione in un database, spesso si utilizza una tabella intermedia.

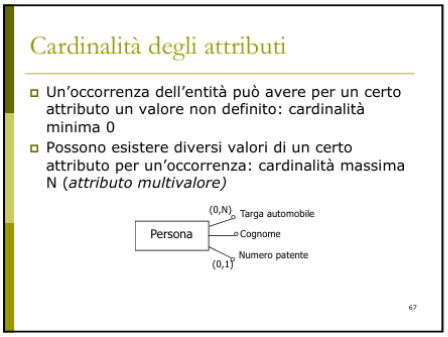

Gli identificatori, si dividono in interni ed esterni:

- Identificatori Interni: Non è legato a informazioni reali, ma viene usato dal sistema per gestire i dati in modo efficiente. Esempio → Un numero ID assegnato a ogni studente in un database (ID_12345).
- Identificatori Esterni: Questi identificatori possono essere utilizzati anche in contesti esterni al sistema, come nella vita quotidiana o in altri sistemi. Esempio → Il codice fiscale di una persona o il numero di targa di un'auto.

Generalizzazione e Specializzazione, cosa indicano?

La Generalizzazione

La generalizzazione è il processo di unire diverse entità simili in un'entità più generale. Questo consente di ridurre la ridondanza e semplificare il modello.

- Entità specifiche:

  - Studente: può avere attributi come “Matricola”, “Corso di Laurea”.
  - Insegnante: può avere attributi come “ID Insegnante”, “Materia”.
- Entità generale:
  - Persona: può avere attributi comuni come “Nome”, “Cognome”, “Data di Nascita”.

La Specializzazione

La specializzazione è il processo opposto: si parte da un’entità generale e si creano entità più specifiche.

- Entità generale:
  - Persona: ha attributi comuni come “Nome”, “Cognome”.
- Entità specifiche:
  - Studente: ha attributi come “Matricola”, “Corso di Laurea”.
  - Insegnante: ha attributi come “ID Insegnante”, “Materia”.

1.2 Il modello relazionale o logico

Su cosa è basato il modello relazionale o logico? Sul concetto di Tabella, nello specifico, sul concetto di Relazione. (Il termine Relazione assume due significati diversi, nel logico e nel E-R)

Nel modello relazionale, una relazione può essere rappresentata appunto da una tabella:

- Colonna: Rappresenta un attributo o campo, che rimane sempre lo stesso.
- Riga: Mostra i dati di un singolo elemento (chiamata tupla o record).

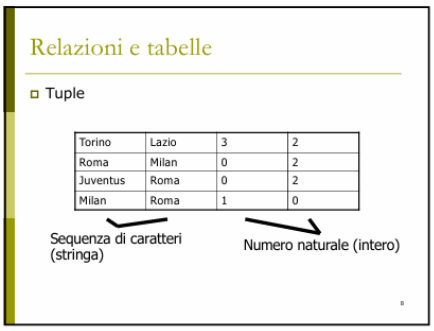

Importante → La definizione di Relazione nel modello relazionale. Una relazione è un insieme di tuple (righe) divise in campi (colonne)

- le righe della relazione devono essere distinte, non ripetute in tabella
- le righe non sono tra loro ordinate

Gli Attributi nel modello relazionale, cosa sono? Gli attributi sono l'intestazione di colonne della tabella. Per esempio: SquadraDiCasa, SquadraOspitata, RetiCasa, RetiOspitata

Le Relazioni nel modello logico, cosa sono? Un database è formato da diverse relazioni, che sono come tabelle. Ogni tabella contiene righe, chiamate tuple, che rappresentano i dati. Ad esempio, potresti avere una tabella per gli studenti, una per gli esami e una per i corsi. Ogni riga in queste tabelle descrive un singolo elemento, come uno studente o un esame. Anche una tabella con una sola colonna (attributo) è considerata una relazione.

I valori, come devono essere? I valori all'interno delle tuple, record o righe devono essere

- Atomici (un solo valore per record)
- Omogenei (dello stesso tipo)

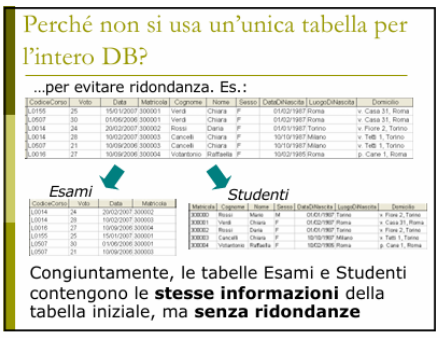

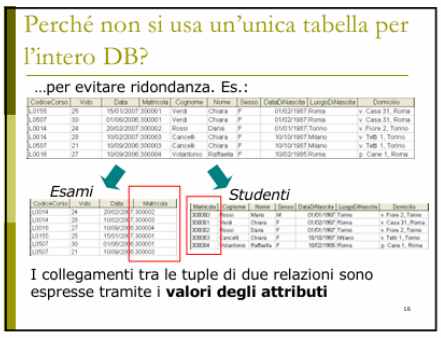

Come identifichiamo le relazioni? Le relazioni sono identificate per nome, quindi, i nomi delle tabelle devono essere diversi.

Per esempio:

Università = {

Studenti(Matricola,Cognome,Nome,DataNascita),

Esami(Studente,Voto,Corso),

Corso(Codice,Titolo,Docente) }

Schema e istanza di una base dati, definiamolo:

- Schema di una base di dati = insieme degli schemi delle relazioni (struttura) (non cambia)
- Istanza di una base di dati = valori dei dati nelle tabelle (record) (cambia spesso)

Istanze incoerenti, cosa sono? Le istanze incoerenti si verificano quando:

1. Duplicati: Due righe hanno lo stesso valore in un attributo unico (es. stessa matricola).
2. Mancata corrispondenza: Un valore in una tabella non esiste in un'altra collegata (es. studente negli Esami ma non nei Studenti).

I Vincoli di integrità, cosa sono? Sono una Soluzione alle istanze incoerenti, sono proprietà che devono essere soddisfatte dalle istanze corrette per un'applicazione. Sono predicati che associano a ogni istanza il valore vero o falso

- Vero: istanza corretta (ammissibile, lecita)
- Falso: istanza incoerente

Quali sono i tipi di vincoli nei database?

1. Vincoli intra-relazionali: Si applicano all'interno di una singola relazione.
    - Vincolo di tupla: Basato su espressioni booleane (es. AND, OR, NOT).
    - Vincolo di dominio: Limita i valori di un attributo (es. Voto $\geq$ 18 e $\leq$ 30).

- Vincolo su più attributi: Regola la combinazione di valori tra attributi (es. NOT(Lode = "Sì" AND Voto $\neq$ 30)).
- Vincolo di chiave: Garantisce l'unicità delle tuple.

2. Vincoli inter-relazionali: Si applicano tra relazioni diverse.
    - Vincolo di integrità referenziale: Assicura la coerenza tra i dati di relazioni correlate.

Importante → I vincoli di chiave, cosa sono? Nel modello relazionale garantiscono l'unicità e la coerenza dei dati nelle tabelle del database.

La Chiave primaria:

- È un insieme di uno o più attributi che identificano univocamente ogni riga in una relazione.
- Non può contenere valori nulli.
- Ogni tabella può avere una sola chiave primaria.

Esempio → in una tabella "Studenti", l'attributo "ID_Studente" può essere la chiave primaria, poiché ogni studente ha un ID unico.

La Chiave esterna:

- È un attributo in una tabella che si riferisce alla chiave primaria di un'altra tabella.
- Serve a mantenere l'integrità referenziale, collegando record di tabelle diverse.
- Può contenere valori nulli, a seconda delle regole impostate.
- Una tabella può avere più chiavi esterne.

Esempio → nella tabella "Iscrizioni", l'attributo "ID_Studente" può essere una chiave esterna che si riferisce alla chiave primaria "ID_Studente" nella tabella "Studenti".

Importante → I vincoli di integrità referenziale, cosa sono? Il vincolo di integrità referenziale garantisce che i valori di una chiave esterna esistano nella chiave primaria della tabella collegata e previene riferimenti non validi durante modifiche o eliminazioni di record.

Cosa succede se si cambia o elimina un record collegato?

- Cascata: I cambiamenti o le eliminazioni si applicano anche ai dati collegati.

- Impedire: L'operazione non è permessa se ci sono dati collegati.
- Null: I riferimenti collegati vengono azzerati (diventano null)

1.3 Dal modello concettuale al modello logico

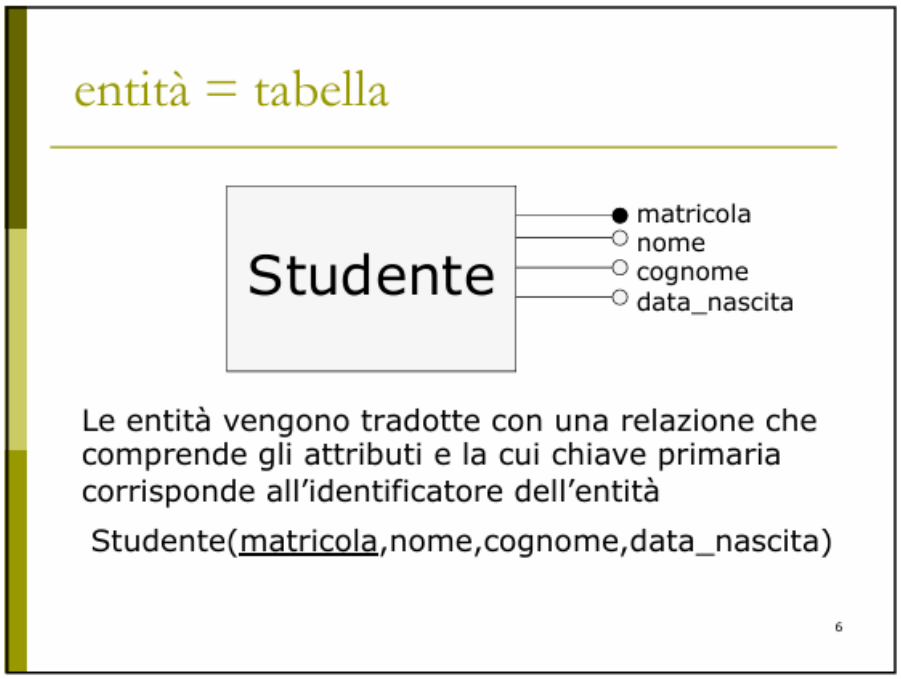

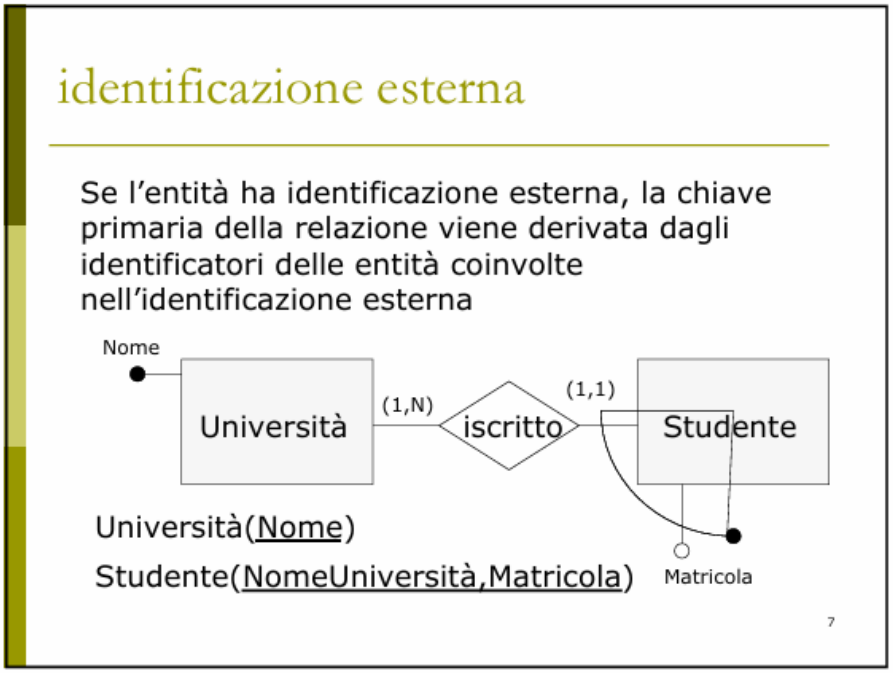

Come si passa da un modello Entità-Relazioni (ER) a un modello Relazionale/Logico?

1. Entità = Tabella: Ogni entità del modello ER diventa una tabella nel modello relazionale. Gli attributi dell'entità diventano le colonne della tabella. Esempio → Un'entità "Studente" con attributi "Nome", "Cognome" e "Matricola" diventa una tabella chiamata "Studente" con colonne "Nome", "Cognome" e "Matricola".
2. Attributi = Colonne: Ogni attributo dell'entità diventa una colonna nella tabella corrispondente.
3. Identificatori Unici (Chiave Primaria): L'attributo o che identificano in modo univoco un'entità diventa la chiave primaria (Primary Key) della tabella. Esempio → Nell'entità "Studente", "Matricola" potrebbe essere la chiave primaria.

Importante → Come gestire le relazioni nelle tabelle di un database?

Per le relazioni 1 a 1: basta aggiungere una colonna in una delle due tabelle che rappresenta l'altra entità. (Chi ha 0 nella minima migra nella 1)

Per le relazioni 1 a molti: Si aggiunge una colonna alla tabella "figlia" che contiene la chiave primaria della tabella "genitore" (questa colonna è una chiave esterna). (Ospita chi ha 1, Chi ha N migra nella 1)

Per le relazioni molti a molti: Si crea una tabella aggiuntiva che rappresenta la relazione. Questa nuova tabella avrà le chiavi primarie di entrambe le entità come chiavi esterne.

Esistono Elementi del modello E-R che non sono traducibili!

1. Attributi multivalore: Possono contenere più valori per una singola entità. Esempio: Uno studente con più numeri di telefono.
2. Attributi composti: Possono essere suddivisi in componenti più piccole. Esempio: Un indirizzo composto da via, città e CAP.
3. Le gerarchie. Le gerarchie organizzano i dati in livelli strutturati, con relazioni padre-figlio. Esempio: Una gerarchia aziendale con Direttore Generale, Responsabili e Impiegati.

Cosa significano totale/parziale ed esclusiva/sovrapposta nelle specializzazioni?

- Totale/parziale:
  - Totale: Ogni entità deve appartenere a una sottoclasse (es. ogni animale è cane, gatto o uccello).
  - Parziale: Non tutte le entità devono appartenere a una sottoclasse (es. alcuni animali non sono né cane, né gatto, né uccello).
- Esclusiva/sovrapposta:
  - Esclusiva: Un'entità appartiene a una sola sottoclasse (es. un animale può essere solo cane o gatto).
  - Sovrapposta: Un'entità può appartenere a più sottoclassi (es. un animale può essere sia cane che animale domestico).

1.4 Ristrutturazione del modello ER

Eliminare attributi composti

1. Soluzione 1: Trasformare l'attributo composto in un semplice attributo eliminando i sotto-attributi.
2. Soluzione 2: Trattare i sotto-attributi come distinti attributi dell'entità. Se questi sono a loro volta composti, ripetere la procedura.

Eliminare attributi multi-valore

1. Creare una nuova entità:

- Si crea una nuova entità per rappresentare l'attributo multi-valore.
- La nuova entità include una chiave esterna che collega all'entità originale → Una tabella separata per i numeri di telefono con riferimento all'ID utente.

2. Vincoli di cardinalità:
   - L'attributo multi-valore diventa una relazione 1:n tra l'entità originale e quella nuova.
   - La nuova entità ha una relazione 1:1 con i valori.
3. Modello logico:
   - Creare una nuova tabella per l'entità ristrutturata.
   - La tabella originale conserva la chiave primaria, utilizzata anche come chiave esterna nella nuova tabella.

Gestione di sottoclassi e superclassi

1. Accorpamento nella superclasse:
   - Unire gli attributi delle sottoclassi nella superclasse.
   - Aggiungere un attributo discriminante per identificare la sottoclasse.
2. Accorpamento nelle sottoclassi:
   - Trasferire tutti gli attributi della superclasse nelle sottoclassi, eliminando la superclasse.
3. Sostituzione della generalizzazione con associazioni:
   - Mantenere superclasse e sottoclassi separate, collegandole tramite relazioni.

Esempio → Sostituzione della generalizzazione con associazioni

1. Modello iniziale:
   - Veicolo: Attributi ID, Marca, Modello, Anno.
   - Auto: Attributi NumeroPorte (sottoclasse di Veicolo).
   - Moto: Attributi Cilindrata (sottoclasse di Veicolo).
2. Nuovo modello:
   - Veicolo rimane un'entità con i suoi attributi.

- Auto e Moto diventano entità distinte con associazioni a Veicolo.
- Relazioni collegano Auto e Moto con Veicolo, eliminando la gerarchia.

Questo approccio mantiene le entità separate e semplifica la gestione della struttura dati.

In sintesi... La ristrutturazione del modello ER serve a semplificare e organizzare meglio il modello, eliminando attributi complessi (come composti o con più valori), trasformandoli in nuove tabelle o colonne, e gestendo le gerarchie unendo o collegando meglio le entità.

1.5 Algebra relazionale

Due operazioni fondamentali, quali sono?

- Selezione: estrarre un sottoinsieme delle righe di una tabella [simbolo: σ]
- Proiezione: estrarre dalla tabella un insieme di colonne [simbolo: π]

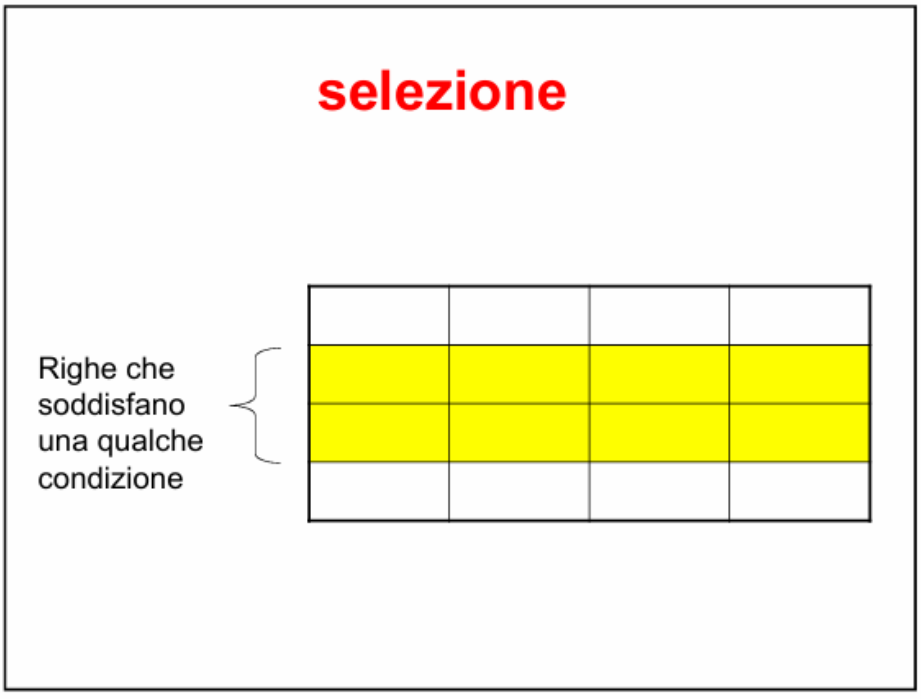

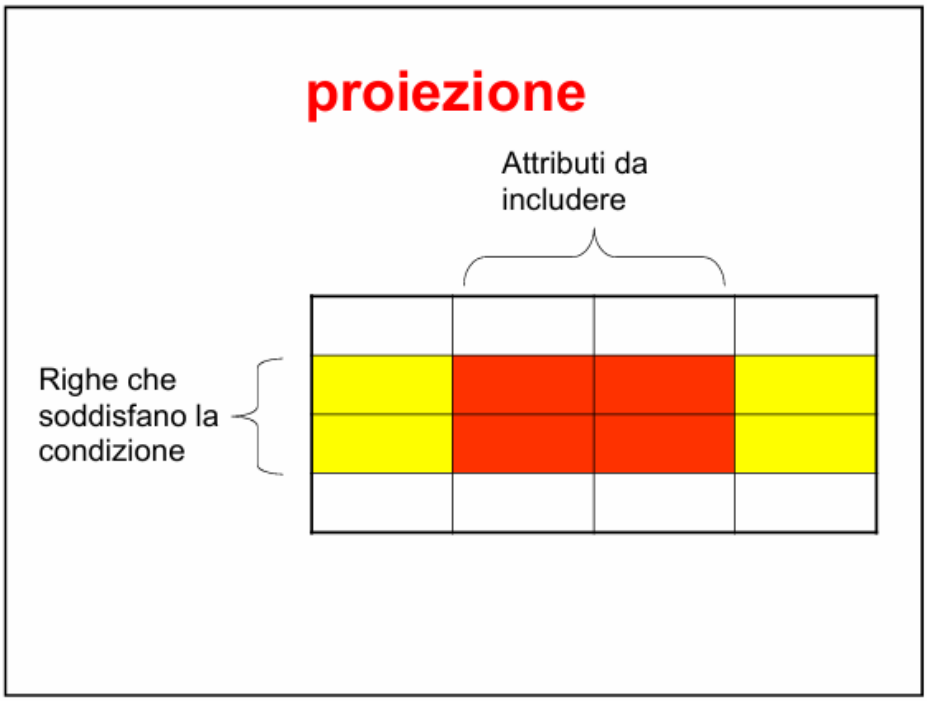

Esempio. Dammi l'autore del libro dal titolo "I promessi sposi"

π AUTORE (σ titolo= "Promessi Sposi" (LIBRO))

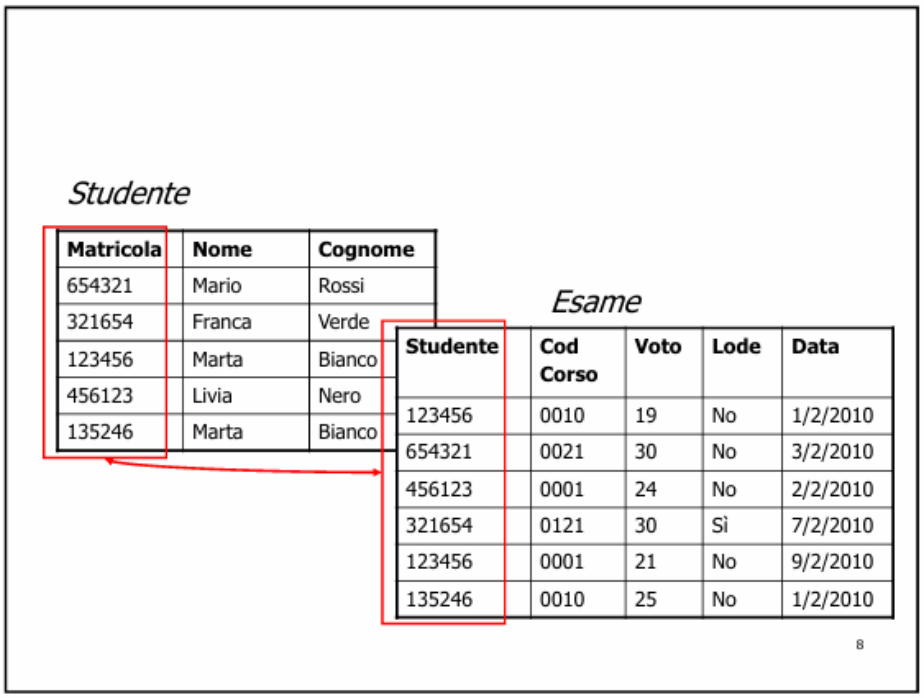

Esempio. Dammi la matricola dello studente con cognome Rossi

π matricola (σ cognome= “Rossi” (STUDENTE))

Operazioni insiemistiche, definiamole... Vedendo ogni tabella come un insieme è facile definire le seguenti operazioni:

- Unione
- Intersezione
- Differenza
- Prodotto cartesiano

Quando parliamo di Compatibilità all'unione? Si parla di compatibilità all'unione quando:

- Le tabelle o dati sono omogenei, ovvero trattano lo stesso argomento.
- I tipi di dati devono essere compatibili (es. int con int, non int con string).
- Sintassi e vincoli devono essere uguali.
- La semantica deve essere coerente (es. unire autore con libro sì, autore con prodotto no).

Compatibilità: esempio

LIBRI BIBLIOTECA

TITOLO	ISBN	AUTORE	COLLOCAZ.
stringa	stringa	stringa	intero

LIBRI PRESTITO

TITOLO_LIBRO	#ISBN	AUTORE	#COLL.
stringa	stringa	stringa	intero

Unione

- R U S
- Tutte le ennuple della prima relazione e tutte le ennuple della seconda
  - Le duplicazioni sono eliminate

aaa	bbbb	cccc
ddd	bbbb	eee
xxx	yyy	zzz

ddd	bbbb	eee
www	yyy	zzz

aaa	bbbb	cccc
ddd	bbbb	eee
xxx	yyy	zzz
www	yyy	zzz

Intersezione

- R ∩ S
- Solo le ennuple che sono sia nella prima relazione che nella seconda

aaa	bbbb	cccc
ddd	bbbb	eee
xxx	yyy	zzz

ddd	bbbb	eee
www	yyy	zzz

ddd	bbbb	eee

Differenza

- R – S
- Solo le ennuple della prima relazione che *non* sono anche nella seconda relazione

aaa	bbbb	cccc
ddd	bbbb	eee
www	yyy	zzz

xxx	bbbb	fff
www	yyy	zzz

aaa	bbbb	cccc
ddd	bbbb	eee

Prodotto cartesiano

- R X S
- Prodotto cartesiano delle ennuple di due relazioni (insieme di tutte le combinazioni)
  - Non serve compatibilità all'unione!

R

aaa	bbbb	cccc
ddd	bbbb	eee

ddd	bbbb
www	yyy

S

aaa	bbbb	cccc	ddd	bbbb
ddd	bbbb	eee	www	yyy
aaa	bbbb	cccc	www	yyy
ddd	bbbb	eee	ddd	bbbb

Importante → IL JOIN, che cos'è? Il join ($R \bowtie S$) è un'operazione che combina due tabelle, R e S, creando nuove righe che uniscono coppie di righe da R e S solo quando una certa condizione è soddisfatta.

Ad esempio: Se una tabella Studenti ha un attributo Matricola e una tabella Esami ha lo stesso attributo Matricola, il join combina le righe di Studenti e Esami basandosi su questa corrispondenza, cioè quando il valore di Matricola in entrambe le tabelle è uguale.

A	B	C
aaa	bbbb	cccc
eee	xxxx	qqq
ddd	www	eee

D	E
ddd	bbbb
rrrr	xxxx

A	B	C	D	E
aaa	bbbb	cccc	ddd	bbbb
eee	xxxx	eee	rrrr	xxxx

Esempio: Join

studente >< corso $_{\text{Matr = CodStud}}$

Nome	Matr	età
Mario	1111	34
Carla	2222	24
Pino	3333	21

Corso	CodStud
inf	1111
sociol	2222

Nome	Matr	età	Corso	CodStud
Mario	1111	34	inf	1111
Carla	2222	24	sociol	2222

Come funziona il join? Il Join è un'operazione che combina due tabelle e può essere vista come una sequenza di due passaggi:

1. Prodotto cartesiano: Si creano tutte le combinazioni possibili tra le righe delle due tabelle.

2. Filtraggio: Si selezionano solo le righe che rispettano una regola comune, ad esempio, un attributo condiviso come una chiave primaria o esterna.

A	B	C
aaa	bbbb	cccc
eee	xxxx	qqq
ddd	gggg	eee

D	E
ddd	bbbb
rrrr	xxxx

prodotto cartesiano

A	B	C	D	E
aaa	bbbb	cccc	ddd	bbbb
eee	xxxx	qqq	ddd	bbbb
ddd	gggg	eee	ddd	bbbb
aaa	bbbb	cccc	rrrr	xxxx
eee	xxxx	qqq	rrrr	xxxx
ddd	gggg	eee	rrrr	xxxx

select

A	B	C	D	E
aaa	bbbb	cccc	ddd	bbbb
eee	xxxx	eee	rrrr	xxxx

Esempio: Join

studente >< corso Matr = CodStud

Nome	Matr	età
Mario	1111	34
Carla	2222	24
Pino	3333	21

Corso	CodStud
inf	1111
sociol	2222

Nome	Matr	età	Corso	CodStud
Mario	1111	34	inf	1111
Mario	1111	34	sociol	2222
Carla	2222	24	inf	1111
Carla	2222	24	sociol	2222
Pino	3333	21	inf	1111
Pino	3333	21	sociol	2222

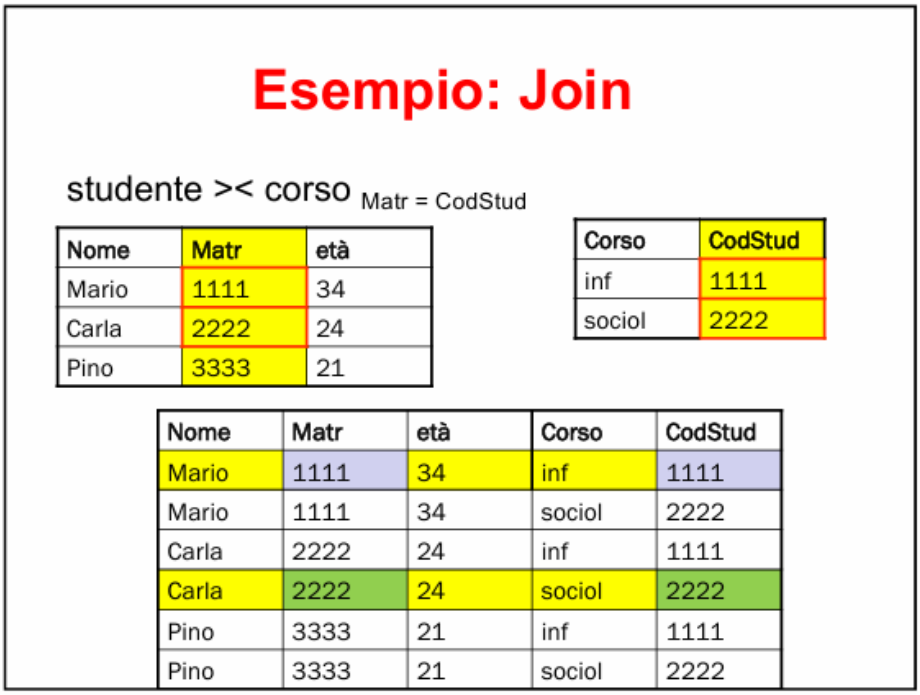

Ricorda → La condizione di join è soddisfatta quando la chiave primaria è uguale alla chiave esterna.

Quale è la differenza tra vincolo e join?

- Il vincolo di integrità referenziale garantisce che i dati tra tabelle collegate siano coerenti, assicurando che i valori della chiave esterna corrispondano a quelli esistenti nella chiave primaria della tabella padre.
- La join è un'operazione che combina dati di più tabelle basandosi su una colonna comune. Non verifica la coerenza, ma serve solo per leggere e unire i dati.

Esempio di algebra relazionale. Dammi la targa di Gino

π guida.targa

σ autista.nome= "gino"

(autista <> guida) autista.npat = guida.npat

Lo schema utilizzato:

- Taglia
- Dove

- (Il join tra le tabelle) le chiavi da eguagliare

1.6 MY SQL

Come funziona questo linguaggio? In un linguaggio dichiarativo, l'utente specifica cosa vuole ottenere, senza preoccuparsi di come il DBMS eseguirà l'operazione. Le query vengono elaborate dal query optimizer, e l'utente riceve il risultato senza conoscere i dettagli del processo.

Gli operatori di selezione, quali sono?

```
SELECT attributi
FROM tabella
WHERE condizione (non sempre necessaria)
```

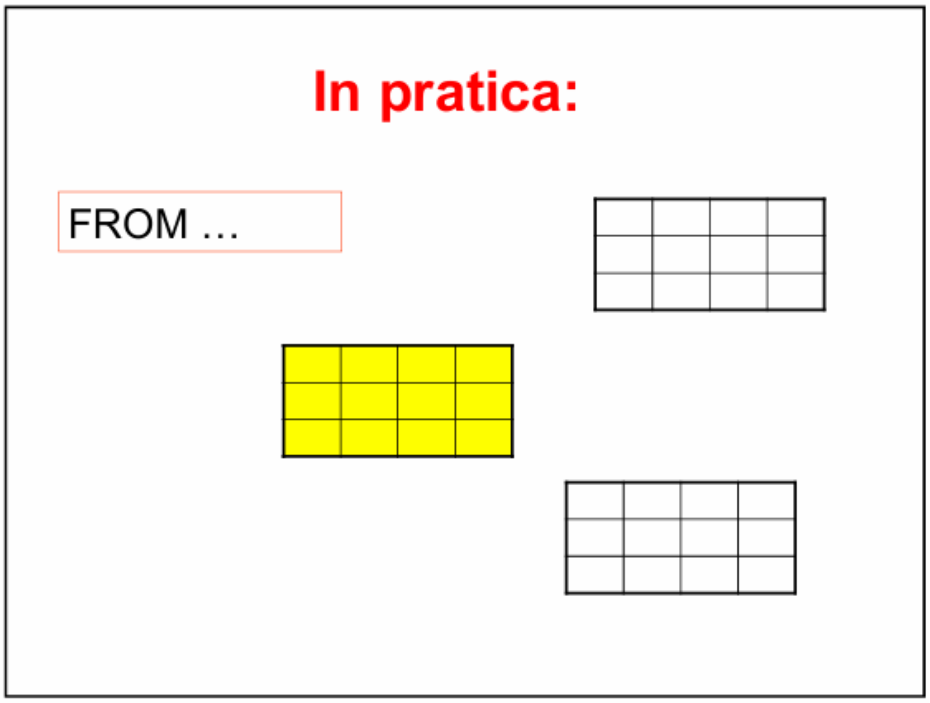

In pratica: selezione

WHERE …

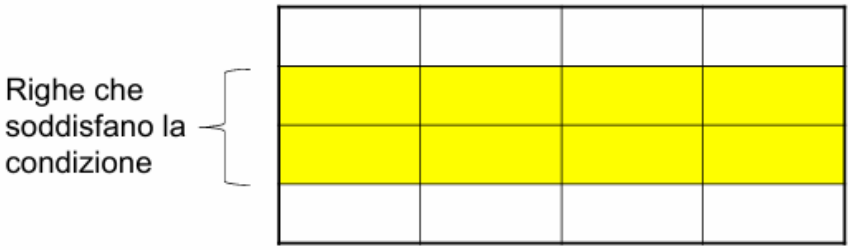

In pratica: proiezione

SELECT …

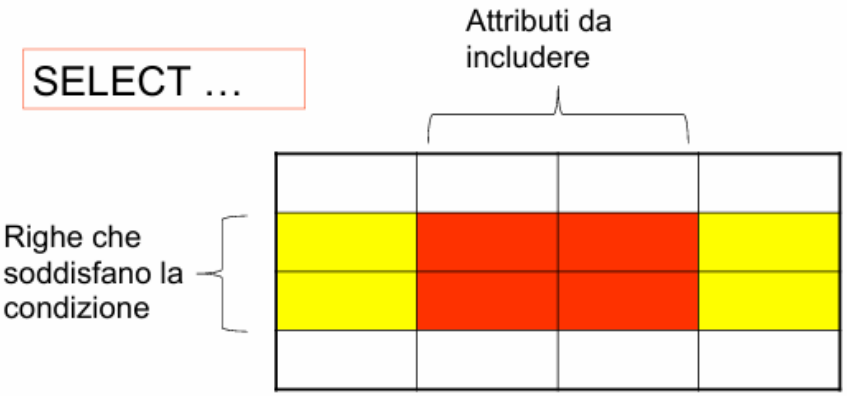

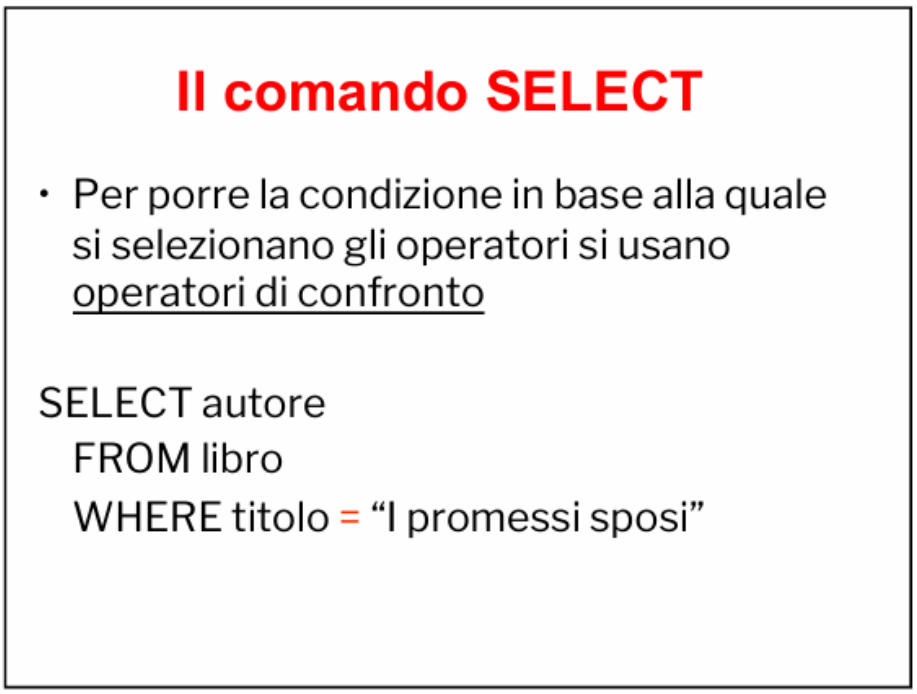

Espressioni nella clausola select, quali può includere? La clausola SELECT può includere espressioni sui valori degli attributi per calcolare nuovi valori riga per riga.

Esempio → Estrarre il peso in grammi delle viti:

Importante → Matching approssimato, il LIKE. L'operatore like permette di confrontare il valore di un attributo con un altro valore specificato in modo incompleto.

Quali sono le forme di utilizzo?

- Inizia con: LIKE “M%”
- Finisce con: LIKE “%M”
- Contiene: LIKE “%M%”

Esempio → selezionare fornitori con nomi che iniziamo per M

Funzioni aggregate: Cosa sono e come si usano? Le funzioni aggregate lavorano su più righe per restituire un valore singolo, utile per sintesi dei dati.

- COUNT: Conta le righe.
- SUM: Somma i valori.

- MAX: Trova il valore massimo.
- MIN: Trova il valore minimo.
- AVG: Calcola la media.

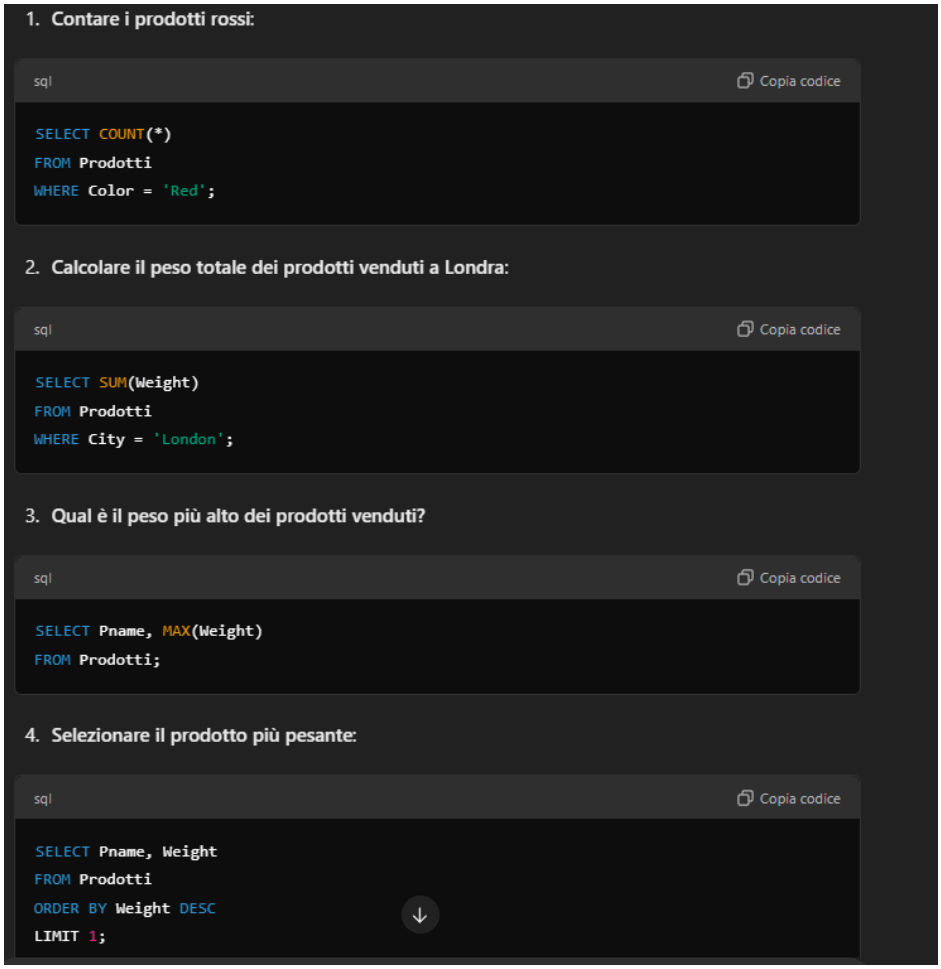

Cosa sono il raggruppamento e gli operatori aggregati?

1. Raggruppare le righe in base a un attributo comune (es. per categoria o reparto).
2. Applicare funzioni aggregate (es. somma, media, massimo, conteggio) a ciascun gruppo per sintetizzare i dati.

Esercizio

Obiettivo: Per ogni colore, contare quanti prodotti ci sono.

sql Copia codice

```sql
SELECT P.Color, COUNT(P.Pnum) AS NumeroProdotti
FROM P
GROUP BY P.Color;
```

- **P.Color:** Raggruppa i prodotti per colore.
- **COUNT(P.Pnum):** Conta il numero di prodotti per ogni colore.
- **GROUP BY P.Color:** Organizza i dati per colore.

Utilizziamo GROUP BY ogni volta che la richiesta inizia con 'per ogni'

Altro modo di raggruppare: La clausola HAVING consente di imporre una condizione sul risultato di una funzione aggregata

Esercizio

Obiettivo: Per ogni città con almeno 2 fornitori, indicare lo status totale.

sql Copia codice

```sql
SELECT City, SUM(status) AS StatusTotale
FROM S
GROUP BY City
HAVING COUNT(*) >= 2;
```

- **SUM(status):** Calcola il totale dello status per ogni città.
- **GROUP BY City:** Raggruppa i dati per città.
- **HAVING COUNT(*) >= 2:** Filtra i gruppi, mostrando solo quelli con almeno 2 fornitori.

Cosa sono le QUERY ANNIDATE e quando le usiamo? Le query annidate permettono di usare il risultato di una query come filtro o condizione per un'altra query.

Query annidate

- SELECT INTERNA produce tabella
- SELECT ESTERNA usa tale tabella come condizione
- RISULTATO è solo la tabella prodotta dalla select esterna

Query annidate

Seleziona il nome del prodotto piu' pesante

1. SELECT Max(Weight)
   FROM P)

2. SELECT Pname
   FROM P
   WHERE Weight=(query1)

   Query corretta

```
SELECT Pname
    FROM P
    WHERE Weight=(SELECT Max(Weight)
                  FROM P)
```

Query annidata

- **Seleziona i nomi dei fornitori il cui status supera la media dello status dei dipendenti**

```
Select AVG(status)
from S

select S.Sname
from S
where status>(Select AVG(status) from S)
```

Query annidata

- **Seleziona il nome dei prodotti il cui peso è inferiore alla media dello peso degli altri prodotti**

```
Select AVG(weight)
from P

select P.Pname
from P
where weight <(Select AVG(weight)
from P)
```

Come eliminare duplicati? SQL restituisce una tabella che contiene tutte le righe che soddisfano una certa condizione e può contenere duplicati. Per eliminare i duplicati utilizziamo DISTINCT accanto SELECT

Esempio: elenca i tipi di prodotti senza ripetizioni

```
SELECT DISTINCT PName
FROM P
ORDER BY PName ASC
```

Esempio: conta quante città diverse ci sono

```
SELECT COUNT (DISTINCT City)
FROM P
ORDER BY PName ASC
```

```
Dammi cognome e stipendio deli impiegati che lavorano a roma

SELECT impiegato.cognome, impiegato.stipendio
FROM  impiegato JOIN Dipartimento ON impiegato.Dipartimento = dipartimento.codice
WHERE Dipartimento.Sede= "roma"



Quanti brani vengono riprodotti in un concerto

SELECT concerto.id, COUNT (brano.codice)
FROM concerto JOIN rappresentato ON concerto.id = rappresentato.codice_concerto
JOIN Brano ON brano.codice = rappresentato.codice_brano
GROUP BY  concerto.id
```

2

Business Intelligence e Data warehouse

Facciamo una prima distinzione:

- Sistemi Informativi: Strutture che gestiscono informazioni per gli obiettivi di un'organizzazione (es. anagrafi, banche).
- Sistemi Informatici: Parte dei sistemi informativi che usa la tecnologia per automatizzare e migliorare la gestione dei dati.

La Piramide di Anthony, quali sono i Livelli Operativi? La piramide di Anthony classifica le operazioni aziendali in tre livelli:

1. Operative: Compiti quotidiani, come gestire ordini e magazzino, con dati in tempo reale.
2. Tattiche: Uso delle risorse per raggiungere obiettivi, con dati riassunti e stabili.
3. Strategiche: Pianificazione a lungo termine, con dati usati solo quando servono.

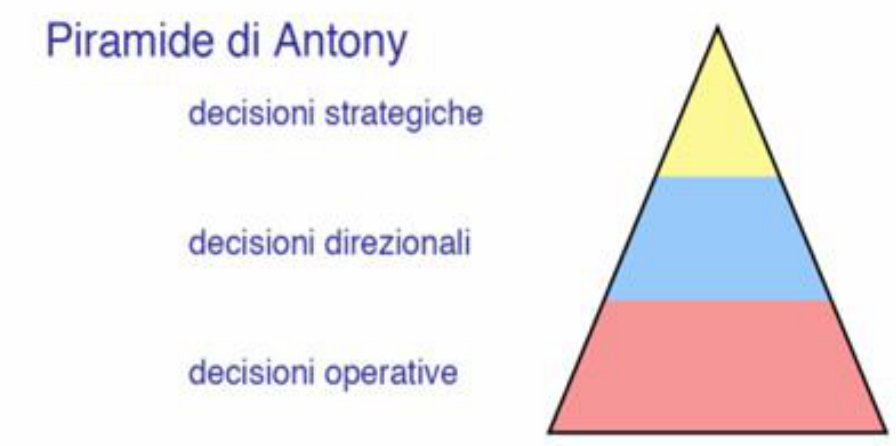

Business Intelligence (BI), che cos'è? La Business Intelligence è un insieme di processi e tecnologie che permettono di analizzare i dati aziendali e prendere decisioni strategiche:

- raccolta e strutturazione dati (data base)
- pulizia, validazione, integrazione (Data Warehouse)
- elaborazione, aggregazione, analisi (OLAP; Data Mining)

La motivazione principale? Offrire un vantaggio strategico nelle decisioni aziendali, come le promozioni di prodotto o l'offerta di contratti personalizzati.

Data Warehouse (DW): Cos'è e a cosa serve? Il Data Warehouse (DW) è come una base dati strutturata specificamente per supportare le decisioni aziendali, per la BI. Esso è progettato per aggregare e storicizzare informazioni che facilitino l'analisi.

Quali sono le Differenze tra Database (DB) e Data Warehouse (DW)? Il Database gestisce dati operativi in tempo reale, il Data Warehouse analizza dati storici per decisioni strategiche.

Tecnologie OLAP e Data Mining, Le due tecnologie chiave del DW.

1. OLAP (On-Line Analytical Processing): Permette l'analisi multidimensionale dei dati, utile per ottenere una visione strategica ed include operazioni come:
    - Drill-down/Roll-up: Per approfondire o sintetizzare i dati.

- Slice/Dice: Per selezionare e visualizzare porzioni specifiche di dati.

2. Data Mining: Strumenti avanzati che supportano decisioni aziendali più efficaci.

Cosa sono i Data Mart? In alcune organizzazioni, il DW si articola in Data Mart: sottosezioni del DW aziendale dedicate a specifici reparti, per analisi più focalizzate.

Riassunto...

Aspetti	Database operazionali	Data Warehouse
Utente	Progettista di sistema, amministratore di sistema, impiegato, addetto al data entry	Costruttore di decisioni, operatore della conoscenza, esecutivo
Funzione	Operazioni giornaliere, elaborazione della transazione on-line (OLTP)	Supporto alla decisione, elaborazione analitica on-line (OLAP)
Progetto di DB	Orientato all'applicazione	Orientato al soggetto
Dato	Corrente, aggiornato, atomico, relazionale (normalizzato), isolato	Storico, riassuntivo, denorm. multidimensionale, integrato
Uso	Ripetitivo, di routine	Ad hoc
Accesso	Transazione semplice di lettura/scrittura (solitamente coinvolge 1-3 tabelle)	Interrogazione complessa principalmente di lettura (coinvolge più tabelle)

2.1 Modello concettuale dei dati

Come è strutturato un Data Warehouse? Un DW raccoglie dati da varie fonti e li organizza per aiutare le aziende a prendere decisioni basate su dati concreti. Piuttosto che limitarsi a registrare le singole operazioni (come farebbe un database tradizionale). Il DW risponde a domande strategiche, come:

- "Qual è stato il fatturato l'anno scorso per ogni regione?"
- "Quale terapia ridurrà maggiormente il tempo di ricovero?".

Quando parliamo di Modello Multidimensionale? Un DW è strutturato in un modello multidimensionale, che rappresenta i dati come un cubo. Ogni asse di questo cubo rappresenta un aspetto diverso dell'analisi:

- si può avere un asse per il tempo (giorno, mese, anno)
- uno per il prodotto (tipo, categoria)
- uno per il luogo (città, regione).

Questo tipo di struttura permette di “guardare” i dati da prospettive diverse. È come se tagliassi il cubo in un punto per ottenere solo i dati che mi servono.

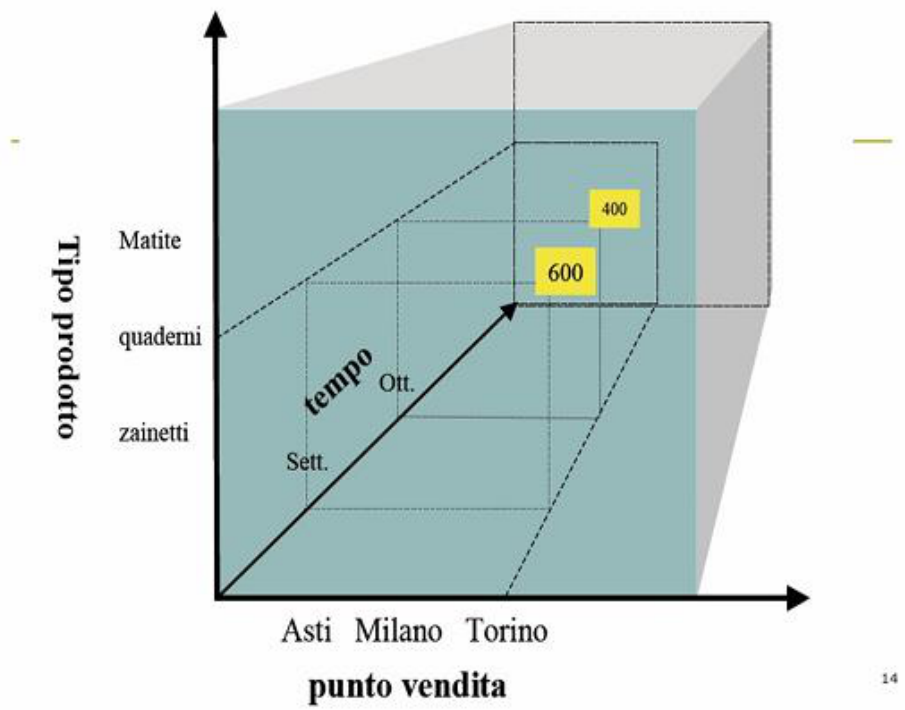

Possiamo identificare degli elementi chiave? Il modello multidimensionale è composto da alcuni elementi chiave:

- Fatti: sono gli eventi che interessano, come una vendita o una spedizione.
- Misure: sono valori numerici che quantificano i fatti, ad esempio il ricavo da una vendita o la quantità spedita.
- Dimensioni: descrivono vari aspetti o “coordinate” di analisi, come il periodo temporale o la località.

Tabella di fatto

punto vendita	tipo prodotto	valore del venduto
Torino	quaderni	1000
Milano	matite	1500
Torino	matite	700
Torino	zainetti	5000
Milano	quaderni	1400
Milano	zainetti	8000
Asti	zainetti	400

- Rappresentazione a matrice

Tabella delle Dimensioni su valore del venduto

tipo prodotto	punto vendita: Asti	Milano	Torino
matite	0	1500	700
quaderni	0	1400	1000
zainetti	400	8000	5000

2 possibilità di Modelli Concettuali nel DW, quali?

Modello a Stella: tutte le dimensioni (ad esempio, tempo, luogo e prodotto) sono collegate direttamente alla tabella dei fatti, che contiene gli eventi. È una struttura semplice e facile da usare.

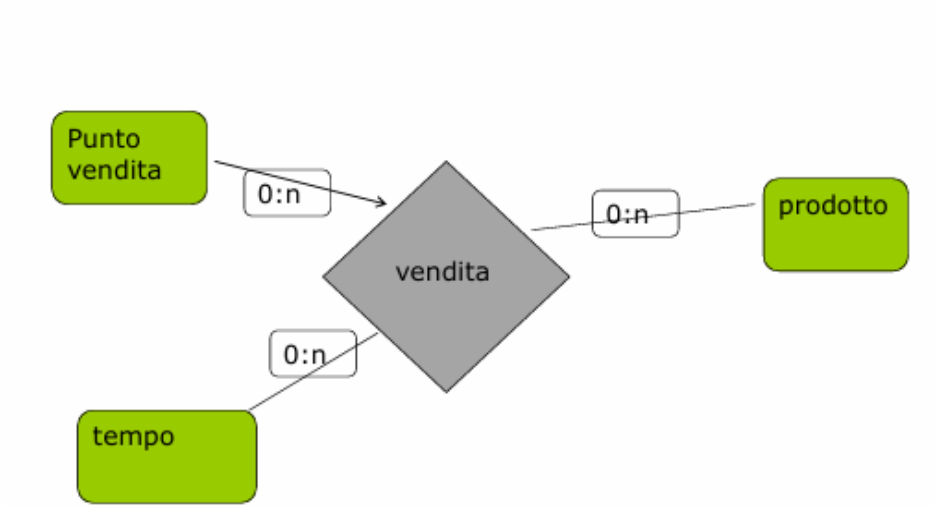

Modello a Fiocco di Neve: le dimensioni sono organizzate in modo gerarchico e sono collegate tra loro (per esempio, città, provincia, regione). Questa struttura è utile quando ci sono molte relazioni tra i dati e permette di rappresentare livelli di dettaglio più complessi.

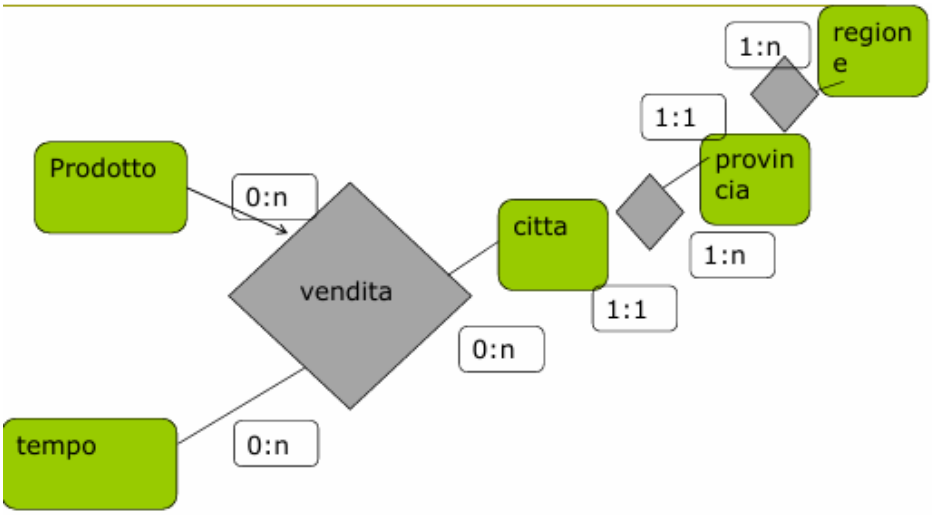

Cardinalità Nel fiocco di neve? Il più particolare 1,1 / il generale 1, N

Città (1,1) ——— (1,N) Provincia

Caratteristiche del modello Stella

1. Struttura. Ha una struttura semplice con una tabella centrale dei fatti collegata direttamente alle tabelle di dimensione.

2. Normalizzazione. Le tabelle di dimensione non sono normalizzate (contengono dati ridondanti), il che facilita la lettura e migliora la velocità di accesso.
3. Complessità. È più semplice da progettare e comprendere perché ha meno tabelle e relazioni.
4. Performance di Query. Ha performance migliori per le query, poiché non richiede molte join tra tabelle.
5. Manutenzione. È più facile da mantenere grazie al minor numero di tabelle e dipendenze.
6. Uso dei Dati. Ideale per scenari in cui si preferisce la velocità e la semplicità, come nei data warehouse orientati alle analisi.

Caratteristiche del modello Fiocco di Neve

1. Struttura. Normalizza le tabelle di dimensione; alcune dimensioni sono suddivise in più tabelle, creando una struttura più complessa.
2. Normalizzazione. Le tabelle di dimensione sono normalizzate, riducendo la ridondanza dei dati e risparmiando spazio.
3. Complessità. È più complesso, con più tabelle e connessioni, rendendo il modello più difficile da navigare e gestire.
4. Performance di Query. Le query possono essere più lente a causa delle molteplici join necessarie per recuperare i dati dalle tabelle normalizzate.
5. Manutenzione. Richiede più sforzo di manutenzione a causa della maggiore complessità e del numero di tabelle.
6. Uso dei Dati. Utilizzato quando è necessario ottimizzare lo spazio di archiviazione e gestire dimensioni grandi e complesse.

Cos'è Il Dot Model? Il Dot Model è un modo semplice e visivo per rappresentare i dati di un Data Warehouse, è utile per vedere a colpo d'occhio come sono organizzati i dati e per capire da quali angolazioni puoi esplorarli, in modo molto semplice e visivo.

- Fatti: Gli eventi principali (es. vendite) sono al centro.
- Dimensioni: Le prospettive per analizzarli (es. tempo, luogo, prodotto) sono intorno.

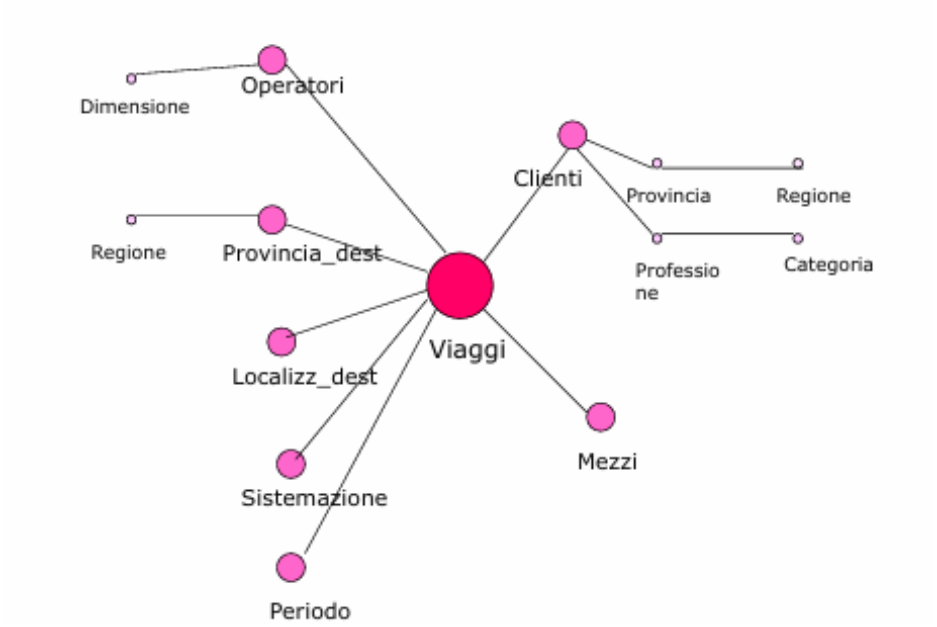

2.2 Datawarehouse: Progettazione logica

1) Modello a stella implementato

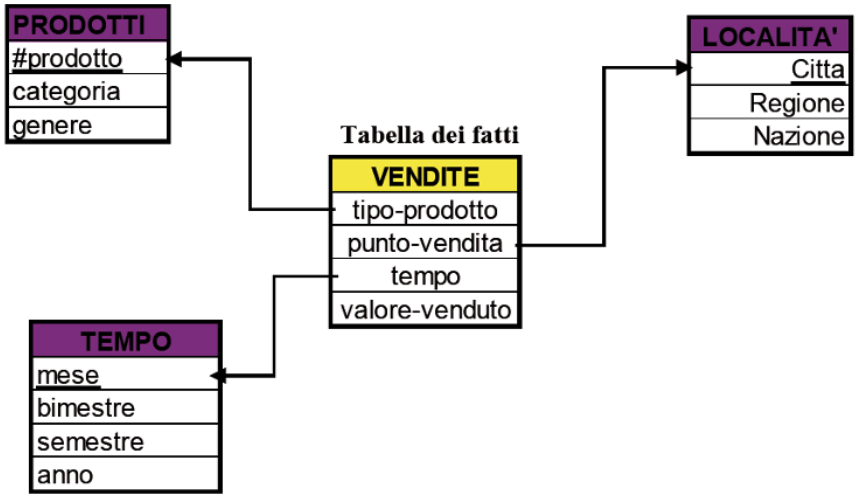

2) Modello a snowflake

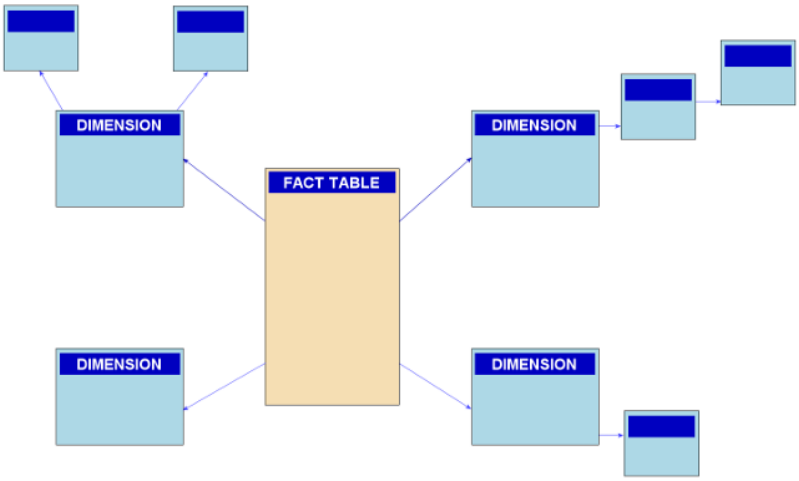

Schema snowflake di Vendite

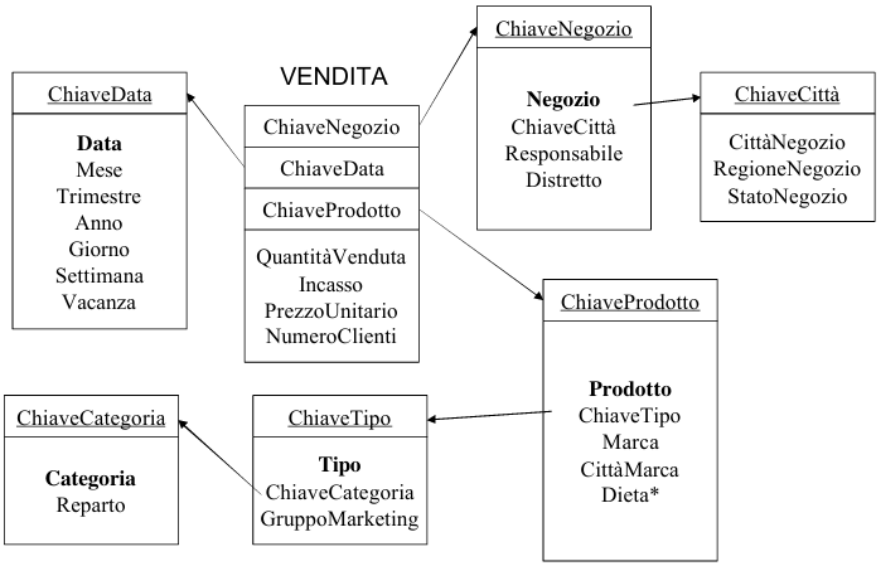

Data normalisation, cosa significa? Obiettivo:

1. Eliminare le duplicazioni non necessarie di dati (ridondanze)
2. Eliminare le dipendenze funzionali tra gli attributi

Ma cosa sono le dipendenze funzionali? Ogni volta che due clienti vivono

nella stessa città, allora vivono anche la stessa regione

- Cliente (città, regione)
- Città[torino] = regione[piemonte]

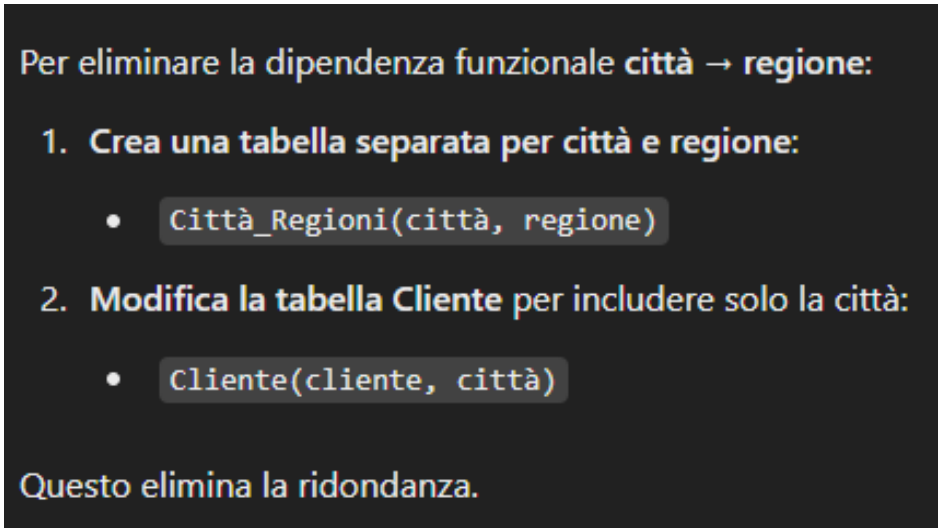

2.3 Data warehouse, regole essenziali

- Dimensioni: Almeno 3, con tabelle di 5-6 righe.
- Tempo: Usalo come dimensione o attributo nei fatti.
- Gerarchia: Aggiungi almeno una, anche condivisa.
- Modello: Modificabile, aggiungi attributi per analisi (es. sesso, età).
- Misure:
  - Concettuale: Tutte nella tabella dei fatti.
  - Logico: Solo misure unitarie, calcoli con Excel OLAP.
- Consegna:
  - Dump in .SQL.
  - Tabella dei fatti in .CSV per analisi.

2.4 Operatori OLAP

Differenza tra OLTP e OLAP:

- OLTP: Gestisce transazioni quotidiane (es. inserimento, aggiornamento, cancellazione) con query SQL per informazioni specifiche.
- OLAP: Si occupa di analisi complesse e multidimensionali, utili per decisioni strategiche, con focus su aggregazione e segmentazione dei dati.

2.5 Operazioni OLAP

Gli operatori OLAP sono strumenti essenziali per fare analisi su dati multidimensionali. Ecco le principali operazioni:

1. Drill-Down
    - Cosa fa: Approfondisce il livello di dettaglio.
    - Esempio: Da vendite mensili → vendite giornaliere.
    - Quando si usa: Quando si vuole esaminare dati più specifici.
2. Roll-Up
    - Cosa fa: Aggrega i dati a un livello superiore.
    - Esempio: Da vendite giornaliere → vendite mensili.
    - Quando si usa: Per avere una visione più generale.
3. Slice
    - Cosa fa: Isola un "pezzo" specifico di dati lungo una dimensione.
    - Esempio: Vendite solo nel mese di gennaio.
    - Quando si usa: Per analizzare una specifica sezione dei dati.
4. Dice
    - Cosa fa: Filtra i dati su due o più dimensioni contemporaneamente.
    - Esempio: Vendite di gennaio per un particolare prodotto e in una regione specifica.
    - Quando si usa: Per analisi più mirate e complesse.
5. Push
    - Cosa fa: trasforma una dimensione in una misura

- Esempio: prodotto → diventa misura: conteggio dei diversi tipi di prodotti venduti per città e mese

6. Pull
    - Cosa fa: inverso del push, trasforma una misura in una dimensione (poco usato)
    - Esempio: la misura ricavi diventa una dimensione: conteggio dei prodotti venduti per città e per ricavi

3

Data mining

Che cos'è? È la risposta tecnologica all'esigenza di saper ricavare conoscenze utili, dalle enormi quantità di dati grezzi che si raccolgono ormai in tutti i contesti sociali.

Esempio → Solo il database del settore consegne della UPS ha una dimensione di 17 Tera-Byte. Questi dati vanno analizzati sia per capire come migliorare il servizio ai clienti, sia per migliorare l'efficienza interna dell'azienda

Distinzione tra Modello e Regola.

- Modello: Ti aiuta a capire come funziona qualcosa, mostra la relazione tra vari elementi. Esempio → Un modello che spiega come il livello di istruzione e il tipo di lavoro influenzano il reddito.
- Regola: Ti dice cosa fare per ottenere un risultato, senza spiegarti il perché. Esempio → Una rete neurale che ti predice il reddito basandosi su dati, ma non ti spiega come arriva al risultato.

Definizione di data mining, quale è?

"Il processo non banale di identificare schemi di dati che siano validi, nuovi, potenzialmente utili e, in ultima analisi, comprensibili."

Il data mining scopre modelli nei dati che sono nuovi, basati su matematica o statistica, utili per decisioni pratiche e facilmente interpretabili.

Esempio "banca"

La banca vuole concedere prestiti solo ai clienti che si prevede pagheranno le rate regolarmente. Per fare ciò, utilizza i dati storici dei prestiti precedenti, analizzando quali clienti hanno rispettato i pagamenti e quali no. Attraverso questi dati, la banca può individuare dei pattern o regole che aiutano a prevedere il comportamento di nuovi clienti. Questi pattern sono modelli

basati su informazioni passate che forniscono indicazioni utili per decidere se approvare o meno un prestito.

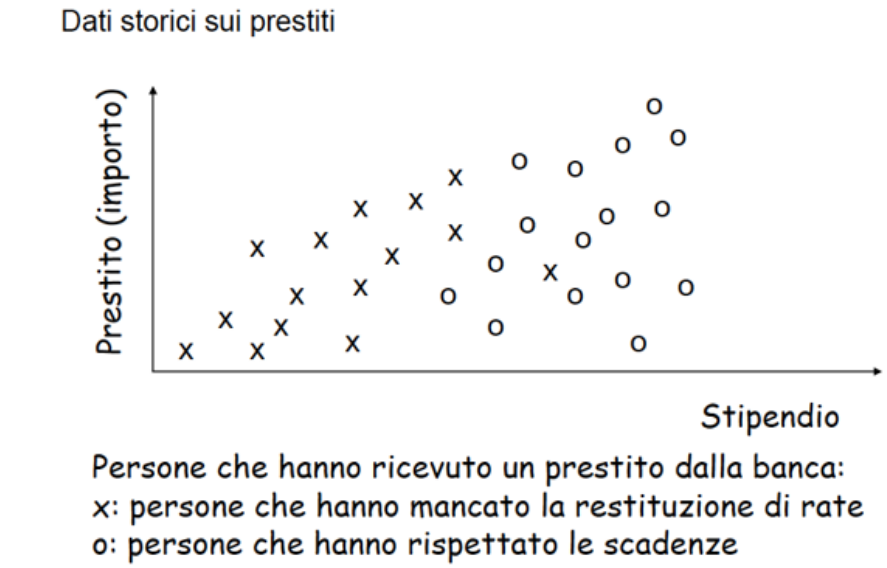

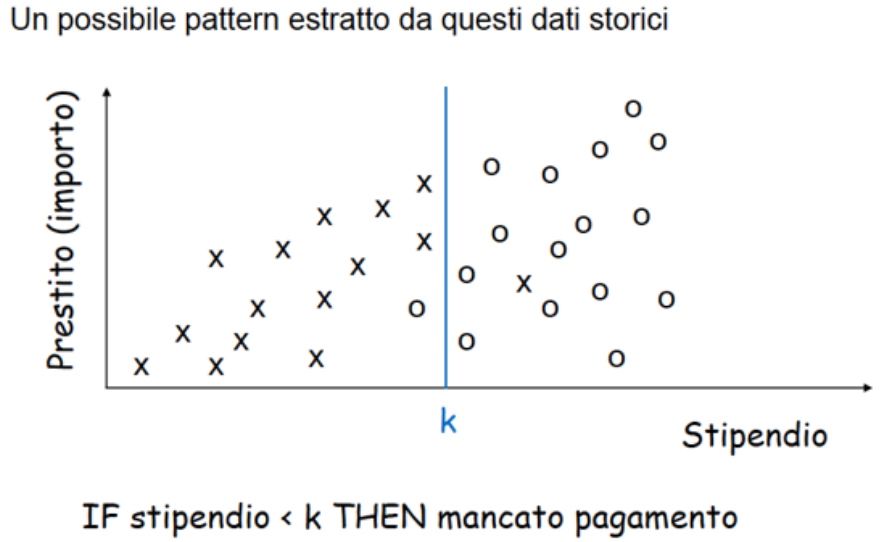

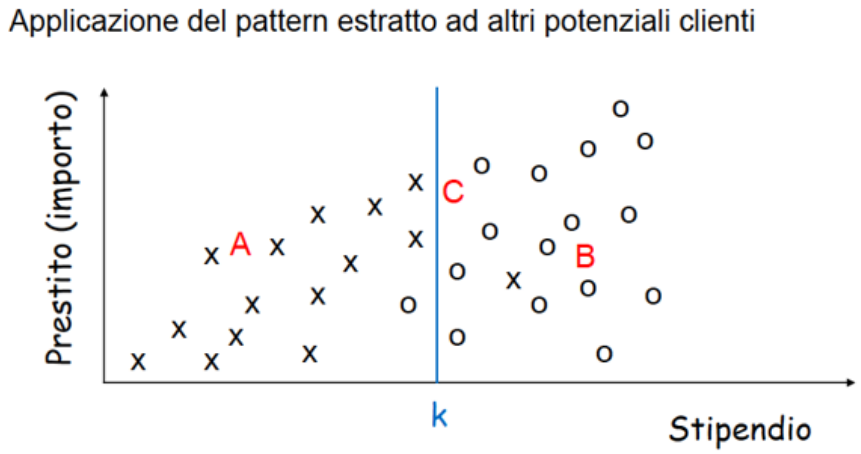

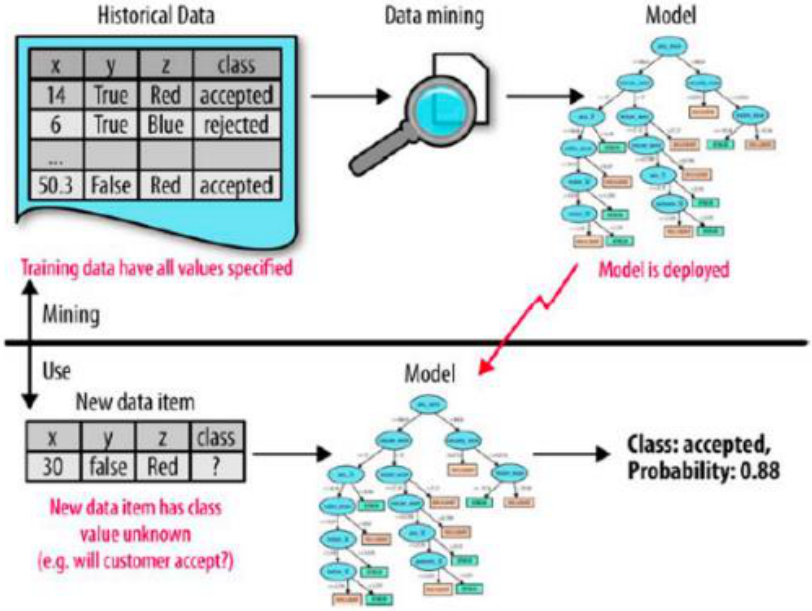

Obiettivi:

- Descrittivo: classificare, individuare gruppi in un insieme di dati la cui struttura non è visibile
- Esplicativo: Spiegare (insight), trovare modelli esplicativi (i fattori legati ad un fenomeno, correlazioni)
- Predittivo: fare previsioni sul futuro, sul valore di variabili

Le tecniche di data mining, quali sono? Il data mining serve a trasformare i dati in informazioni utili e può essere usato in due modi:

1. Non supervisionato: Lo usi quando non sai cosa cercare, analizza i dati per trovare schemi o gruppi nascosti. Esempio: Scoprire clienti con comportamenti simili.
2. Supervisionato: Lo usi quando hai un obiettivo specifico, come prevedere un risultato.
    - Classificazione: Prevede categorie (es. "cliente fedele" o "cliente a rischio").
    - Regressione: Prevede numeri (es. "quante vendite avremo il mese prossimo?").

- Supervisionato: L'algoritmo impara da esempi con risposte note.
- Non supervisionato: L'algoritmo esplora i dati per scoprire da solo schemi o gruppi.

3.1 Task supervisionati

Obiettivi

- Classificazione
- Stima
- Previsione

Tecniche di data mining

- Alberi decisionali
- Reti neurali

1. Stima (Regressione)

   Serve per calcolare numeri precisi, come il reddito di una persona o il prezzo di una casa, usando i dati già esistenti per fare previsioni.

2. Classificazione

   Mette persone o oggetti in gruppi predefiniti. Esempio → Dire se un cliente è "fedele" o "a rischio", o se un prodotto è "premium" o "base".

3. Previsione

Sia la stima che la classificazione aiutano a fare previsioni sul futuro. Un esempio è prevedere se un cliente disdirà un abbonamento, utilizzando i dati passati per anticipare comportamenti futuri.

3.2 Task NON supervisionati

Non c'è alcuna variabile target da prevedere

Obiettivi:

- raggruppare
- Scoprire associazioni tra variabili

Tecniche di data mining:

- Cluster
- Regole di associazione

Clustering, che cos'è? l clustering è un metodo per creare gruppi di elementi simili basandosi sui dati. Non ci sono categorie già decise, l'algoritmo trova i gruppi da solo. Dopo, spetta a chi analizza i dati capire cosa rappresentano i gruppi trovati. Lo strumento principale per applicare il clustering è la cluster analysis.

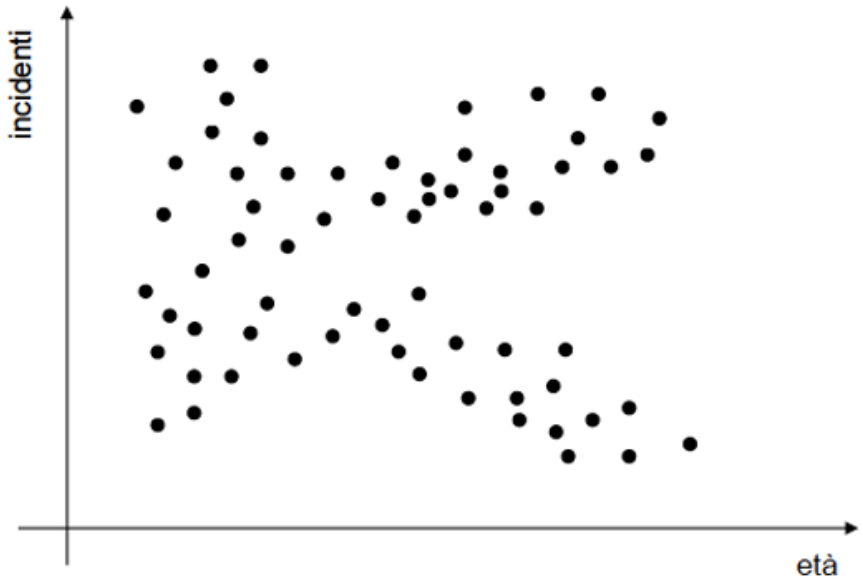

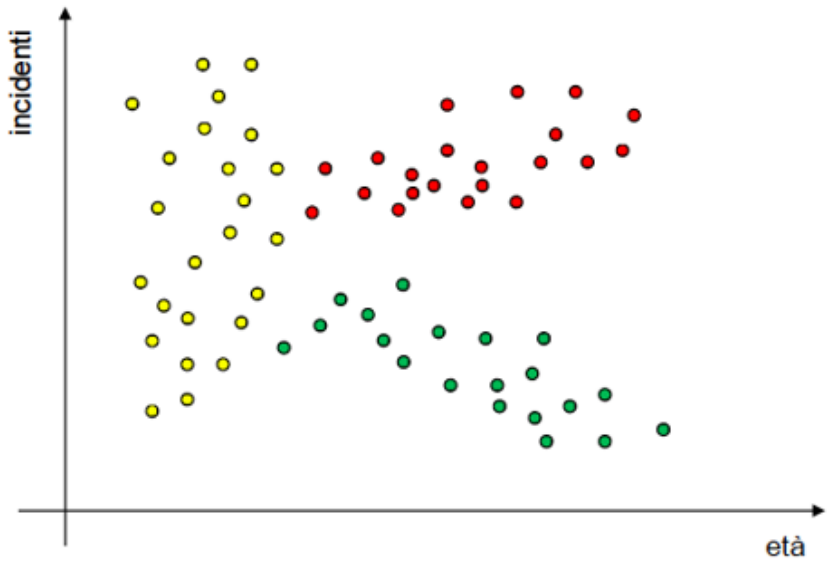

Le Regole di associazione

L'analisi dei dati permette ad esempio di identificare quali oggetti o prodotti vengono spesso acquistati insieme, come avviene nella Market Basket Analysis. Questa informazione è utile per ottimizzare la disposizione dei prodotti sugli scaffali, posizionandoli vicini per facilitare l'acquisto combinato. Inoltre, si analizzano le sequenze di acquisto per capire il comportamento dei clienti nel tempo.

3.3 Contesto applicativo e contesto aziendale

Data mining: quale è il contesto applicativo? Alcuni esempi

- Marketing: analisi del comportamento d'acquisto, per segmentare clienti, focalizzare le offerte su clienti migliori
- Machine learning (AI): far apprendere le macchine da esempi

Data mining: contesto aziendale

Un'informazione è utile se il valore che genera supera il costo sostenuto per ottenerla.

Il data mining è un processo per risolvere problemi decisionali in modo (ragionevolmente) consistente, ripetibile e oggettivo

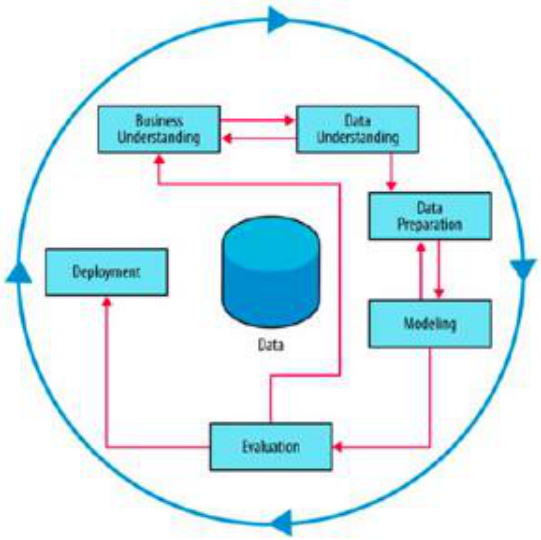

In sintesi

Il processo di data mining → Si puliscono i dati, si analizzano per creare un modello affidabile e comprensibile, e i risultati vengono presentati per decisioni pratiche.

4

Cluster Analysis

Che cos'è? La Cluster Analysis è una tecnica di data mining non supervisionato. Consiste nel suddividere un insieme di dati i in sottogruppi, chiamati cluster. A differenza della classificazione, il clustering non si basa su classi predefinite, ma identifica gruppi direttamente dai dati.

Esempio → il raggruppamento di utenti in base agli acquisti di materiale video e audio per identificare diverse sottoculture.

Finalità della cluster analysis/3

Extract Common Features:
- Sex
- Glasses
- Smile
- Hat
- Moustache

a) Al fine di chiarirsi le idee e meglio comunicarle (riduzione dei dati);
b) Per scoprire nuovi soggetti di ricerca (oulier o gruppi particolari);
c) Per pianificare una struttura organizzativa (zoning territoriale);
d) Per stabilire un elenco di riscontro (verifica di ipotesi);
e) Per definire particulari profili di entità;
f) Perché si hanno dei dati e qualcosa bisogna pur farne.

Cluster naturali

Kruskal (1977):" ... We call clusters natural if the membership is determined fairly well in a natural way by the data, and we call the clusters arbitrary if there is a substantial arbitrary element in the assignment process".

Clustering is subjective

Cluster naturali/2

Ad esempio le carte di un mazzo francese si raggruppano per seme se si gioca a Bridge, ma si raggruppano per valore se si gioca a Ramino.

Poiché i risultati sono influenzati sia dall'obiettivo della indagine che dal contesto applicativo, occorre effettuare delle scelte che individuino la procedura più adatta.

La scelta delle variabili da usare per la clustering determina il tipo di cluster che otteniamo

Quando utilizziamo la cluster analysis? La Cluster Analysis è utilizzata per raggruppare dati con caratteristiche simili. È una tecnica fondamentale per

suddividere dataset complessi in sottogruppi più semplici.

Esempi di applicazioni

- Marketing: Identifica segmenti distinti nella clientela per campagne mirate.
- Assicurazioni: Segmenta il portafoglio clienti per ottimizzare il marketing mirato.

Che scopo abbiamo? L'obiettivo è semplificare dataset complessi per permettere alle tecniche di data mining supervisionato di lavorare meglio. È fondamentale scegliere un numero appropriato di cluster (k):

- k troppo basso (es. 1)
- k troppo alto (pari al numero di record) non è utile.

4.1 K-means

K-means, che cos'è? (dati numerici) Il k-means è un algoritmo di clustering che divide i dati in un numero definito di gruppi (k), rendendo i punti dello stesso cluster il più simili possibile tra loro e diversi da quelli degli altri cluster.

Nota Il termine "means" si riferisce alla media statistica.

Come funziona il k-means? Ecco i 5 passi del clustering con k-means:

1. Scegliere il numero di cluster (k): Decidi quanti gruppi vuoi creare.
2. Inizializzare i centroidi: Seleziona casualmente k punti dal dataset come centroidi iniziali.
3. Calcolare la distanza geometrica: Per ogni punto del dataset, calcola la distanza da ciascun centroide.
4. Assegnare il punto al cluster più vicino: Ogni punto viene assegnato al cluster del centroide più vicino.
5. Calcolare il punto medio del cluster: Per ogni cluster, ricalcola il centroide come media dei punti assegnati.

(Ripeti i passaggi 3-5 fino a quando i centroidi non cambiano più o si raggiunge un criterio di stop).

Nota

- Confini fissi: Ogni punto appartiene al cluster più vicino

- Minimizza errore quadratico medio: ottimizza la compattezza dei cluster.

Focus Il centroide è il punto che sta nel mezzo di un gruppo. Si calcola facendo la media dei valori di tutti i punti del gruppo ed è usato per capire a quale gruppo appartengono gli altri punti.

Per quanto riguarda le distanze, quali conosciamo?

1. Distanza euclidea: Misura la distanza "in linea retta" tra due punti, come se si potesse attraversare tutto direttamente.
2. Distanza di Manhattan (o Taxi): Misura la distanza seguendo percorsi a griglia, come farebbe un taxi in una città con strade che si incrociano, cercando il percorso minimo come fa il navigatore.

Figura 1: Distribuzione dei dati nello spazio X1,X2

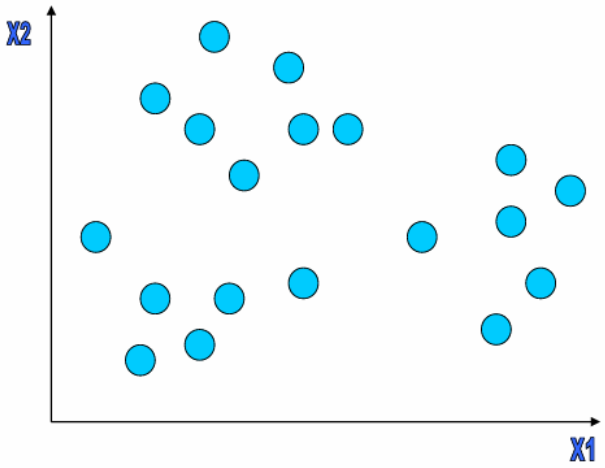

Passo 1: scegliamo k=3 e i seguenti semi iniziali:

Figura 2: Semi dei Cluster iniziali

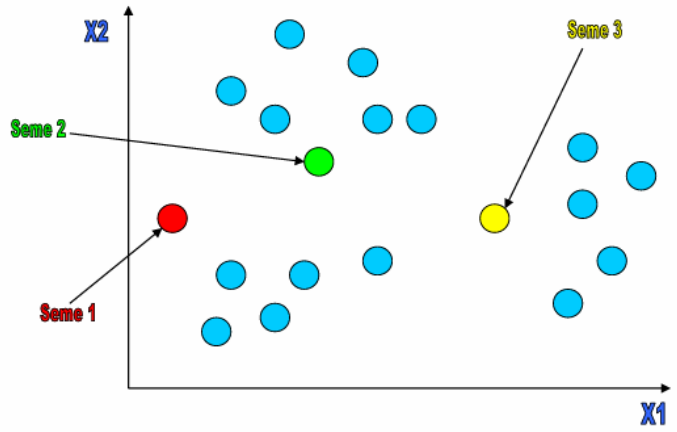

Passo 2: Assegniamo ogni record al cluster con il centroide (o seme) più vicino

Figura 3: Confini dei Cluster iniziali

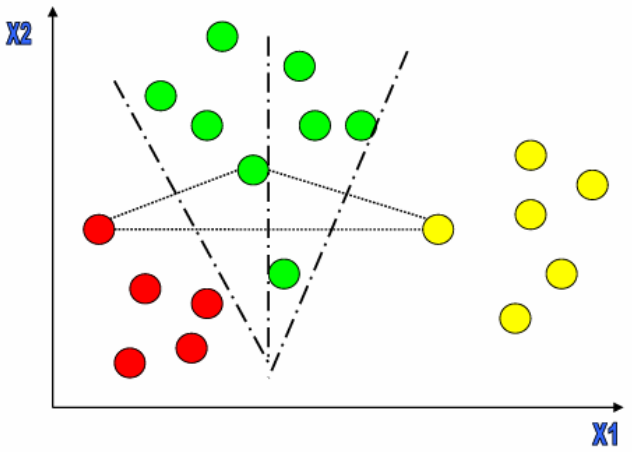

Passo 3: Il passo due ha individuato nuovi cluster. Ci calcoliamo i centroidi (o semi) di questi

Figura 4: I nuovi Semi dopo una iterazione

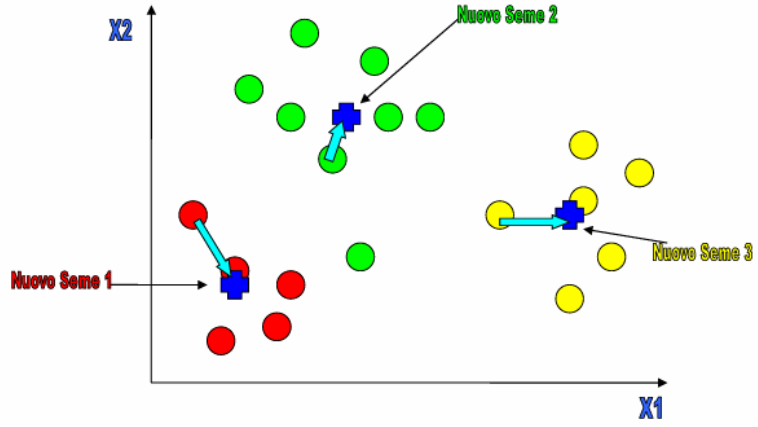

Passo 2:Riaggrego ogni record al cluster di centroide più vicino. Notare cosa succede a un dato

Un dato inizialmente assegnato al cluster 2, nella seconda iterazione viene assegnato al cluster 3

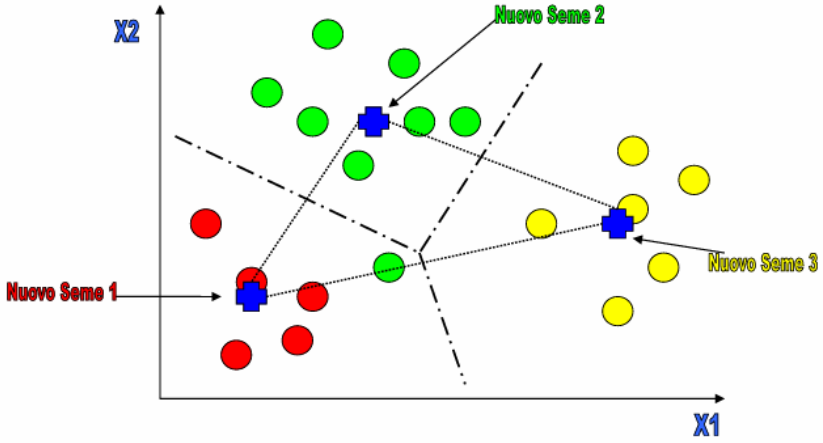

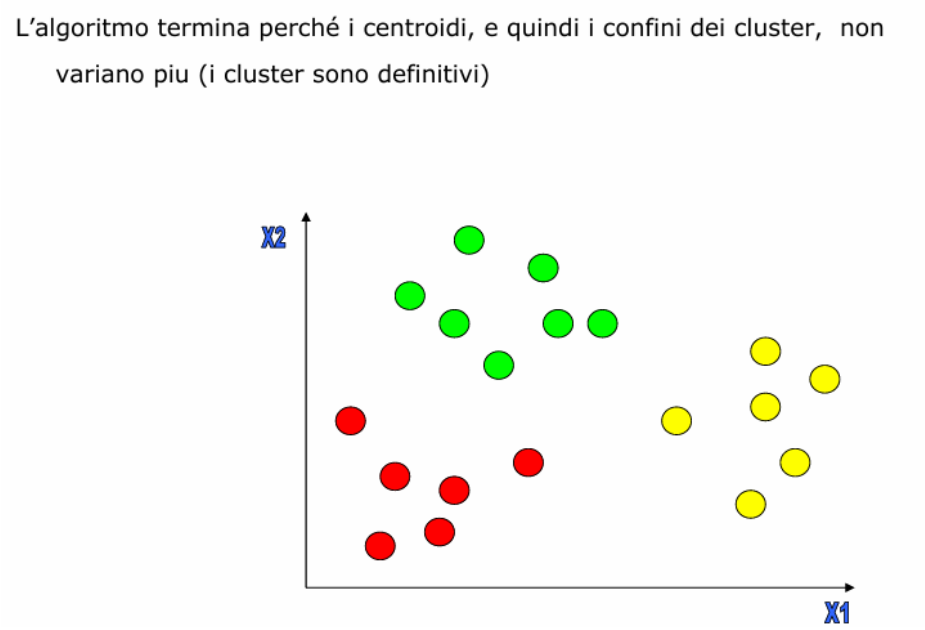

4.2 Il problema del k-means

Quale è il Problema del k-means? Il principale limite dell'algoritmo k-means è la scelta del numero di cluster, che deve essere impostato dall'utente. Se k non riflette la struttura naturale dei dati, i risultati saranno poco significativi.

Esempio.

Immagina di avere un gruppo di 100 persone, suddivise in 3 gruppi:

- famiglia
- gruppo di amici
- colleghi di lavoro.

Se imposti k = 2 (cioè, chiedi all'algoritmo di trovare solo 2 gruppi), l'algoritmo potrebbe erroneamente combinare la famiglia e i colleghi in un unico cluster, ignorando la vera struttura dei dati, e quindi i risultati non sarebbero utili o corretti.

Focus Alcuni software aiutano nella selezione ottimale di k, ad esempio tramite il metodo del "gomito," che individua il punto oltre il quale aumentare il numero di cluster non porta miglioramenti significativi.

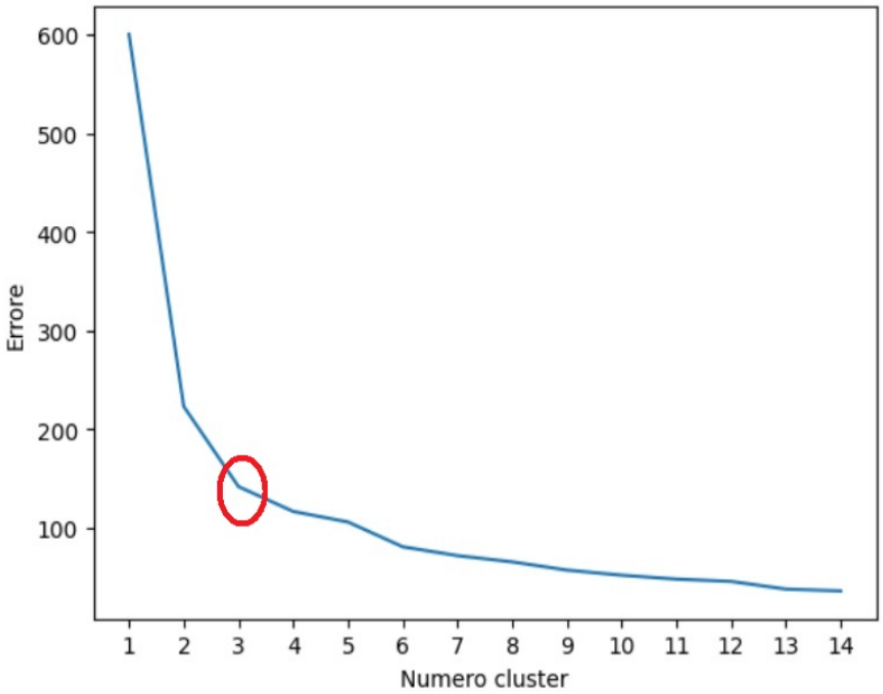

L'obiettivo? è trovare un k che bilanci un basso errore senza creare troppi cluster.

- Con k=1, tutti i punti sono in un unico cluster; quindi, l'errore quadratico medio è alto perché molti punti sono lontani dal centroide
- Aumentando k, i cluster diventano più specifici e l'errore si riduce.

Quando abbiamo un buon cluster? l miglior cluster è quello in cui

- i membri sono il più simili possibile tra loro (distanza minima interna)
- i membri sono il più diversi dagli altri cluster (distanza massima esterna).

In conclusione...

Il rilevamento dei cluster è utile quando non si conosce la struttura dei dati. Essendo non supervisionato, trova gruppi basandosi sulla distribuzione, ma interpretarli e usarli può essere complicato.

Vantaggi e limiti

Il k-means è un algoritmo di clustering semplice ed efficiente, con complessità O(tkn), dove n è il numero di record, k il numero di cluster, e t le iterazioni. È rapido e facile da implementare, ma presenta alcuni limiti:

- funziona solo con dati numerici (media definita),
- richiede di specificare a priori k,
- i risultati necessitano di interpretazione.

4.3 Introduzione ai Cluster Gerarchici

Obiettivo? Identificare gruppi omogenei di dati attraverso tecniche di clustering.

Ricordiamo → il clustering è un processo di classificazione basato su vicinanza o similarità.

Quali Tipi di Attributi troviamo nei Dataset?

1. Attributi Numerici:
   - Possiedono un criterio di ordinamento naturale.
   - Proprietà geometriche ben definite.
   - Distanze calcolabili tramite metodi classici come la distanza euclidea.
2. Attributi Categorici:
   - Nessun criterio di ordinamento predefinito.
   - Proprietà geometriche soggettive.
   - Necessità di sviluppare nuovi metodi di calcolo delle distanze, basati sulla similarità.

Quali sono gli Algoritmi di Clustering per Dati Categorici?

1. k-modes:

   è un'estensione del k-means per dati categorici. Utilizza la moda come rappresentante del cluster, calcolando la distanza basandosi sulle differenze tra attributi.

2. k-prototypes:

   questo algoritmo combina k-means e k-modes, poiché gestisce dataset misti con attributi sia numerici che categorici.

Nota La distanza tra due elementi in un dataset viene calcolata combinando:

- Distanza euclidea per attributi numerici.

- Mismatch per attributi categorici.

Analizziamo dei metodi di Clustering Gerarchico.

Approccio Aggregativi (agglomerativi): Parto da n cluster (ogni oggetto è un cluster) & uniscono progressivamente i cluster più vicini fino a ottenere un unico cluster.

Approccio Divisivi (scissori): Contrariamente, parte da un unico cluster & suddivide iterativamente fino a ottenere n cluster singoli.

Criteri di Aggregazione nei Metodi Gerarchici

Legame Singolo → Distanza minima tra elementi di cluster differenti.

Legame Completo → Distanza massima tra elementi di cluster differenti.

Legame Medio → Media aritmetica delle distanze tra tutti i membri dei cluster.

Metodo del Centroide → Si applica solo a variabili quantitative & calcola la distanza tra i baricentri dei cluster.

il Dendrogramma, che cos'è? Il dendrogramma è un grafico che mostra come vengono formati i gruppi (cluster) durante un'analisi.

- Asse X: Le unità (persone, oggetti, ecc.) o i gruppi creati.
- Asse Y: La distanza tra le unità o i gruppi.

Come si usa? Guardi a che altezza (asse Y) separare il dendrogramma per ottenere gruppi. Più in alto tagli, meno gruppi ci saranno.

Esempio: Se tagli a metà del dendrogramma, potresti ottenere 3 gruppi. Se tagli più in basso, potresti averne 5. Il punto di taglio dipende da quanti cluster ti servono.

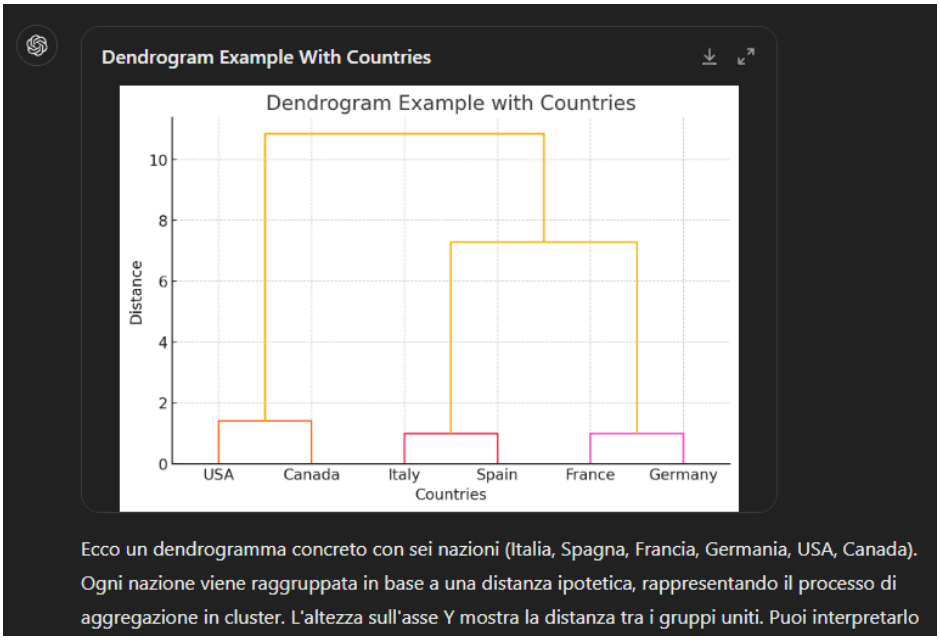

4.4 Logica del k-modes

Logica del k-modes: spiegazione semplice

Come funziona? Il k-modes è un algoritmo di clustering usato per raggruppare dati categorici.

L'obiettivo? è mettere insieme elementi simili in base ai loro attributi.

Perché è utile? Molti dataset reali contengono attributi non numerici (es. colore, tipo di prodotto, categoria).

Che passi segue?

1. Inizializzazione: Sceglie casualmente i primi k oggetti come rappresentanti iniziali dei cluster (chiamati "mode").
2. Assegnazione:
   - Per ogni elemento del dataset, calcola quanto è diverso (o "distante") da ciascun cluster.
   - Distanza = numero di attributi diversi tra l'elemento e la "mode" del cluster.
   - Assegna l'elemento al cluster più vicino (con meno differenze).
3. Aggiornamento delle mode:

Dopo ogni assegnazione, la moda del cluster viene aggiornata. La nuova mode è calcolata trovando il valore più comune (la moda) per ogni attributo tra gli elementi del cluster.

4. Ripeti:

   Continua a riassegnare gli elementi ai cluster e aggiornare le mode fino a quando non ci sono più cambiamenti.

Che problemi risolve? Adatta un algoritmo noto (k-means) per lavorare su dati non numerici.

4.5 Considerazioni Finali

- k-modes per dati categorici puri.
- k-prototypes per dati misti.
- Metodi gerarchici per una rappresentazione più visiva (dendrogrammi) e per trovare relazioni gerarchiche nei dati.

Il k-means è stato pensato per creare cluster in modo più semplice e veloce rispetto al dendrogramma. Invece di unire i dati passo dopo passo, come fa il dendrogramma, il k-means divide direttamente i dati in k gruppi, rendendolo ideale per dataset grandi.

5

Alberi Decisionali

Che cos'è? è un modello usato per prendere decisioni o classificare dati. Si presenta come una struttura ad albero dove:

- Nodi interni: rappresentano domande basate su una variabile.
- Rami: indicano le possibili risposte o valori delle variabili.
- Foglie: contengono la decisione finale o la classe prevista.
- Cammino: è la sequenza di regole dal nodo iniziale (radice) alla foglia.

Come funziona?

1. Si parte da un insieme di dati noti (training set) con esempi già classificati.
2. L'albero viene costruito ponendo domande (nodi) per suddividere i dati in base ai valori delle variabili.
3. Ogni cammino nell'albero rappresenta una regola del tipo: "Se... allora...".

Esempio:

- Se ruote = 4 e motore = sì, allora è un'auto.
- Se ruote = 2 e motore = no, allora è una bici.

Gli Elementi principali?

- Input (Dati in ingresso):

  Ad esempio: Un oggetto ha ruote = 4 e motore = sì.

  nota → ogni esempio ha una "classe" già nota (come auto, moto, bici).

- Output (Risultato):

  L'albero decide a quale classe appartiene un oggetto nuovo basandosi sulle regole. Ad esempio: Se ruote = 4 e motore = sì, l'output è "auto".

In breve, L'albero usa i dati in ingresso (input) per imparare le regole che collegano le caratteristiche alla classe corretta. Poi applica queste regole per classificare nuovi oggetti.

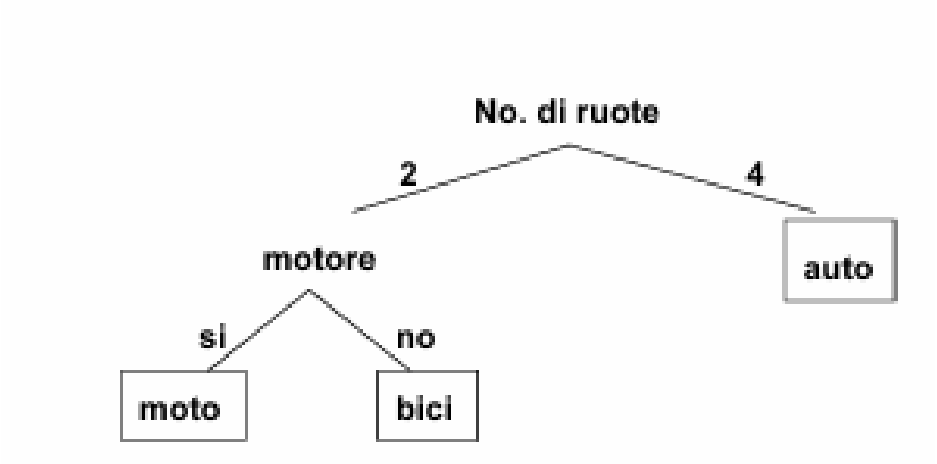

5.1 L'Entropia

L'Entropia (misura del disordine), cos'è? L'entropia, che misura quanto i dati in un nodo sono disordinati.

- È alta quando le classi sono distribuite in modo uniforme (es. 50%-50%).
- È bassa quando i dati sono più omogenei (es. 100% di una sola classe).

Quale attributo è migliore? Un attributo che crea nodi con classi molto omogenee (bassa entropia) è considerato migliore. il guadagno di informazione ci aiuta a scegliere l'attributo che più "ordina" i dati in ogni passo dell'albero decisionale.

Esempio:

1. Nodo iniziale: Se le classi sono distribuite 50%-50%, l'entropia è massima (poco informativa).
2. Suddivisione: Un attributo che divide i dati in modo efficace (nodi con classi più pure) riduce l'entropia e porta a un alto guadagno di informazione.

L'overfitting, cos'è? è quando un modello impara troppo dai dettagli e dal rumore nei dati di allenamento, diventando incapace di funzionare bene con dati nuovi.

Quale è il Legame con l'entropia? L'entropia rappresenta il disordine nei dati. Ridurla troppo può portare il modello a concentrarsi su dettagli inutili, creando overfitting.

5.2 L'Algoritmo ID3

Cosa fa? L'algoritmo ID3 costruisce un albero decisionale scegliendo gli attributi che massimizzano il guadagno di informazione. Parte dal nodo radice e divide i dati iterativamente, selezionando ogni volta l'attributo che meglio separa le classi, fino a ottenere nodi puri o soddisfare un criterio di arresto.

Quale attributo è migliore? Una buona "domanda" in un albero decisionale è quella che divide i dati in gruppi più simili tra loro rispetto al punto di partenza.

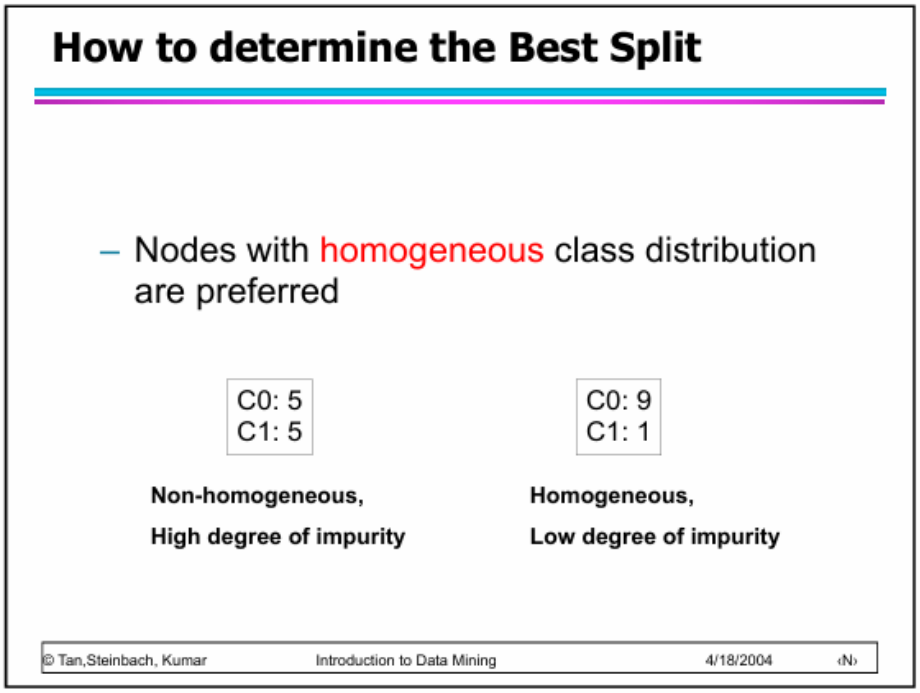

5.3 Il modello predittivo

Cosa significa creare un modello predittivo? Creare un modello predittivo significa usare un insieme di dati per insegnare al modello a fare previsioni, L'obiettivo è fare previsioni corrette per nuovi dati nel modo più preciso possibile.

I dati iniziali vengono divisi in:

- Training set: Serve per costruire il modello.
- Test set: Serve per verificare quanto funziona bene.

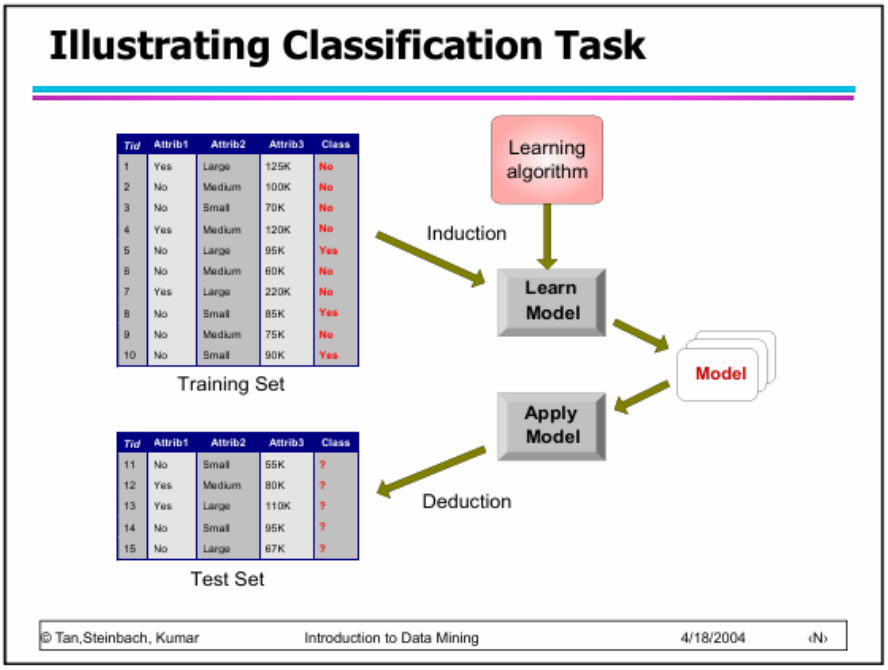

Example of a Decision Tree

Tid	Refund (categorical)	Marital Status (categorical)	Taxable Income (continuous)	Cheat (class)
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Training Data

ESEMPIO 2

Input

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

[See: Tom M. Mitchell, *Machine Learning*, McGraw-Hill, 1997]

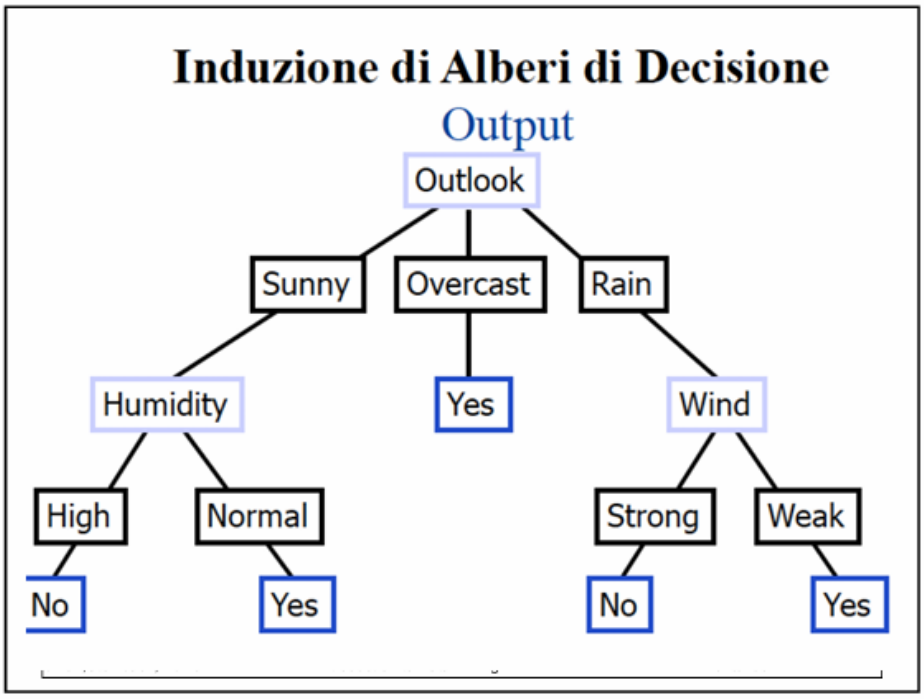
Induzione di Alberi di Decisione
Output
Outlook
Sunny
Overcast
Rain
Humidity
Yes
Wind
High
Normal
Strong
Weak
No
Yes
No
Yes

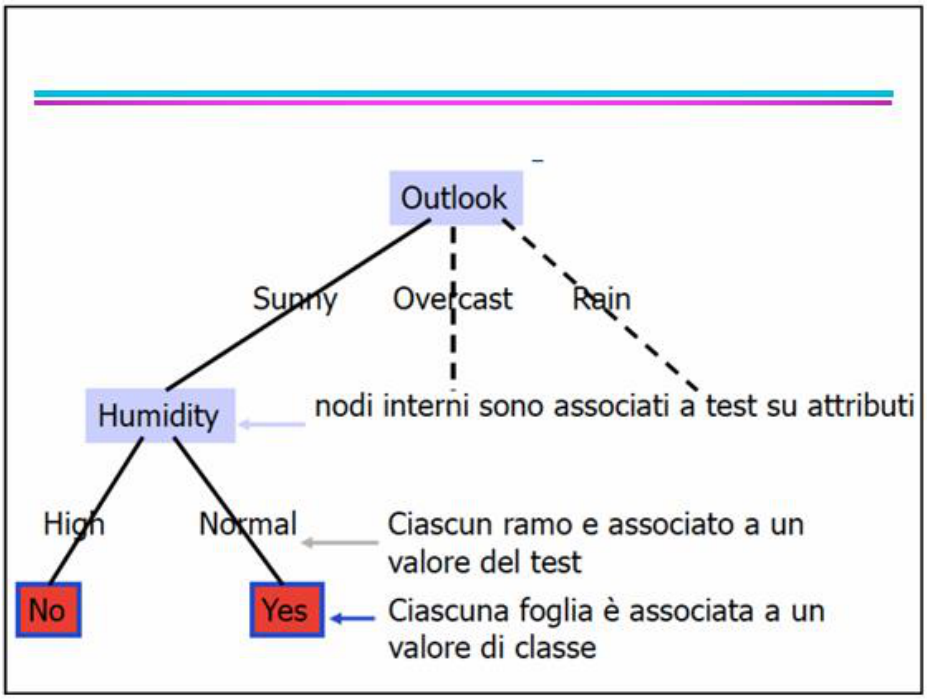
Outlook
Sunny
Overcast
Rain
Humidity
nodi interni sono associati a test su attributi
High
Normal
Ciascun ramo e associato a un valore del test
No
Yes
Ciascuna foglia è associata a un valore di classe

Predictors | Target

Outlook	Temp	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No

Esempio 3 [Russel, Norvig]: entrare in un ristorante?

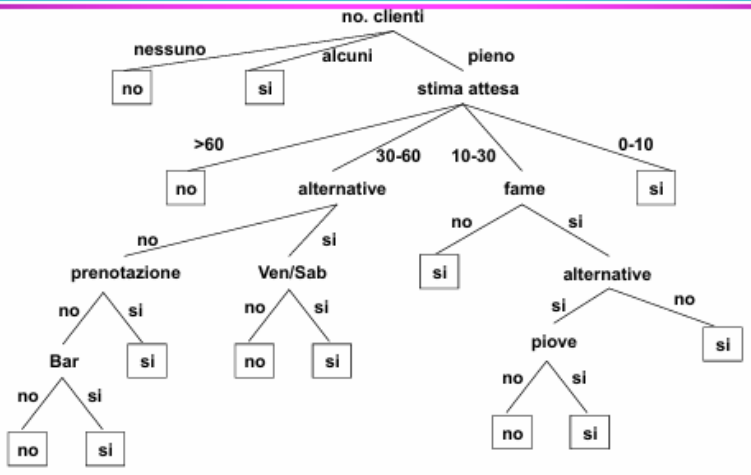

si e no sono le due classi di decisione

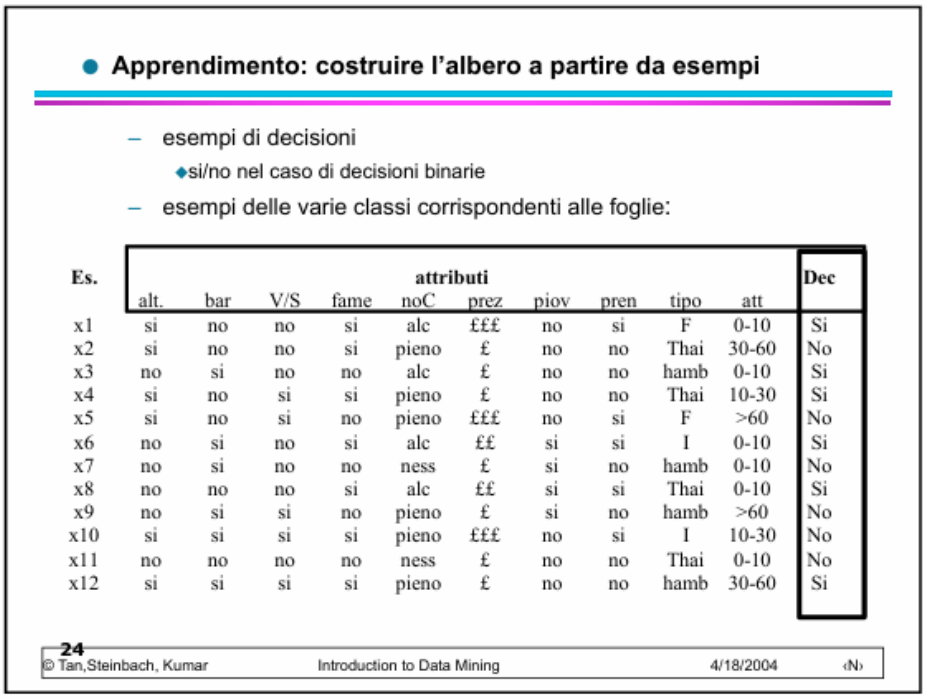

- **Apprendimento: costruire l'albero a partire da esempi**
  - esempi di decisioni
    - si/no nel caso di decisioni binarie
  - esempi delle varie classi corrispondenti alle foglie:

Es.	attributi										Dec
	alt.	bar	V/S	fame	noC	prez	piov	pren	tipo	att	
x1	si	no	no	si	alc	£££	no	si	F	0-10	Si
x2	si	no	no	si	pieno	£	no	no	Thai	30-60	No
x3	no	si	no	no	alc	£	no	no	hamb	0-10	Si
x4	si	no	si	si	pieno	£	no	no	Thai	10-30	Si
x5	si	no	si	no	pieno	£££	no	si	F	>60	No
x6	no	si	no	si	alc	££	si	si	I	0-10	Si
x7	no	si	no	no	ness	£	si	no	hamb	0-10	No
x8	no	no	no	si	alc	££	si	si	Thai	0-10	Si
x9	no	si	si	no	pieno	£	si	no	hamb	>60	No
x10	si	si	si	si	pieno	£££	no	si	I	10-30	No
x11	no	no	no	no	ness	£	no	no	Thai	0-10	No
x12	si	si	si	si	pieno	£	no	no	hamb	30-60	Si

5.4 Valutazione delle prestazioni

Valutazione delle prestazioni, quali sono?

- Precision: Misura % di quanto sono accurate le previsioni positive. Esempio: Quanti dei "positivi" che ho previsto lo sono davvero?
- Recall: È la percentuale di casi positivi correttamente previsti rispetto a tutti i casi realmente positivi. Esempio: Quanti dei veri "positivi" sono riuscito a trovare?
- Accuracy: misura quanto il modello è preciso in generale. È la percentuale di previsioni corrette (sia positive che negative) rispetto a tutte le previsioni. In pratica, indica quanto spesso il modello "azzecca" la risposta.
- F-measure: Combina Precision e Recall in un'unica metrica, bilanciandole. È utile quando serve considerare entrambe le misure contemporaneamente. Esempio: Quanto sono bilanciate la mia accuratezza e la mia capacità di trovare tutti i positivi?

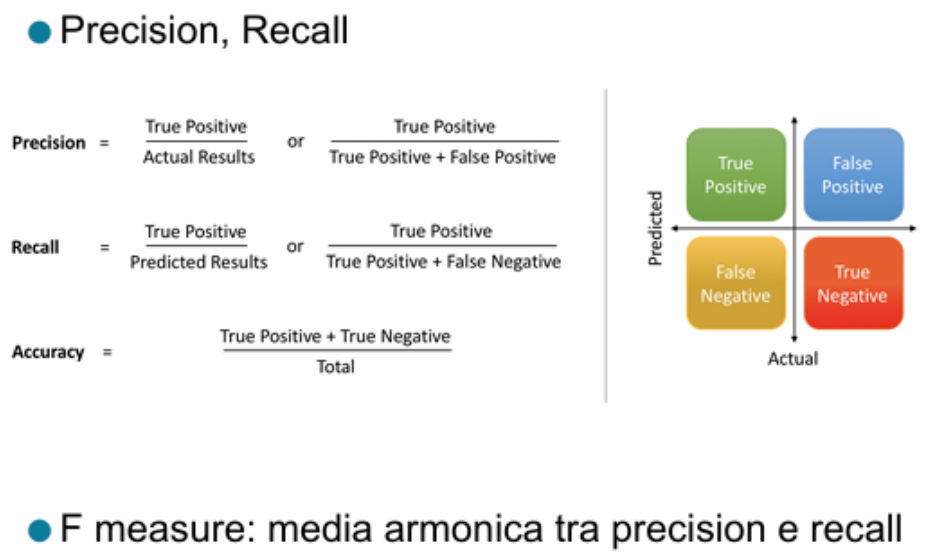

5.5 Le matrici di confusione

Le matrici di confusione, cosa sono?

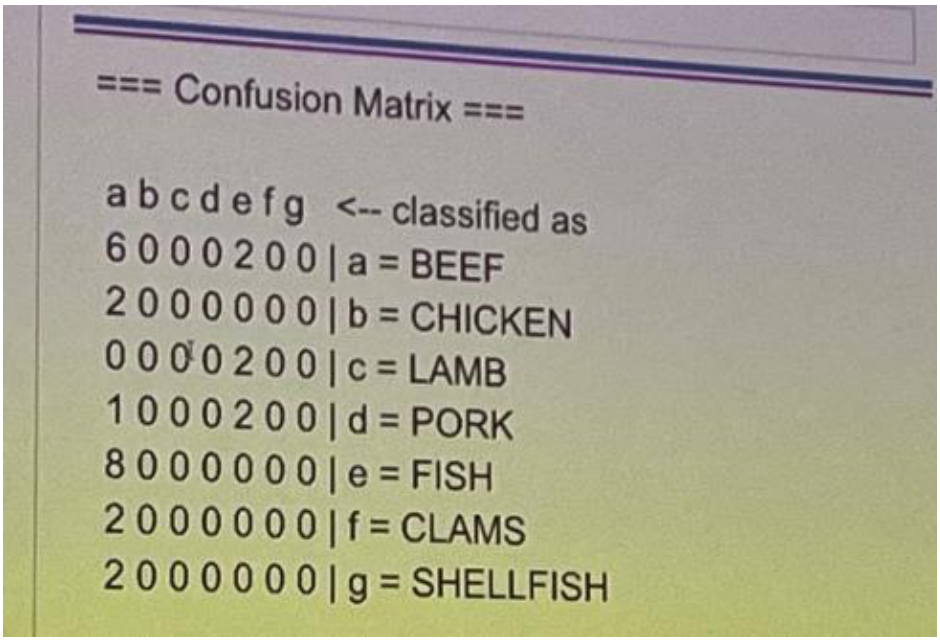

Questa matrice di confusione cosa rappresenta? il risultato di un modello di classificazione che cerca di distinguere tra sette categorie alimentari (Beef, Chicken, Lamb, Pork, Fish, Clams, Shellfish).

Ora analizziamo i falsi positivi (FP) e i falsi negativi (FN):

1. Falsi Positivi (FP):
    - I falsi positivi si trovano sommando i valori in ogni colonna escluso il valore diagonale. Rappresentano il numero di volte in cui il modello ha classificato un elemento come appartenente a una certa categoria (es. Beef), quando in realtà non lo era.
    - Esempio per Beef (a): nella prima colonna, i valori FP sono dati dalla somma di tutti i numeri eccetto il 6 in posizione diagonale (2+0+1+8+2+2 = 15 FP per Beef).
2. Falsi Negativi (FN):
    - I falsi negativi si trovano sommando i valori in ogni riga escluso il valore diagonale. Indicano il numero di elementi di una certa categoria che il modello non ha riconosciuto correttamente.
    - Esempio per Beef (a): nella prima riga, i valori FN sono dati dalla somma di tutti i numeri eccetto il 6 (2+0+0+1+8+2 = 13 FN per Beef).

Questa è una **matrice di confusione** utilizzata per valutare le prestazioni di un modello di classificazione. Ti fornisco una spiegazione chiara e semplice:

Come leggere la matrice:

- Ogni riga rappresenta le **etichette reali** (cioè la vera categoria dell'elemento).
- Ogni colonna rappresenta le **etichette previste** dal modello (cioè la categoria che il modello ha assegnato).
- I valori nelle celle indicano il numero di elementi classificati in un determinato modo.

Ad esempio:

- Nella riga di "BEEF" (a), ci sono **6 elementi correttamente classificati come BEEF**, ma anche **2 elementi confusi come FISH**.
- Nella riga di "CHICKEN" (b), ci sono **2 elementi correttamente classificati come CHICKEN** e nessuna confusione.

Punti chiave per ogni categoria:

1. **BEEF (a):**
   - **6 corretti (a->a).**
   - **2 confusi con FISH (a->e).**
   - Il modello tende a confondere BEEF con FISH.
2. **CHICKEN (b):**
   - **2 corretti (b->b).**
   - Nessuna confusione.
3. **LAMB (c):**
   - **2 corretti (c->c).**
   - Nessuna confusione.
4. **PORK (d):**
   - **1 corretto (d->d).**
   - **2 confusi con BEEF (d->a).**
   - **2 confusi con FISH (d->e).**
5. **FISH (e):**
   - **8 corretti (e->e).**
   - Nessuna confusione.

6. **CLAMS (f):**
   - **2 corretti (f->f).**
   - Nessuna confusione.
7. **SHELLFISH (g):**
   - **2 corretti (g->g).**
   - Nessuna confusione.

Valutazione generale:

- Le categorie **CHICKEN, LAMB, CLAMS, e SHELLFISH** hanno classificazioni perfette o senza ambiguità.
- **BEEF** è confuso con FISH.
- **PORK** ha il maggior numero di confusione: è scambiato sia con BEEF che con FISH.

Esercizio 1

- Partendo dal seguente dataset provare a costruire un albero decisionale

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Costruzione dell'albero:

1. Partiamo dal dataset:
   - Ogni riga rappresenta una persona con informazioni (Refund, Marital Status, Taxable Income) e se ha imbrogliato o no.
2. Guardiamo un attributo, ad esempio **Refund**:
   - Se Refund = Yes → Tutti "No" (nessuno ha imbrogliato).
   - Se Refund = No → Ci sono sia "Yes" che "No".

   Quindi, **Refund** è una buona prima domanda.
3. Guardiamo il secondo attributo, ad esempio **Taxable Income**:
   - Se il reddito è sotto una certa soglia (es. 80K), è più probabile "Yes".
   - Se è sopra una soglia (es. 100K), è più probabile "No".
4. Ripetiamo fino a costruire un albero:
   - Alla fine, ogni ramo ti dice chiaramente "Yes" o "No".

Esercizio: Calcola la frequenza relativa, il numero di decisioni rispetto al totale

Cos'è un albero decisionale?

Un albero decisionale è come fare domande per arrivare alla risposta giusta. Qui vogliamo capire se una persona ha imbrogliato (**Cheat: Yes o No**) usando le informazioni nel dataset.

Esempio: Immagina di dover capire se qualcuno ha imbrogliato. Chiedi:

1. **"Ha ricevuto un rimborso (Refund)?"**
   - Se la risposta è "Yes", probabilmente **NON ha imbrogliato**.
   - Se la risposta è "No", dobbiamo fare un'altra domanda.
2. **"Quanto è il reddito imponibile (Taxable Income)?"**
   - Se è basso (es. sotto 80K), è più probabile che abbia imbrogliato (**Yes**).
   - Se è alto (es. sopra 100K), probabilmente non ha imbrogliato (**No**).
3. **Continuiamo con altre domande:**
   - Se non basta, possiamo chiedere lo stato civile (**Marital Status**): "Single", "Married", "Divorced".

6

Naive Bayes

Cosa sono i modelli Naive Bayes? Naive Bayes è un modello di classificazione che si basa sulla probabilità. Serve per capire a quale gruppo appartiene un oggetto, analizzando le sue caratteristiche (o attributi). È molto usato perché è semplice, veloce e funziona bene in tante situazioni, soprattutto con dati testuali (esempio: classificare e-mail come "spam" o "non spam").

Come funzionano? Immagina di avere un sistema che deve rispondere a una domanda: "A quale categoria appartiene questo oggetto?"

Per farlo, il modello calcola una probabilità per ogni possibile categoria, scegliendo poi quella più alta. Ecco come:

1. Probabilità condizionata: Calcola la probabilità che un oggetto appartenga a una categoria specifica, considerando le sue caratteristiche. Per esempio, "Qual è la probabilità che un'email sia spam, sapendo che contiene la parola 'gratis'?"
2. Indipendenza (Naive): Si assume che ogni caratteristica sia indipendente dalle altre. Anche se in realtà non sempre è così, questa semplificazione rende il modello più veloce e facile da usare.
3. Bayes: Usa la formula di Bayes, che combina le probabilità per dirci quale categoria è più probabile.

6.1 Esempio pratico

Supponiamo di voler capire se un'e-mail è spam o non spam, usando due caratteristiche:

- Contiene la parola "gratis".
- Contiene la parola "offerta".

1. Dati iniziali:

- Spam: il 70% delle e-mail che contengono “gratis” sono spam, e il 80% di quelle con “offerta” sono spam.
- Non spam: il 30% delle e-mail che contengono “gratis” non sono spam, e il 20% di quelle con “offerta” non sono spam.
- Probabilità iniziale: il 50% delle e-mail sono spam.

2. Calcolo: Supponiamo di ricevere un’e-mail con entrambe le parole (“gratis” e “offerta”). Calcoliamo:
   - Probabilità che sia spam (combinando i dati di “gratis” e “offerta”).
   - Probabilità che sia non spam.
3. Classificazione: La categoria con la probabilità maggiore sarà il risultato (spam o non spam).

A cosa servono? I modelli Naive Bayes vengono usati quando devi classificare qualcosa rapidamente e in modo semplice. Alcuni esempi:

- Filtri antispam: Capire se un’e-mail è spam.
- Analisi di sentiment: Determinare se una recensione è positiva o negativa.
- Diagnosi medica: Aiutare a capire la probabilità di avere una malattia in base ai sintomi.

6.2 Vantaggi e svantaggi

Vantaggi e svantaggi, vediamoli

- Vantaggi:
  - È semplice e veloce.
  - Funziona bene anche con pochi dati.
  - Efficace per problemi di testo (ad esempio, classificazione di parole).
- Svantaggi:
  - Assumere che le caratteristiche siano indipendenti non è sempre realistico.
  - Può non funzionare bene con dati complessi o troppo correlati.

Sintesi. . .

La formula del Naive Bayes si basa sul teorema di Bayes, che permette di calcolare la probabilità che un evento accada dato che un altro evento è già accaduto.

Esempio sintetico:

Vuoi sapere se piove (C) dato che vedi il cielo grigio (X):

- $P(C|X)$: Probabilità che piova, sapendo che il cielo è grigio.
- Usi il teorema di Bayes combinando:
  - Quante volte piove in generale ($P(C)$).
  - Quante volte il cielo è grigio quando piove ($P(X|C)$).
  - Quante volte il cielo è grigio in generale ($P(X)$).

Risultato: probabilità aggiornata che stia piovendo!

Formula Generale

$$P(C|X) = \frac{P(X|C) \cdot P(C)}{P(X)}$$

Che cosa significa?

- $P(C|X)$: Probabilità che la classe C sia vera dato che abbiamo osservato i dati X. È quella che vogliamo calcolare (probabilità "a posteriori").
- $P(X|C)$: Probabilità di osservare i dati X se sappiamo che appartengono alla classe C.
- $P(C)$: Probabilità iniziale della classe C (detta probabilità "a priori").
- $P(X)$: Probabilità di osservare i dati X in generale (per tutte le classi).

Naive Bayes

Il modello **Naive Bayes** aggiunge un'ipotesi semplificativa: assume che le variabili che compongono i dati X siano **indipendenti tra loro** (da cui il termine "naive", cioè ingenuo).

In pratica, se X è composto da più caratteristiche $x_1, x_2, ..., x_n$, allora:

$$P(X|C) = P(x_1|C) \cdot P(x_2|C) \cdot ... \cdot P(x_n|C)$$

Formula di Naive Bayes

Con questa semplificazione, la probabilità $P(C|X)$ diventa:

$$P(C|X) \propto P(C) \cdot P(x_1|C) \cdot P(x_2|C) \cdot ... \cdot P(x_n|C)$$

Dove:

- Il simbolo $\propto$ significa "proporzionale a" perché non calcoliamo direttamente $P(X)$, che è costante per tutte le classi.

In breve:

1. Calcoliamo quanto è probabile ogni classe C considerando tutte le caratteristiche x_i.
2. Scegliamo la classe C con la probabilità più alta.

Esempio:

Supponiamo di voler prevedere se un'email è "spam" o "non spam" (C) basandoci su due caratteristiche:

- x_1: La parola "gratis" è presente?
- x_2: La parola "offerta" è presente?

Se conosciamo $P(C)$, $P(x_1|C)$, $P(x_2|C)$, possiamo calcolare $P(C|X)$ per entrambe le classi ("spam" e "non spam") e classificare l'email.

7

Text mining

Cos'è un Task? compito da portare a termine, in questo caso, ciò che vogliamo capire dal testo.

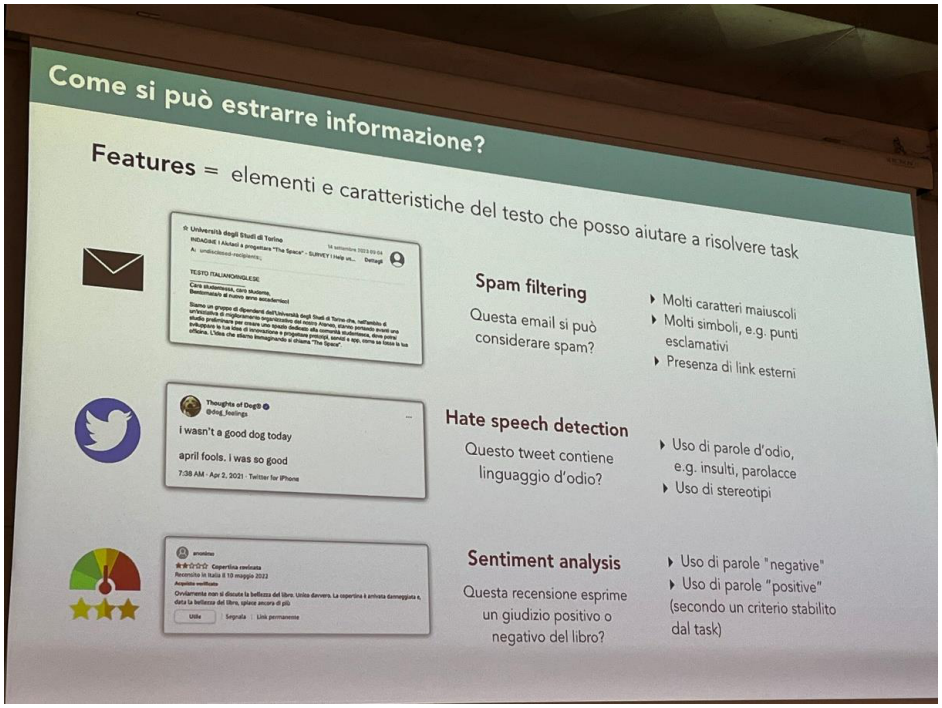

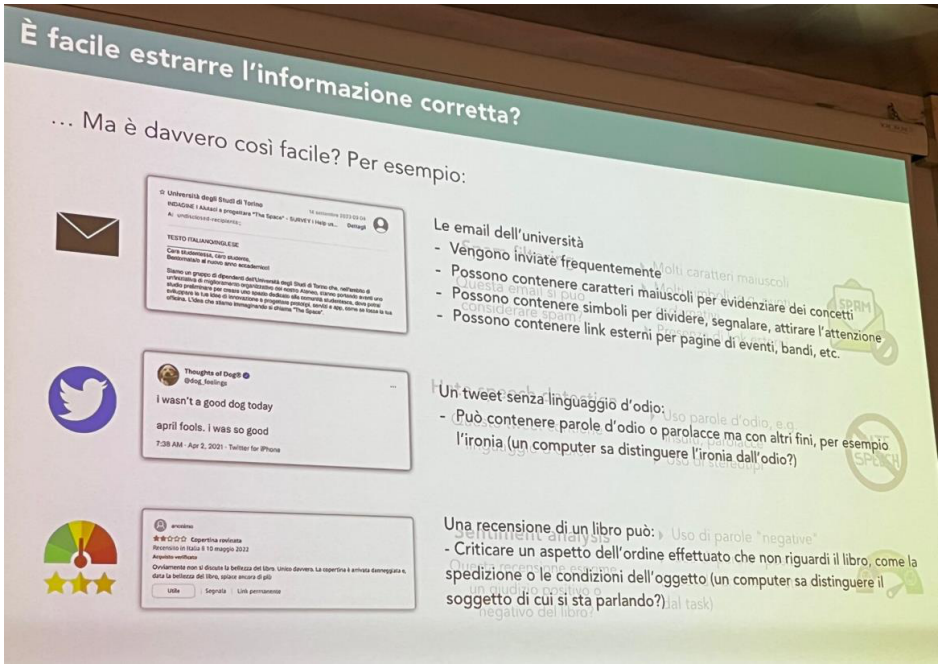

Che cosa intendiamo per testo? Un testo è un dato non strutturato, quindi ha bisogno di essere strutturato per essere utile e avere informazioni da apprendere.

Linguaggio naturale = linguaggio utilizzato dall'uomo

Elaborazione di linguaggio naturale (NLP)

Queste tecniche permettono di pulire i testi in linguaggio naturale ed estrarre elementi dal testo che siano rappresentabili come dati strutturati (numeri, stringhe, etc.)

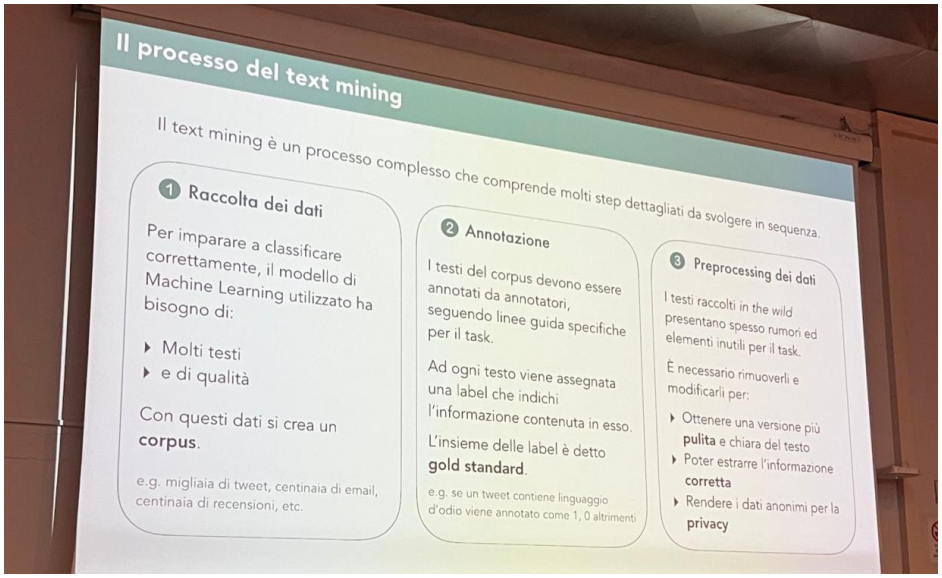

7.1 Raccolta di dati

Tipo di dato → solamente i testi

Da dove → social, siti, documenti

Come → API, tool specifici

Quali → devono essere coerenti col task, privi di bias

Quanti → tanti ma non troppi

Chi → specialisti esperti nel task, con linee guida apposite

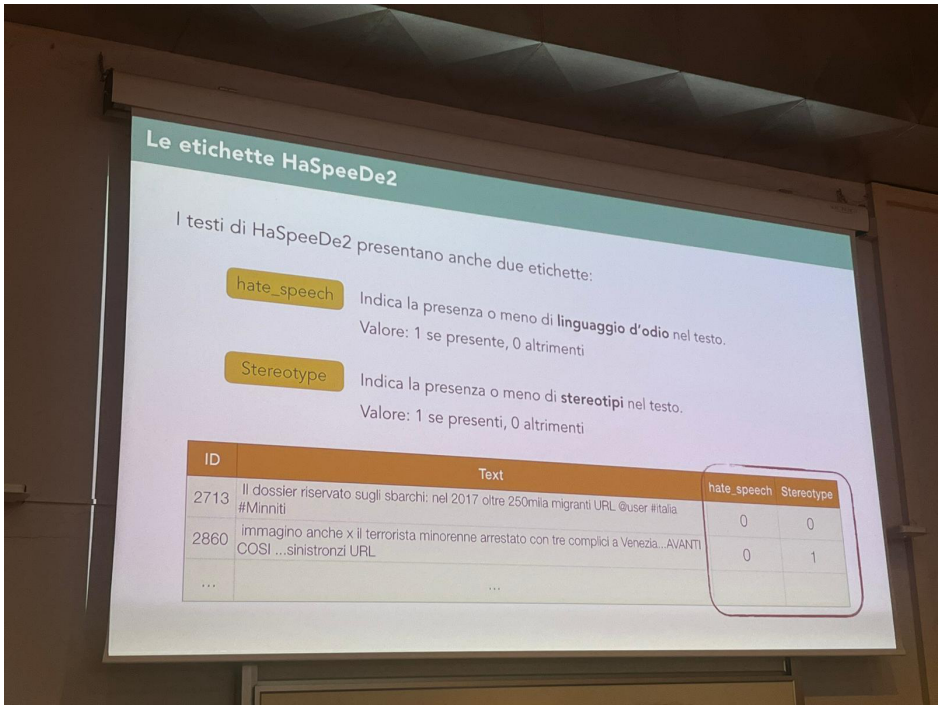

7.2 Annotazione

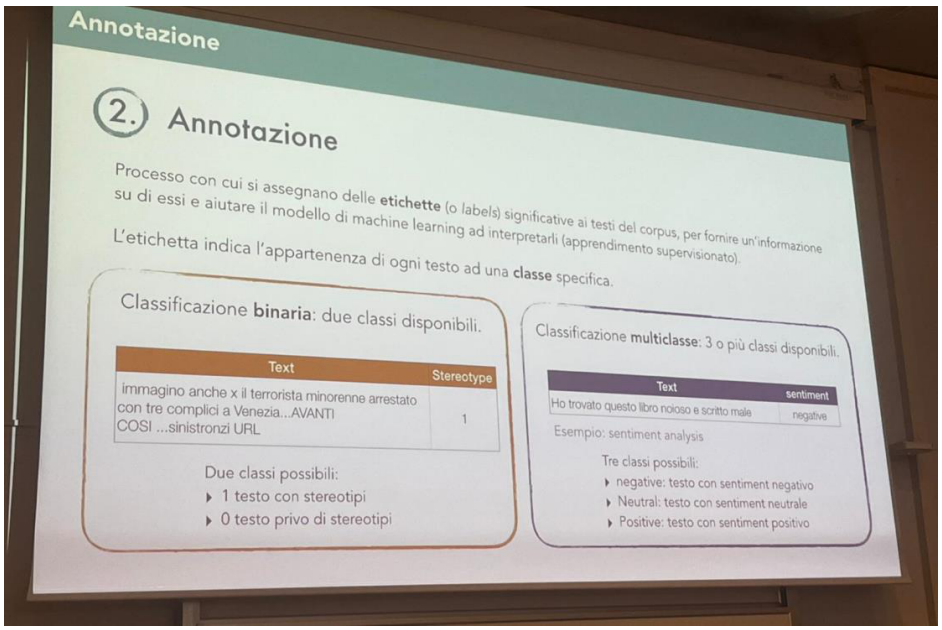

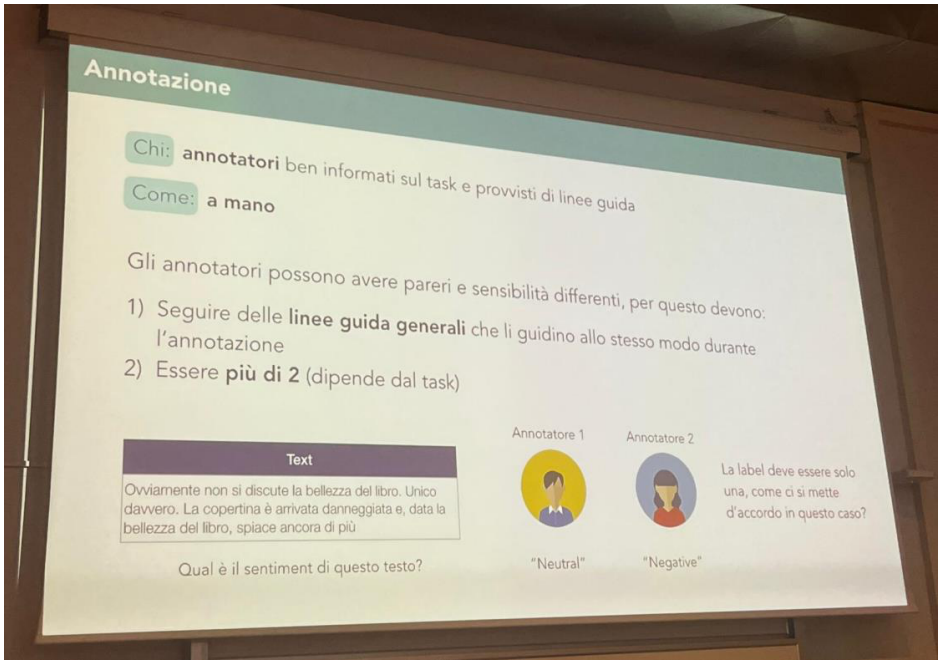
Annotazione
Chi: annotatori ben informati sul task e provvisti di linee guida
Come: a mano
Gli annotatori possono avere pareri e sensibilità differenti, per questo devono:
1) Seguire delle linee guida generali che li guidino allo stesso modo durante l'annotazione
2) Essere più di 2 (dipende dal task)
Text
Ovviamente non si discute la bellezza del libro. Unico davvero. La copertina è arrivata danneggiata e, data la bellezza del libro, spiace ancora di più
Qual è il sentiment di questo testo?
Annotatore 1
Annotatore 2
"Neutral"
"Negative"
La label deve essere solo una, come ci si mette d'accordo in questo caso?

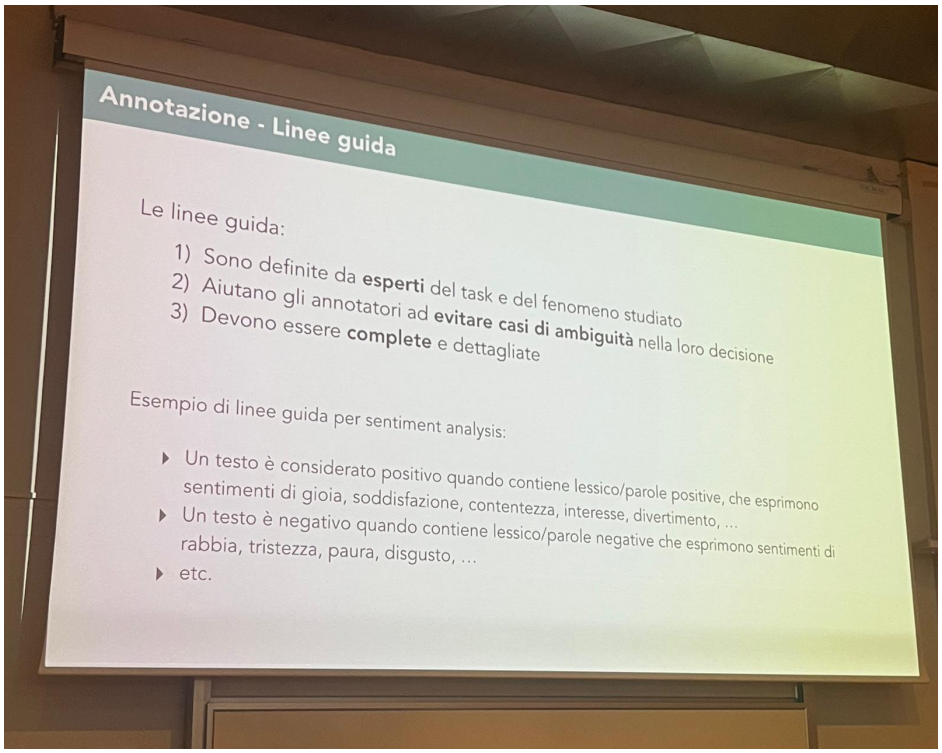
Annotazione - Linee guida
Le linee guida:
1) Sono definite da esperti del task e del fenomeno studiato
2) Aiutano gli annotatori ad evitare casi di ambiguità nella loro decisione
3) Devono essere complete e dettagliate
Esempio di linee guida per sentiment analysis:
Un testo è considerato positivo quando contiene lessico/parole positive, che esprimono sentimenti di gioia, soddisfazione, contentezza, interesse, divertimento, ...
Un testo è negativo quando contiene lessico/parole negative che esprimono sentimenti di rabbia, tristezza, paura, disgusto, ...
etc.

Annotazione - Linee guida
Una volta definite le linee guida, gli annotatori annotano alcuni testi.
Sentiment analysis
Text
Ovviamente non si discute la bellezza del libro. Unico davvero. La copertina è arrivata danneggiata e, data la bellezza del libro, spiace ancora di più
Annotatore 1
Annotatore 2
Annotatore 3
Annotatore 4
"Neutral"
"Negative"
"Positive"
"Neutral"
Come si fa a sapere se le linee guida sono complete, coerenti e comprensibili?
Inter annotators agreement = metrica per definire quanto gli annotatori siano allineati nelle decisioni.

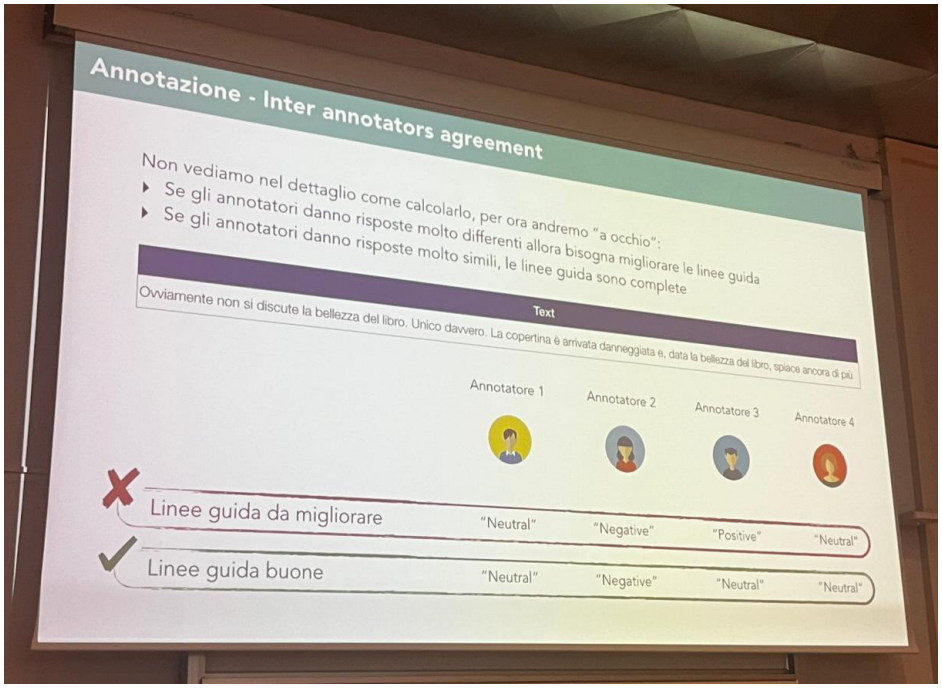
Annotazione - Inter annotators agreement
Non vediamo nel dettaglio come calcolarlo, per ora andremo "a occhio":
Se gli annotatori danno risposte molto differenti allora bisogna migliorare le linee guida
Se gli annotatori danno risposte molto simili, le linee guida sono complete
Text
Ovviamente non si discute la bellezza del libro. Unico davvero. La copertina è arrivata danneggiata e, data la bellezza del libro, spiace ancora di più
Annotatore 1
Annotatore 2
Annotatore 3
Annotatore 4
Linee guida da migliorare
"Neutral"
"Negative"
"Positive"
"Neutral"
Linee guida buone
"Neutral"
"Negative"
"Neutral"
"Neutral"

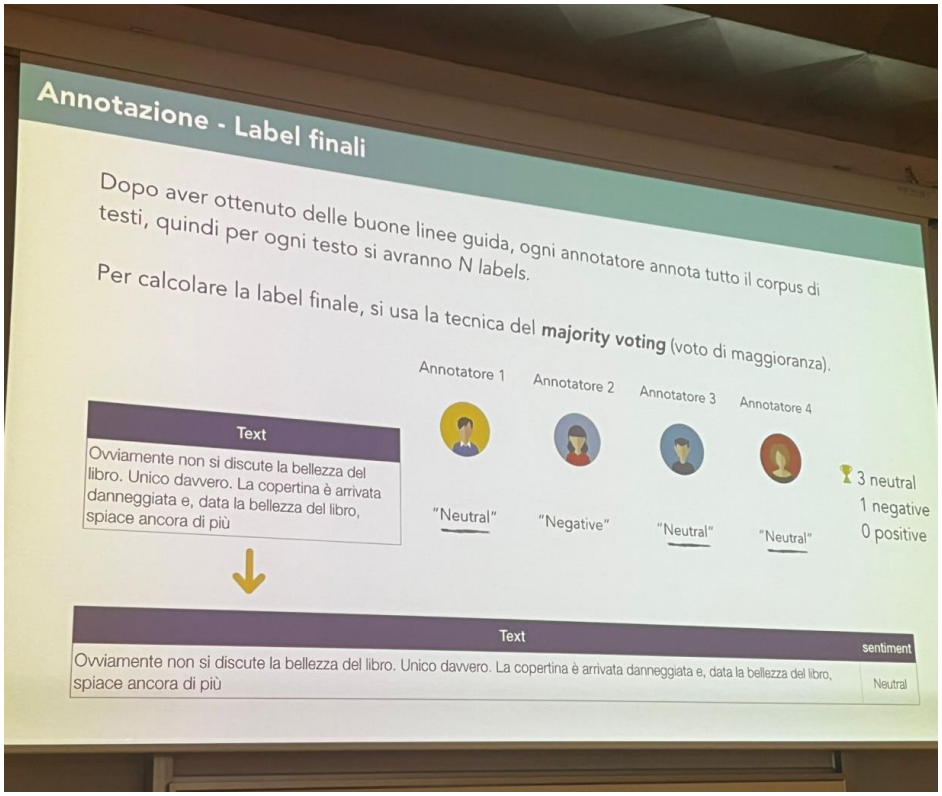

7.3 Preprocessing

Che cos'è? Il preprocessing è la preparazione dei dati grezzi per renderli adatti all'analisi o all'uso in un modello. Si tratta di pulire, trasformare e standardizzare i dati.

Esempi:

- Testo: Rimuovere punteggiatura e mettere in minuscolo ("CIAO!!!" $\rightarrow$ "ciao").
- Numeri: Normalizzare valori per portarli tra 0 e 1.
- Immagini: Ridurre la risoluzione per ottimizzare il calcolo.

Serve per garantire che i dati siano coerenti e pronti per essere processati.

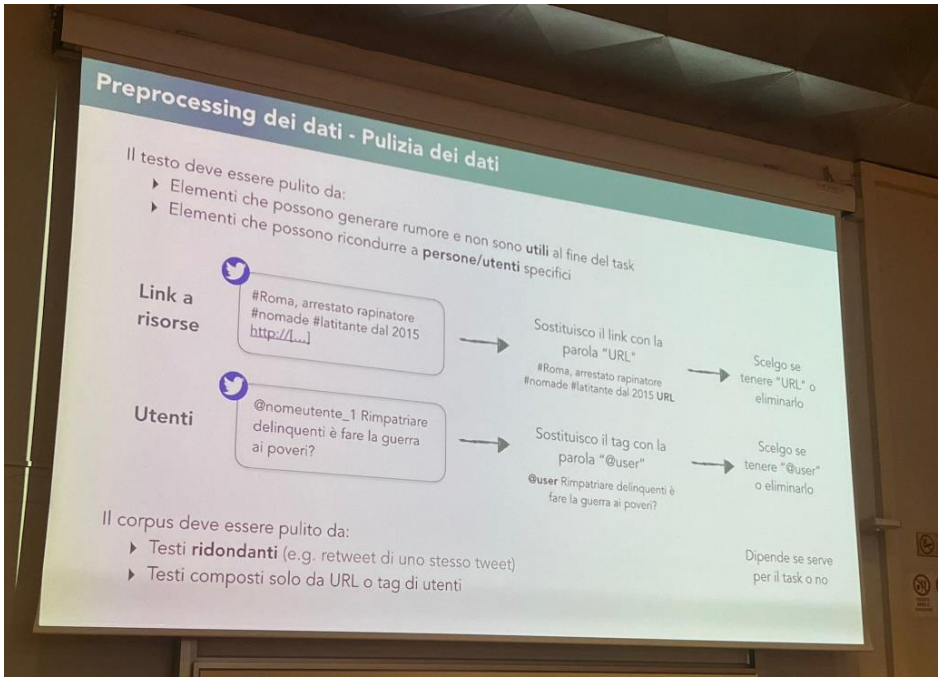
Preprocessing dei dati - Pulizia dei dati
Il testo deve essere pulito da:
Elementi che possono generare rumore e non sono utili al fine del task
Elementi che possono ricondurre a persone/utenti specifici
Link a risorse
#Roma, arrestato rapinatore #nomade #latitante dal 2015 http://[...]
Sostituisco il link con la parola "URL"
#Roma, arrestato rapinatore #nomade #latitante dal 2015 URL
Scelgo se tenere "URL" o eliminarlo
Utenti
@nomeutente_1 Rimpatriare delinquenti è fare la guerra ai poveri?
Sostituisco il tag con la parola "@user"
@user Rimpatriare delinquenti è fare la guerra ai poveri?
Scelgo se tenere "@user" o eliminarlo
Il corpus deve essere pulito da:
Testi ridondanti (e.g. retweet di uno stesso tweet)
Testi composti solo da URL o tag di utenti
Dipende se serve per il task o no

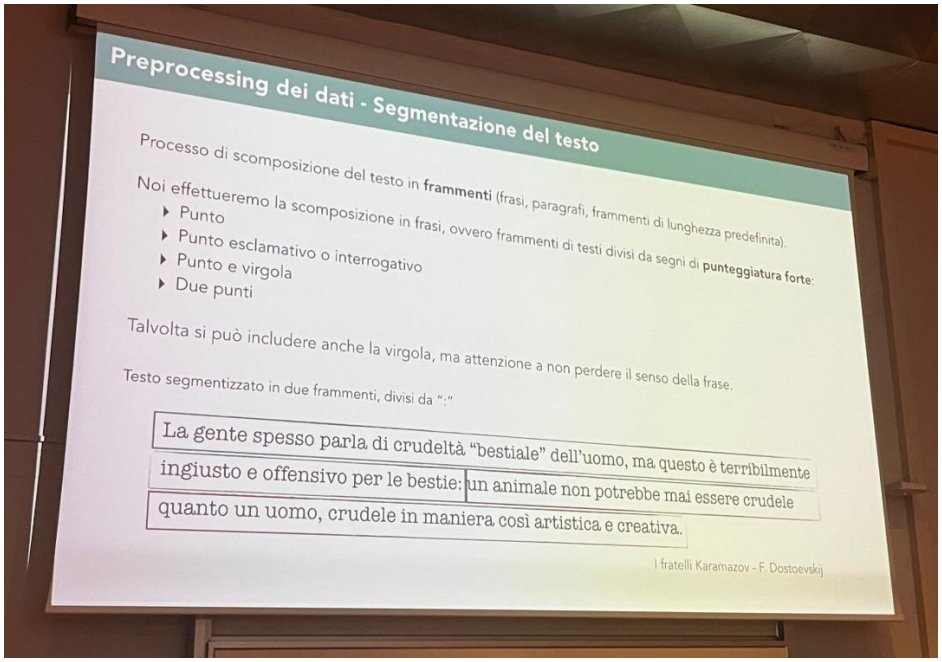
Preprocessing dei dati - Segmentazione del testo
Processo di scomposizione del testo in frammenti (frasi, paragrafi, frammenti di lunghezza predefinita).
Noi effettueremo la scomposizione in frasi, ovvero frammenti di testi divisi da segni di punteggiatura forte:
Punto
Punto esclamativo o interrogativo
Punto e virgola
Due punti
Talvolta si può includere anche la virgola, ma attenzione a non perdere il senso della frase.
Testo segmentizzato in due frammenti, divisi da ":"
La gente spesso parla di crudeltà "bestiale" dell'uomo, ma questo è terribilmente ingiusto e offensivo per le bestie: un animale non potrebbe mai essere crudele quanto un uomo, crudele in maniera così artistica e creativa.
I fratelli Karamazov - F. Dostoevskij

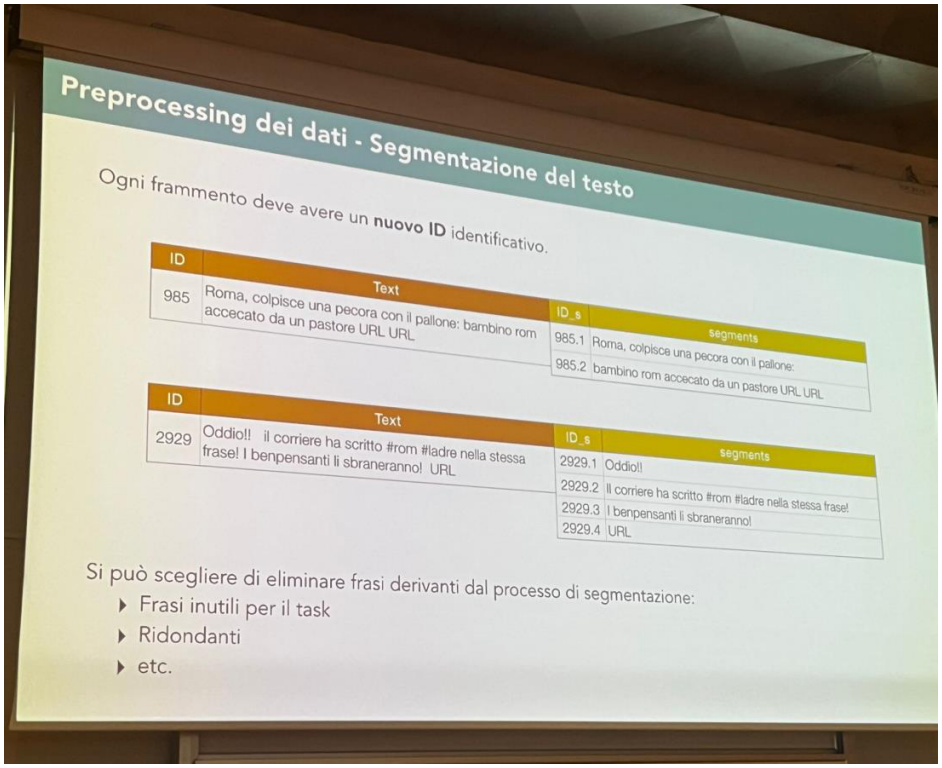
Preprocessing dei dati - Segmentazione del testo
Ogni frammento deve avere un nuovo ID identificativo.
ID
Text
985
Roma, colpisce una pecora con il pallone: bambino rom accecato da un pastore URL URL
ID_s
segments
985.1
Roma, colpisce una pecora con il pallone:
985.2
bambino rom accecato da un pastore URL URL
ID
Text
2929
Oddio!! il corriere ha scritto #rom #ladre nella stessa frase! I benpensanti li sbraneranno! URL
ID_s
segments
2929.1
Oddio!!
2929.2
Il corriere ha scritto #rom #ladre nella stessa frase!
2929.3
I benpensanti li sbraneranno!
2929.4
URL
Si può scegliere di eliminare frasi derivanti dal processo di segmentazione:
Frasi inutili per il task
Ridondanti
etc.

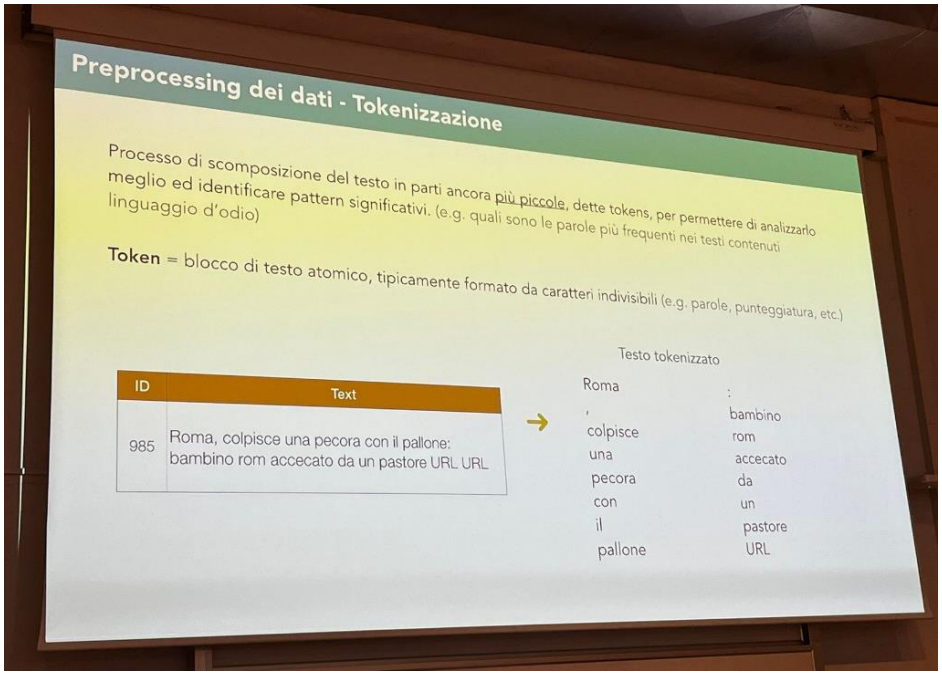
Preprocessing dei dati - Tokenizzazione
Processo di scomposizione del testo in parti ancora più piccole, dette tokens, per permettere di analizzarlo meglio ed identificare pattern significativi. (e.g. quali sono le parole più frequenti nei testi contenuti linguaggio d'odio)
Token = blocco di testo atomico, tipicamente formato da caratteri indivisibili (e.g. parole, punteggiatura, etc.)
ID
Text
985
Roma, colpisce una pecora con il pallone: bambino rom accecato da un pastore URL URL
Testo tokenizzato
Roma
,
colpisce
una
pecora
con
il
pallone
:
bambino
rom
accecato
da
un
pastore
URL

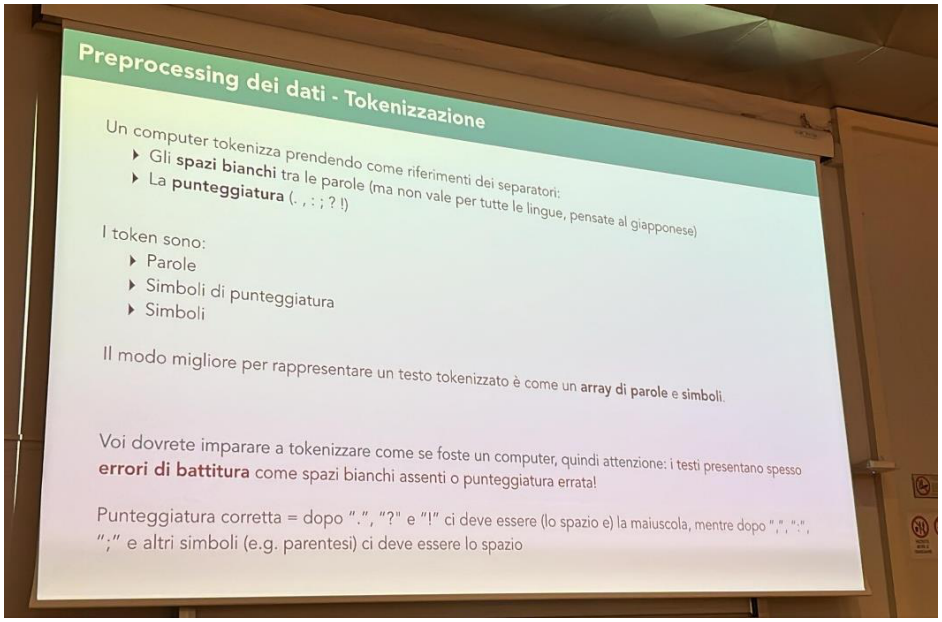
Preprocessing dei dati - Tokenizzazione
Un computer tokenizza prendendo come riferimenti dei separatori:
Gli spazi bianchi tra le parole (ma non vale per tutte le lingue, pensate al giapponese)
La punteggiatura (. , : ; ? !)
I token sono:
Parole
Simboli di punteggiatura
Simboli
Il modo migliore per rappresentare un testo tokenizzato è come un array di parole e simboli.
Voi dovrete imparare a tokenizzare come se foste un computer, quindi attenzione: i testi presentano spesso errori di battitura come spazi bianchi assenti o punteggiatura errata!
Punteggiatura corretta = dopo ".", "?" e "!" ci deve essere (lo spazio e) la maiuscola, mentre dopo "," ,":" ,";" e altri simboli (e.g. parentesi) ci deve essere lo spazio

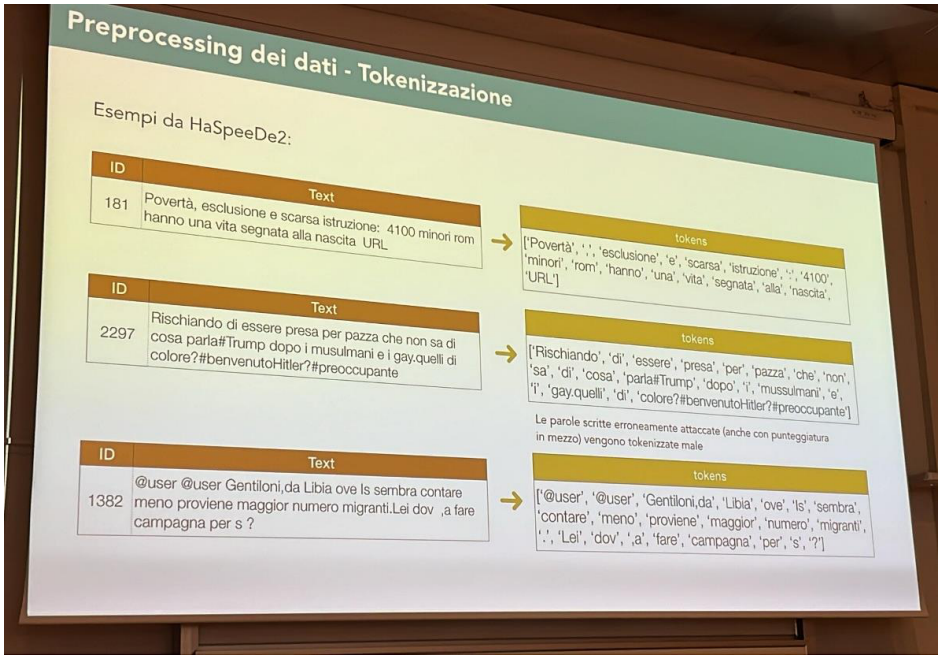
Preprocessing dei dati - Tokenizzazione
Esempi da HaSpeeDe2:
ID
Text
181
Povertà, esclusione e scarsa istruzione: 4100 minori rom hanno una vita segnata alla nascita URL
tokens
['Povertà', ',', 'esclusione', 'e', 'scarsa', 'istruzione', ':', '4100', 'minori', 'rom', 'hanno', 'una', 'vita', 'segnata', 'alla', 'nascita', 'URL']
ID
Text
2297
Rischiando di essere presa per pazza che non sa di cosa parla#Trump dopo i musulmani e i gay.quelli di colore?#benvenutoHitler?#preoccupante
tokens
['Rischiando', 'di', 'essere', 'presa', 'per', 'pazza', 'che', 'non', 'sa', 'di', 'cosa', 'parla#Trump', 'dopo', 'i', 'mussulmani', 'e', 'gay.quelli', 'di', 'colore?#benvenutoHitler?#preoccupante']
Le parole scritte erroneamente attaccate (anche con punteggiatura in mezzo) vengono tokenizzate male
ID
Text
1382
@user @user Gentiloni,da Libia ove ls sembra contare meno proviene maggior numero migranti.Lei dov ,a fare campagna per s ?
tokens
['@user', '@user', 'Gentiloni,da', 'Libia', 'ove', 'ls', 'sembra', 'contare', 'meno', 'proviene', 'maggior', 'numero', 'migranti', '.', 'Lei', 'dov', ',a', 'fare', 'campagna', 'per', 's', '?']

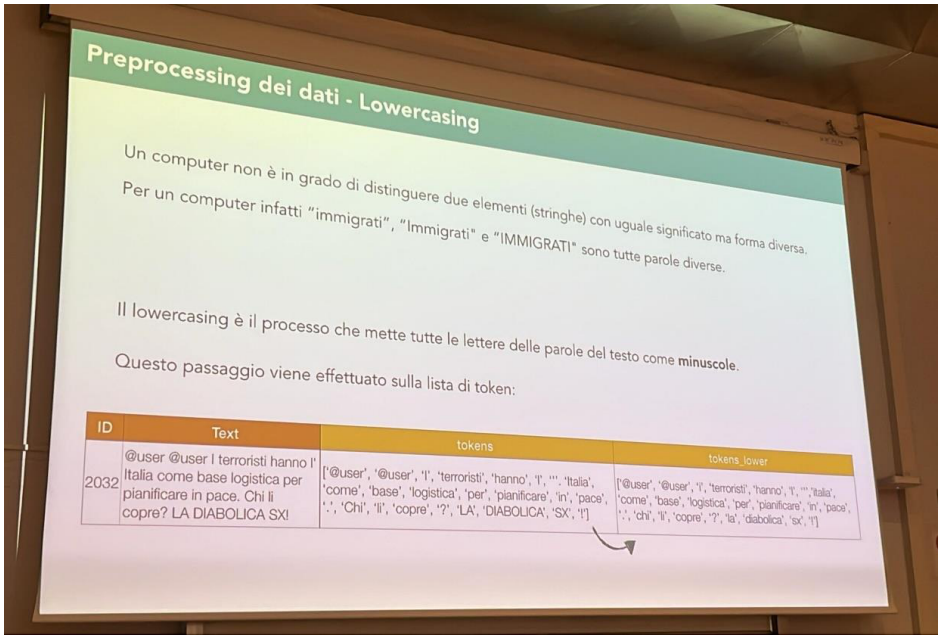
Preprocessing dei dati - Lowercasing
Un computer non è in grado di distinguere due elementi (stringhe) con uguale significato ma forma diversa.
Per un computer infatti "immigrati", "Immigrati" e "IMMIGRATI" sono tutte parole diverse.
Il lowercasing è il processo che mette tutte le lettere delle parole del testo come minuscole.
Questo passaggio viene effettuato sulla lista di token:
ID
Text
tokens
tokens_lower
2032
@user @user I terroristi hanno l' Italia come base logistica per pianificare in pace. Chi li copre? LA DIABOLICA SX!
['@user', '@user', 'I', 'terroristi', 'hanno', 'l', "'", 'Italia', 'come', 'base', 'logistica', 'per', 'pianificare', 'in', 'pace', '.', 'Chi', 'li', 'copre', '?', 'LA', 'DIABOLICA', 'SX', '!']
['@user', '@user', 'i', 'terroristi', 'hanno', 'l', "'", 'italia', 'come', 'base', 'logistica', 'per', 'pianificare', 'in', 'pace', '.', 'chi', 'li', 'copre', '?', 'la', 'diabolica', 'sx', '!']

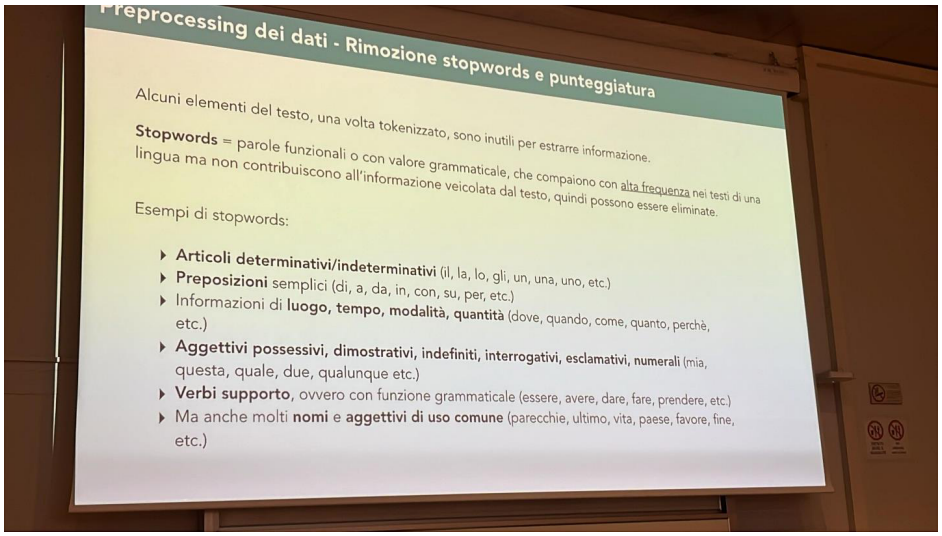
Preprocessing dei dati - Rimozione stopwords e punteggiatura
Alcuni elementi del testo, una volta tokenizzato, sono inutili per estrarre informazione.
Stopwords = parole funzionali o con valore grammaticale, che compaiono con alta frequenza nei testi di una lingua ma non contribuiscono all'informazione veicolata dal testo, quindi possono essere eliminate.
Esempi di stopwords:
Articoli determinativi/indeterminativi (il, la, lo, gli, un, una, uno, etc.)
Preposizioni semplici (di, a, da, in, con, su, per, etc.)
Informazioni di luogo, tempo, modalità, quantità (dove, quando, come, quanto, perchè, etc.)
Aggettivi possessivi, dimostrativi, indefiniti, interrogativi, esclamativi, numerali (mia, questa, quale, due, qualunque etc.)
Verbi supporto, ovvero con funzione grammaticale (essere, avere, dare, fare, prendere, etc.)
Ma anche molti nomi e aggettivi di uso comune (parecchie, ultimo, vita, paese, favore, fine, etc.)

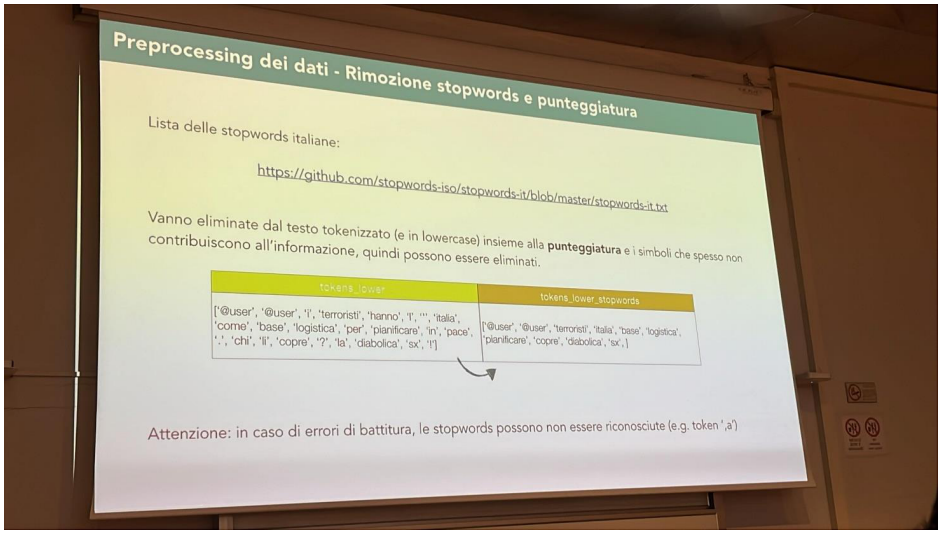
Preprocessing dei dati - Rimozione stopwords e punteggiatura
Lista delle stopwords italiane:
https://github.com/stopwords-iso/stopwords-it/blob/master/stopwords-it.txt
Vanno eliminate dal testo tokenizzato (e in lowercase) insieme alla punteggiatura e i simboli che spesso non contribuiscono all'informazione, quindi possono essere eliminati.
tokens_lower
['@user', '@user', 'i', 'terroristi', 'hanno', 'l', "'", 'italia', 'come', 'base', 'logistica', 'per', 'pianificare', 'in', 'pace', '.', 'chi', 'li', 'copre', '?', 'la', 'diabolica', 'sx', 'l']
tokens_lower_stopwords
['@user', '@user', 'terroristi', 'italia', 'base', 'logistica', 'pianificare', 'copre', 'diabolica', 'sx', 'l']
Attenzione: in caso di errori di battitura, le stopwords possono non essere riconosciute (e.g. token 'a')

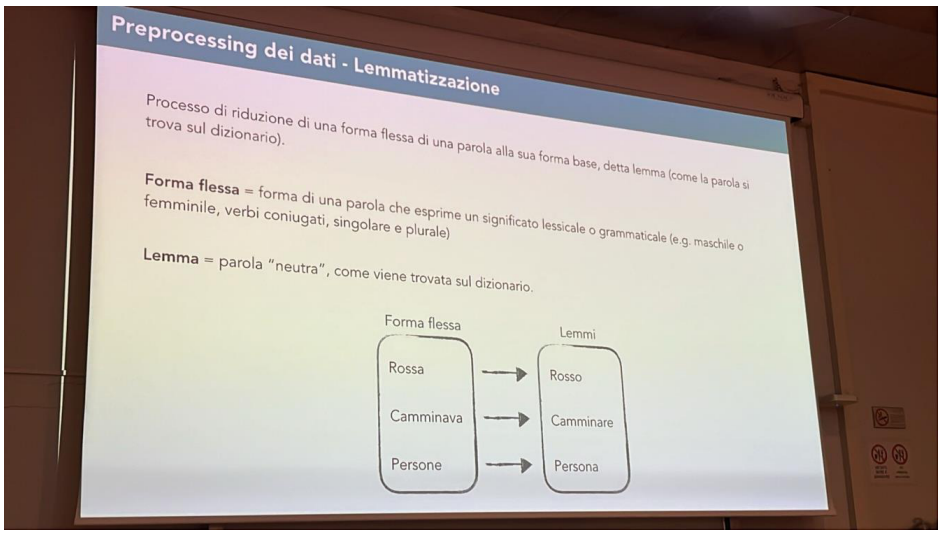
Preprocessing dei dati - Lemmatizzazione
Processo di riduzione di una forma flessa di una parola alla sua forma base, detta lemma (come la parola si trova sul dizionario).
Forma flessa = forma di una parola che esprime un significato lessicale o grammaticale (e.g. maschile o femminile, verbi coniugati, singolare e plurale)
Lemma = parola "neutra", come viene trovata sul dizionario.
Forma flessa
Lemmi
Rossa
Rosso
Camminava
Camminare
Persone
Persona

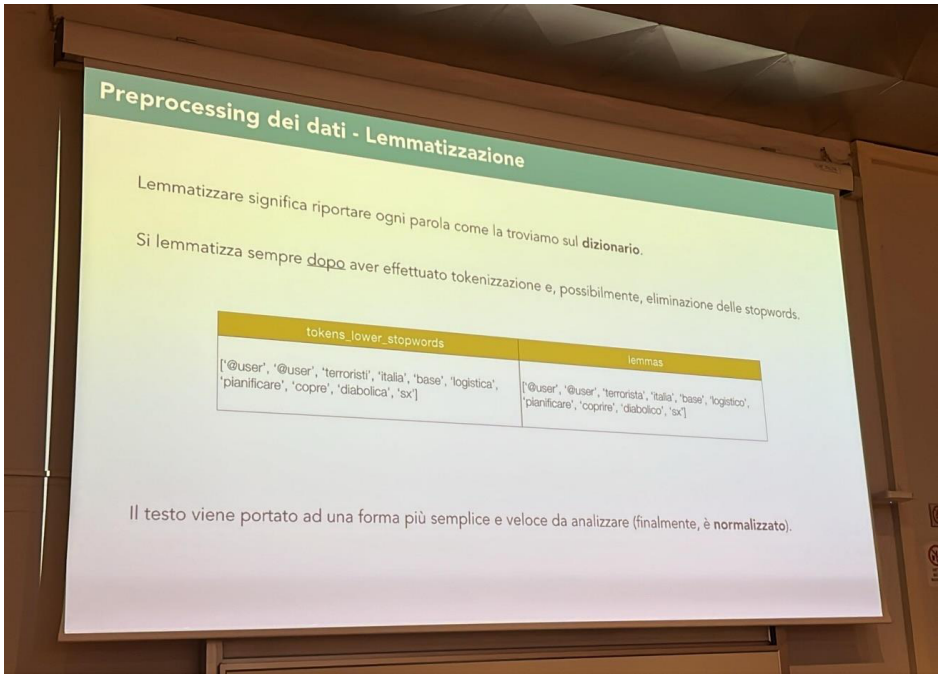
Preprocessing dei dati - Lemmatizzazione
Lemmatizzare significa riportare ogni parola come la troviamo sul dizionario.
Si lemmatizza sempre dopo aver effettuato tokenizzazione e, possibilmente, eliminazione delle stopwords.
tokens_lower_stopwords
['@user', '@user', 'terroristi', 'italia', 'base', 'logistica', 'pianificare', 'copre', 'diabolica', 'sx']
lemmas
['@user', '@user', 'terrorista', 'italia', 'base', 'logistico', 'pianificare', 'coprire', 'diabolico', 'sx']
Il testo viene portato ad una forma più semplice e veloce da analizzare (finalmente, è normalizzato).

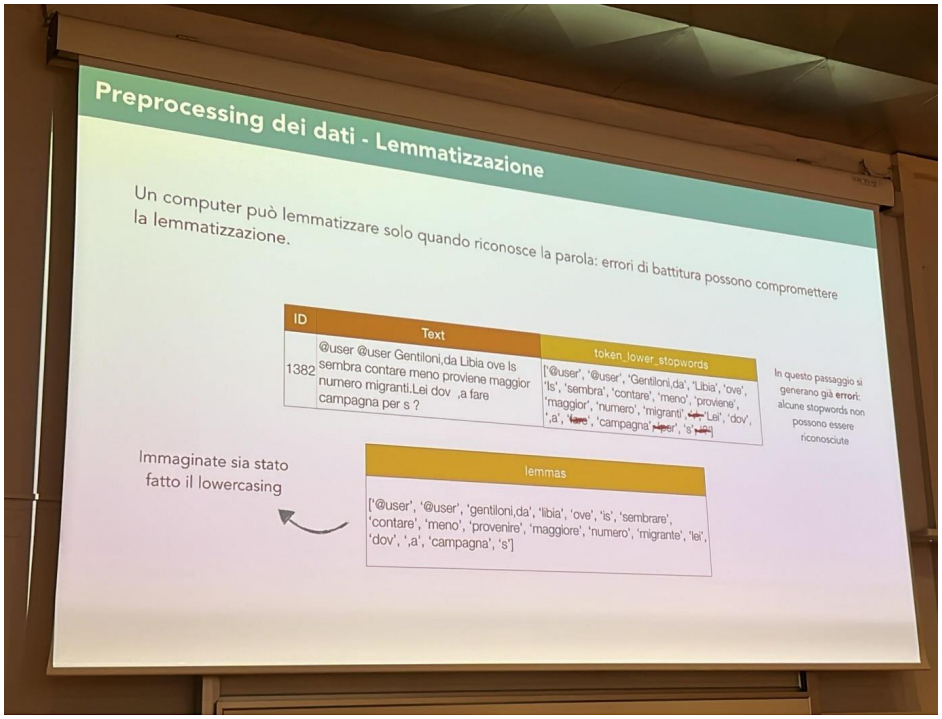
Preprocessing dei dati - Lemmatizzazione
Un computer può lemmatizzare solo quando riconosce la parola: errori di battitura possono compromettere la lemmatizzazione.
ID
Text
token_lower_stopwords
1382
@user @user Gentiloni,da Libia ove ls sembra contare meno proviene maggior numero migranti.Lei dov ,a fare campagna per s ?
['@user', '@user', 'Gentiloni,da', 'Libia', 'ove', 'ls', 'sembra', 'contare', 'meno', 'proviene', 'maggior', 'numero', 'migranti', 'Lei', 'dov', ',a', 'fare', 'campagna' 'per', 's']
In questo passaggio si generano già errori: alcune stopwords non possono essere riconosciute
Immaginate sia stato fatto il lowercasing
lemmas
['@user', '@user', 'gentiloni,da', 'libia', 'ove', 'is', 'sembrare', 'contare', 'meno', 'provenire', 'maggiore', 'numero', 'migrante', 'lei', 'dov', ',a', 'campagna', 's']

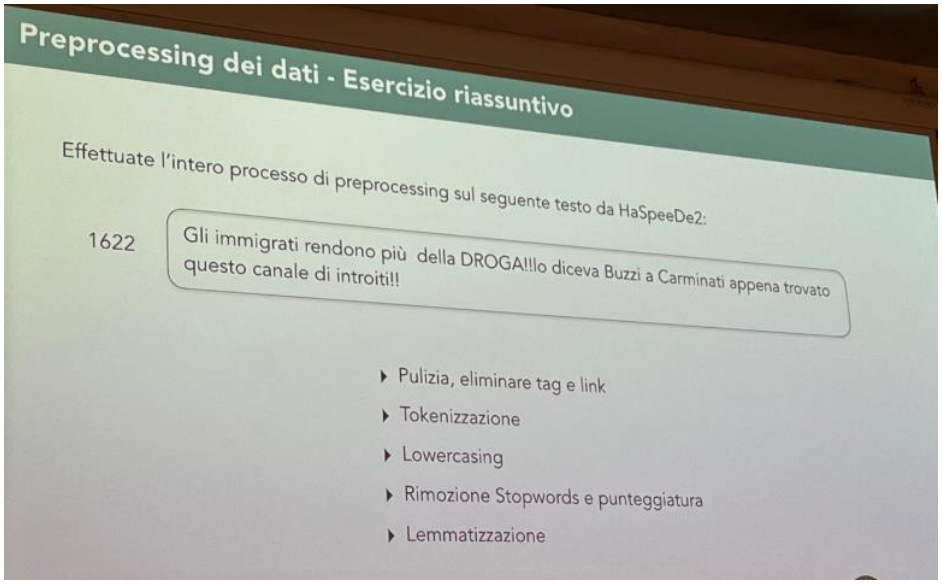
Preprocessing dei dati - Esercizio riassuntivo
Effettuate l'intero processo di preprocessing sul seguente testo da HaSpeeDe2:
1622
Gli immigrati rendono più della DROGA!!lo diceva Buzzi a Carminati appena trovato questo canale di introiti!!
Pulizia, eliminare tag e link
Tokenizzazione
Lowercasing
Rimozione Stopwords e punteggiatura
Lemmatizzazione

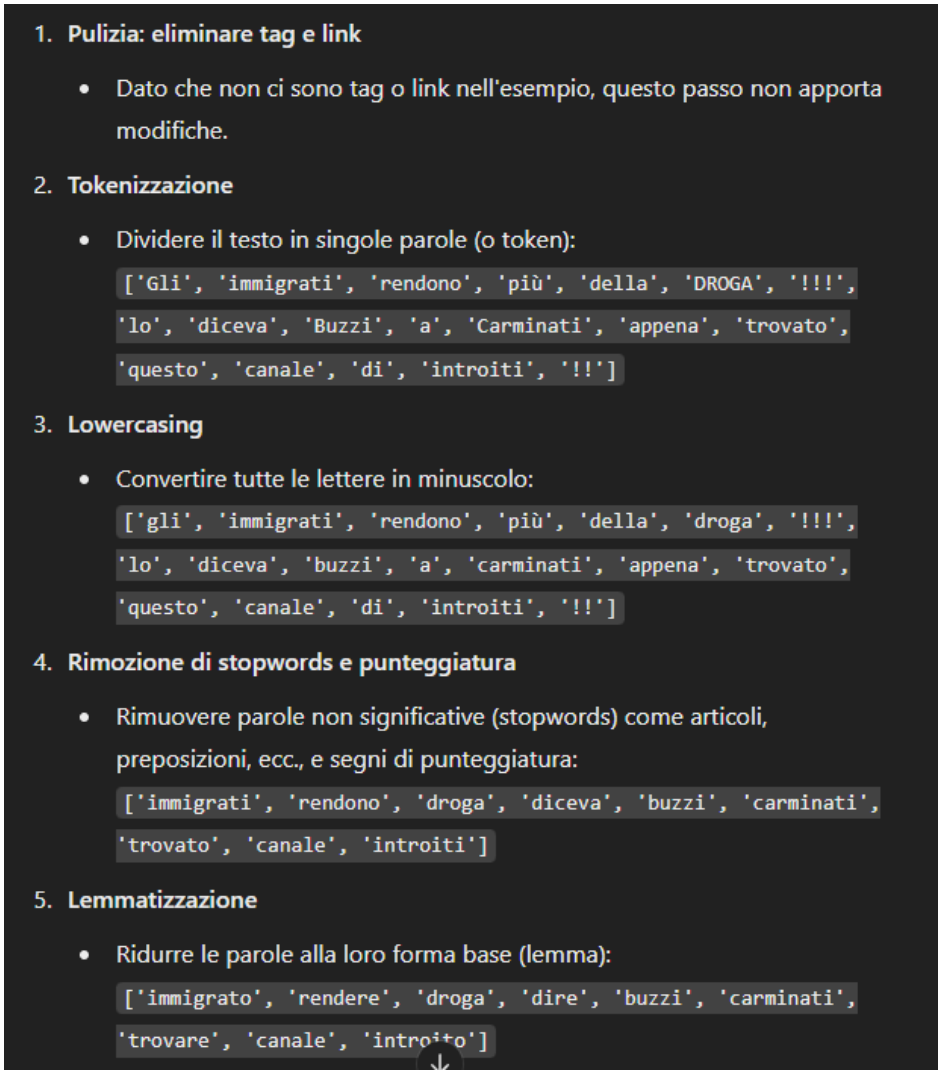

Risultato finale:

['immigrato', 'rendere', 'droga', 'dire', 'buzzi', 'carminati', 'trovare', 'canale', 'introito']

7.4 Vettorizzazione

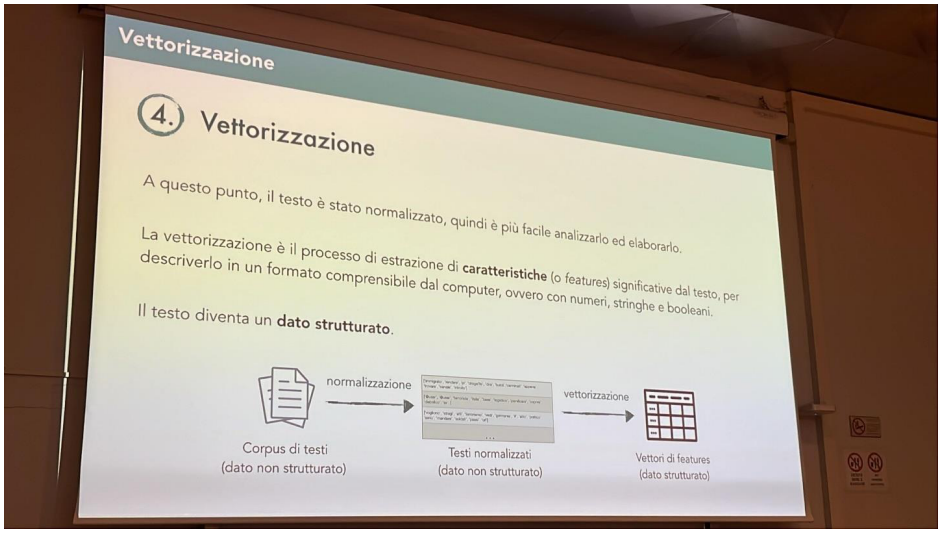

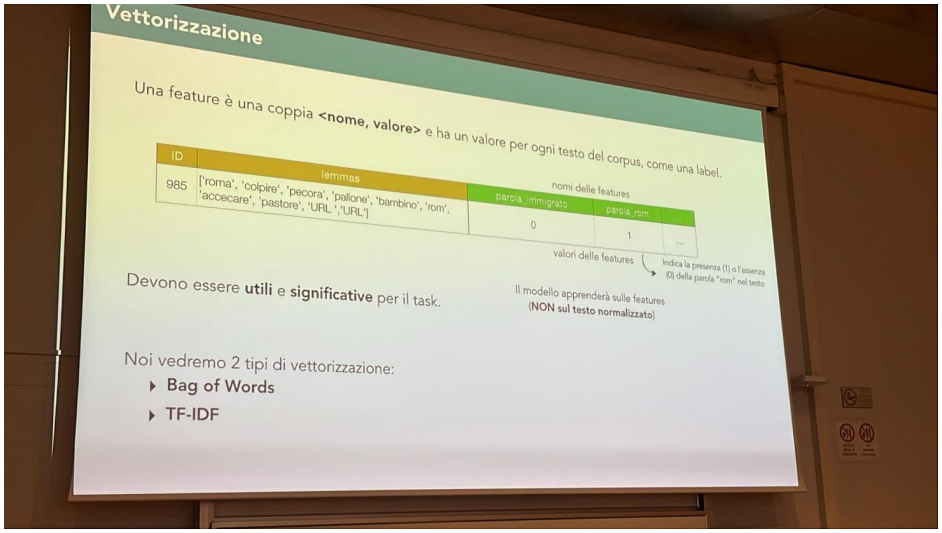

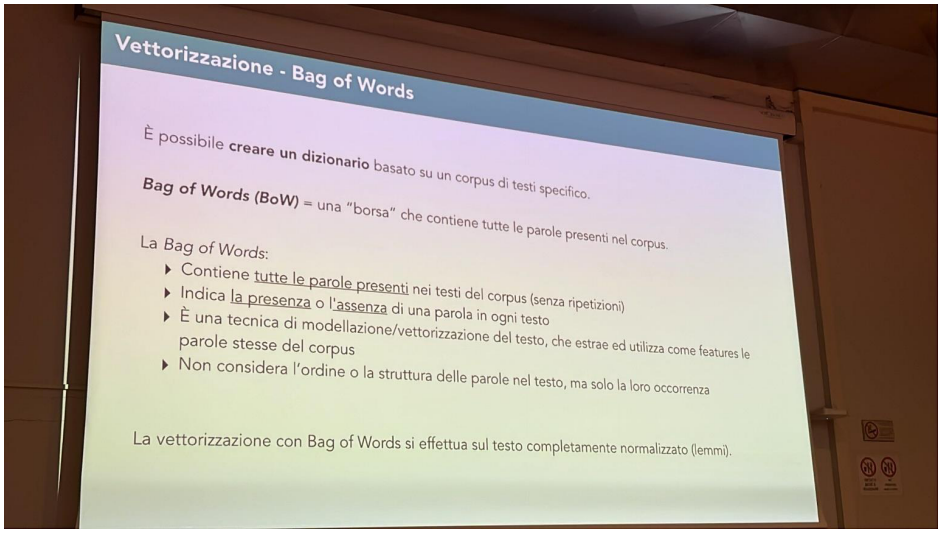
Vettorizzazione - Bag of Words
È possibile creare un dizionario basato su un corpus di testi specifico.
Bag of Words (BoW) = una "borsa" che contiene tutte le parole presenti nel corpus.
La Bag of Words:
Contiene tutte le parole presenti nei testi del corpus (senza ripetizioni)
Indica la presenza o l'assenza di una parola in ogni testo
È una tecnica di modellazione/vettorizzazione del testo, che estrae ed utilizza come features le parole stesse del corpus
Non considera l'ordine o la struttura delle parole nel testo, ma solo la loro occorrenza
La vettorizzazione con Bag of Words si effettua sul testo completamente normalizzato (lemmi).

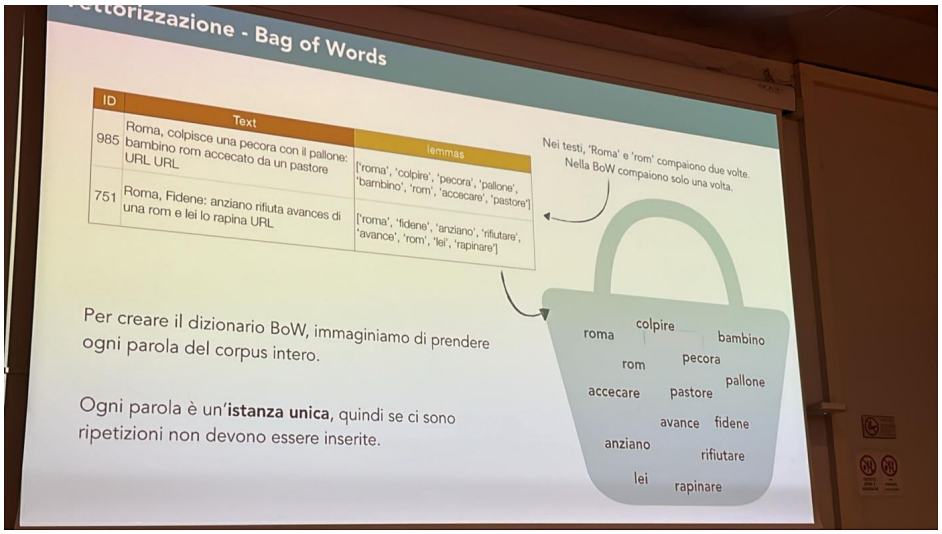
Vettorizzazione - Bag of Words
ID
Text
lemmas
985
Roma, colpisce una pecora con il pallone: bambino rom accecato da un pastore URL URL
['roma', 'colpire', 'pecora', 'pallone', 'bambino', 'rom', 'accecare', 'pastore']
751
Roma, Fidene: anziano rifiuta avances di una rom e lei lo rapina URL
['roma', 'fidene', 'anziano', 'rifiutare', 'avance', 'rom', 'lei', 'rapinare']
Nei testi, 'Roma' e 'rom' compaiono due volte. Nella BoW compaiono solo una volta.
Per creare il dizionario BoW, immaginiamo di prendere ogni parola del corpus intero.
Ogni parola è un'istanza unica, quindi se ci sono ripetizioni non devono essere inserite.
roma
colpire
bambino
rom
pecora
pallone
accecare
pastore
avance
fidene
anziano
rifiutare
lei
rapinare

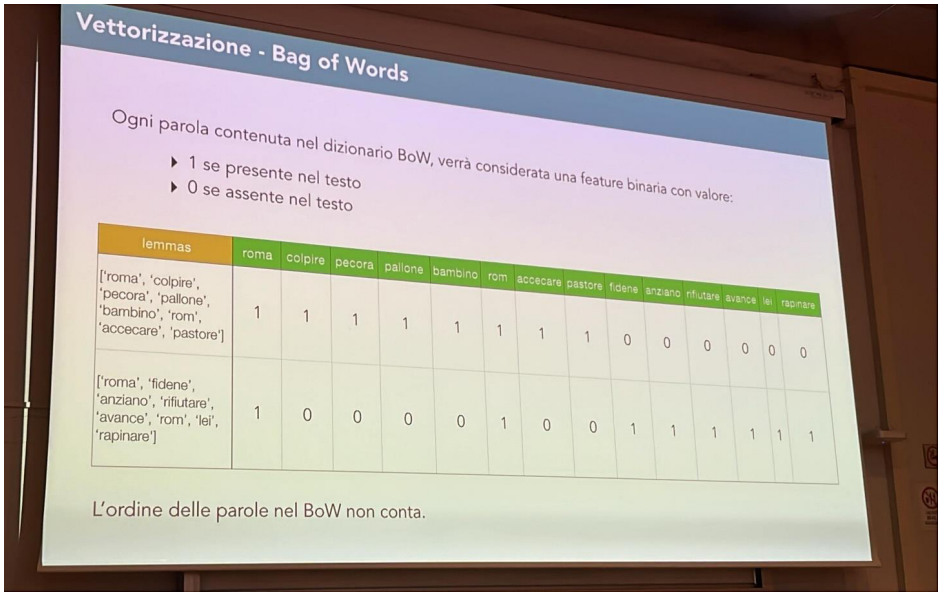

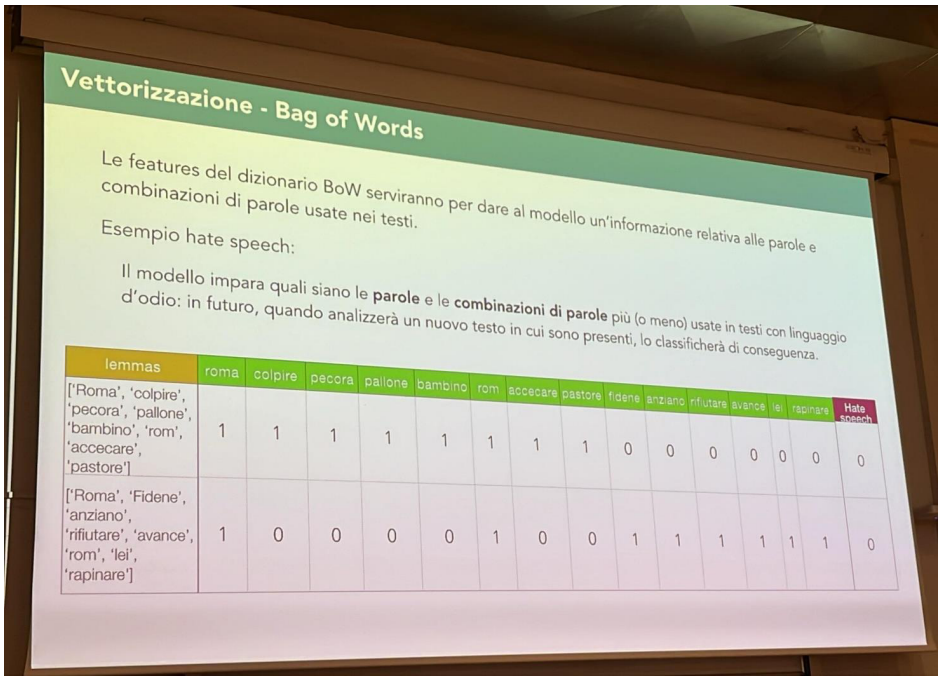

7.5 TF-IDF

TF-IDF (Term Frequency-Inverse Document Frequency), cos'è? è un metodo per valutare l'importanza di una parola in un testo rispetto a un insieme di documenti.

- TF (Term Frequency): Quanto spesso una parola appare in un testo.

- IDF (Inverse Document Frequency): Quanto è "rara" quella parola in tutti i documenti.

A cosa serve? Serve per identificare le parole chiave, dando più peso a quelle frequenti in un documento ma che sono rare in generale, ed è usato in motori di ricerca e analisi del testo.

Immaginiamo un insieme di 3 documenti:

1. Doc 1: "Il gatto dorme sul divano."
2. Doc 2: "Il cane dorme nella cuccia."
3. Doc 3: "Il gatto e il cane giocano insieme."

Calcolo di TF-IDF per la parola "gatto":

1. TF (Term Frequency):
    - In Doc 1, "gatto" appare 1 volta su 5 parole: TF = 1/5 = 0,2.
    - In Doc 2, "gatto" non appare: TF = 0.
    - In Doc 3, "gatto" appare 1 volta su 7 parole: TF = 1/7 $\approx$ 0,14.
2. IDF (Inverse Document Frequency):
    - "Gatto" appare in 2 documenti su 3. IDF = log (3/2) $\approx$ 0,18.
3. TF-IDF:
    - Doc 1: 0,2 $\times$ 0,18 $\approx$ 0,036.
    - Doc 2: 0 $\times$ 0,18 = 0.
    - Doc 3: 0,14 $\times$ 0,18 $\approx$ 0,025.

Interpretazione:

La parola "gatto" è più importante nel Doc 1, dove ha il valore TF-IDF più alto, rispetto al Doc 3 e non ha importanza nel Doc 2 perché lì non compare.

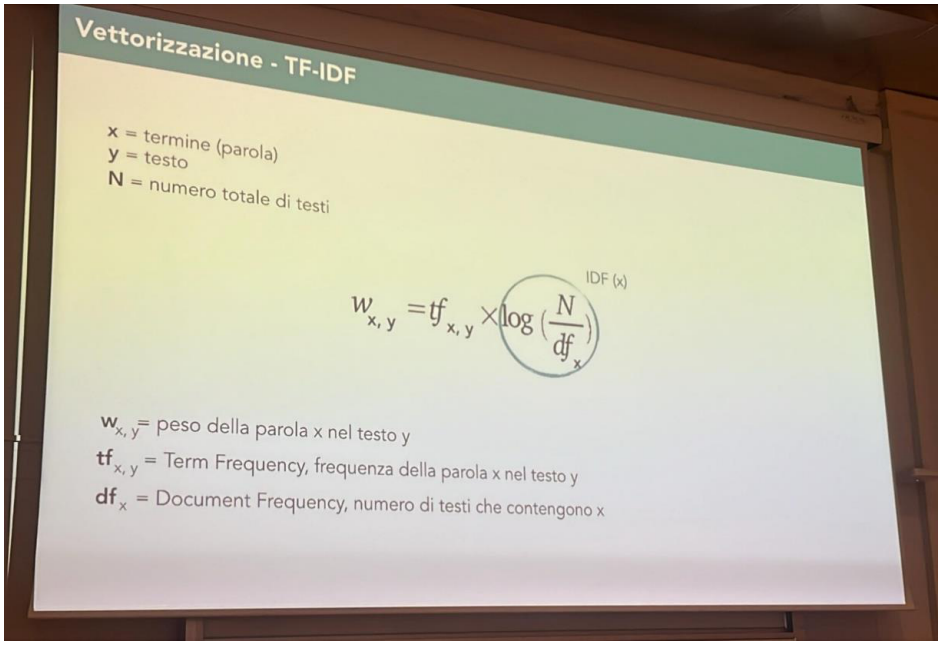
Vettorizzazione - TF-IDF
x = termine (parola)
y = testo
N = numero totale di testi
$w_{x,y} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$
IDF (x)
$w_{x,y}$ = peso della parola x nel testo y
$tf_{x,y}$ = Term Frequency, frequenza della parola x nel testo y
df_x = Document Frequency, numero di testi che contengono x

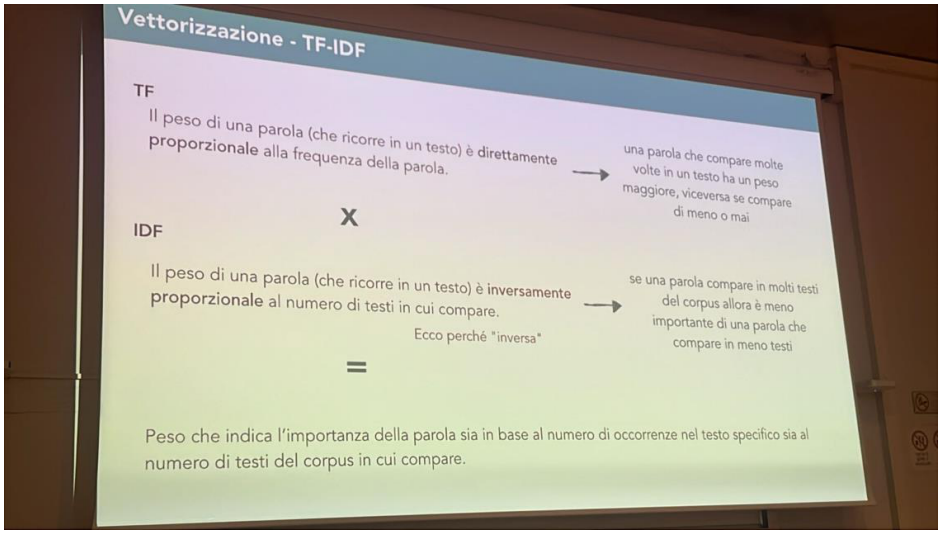
Vettorizzazione - TF-IDF
TF
Il peso di una parola (che ricorre in un testo) è direttamente proporzionale alla frequenza della parola.
una parola che compare molte volte in un testo ha un peso maggiore, viceversa se compare di meno o mai
X
IDF
Il peso di una parola (che ricorre in un testo) è inversamente proporzionale al numero di testi in cui compare.
Ecco perché "inversa"
se una parola compare in molti testi del corpus allora è meno importante di una parola che compare in meno testi
=
Peso che indica l'importanza della parola sia in base al numero di occorrenze nel testo specifico sia al numero di testi del corpus in cui compare.

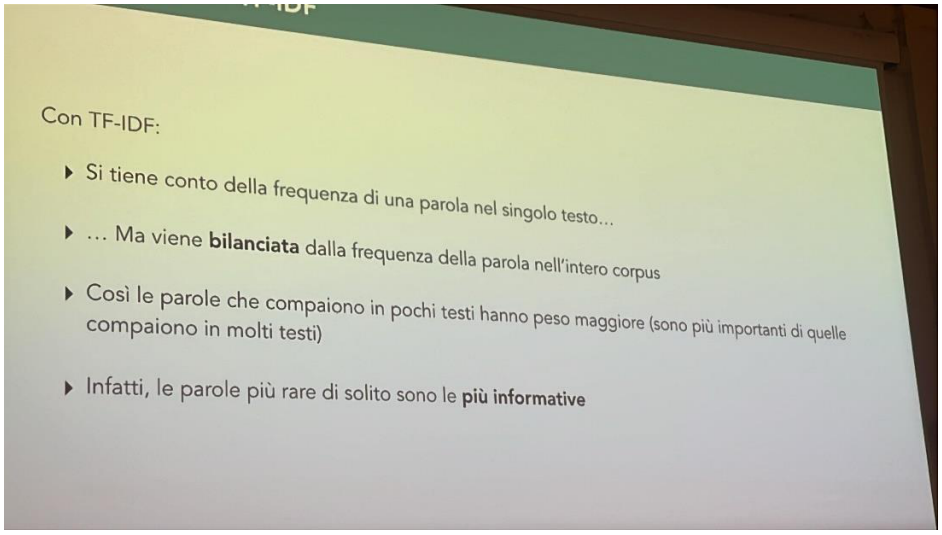

Per calcolare il peso **TF-IDF** della parola "rom" nel testo x:

1. **TF (Term Frequency):**
   La parola "rom" compare 2 volte nel testo x. Quindi, $TF = 2$.
2. **IDF (Inverse Document Frequency):**
   $IDF = \log\left(\frac{\mathrm{N}}{\mathrm{df}}\right)$, dove:
   - $\mathrm{N} = 100$ (numero totale di documenti),
   - $\mathrm{df} = 20$ (numero di documenti in cui "rom" compare).

   Quindi:
   $IDF = \log\left(\frac{100}{20}\right)$.
3. **TF-IDF:**
   $w = TF \times IDF = 2 \times \log\left(\frac{100}{20}\right)$.

Risposta corretta: d. $w = 2 \times \log(100/20)$.